

# Livrable IA T1 : Conception Théorique d'un Moteur de Recherche Sémantique par Similarité Cosinus

Charles EDOU NZE

7 juillet 2026

# Table des matières

# Chapitre 1

## Cours Principal

### 1.1 Jalon 12 : Livrable IA T1 : Conception théorique d’un moteur de recherche sémantique par similarité cosinus (dualité et géométrie des espaces de plongement) et résolution d’un problème d’algèbre de l’X

#### 1.1.1 1. Présentation du concept clé

L’émergence de la similarité cosinus s’inscrit dans le besoin fondamental de quantifier l’alignement conceptuel au-delà de la stricte égalité syntaxique. Historiquement, le passage de la recherche par mots-clés booléens aux espaces sémantiques continus marque un point d’inflexion majeur. Dans ce paradigme, le sens d’un objet (mot, document, requête) est capturé par sa position relative au sein d’un espace vectoriel de haute dimension, dictée par la conjecture distributionnelle de Harris : le sens est déterminé par le contexte d’apparition.

Ainsi, la mesure de pertinence bascule d’une métrique discrète (présence ou absence) vers une géométrie continue. La similarité cosinus s’impose naturellement : en évaluant exclusivement l’angle entre deux vecteurs, elle normalise intrinsèquement l’influence de leur magnitude (qui encode souvent des biais de fréquence pure) pour isoler la pure orientation sémantique.

- Imaginez une bibliothèque immense où les livres ne sont pas rangés par ordre alphabétique ou par genre conventionnel, mais par leur “sens” intrinsèque. Deux livres parlant de concepts similaires (par exemple, “chiens de berger” et “loups en liberté”) seraient physiquement très proches, même si leurs titres diffèrent. En revanche, un livre sur “la fusion nucléaire” serait situé très loin. Pour trouver un livre, au lieu d’utiliser des mots-clés exacts, vous lancez un petit éclaireur sémantique (votre requête) qui va se positionner dans cette bibliothèque là où le “sens” qu’il incarne est le plus proche de celui des livres. La **similarité cosinus** est l’outil fondamental qui permet à cet éclaireur de mesurer l’orientation commune qu’il partage avec chaque livre : plus l’angle entre la “direction sémantique” de l’éclaireur et celle d’un livre est petit, plus leurs significations sont alignées, et donc plus ils sont sémantiquement proches.
- Les ordinateurs, par nature, manipulent des symboles et non du sens. Une séquence de lettres comme “voiture” n’a pas plus de signification pour eux qu’une séquence de bits. Pour que les machines puissent “comprendre” et traiter des requêtes basées sur le sens (recherche sémantique, traduction, recommandation), il a fallu développer une méthode pour transformer ces symboles linguistiques en entités numériques (des listes de nombres, appelées vecteurs) dans un espace abstrait. Cet espace est conçu de telle manière que les relations géométriques entre ces vecteurs (proximité, angle) reflètent fidèlement les relations sémantiques entre les entités qu’ils représentent.
- Considérez un espace abstrait, de très haute dimension (plusieurs centaines, voire milliers), mais pour l’intuition, imaginez-le en 3 dimensions. Chaque mot, phrase ou document

est représenté par une flèche (un vecteur) partant de l'origine. Si le vecteur "Roi" et le vecteur "Reine" représentent des concepts sémantiquement très proches et liés, leurs flèches pointeront dans des directions presque identiques, formant un angle infime. Au contraire, le vecteur "Roi" et le vecteur "Chaussette" pointeront dans des directions radicalement différentes, formant un angle large. La similarité cosinus quantifie précisément cet angle, nous indiquant à quel point deux éléments "regardent" dans la même direction sémantique. Elle ne se préoccupe pas de la "longueur" de la flèche (qui pourrait représenter la fréquence d'un mot, par exemple), mais uniquement de son orientation.

## 1.1.2 2. Formalisation & Rigueur Académique

### B. Exégèse Formelle du Produit Scalaire et de la Norme

Soit l'espace vectoriel réel  $E = \mathbb{R}^d$ . - Le vecteur  $u = (u_1, \dots, u_d)^T \in \mathbb{R}^d$  représente le plongement (embedding) de la requête. - Le vecteur  $v = (v_1, \dots, v_d)^T \in \mathbb{R}^d$  représente le plongement du document.

La similarité cosinus tire sa légitimité de l'inégalité de Cauchy-Schwarz, qui garantit que :

$$|\langle u, v \rangle| \leq \|u\| \|v\|$$

Par un calcul algébrique direct, nous obtenons, pour des vecteurs non nuls, l'encadrement strict :

$$-1 \leq \frac{\langle u, v \rangle}{\|u\| \|v\|} \leq 1$$

Ce rapport est ainsi l'unique candidat géométrique valide pour définir le cosinus de l'angle  $\theta \in [0, \pi]$  entre  $u$  et  $v$ .

**Exemples et Cas Limites :** 1. **Alignement parfait (Synonymie totale) :** Si  $u = \alpha v$  avec  $\alpha > 0$ , alors  $\langle u, \alpha v \rangle / (\|u\| \|\alpha v\|) = \alpha \|u\|^2 / (\alpha \|u\|^2) = 1$ . L'angle est nul,  $\theta = 0$ . 2. **Orthogonalité (Indépendance sémantique) :** Si  $\langle u, v \rangle = 0$ , les concepts ne partagent aucune dimension commune dans l'espace latent.  $S_C(u, v) = 0$ ,  $\theta = \pi/2$ . 3. **Opposition absolue (Antonymie stricte) :** Si  $u = -\alpha v$  avec  $\alpha > 0$ , alors  $S_C(u, v) = -1$ ,  $\theta = \pi$ . 4. **Cas limite du vecteur nul :** La similarité cosinus est strictement indéfinie si  $u = 0_E$  ou  $v = 0_E$ . Dans les espaces sémantiques, un vecteur nul représenterait une entité dépourvue de toute caractéristique mesurable, une singularité sémantique.

### A. Définitions Formelles

Soit  $E = \mathbb{R}^d$  un espace vectoriel euclidien de dimension  $d$ , muni du produit scalaire canonique et de la norme euclidienne associée. Les éléments de  $E$  sont appelés des vecteurs de plongement ou *embeddings*.

1. **Produit Scalaire Canonique et Norme Euclidienne :** Pour deux vecteurs  $u = (u_1, u_2, \dots, u_d) \in \mathbb{R}^d$  et  $v = (v_1, v_2, \dots, v_d) \in \mathbb{R}^d$ , Le **produit scalaire** est défini par :

$$\langle u, v \rangle = \sum_{i=1}^d u_i v_i$$

La **norme euclidienne** (ou norme  $L_2$ ) d'un vecteur  $u \in \mathbb{R}^d$  est définie par :

$$\|u\| = \sqrt{\langle u, u \rangle} = \sqrt{\sum_{i=1}^d u_i^2}$$

2. **Similarité Cosinus** : Pour deux vecteurs non nuls  $u, v \in E \setminus \{0\}$ , la similarité cosinus est une mesure de l'angle  $\theta$  entre ces deux vecteurs et est définie par :

$$S_C(u, v) = \frac{\langle u, v \rangle}{\|u\| \|v\|} = \cos(\theta)$$

Cette définition est valide car l'inégalité de Cauchy-Schwarz (énoncée ci-dessous) garantit que  $-1 \leq \frac{\langle u, v \rangle}{\|u\| \|v\|} \leq 1$ , ce qui permet d'interpréter cette valeur comme le cosinus d'un angle  $\theta$ . **Espace de  $\mathbb{P}^d$** , où des entités discrètes (telles que des mots, des phrases, des documents, des images, ou des nœuds de graphe) sont représentées par des vecteurs de telle sorte que les relations sémantiques ou structurelles entre les entités sont préservées par des opérations et des métriques géométriques dans  $E$ . *Exemple classique* : Dans certains modèles de plongement de mots, la relation  $v_{\text{roi}} - v_{\text{homme}} + v_{\text{femme}} \approx v_{\text{reine}}$  peut être observée, illustrant que la sémantique est encodée dans la géométrie des vecteurs.

3. **Dualité et Recherche Sémantique** : En algèbre linéaire, le concept de **dualité** établit une correspondance entre les vecteurs d'un espace vectoriel et les formes linéaires agissant sur cet espace. Soit  $E = \mathbb{R}^d$  un espace euclidien. Pour tout vecteur  $q \in E$ , il existe une unique forme linéaire  $\phi_q : E \rightarrow \mathbb{R}$  définie par  $\phi_q(x) = \langle q, x \rangle$  pour tout  $x \in E$ . Réciproquement, par le **Théorème de Représentation de Riesz** pour les espaces euclidiens, toute forme linéaire  $\phi \in E^*$  (l'espace dual de  $E$ ) peut être représentée par un unique vecteur  $q \in E$  tel que  $\phi(x) = \langle q, x \rangle$ . Dans le contexte de la recherche sémantique, une requête  $q$  peut être interprétée comme le vecteur définissant une forme linéaire  $\phi_q$ . Si tous les vecteurs de document  $x$  sont normalisés à l'unité (i.e.,  $\|x\| = 1$ ), alors la similarité cosinus  $S_C(q, x) = \frac{\langle q, x \rangle}{\|q\| \|x\|} = \frac{\langle q, x \rangle}{\|q\|}$ . Si la requête  $q$  est également normalisée (i.e.,  $\|q\| = 1$ ), alors  $S_C(q, x) = \langle q, x \rangle = \phi_q(x)$ . Dans ce scénario courant, trouver le document  $x$  le plus sémantiquement similaire à la requête  $q$  revient à chercher le vecteur  $x$  (normalisé) qui maximise la valeur de la forme linéaire  $\phi_q(x)$ . Cela correspond géométriquement à trouver le vecteur  $x$  qui a la projection la plus longue sur la direction définie par  $q$ .

## B. Théorèmes, Propositions & Lemmes

**Théorème (Inégalité de Cauchy-Schwarz)** : Soit  $E$  un espace vectoriel euclidien (ici  $E = \mathbb{R}^d$ ). Pour tous vecteurs  $u, v \in E$ , l'inégalité suivante est vérifiée :

$$|\langle u, v \rangle| \leq \|u\| \|v\|$$

L'égalité a lieu si et seulement si les vecteurs  $u$  et  $v$  sont linéairement dépendants (colinéaires), c'est-à-dire s'il existe un scalaire  $\lambda \in \mathbb{R}$  tel que  $u = \lambda v$  ou  $v = \lambda u$ .

**Corollaire (Bornes de la Similarité Cosinus)** : L'inégalité de Cauchy-Schwarz garantit que pour tous vecteurs non nuls  $u, v \in E \setminus \{0\}$ , la similarité cosinus  $S_C(u, v)$  est bornée dans l'intervalle  $[-1, 1]$ . En effet, en divisant l'inégalité  $|\langle u, v \rangle| \leq \|u\| \|v\|$  (qui est strictement positif puisque  $u, v \neq 0$ ), on obtient :

$$\frac{|\langle u, v \rangle|}{\|u\| \|v\|} \leq 1$$

Ce qui implique :

$$-1 \leq \frac{\langle u, v \rangle}{\|u\| \|v\|} \leq 1$$

Et donc,  $S_C(u, v) \in [-1, 1]$ .

### 1.1.3 3. Démonstrations Pas-à-Pas

#### Démonstration 1 : Inégalité de Cauchy-Schwarz pour $\mathbb{R}^d$

**Énoncé :** Pour tous vecteurs  $u, v \in \mathbb{R}^d$ , on a  $|\langle u, v \rangle| \leq \|u\| \|v\|$ .

**Démonstration :**

1. **Cas limite du vecteur nul :** Si  $v = 0_E$  (le vecteur nul), alors  $\|v\| = 0$  et  $\langle u, v \rangle = 0$ . L'inégalité devient  $0 \leq \|u\| \cdot 0$ , soit  $0 \leq 0$ , qui est vraie. Le cas  $u = 0_E$  est symétrique. Nous pouvons donc supposer que  $v \neq 0_E$ .
2. **Construction d'une fonction quadratique :** Considérons, pour tout scalaire  $\lambda \in \mathbb{R}$ , le vecteur  $w = u - \lambda v$ . Puisque la norme euclidienne est toujours non-négative, nous avons  $\|w\|^2 \geq 0$ .

$$\|u - \lambda v\|^2 \geq 0$$

3. **Développement de l'expression quadratique :** Utilisons la propriété du produit scalaire  $\|x\|^2 = \langle x, x \rangle$  et sa bilinéarité (linéarité par rapport à chaque argument).

$$\langle u - \lambda v, u - \lambda v \rangle \geq 0$$

$$\langle u, u \rangle - \lambda \langle u, v \rangle - \lambda \langle v, u \rangle + \lambda^2 \langle v, v \rangle \geq 0$$

Puisque le produit scalaire est symétrique ( $\langle u, v \rangle = \langle v, u \rangle$ ), on a :

$$\|u\|^2 - 2\lambda \langle u, v \rangle + \lambda^2 \|v\|^2 \geq 0$$

Cette expression est un trinôme du second degré en  $\lambda$ , de la forme  $A\lambda^2 + B\lambda + C \geq 0$ , où  $A = \|v\|^2$ ,  $B = -2\langle u, v \rangle$ , et  $C = \|u\|^2$ .

4. **Analyse du trinôme :** Puisque le trinôme  $P(\lambda) = \|v\|^2 \lambda^2 - 2\langle u, v \rangle \lambda + \|u\|^2$  est toujours supérieur ou égal à zéro pour tout  $\lambda \in \mathbb{R}$ , cela signifie que ce polynôme n'a pas deux racines réelles distinctes. Par conséquent, son discriminant  $\Delta$  doit être inférieur ou égal à zéro. Le discriminant est donné par  $\Delta = B^2 - 4AC$ .

$$\Delta = (-2\langle u, v \rangle)^2 - 4(\|v\|^2)(\|u\|^2)$$

$$\Delta = 4(\langle u, v \rangle)^2 - 4\|u\|^2 \|v\|^2$$

5. **Application de la condition  $\Delta \leq 0$  :**

$$4(\langle u, v \rangle)^2 - 4\|u\|^2 \|v\|^2 \leq 0$$

Divisons par 4 (qui est positif, donc l'inégalité est conservée) :

$$(\langle u, v \rangle)^2 - \|u\|^2 \|v\|^2 \leq 0$$

$$(\langle u, v \rangle)^2 \leq \|u\|^2 \|v\|^2$$

6. **Passage à la racine carrée :** Prenons la racine carrée des deux membres. Puisque  $\sqrt{x^2} = |x|$  pour tout réel  $x \geq 0$  et que les normes sont toujours non-négatives :

$$\sqrt{(\langle u, v \rangle)^2} \leq \sqrt{\|u\|^2 \|v\|^2}$$

$$|\langle u, v \rangle| \leq \|u\| \|v\|$$

Ceci achève la démonstration de l'inégalité de Cauchy-Schwarz.

7. **Condition d'égalité :** L'égalité  $|\langle u, v \rangle| = \|u\| \|v\|$  a lieu si et seulement si  $\Delta = 0$ . Si  $\Delta = 0$ , le trinôme  $P(\lambda)$  a exactement une racine réelle (double). Cela signifie qu'il existe un  $\lambda_0 \in \mathbb{R}$  tel que  $P(\lambda_0) = 0$ , ce qui implique  $\|u - \lambda_0 v\|^2 = 0$ . Par la propriété de la norme, ceci équivaut à  $u - \lambda_0 v = 0_E$ , c'est-à-dire  $u = \lambda_0 v$ . Ainsi, l'égalité est atteinte si et seulement si  $u$  et  $v$  sont colinéaires.

## Démonstration 2 : Invariance de la similarité cosinus par homothétie

**Théorème Pivot :** Montrons que la similarité cosinus entre deux vecteurs  $u$  et  $v$  reste inchangée si l'un des vecteurs est multiplié par un scalaire positif. Ceci est une propriété fondamentale pour la recherche sémantique, car la “longueur” d'un vecteur (sa norme) peut varier selon le modèle d'embedding, mais seule sa “direction” (son orientation sémantique) doit être pertinente.

**Démonstration :**

1. **Initialisation / Cadre de la preuve :** Soient  $u, v \in \mathbb{R}^d \setminus \{0\}$  deux vecteurs non nuls de l'espace euclidien  $E = \mathbb{R}^d$ . Soit  $\alpha \in \mathbb{R}$  un scalaire strictement positif, c'est-à-dire  $\alpha > 0$ . Nous définissons un nouveau vecteur  $u'$  comme une homothétie de  $u$  :  $u' = \alpha u$ .
2. **Étape 1 : Calcul du produit scalaire entre  $u'$  et  $v$**  Nous devons calculer  $\langle u', v \rangle$ . Par définition de  $u'$  :

$$\langle u', v \rangle = \langle \alpha u, v \rangle$$

Par la propriété de linéarité du produit scalaire par rapport à son premier argument (homogénéité) :

$$\langle \alpha u, v \rangle = \alpha \langle u, v \rangle$$

Donc, nous avons :

$$\langle u', v \rangle = \alpha \langle u, v \rangle \quad (*)$$

3. **Étape 2 : Calcul de la norme de  $u'$**  Nous devons calculer  $\|u'\|$ . Par définition de  $u'$  :

$$\|u'\| = \|\alpha u\|$$

Par la propriété d'homogénéité de la norme (provenant de la bilinéarité du produit scalaire :  $\|x\|^2 = \langle x, x \rangle$ ) :

$$\|\alpha u\| = \sqrt{\langle \alpha u, \alpha u \rangle}$$

En utilisant la bilinéarité du produit scalaire :

$$\begin{aligned} \sqrt{\alpha \langle u, \alpha u \rangle} &= \sqrt{\alpha^2 \langle u, u \rangle} \\ &= \sqrt{\alpha^2 \|u\|^2} \end{aligned}$$

En utilisant la propriété  $\sqrt{ab} = \sqrt{a}\sqrt{b}$  pour  $a, b \geq 0$  et  $\sqrt{x^2} = |x|$  :

$$|\alpha| \|u\|$$

Puisque nous avons supposé  $\alpha > 0$ , alors  $|\alpha| = \alpha$ . Donc, nous avons :

$$\|u'\| = \alpha \|u\| \quad (**)$$

4. **Étape 3 : Calcul de la similarité cosinus de  $(u', v)$**  Nous appliquons la définition de la similarité cosinus pour les vecteurs  $u'$  et  $v$  :

$$S_C(u', v) = \frac{\langle u', v \rangle}{\|u'\| \|v\|}$$

Substituons les expressions obtenues aux étapes 1 et 2, données par (\*) et (\*\*) :

$$S_C(u', v) = \frac{\alpha \langle u, v \rangle}{(\alpha \|u\|) \|v\|}$$

Comme  $\alpha$  est un scalaire strictement positif,  $\alpha \neq 0$ . Nous pouvons donc simplifier le numérateur et le dénominateur par  $\alpha$  :

$$S_C(u', v) = \frac{\langle u, v \rangle}{\|u\| \|v\|}$$

Par définition, l'expression obtenue est exactement la similarité cosinus entre  $u$  et  $v$ , c'est-à-dire  $S_C(u, v)$ .

$$S_C(u', v) = S_C(u, v)$$

5. **Conclusion :** La similarité cosinus est effectivement invariante par multiplication par un scalaire positif. Cela démontre formellement pourquoi cette mesure est robuste aux variations d'amplitude (longueur) des vecteurs, ne dépendant que de leur orientation relative dans l'espace. Cette propriété est essentielle pour la recherche sémantique, car elle permet de ne considérer que le "sens" et non une quelconque "intensité" arbitraire du vecteur.

#### 1.1.4 4. Exercices d'Application

##### Exercice 1 : Application IA (Calcul de similarité sémantique)

**Énoncé :** Soit un espace de plongement sémantique  $E = \mathbb{R}^3$ . Nous avons une requête  $Q$  et deux documents  $D_1$  et  $D_2$ , représentés par les vecteurs suivants : -  $Q = (1, 1, 0)$  -  $D_1 = (2, 2, 0)$  -  $D_2 = (0, 1, 1)$

Votre tâche est de déterminer lequel des deux documents,  $D_1$  ou  $D_2$ , est le plus "proche" sémantiquement de la requête  $Q$  en utilisant la similarité cosinus. Interprétez les résultats en termes d'angle.

##### Correction Détaillée :

Pour déterminer la proximité sémantique, nous devons calculer la similarité cosinus  $S_C(Q, D_1)$  et  $S_C(Q, D_2)$ . La formule est  $S_C(u, v) = \frac{\langle u, v \rangle}{\|u\| \|v\|}$ .

1. **Calcul des normes des vecteurs :** La norme euclidienne  $\|v\|$  d'un vecteur  $v = (v_1, v_2, v_3)$  est donnée par  $\sqrt{v_1^2 + v_2^2 + v_3^2}$ .
  - **Norme de  $Q$  :**  $\|Q\| = \sqrt{1^2 + 1^2 + 0^2} \|Q\| = \sqrt{1 + 1 + 0} \|Q\| = \sqrt{2}$
  - **Norme de  $D_1$  :**  $\|D_1\| = \sqrt{2^2 + 2^2 + 0^2} \|D_1\| = \sqrt{4 + 4 + 0} \|D_1\| = \sqrt{8} \|D_1\| = \sqrt{4 \times 2} \|D_1\| = 2\sqrt{2}$
  - **Norme de  $D_2$  :**  $\|D_2\| = \sqrt{0^2 + 1^2 + 1^2} \|D_2\| = \sqrt{0 + 1 + 1} \|D_2\| = \sqrt{2}$
2. **Calcul des produits scalaires :** Le produit scalaire  $\langle u, v \rangle$  de deux vecteurs  $u = (u_1, u_2, u_3)$  et  $v = (v_1, v_2, v_3)$  est donné par  $u_1v_1 + u_2v_2 + u_3v_3$ .
  - **Produit scalaire  $\langle Q, D_1 \rangle$  :**  $\langle Q, D_1 \rangle = (1 \times 2) + (1 \times 2) + (0 \times 0) \langle Q, D_1 \rangle = 2 + 2 + 0 \langle Q, D_1 \rangle = 4$
  - **Produit scalaire  $\langle Q, D_2 \rangle$  :**  $\langle Q, D_2 \rangle = (1 \times 0) + (1 \times 1) + (0 \times 1) \langle Q, D_2 \rangle = 0 + 1 + 0 \langle Q, D_2 \rangle = 1$
3. **Calcul des similarités cosinus :**
  - **Similarité entre  $Q$  et  $D_1$  :**  $S_C(Q, D_1) = \frac{\langle Q, D_1 \rangle}{\|Q\| \|D_1\|} S_C(Q, D_1) = \frac{4}{\sqrt{2} \times 2\sqrt{2}} S_C(Q, D_1) = \frac{4}{2 \times 2} S_C(Q, D_1) = \frac{4}{4} S_C(Q, D_1) = 1$
  - **Similarité entre  $Q$  et  $D_2$  :**  $S_C(Q, D_2) = \frac{\langle Q, D_2 \rangle}{\|Q\| \|D_2\|} S_C(Q, D_2) = \frac{1}{\sqrt{2} \times \sqrt{2}} S_C(Q, D_2) = \frac{1}{2} S_C(Q, D_2) = 0.5$
4. **Interprétation des résultats :** La similarité cosinus  $S_C(Q, D_1) = 1$ . Un cosinus de 1 correspond à un angle de  $0^\circ$  (ou 0 radians). Cela signifie que le vecteur  $Q$  et le vecteur  $D_1$  sont colinéaires et pointent dans la même direction. Ils sont parfaitement alignés sémantiquement. La similarité cosinus  $S_C(Q, D_2) = 0.5$ . Un cosinus de 0.5 correspond à un angle de  $60^\circ$  (ou  $\pi/3$  radians). Cela signifie que le vecteur  $Q$  et le vecteur  $D_2$  ont une orientation sémantique moins alignée, bien qu'ils partagent une certaine proximité.

**Conclusion :** Le document  $D_1$  a une similarité cosinus de 1 avec la requête  $Q$ , tandis que le document  $D_2$  a une similarité cosinus de 0.5. Par conséquent,  $D_1$  est le document le plus sémantiquement proche de la requête  $Q$ , indiquant une correspondance sémantique parfaite.



## Exercice 2 : Problème d'Algèbre (Inspiré de l'X - Intersection d'hyperplans)

**Énoncé :** Soit  $E$  un espace vectoriel sur le corps  $\mathbb{K}$  (où  $\mathbb{K} = \mathbb{R}$  ou  $\mathbb{C}$ ), de dimension finie  $n \geq 1$ . Soient  $H_1, H_2, \dots, H_p$  des hyperplans de  $E$ . Montrer que la dimension de l'intersection de ces hyperplans est minorée par  $n - p$ . C'est-à-dire, démontrer que  $\dim(\bigcap_{i=1}^p H_i) \geq n - p$ .

**Correction Détaillée :**

1. **Définition Formelle d'un Hyperplan :** Dans un espace vectoriel  $E$  de dimension finie  $n \geq 1$ , un hyperplan  $H$  est un sous-espace vectoriel de  $E$  de codimension 1, c'est-à-dire que  $\dim(H) = n - 1$ . Par le théorème du noyau pour les formes linéaires, un sous-espace  $H \subseteq E$  est un hyperplan si et seulement s'il existe une forme linéaire  $\phi \in E^*$  (l'espace dual de  $E$ ) non nulle telle que  $H = \ker(\phi)$ , où  $\ker(\phi) = \{x \in E \mid \phi(x) = 0\}$ .
2. **Représentation des Hyperplans par des Formes Linéaires :** Pour chaque hyperplan  $H_i$  (pour  $i \in \{1, \dots, p\}$ ), il existe une forme linéaire  $\phi_i \in E^*$  qui est non nulle, telle que  $H_i = \ker(\phi_i)$ .
3. **Caractérisation de l'Intersection :** L'intersection des hyperplans  $\bigcap_{i=1}^p H_i$  est l'ensemble des vecteurs  $x \in E$  qui appartiennent simultanément à tous les hyperplans  $H_i$ . Autrement dit,  $x \in \bigcap_{i=1}^p H_i$  si et seulement si  $x \in H_i$  pour tout  $i \in \{1, \dots, p\}$ . Ceci équivaut à dire que  $\phi_i(x) = 0$  pour tout  $i \in \{1, \dots, p\}$ .
4. **Construction d'une Application Linéaire Globale :** Considérons l'application linéaire  $\Phi : E \rightarrow \mathbb{K}^p$  définie par :

$$\Phi(x) = (\phi_1(x), \phi_2(x), \dots, \phi_p(x))$$

pour tout  $x \in E$ . Le noyau de cette application  $\Phi$  est l'ensemble des vecteurs  $x \in E$  tels que  $\Phi(x) = (0, 0, \dots, 0) \in \mathbb{K}^p$ . Par définition,  $\ker(\Phi) = \{x \in E \mid \phi_1(x) = 0, \phi_2(x) = 0, \dots, \phi_p(x) = 0\}$ . En comparant avec l'étape 3, nous voyons que le noyau de  $\Phi$  est précisément l'intersection des hyperplans :

$$\ker(\Phi) = \bigcap_{i=1}^p H_i$$

5. **Application du Théorème du Rang :** Le théorème du rang stipule que pour toute application linéaire  $\Phi : E \rightarrow F$  entre espaces vectoriels de dimension finie, on a :

$$\dim(E) = \dim(\ker(\Phi)) + \dim(\text{Im}(\Phi))$$

où  $\text{Im}(\Phi)$  est l'image de  $\Phi$ . Dans notre cas,  $E$  est de dimension  $n$ , donc :

$$n = \dim\left(\bigcap_{i=1}^p H_i\right) + \dim(\text{Im}(\Phi))$$

6. **Estimation de la Dimension de l'Image :** L'image de l'application linéaire  $\Phi$ , notée  $\text{Im}(\Phi)$ , est un sous-espace vectoriel de l'espace d'arrivée  $\mathbb{K}^p$ . Par conséquent, la dimension de l'image de  $\Phi$  est nécessairement inférieure ou égale à la dimension de l'espace d'arrivée :

$$\dim(\text{Im}(\Phi)) \leq \dim(\mathbb{K}^p)$$

Puisque  $\dim(\mathbb{K}^p) = p$ , nous avons :

$$\dim(\text{Im}(\Phi)) \leq p$$

7. **Conclusion** : En reprenant l'équation du théorème du rang :

$$n = \dim \left( \bigcap_{i=1}^p H_i \right) + \dim(\text{Im}(\Phi))$$

Nous pouvons exprimer la dimension de l'intersection :

$$\dim \left( \bigcap_{i=1}^p H_i \right) = n - \dim(\text{Im}(\Phi))$$

Puisque nous avons établi que  $\dim(\text{Im}(\Phi)) \leq p$ , en multipliant par  $-1$  l'inégalité change de sens :

$$-\dim(\text{Im}(\Phi)) \geq -p$$

En ajoutant  $n$  aux deux membres de l'inégalité :

$$n - \dim(\text{Im}(\Phi)) \geq n - p$$

Par substitution, nous obtenons le résultat souhaité :

$$\dim \left( \bigcap_{i=1}^p H_i \right) \geq n - p$$

Ceci démontre que l'intersection de  $p$  hyperplans dans un espace de dimension  $n$  a une dimension d'au moins  $n - p$ .

### 1.1.5 5. Ancrage & Application en Intelligence Artificielle

- **Le Pont Théorique vers l'Ingénierie des Données et l'IA** : Ce jalon représente une synthèse fondamentale entre l'**Algèbre Linéaire Abstraite** (espaces vectoriels, formes linéaires, hyperplans, dualité) et les défis pratiques de l'**Ingénierie des Données et de l'Intelligence Artificielle**. La capacité à représenter des entités sémantiques par des vecteurs dans un espace euclidien, puis à mesurer leur proximité via des métriques géométriques comme la similarité cosinus, est la pierre angulaire de nombreuses applications d'IA contemporaines. La compréhension de la dualité et des hyperplans fournit un cadre conceptuel puissant pour l'organisation et l'interrogation de ces données vectorielles.
- **Exemples Concrets en IA** :

1. **Moteurs de Recherche Sémantique et Systèmes de Recommandation** : Au cœur de la recherche sémantique (comme celle de Google, Bing, ou les fonctions de recherche interne des plateformes) et des systèmes de recommandation (Netflix, Amazon, Spotify), se trouvent des **Bases de Données Vectorielles** (Vector Databases) comme Pinecone, Milvus, Qdrant ou FAISS. Ces bases stockent des millions, voire des milliards de vecteurs de haute dimension (souvent 128, 768, 1536 dimensions ou plus), chacun représentant un mot, une phrase, un document, une image, un produit, un utilisateur, etc. Lorsqu'une requête est soumise, elle est d'abord transformée en un vecteur (embedding). Le moteur de recherche doit alors trouver les vecteurs les plus sémantiquement similaires dans la base de données en quelques millisecondes. C'est ici que le calcul de la **similarité cosinus** intervient comme l'opération atomique, effectuée des milliards de fois par jour.
2. **Indexation Spatiale et Algorithmes d'Approximate Nearest Neighbor (ANN)** : Rechercher le "voisin le plus proche" (Nearest Neighbor Search) exact dans des espaces de très haute dimension est computationnellement prohibitif (malédiction de la dimension). Pour surmonter ce défi, les systèmes d'IA utilisent des structures d'**Indexation**

**Spatiale** et des algorithmes d'Approximate Nearest Neighbor (ANN). Beaucoup de ces algorithmes (comme Locality Sensitive Hashing (LSH), Hierarchical Navigable Small Worlds (HNSW), ou Product Quantization) s'appuient sur des concepts géométriques profonds. Par exemple, LSH utilise des **hyperplans de séparation** aléatoires pour "hacher" des points proches dans les mêmes seaux, réduisant ainsi l'espace de recherche. Comprendre la nature des hyperplans (comme le noyau de formes linéaires) est donc crucial pour concevoir, analyser et optimiser ces algorithmes qui partitionnent l'espace euclidien de manière à accélérer la recherche des vecteurs les plus similaires.

3. **Traitement du Langage Naturel (NLP) et Modèles de Langage (LLM) :** Les embeddings sont le fondement des modèles de langage modernes tels que BERT, GPT (qui alimente ChatGPT), et bien d'autres. Chaque mot, sous-mot, ou même phrase est projeté dans un espace de plongement. La similarité cosinus est ensuite utilisée pour :
  - **Trouver des synonymes ou des mots contextuellement proches.**
  - **Évaluer la cohérence ou la pertinence d'une réponse générée par un LLM.**
  - **Améliorer la traduction automatique** en alignant des concepts entre différentes langues. La dualité entre vecteurs et formes linéaires est intrinsèquement liée à la manière dont ces modèles "interrogent" l'espace sémantique pour générer des prédictions ou des réponses.

En somme, ce jalon, en démystifiant la similarité cosinus, la dualité et la géométrie des hyperplans, fournit les outils intellectuels indispensables pour comprendre non seulement comment fonctionnent les systèmes d'IA les plus avancés, mais aussi comment les concevoir et les améliorer.

### 1.1.6 6. Liens Sémantiques

- **Concepts Précédents Requis :** La pleine compréhension de ce jalon nécessite une maîtrise solide des concepts d'algèbre linéaire fondamentaux :
  - [[Jalon-8 (Espaces Vectoriels et Applications Linéaires)]] : Pour la compréhension des espaces  $E = \mathbb{R}^d$  et des applications linéaires.
  - [[Jalon 9 (Calcul matriciel)]] : Pour la manipulation des vecteurs comme matrices colonnes et des produits scalaires.
  - [[Jalon 11 (Formes linéaires)]] : Crucial pour le concept de dualité et la caractérisation des hyperplans.
- **Concepts Futurs Dépendants :** Ce jalon est une pierre angulaire pour plusieurs sujets avancés en mathématiques et en IA :
  - [[Jalon 13 (Structure de R)]] : Renforce la compréhension des propriétés topologiques des espaces euclidiens.
  - [[Jalon 26 (Espaces euclidiens)]] : Approfondira les propriétés des produits scalaires, des normes et des angles dans des espaces plus abstraits.
  - [[Jalon 60 (Livrible IA)]] : Sera directement appliqué dans la conception et l'implémentation de systèmes d'IA basés sur les embeddings et la recherche par similarité.
  - **Recherche par les plus proches voisins (k-NN) :** Algorithmes fondamentaux qui s'appuient directement sur des mesures de distance ou de similarité comme le cosinus.
  - **Analyse en Composantes Principales (ACP) :** Technique de réduction de dimension qui utilise des concepts de projection et d'orthogonalité liés aux espaces euclidiens.
  - **Algorithmes de clustering :** Des méthodes comme k-means ou DBSCAN peuvent utiliser la similarité cosinus pour regrouper des vecteurs sémantiquement proches.




FIGURE 1.1 – Similarité Cosinus : L'angle  $\theta$  entre les vecteurs  $u$  et  $v$  détermine leur similarité sémantique.

# Chapitre 2

## Exercices d'Application

### Exercice 1

#### 2.1 Exercice 01 (1 ★) : Invariance de la Similarité Cosinus par Mise à l'Échelle Positive et son Interprétation Géométrique pour les Espaces de Plongement

##### 2.1.1 Énoncé

Soit  $E = \mathbb{R}^n$  l'espace vectoriel euclidien standard, muni du produit scalaire canonique  $\langle x, y \rangle = \sum_{i=1}^n x_i y_i$  pour  $x = (x_1, \dots, x_n)$  et  $y = (y_1, \dots, y_n)$  dans  $E$ . La norme euclidienne associée est  $\|x\| = \sqrt{\langle x, x \rangle}$ . Soient  $u$  et  $v$  deux vecteurs non nuls de  $E$ .

1. Définir rigoureusement la similarité cosinus  $\text{sim}(u, v)$  entre les vecteurs  $u$  et  $v$ .
2. Soient  $\alpha$  et  $\beta$  deux scalaires réels strictement positifs, c'est-à-dire  $\alpha \in \mathbb{R}^{+*}$  et  $\beta \in \mathbb{R}^{+*}$ . Démontrer que la similarité cosinus entre les vecteurs  $u$  et  $v$  est identique à la similarité cosinus entre les vecteurs  $\alpha u$  et  $\beta v$ . C'est-à-dire, montrer que  $\text{sim}(u, v) = \text{sim}(\alpha u, \beta v)$ .
3. Expliquer en quoi cette propriété fondamentale est cruciale pour la conception et le fonctionnement des moteurs de recherche sémantiques basés sur des espaces de plongement (embedding spaces).

##### Analyse Topologique de l'Invariance

Remarquons formellement que l'application  $S_C : (E \setminus \{0_E\}) \times (E \setminus \{0_E\}) \rightarrow [-1, 1]$  est homogène de degré 0. Soient  $u, v \in E \setminus \{0_E\}$  et  $\alpha, \beta \in \mathbb{R}^{+*}$ . Par bilinéarité du produit scalaire, nous avons  $\langle \alpha u, \beta v \rangle = \alpha \beta \langle u, v \rangle$ . De même, par homogénéité absolue de la norme euclidienne,  $\|\alpha u\| = |\alpha| \|u\| = \alpha \|u\|$  car  $\alpha > 0$ . L'évaluation donne alors :

$$S_C(\alpha u, \beta v) = \frac{\langle \alpha u, \beta v \rangle}{\|\alpha u\| \|\beta v\|} = \frac{\alpha \beta \langle u, v \rangle}{\alpha \beta \|u\| \|v\|} = \frac{\langle u, v \rangle}{\|u\| \|v\|} = S_C(u, v)$$

La fonction est donc invariante par rapport au groupe des homothéties de rapport strictement positif.

##### 2.1.2 Correction Détaillée

##### Analyse et Stratégie

Le problème se décompose en trois parties distinctes. Premièrement, il s'agit de rappeler la définition formelle de la similarité cosinus, qui est une mesure de l'angle entre deux vecteurs dans un espace euclidien. Deuxièmement, nous devons prouver une propriété d'invariance de

cette mesure lorsque les vecteurs sont mis à l'échelle par des scalaires strictement positifs. Enfin, la troisième partie demande une interprétation de cette propriété dans le contexte spécifique des moteurs de recherche sémantiques et des espaces de plongement.

Pour la première partie, nous utiliserons la définition standard de la similarité cosinus, qui est le rapport du produit scalaire des vecteurs au produit de leurs normes euclidiennes. La condition que les vecteurs soient non nuls est cruciale pour assurer que les normes au dénominateur sont strictement positives.

Pour la deuxième partie, la démonstration de l'invariance, nous allons substituer les vecteurs mis à l'échelle  $\alpha u$  et  $\beta v$  dans la formule de la similarité cosinus. Nous exploiterons les propriétés de bilinéarité du produit scalaire et la propriété de la norme euclidienne concernant la multiplication par un scalaire, à savoir  $\|\lambda x\| = |\lambda| \|x\|$ . Étant donné que les scalaires  $\alpha$  et  $\beta$  sont strictement positifs, leurs valeurs absolues sont égales à eux-mêmes ( $|\alpha| = \alpha$  et  $|\beta| = \beta$ ), ce qui simplifiera les expressions. L'objectif est de montrer que les termes scalaires  $\alpha$  et  $\beta$  s'annulent dans la fraction finale, laissant l'expression originale de la similarité cosinus.

Pour la troisième partie, l'explication de l'importance, nous nous appuyerons sur l'interprétation géométrique de la similarité cosinus comme le cosinus de l'angle entre les vecteurs. Nous discuterons de la manière dont les espaces de plongement représentent des entités sémantiques et comment la direction d'un vecteur encode le sens, tandis que sa magnitude peut représenter d'autres informations (comme la fréquence ou l'importance). L'invariance par mise à l'échelle signifie que la similarité sémantique, mesurée par l'angle, n'est pas affectée par ces facteurs de magnitude, ce qui est souhaitable pour une recherche sémantique pure.

## Résolution Pas-à-Pas

1. **Définition de la similarité cosinus** Soient  $u$  et  $v$  deux vecteurs non nuls de l'espace euclidien  $E = \mathbb{R}^n$ . Le produit scalaire canonique entre  $u$  et  $v$  est  $\langle u, v \rangle = \sum_{i=1}^n u_i v_i$ . La norme euclidienne de  $u$  est  $\|u\| = \sqrt{\langle u, u \rangle} = \sqrt{\sum_{i=1}^n u_i^2}$ . De même,  $\|v\| = \sqrt{\langle v, v \rangle} = \sqrt{\sum_{i=1}^n v_i^2}$ . Puisque  $u$  et  $v$  sont des vecteurs non nuls, leurs normes  $\|u\|$  et  $\|v\|$  sont strictement positives. La similarité cosinus entre  $u$  et  $v$ , notée  $\text{sim}(u, v)$ , est définie par :

$$\text{sim}(u, v) = \frac{\langle u, v \rangle}{\|u\| \|v\|}$$

Cette définition est bien posée car le dénominateur est non nul.

2. **Démonstration de l'invariance par mise à l'échelle positive** Nous voulons démontrer que pour  $\alpha, \beta \in \mathbb{R}^{+*}$ , on a  $\text{sim}(u, v) = \text{sim}(\alpha u, \beta v)$ . Commençons par calculer la similarité cosinus entre les vecteurs  $\alpha u$  et  $\beta v$  en utilisant la définition établie en partie 1 :

$$\text{sim}(\alpha u, \beta v) = \frac{\langle \alpha u, \beta v \rangle}{\|\alpha u\| \|\beta v\|}$$

**Calcul du numérateur :** Le produit scalaire  $\langle \alpha u, \beta v \rangle$  est calculé en utilisant la bilinéarité du produit scalaire canonique dans  $\mathbb{R}^n$ . Pour tout  $x, y \in E$  et tout  $\lambda, \mu \in \mathbb{R}$ , nous avons  $\langle \lambda x, \mu y \rangle = \lambda \mu \langle x, y \rangle$ . En appliquant cette propriété :

$$\langle \alpha u, \beta v \rangle = \alpha \beta \langle u, v \rangle$$

**Calcul du dénominateur :** Le dénominateur est le produit des normes de  $\alpha u$  et  $\beta v$ . Nous utilisons la propriété de la norme euclidienne qui stipule que pour tout scalaire  $\lambda \in \mathbb{R}$  et tout vecteur  $x \in E$ ,  $\|\lambda x\| = |\lambda| \|x\|$ . Puisque  $\alpha \in \mathbb{R}^{+*}$ ,  $\alpha$  est strictement positif, donc  $|\alpha| = \alpha$ . Par conséquent :

$$\|\alpha u\| = |\alpha| \|u\| = \alpha \|u\|$$

De même, puisque  $\beta \in \mathbb{R}^{+*}$ ,  $\beta$  est strictement positif, donc  $|\beta| = \beta$ . Par conséquent :

$$\|\beta v\| = |\beta| \|v\| = \beta \|v\|$$

En multipliant ces deux expressions pour obtenir le dénominateur :

$$\|\alpha u\| \|\beta v\| = (\alpha \|u\|)(\beta \|v\|) = \alpha \beta \|u\| \|v\|$$

**Substitution et simplification :** Maintenant, nous substituons les expressions obtenues pour le numérateur et le dénominateur dans la formule de la similarité cosinus pour  $\alpha u$  et  $\beta v$  :

$$\text{sim}(\alpha u, \beta v) = \frac{\alpha \beta \langle u, v \rangle}{\alpha \beta \|u\| \|v\|}$$

Puisque  $\alpha \in \mathbb{R}^{+*}$  et  $\beta \in \mathbb{R}^{+*}$ , leur produit  $\alpha \beta$  est également un scalaire strictement positif. Nous pouvons donc diviser le numérateur et le dénominateur par  $\alpha \beta$  :

$$\text{sim}(\alpha u, \beta v) = \frac{\langle u, v \rangle}{\|u\| \|v\|}$$

En comparant cette expression avec la définition de  $\text{sim}(u, v)$  de la partie 1, nous constatons qu’elles sont identiques. Ainsi, nous avons rigoureusement démontré que :

$$\text{sim}(u, v) = \text{sim}(\alpha u, \beta v)$$

La similarité cosinus est bien invariante par mise à l’échelle par des scalaires strictement positifs.

3. **Importance pour les moteurs de recherche sémantiques** Dans le domaine des moteurs de recherche sémantiques, des entités telles que des mots, des phrases, des documents ou des requêtes sont transformées en vecteurs numériques dans un espace de plongement (embedding space) de haute dimension. Ces vecteurs sont conçus de telle sorte que leur position et leur orientation dans cet espace encodent leur signification sémantique. La similarité cosinus est une métrique couramment utilisée pour quantifier la proximité sémantique entre ces entités.

Géométriquement, la similarité cosinus est égale au cosinus de l’angle  $\theta$  entre les deux vecteurs  $u$  et  $v$ , c’est-à-dire  $\text{sim}(u, v) = \cos(\theta)$ . Un cosinus proche de 1 (angle petit) indique une forte similarité sémantique, tandis qu’un cosinus proche de -1 (angle grand, vecteurs opposés) indique une forte dissemblance.

La propriété d’invariance démontrée ci-dessus est cruciale car elle signifie que la similarité cosinus ne dépend pas de la *magnitude* (longueur) des vecteurs, mais uniquement de leur *direction* relative. Dans les espaces de plongement, la magnitude d’un vecteur peut parfois être influencée par des facteurs non sémantiques, tels que la fréquence d’apparition d’un mot dans un corpus (par exemple, un mot très fréquent pourrait avoir un vecteur de plus grande magnitude) ou la longueur d’un document.

Si un moteur de recherche utilisait une métrique de distance euclidienne (qui dépend de la magnitude) pour la similarité sémantique, un mot rare mais sémantiquement pertinent pourrait être jugé “moins similaire” à un mot fréquent simplement à cause de la différence de magnitude de leurs vecteurs, même si leurs directions sémantiques sont très proches.

En utilisant la similarité cosinus, le moteur de recherche se concentre exclusivement sur l’alignement directionnel des vecteurs. Cela permet de mesurer la similarité sémantique pure, en ignorant les variations de magnitude qui pourraient être des artefacts du processus de plongement ou des caractéristiques non pertinentes pour la sémantique. Par exemple, si “voiture” et “automobile” sont sémantiquement très proches, leurs vecteurs  $u$  et  $v$  pointeront dans des directions très similaires, et leur similarité cosinus sera élevée,

indépendamment du fait que l'un des mots soit beaucoup plus fréquent que l'autre dans le corpus d'entraînement et ait, par conséquent, un vecteur de magnitude différente. Cette robustesse aux variations d'échelle est essentielle pour une recherche sémantique efficace et pertinente.

## Conclusion

Nous avons défini la similarité cosinus comme le rapport du produit scalaire au produit des normes des vecteurs. Nous avons ensuite démontré rigoureusement que la similarité cosinus est invariante par mise à l'échelle par des scalaires strictement positifs, c'est-à-dire que  $\text{sim}(u, v) = \text{sim}(\alpha u, \beta v)$  pour tout  $\alpha, \beta \in \mathbb{R}^{+*}$ . Cette propriété est d'une importance capitale pour les moteurs de recherche sémantiques, car elle garantit que la mesure de similarité se concentre exclusivement sur la direction des vecteurs de plongement, qui encode l'information sémantique, et n'est pas influencée par leur magnitude. Cela permet une évaluation robuste et pertinente de la proximité conceptuelle entre les entités représentées dans les espaces de plongement.

## Exercice 2

### 2.2 Exercice 02 (1 ★) : Exploration de la Similarité Cosinus et des Formes Duales en $\mathbb{R}^2$

#### 2.2.1 Énoncé

Soit  $E = \mathbb{R}^2$  l'espace vectoriel réel muni du produit scalaire euclidien standard, défini pour tout  $x = (x_1, x_2) \in E$  et  $y = (y_1, y_2) \in E$  par  $\langle x, y \rangle = x_1 y_1 + x_2 y_2$ . On considère les deux vecteurs  $u = (3, 4)$  et  $v = (5, 12)$  appartenant à  $E$ .

1. Calculer la norme euclidienne de  $u$  et de  $v$ .
2. Calculer le produit scalaire  $\langle u, v \rangle$ .
3. En déduire la similarité cosinus entre  $u$  et  $v$ .
4. Pour chaque vecteur  $x \in E$ , on associe une forme linéaire  $\phi_x \in E^*$  (le dual de  $E$ ) définie par  $\phi_x(y) = \langle x, y \rangle$  pour tout  $y \in E$ .
  - a. Déterminer les expressions explicites des formes linéaires  $\phi_u$  et  $\phi_v$ .
  - b. Vérifier que  $\langle u, v \rangle = \phi_u(v)$  et que  $\langle u, v \rangle = \phi_v(u)$ .
  - c. Exprimer la similarité cosinus entre  $u$  et  $v$  en utilisant les formes linéaires  $\phi_u$ ,  $\phi_v$  et les normes de  $u$  et  $v$ .

#### Exégèse de l'Orthogonalité Sémantique

Le concept d'orthogonalité transcende la géométrie pour devenir une condition d'indépendance sémantique absolue. Soient  $u, v \in E$ . Si  $\langle u, v \rangle = 0$ , la similarité cosinus est strictement nulle. Dans l'espace des plongements, cela implique que les représentations latentes n'ont aucune projection commune. La projection orthogonale de  $v$  sur la droite engendrée par  $u$  est  $\text{proj}_u(v) = \frac{\langle u, v \rangle}{\|u\|^2} u = 0_E$ .

#### 2.2.2 Correction Détaillée

##### Analyse et Stratégie

L'objectif de cet exercice est de renforcer la compréhension des concepts fondamentaux liés à la géométrie des espaces vectoriels euclidiens, notamment la norme, le produit scalaire, la



similarité cosinus, et la dualité. Étant donné la difficulté de 1 étoile, la résolution s'appuiera sur l'application directe des définitions et des propriétés de base.

La démarche sera la suivante : Pour les questions 1, 2 et 3, nous appliquerons rigoureusement les définitions de la norme euclidienne, du produit scalaire euclidien standard et de la similarité cosinus. Pour la question 4.a, nous utiliserons la définition de la forme linéaire  $\phi_x$  associée à un vecteur  $x$  et les coordonnées des vecteurs  $u$  et  $v$  pour obtenir leurs expressions explicites. Pour la question 4.b, nous substituerons les vecteurs et les formes linéaires dans les expressions  $\phi_u(v)$  et  $\phi_v(u)$  et vérifierons que les résultats sont égaux au produit scalaire  $\langle u, v \rangle$  calculé précédemment. Pour la question 4.c, nous réécrivons la formule de la similarité cosinus en remplaçant le produit scalaire par son expression en termes de formes linéaires, en utilisant les résultats de la question 4.b.

Les hypothèses de régularité (continuité, dérivabilité, intégrabilité) ne sont pas pertinentes dans le cadre de cet exercice. Nous travaillons dans un espace vectoriel de dimension finie ( $\mathbb{R}^2$ ) avec des vecteurs fixes et des opérations algébriques bien définies. Les formes linéaires sont par définition continues et différentiables sur un espace vectoriel normé de dimension finie.

### Résolution Pas-à-Pas

1. **Calcul des normes euclidiennes de  $u$  et de  $v$  :** La norme euclidienne d'un vecteur  $x = (x_1, x_2) \in \mathbb{R}^2$  est définie par  $\|x\| = \sqrt{\langle x, x \rangle} = \sqrt{x_1^2 + x_2^2}$ .

Pour le vecteur  $u = (3, 4)$  :

$$\|u\| = \sqrt{3^2 + 4^2}$$

$$\|u\| = \sqrt{9 + 16}$$

$$\|u\| = \sqrt{25}$$

$$\|u\| = 5$$

Pour le vecteur  $v = (5, 12)$  :

$$\|v\| = \sqrt{5^2 + 12^2}$$

$$\|v\| = \sqrt{25 + 144}$$

$$\|v\| = \sqrt{169}$$

$$\|v\| = 13$$

2. **Calcul du produit scalaire  $\langle u, v \rangle$  :** Le produit scalaire euclidien standard de  $u = (u_1, u_2)$  et  $v = (v_1, v_2)$  est  $\langle u, v \rangle = u_1 v_1 + u_2 v_2$ .

Pour  $u = (3, 4)$  et  $v = (5, 12)$  :

$$\langle u, v \rangle = (3)(5) + (4)(12)$$

$$\langle u, v \rangle = 15 + 48$$

$$\langle u, v \rangle = 63$$

3. **Calcul de la similarité cosinus entre  $u$  et  $v$  :** La similarité cosinus entre deux vecteurs non nuls  $u$  et  $v$  est définie par la formule :

$$\text{sim}(u, v) = \frac{\langle u, v \rangle}{\|u\| \|v\|}$$

En utilisant les résultats obtenus aux questions 1 et 2 :

$$\text{sim}(u, v) = \frac{63}{(5)(13)}$$

$$\text{sim}(u, v) = \frac{63}{65}$$

#### 4. Exploration des formes linéaires duales :

- a. **Détermination des expressions explicites des formes linéaires  $\phi_u$  et  $\phi_v$**  : Pour un vecteur  $x = (x_1, x_2)$ , la forme linéaire  $\phi_x$  est définie par  $\phi_x(y) = \langle x, y \rangle$  pour tout  $y = (y_1, y_2) \in E$ . En substituant l'expression du produit scalaire euclidien standard, nous obtenons :

$$\phi_x(y_1, y_2) = x_1 y_1 + x_2 y_2$$

Pour le vecteur  $u = (3, 4)$  :

$$\phi_u(y_1, y_2) = 3y_1 + 4y_2$$

Pour le vecteur  $v = (5, 12)$  :

$$\phi_v(y_1, y_2) = 5y_1 + 12y_2$$

- b. **Vérification de  $\langle u, v \rangle = \phi_u(v)$  et  $\langle u, v \rangle = \phi_v(u)$**  : Calculons  $\phi_u(v)$  en substituant les coordonnées de  $v = (5, 12)$  dans l'expression de  $\phi_u$  :

$$\phi_u(v) = \phi_u(5, 12) = 3(5) + 4(12)$$

$$\phi_u(v) = 15 + 48$$

$$\phi_u(v) = 63$$

Nous constatons que  $\phi_u(v)$  est égal au produit scalaire  $\langle u, v \rangle$  calculé à la question 2.

Calculons  $\phi_v(u)$  en substituant les coordonnées de  $u = (3, 4)$  dans l'expression de  $\phi_v$  :

$$\phi_v(u) = \phi_v(3, 4) = 5(3) + 12(4)$$

$$\phi_v(u) = 15 + 48$$

$$\phi_v(u) = 63$$

Nous constatons également que  $\phi_v(u)$  est égal au produit scalaire  $\langle u, v \rangle$ . Ces vérifications illustrent la relation d'isomorphisme entre l'espace vectoriel  $E$  et son dual  $E^*$  dans le cas d'un espace euclidien de dimension finie, et confirment la propriété de symétrie du produit scalaire,  $\langle u, v \rangle = \langle v, u \rangle$ .

- c. **Expression de la similarité cosinus en utilisant les formes linéaires** : La formule générale de la similarité cosinus est  $\text{sim}(u, v) = \frac{\langle u, v \rangle}{\|u\| \|v\|}$ . En utilisant les résultats de la question 4.b, nous pouvons remplacer le produit scalaire  $\langle u, v \rangle$  par  $\phi_u(v)$  ou par  $\phi_v(u)$ .

Ainsi, la similarité cosinus peut être exprimée de deux manières équivalentes en utilisant les formes linéaires duales :

$$\text{sim}(u, v) = \frac{\phi_u(v)}{\|u\| \|v\|}$$

ou

$$\text{sim}(u, v) = \frac{\phi_v(u)}{\|u\| \|v\|}$$

## Conclusion

Nous avons effectué une analyse complète des vecteurs  $u = (3, 4)$  et  $v = (5, 12)$  dans l'espace euclidien  $\mathbb{R}^2$ . Les normes euclidiennes ont été calculées comme  $\|u\| = 5$  et  $\|v\| = 13$ . Le produit scalaire  $\langle u, v \rangle$  a été déterminé à 63. En conséquence, la similarité cosinus entre ces deux vecteurs est  $\frac{63}{65}$ .

Par la suite, nous avons exploré la dualité en déterminant les formes linéaires associées à ces vecteurs :  $\phi_u(y_1, y_2) = 3y_1 + 4y_2$  et  $\phi_v(y_1, y_2) = 5y_1 + 12y_2$ . Nous avons vérifié que le produit scalaire  $\langle u, v \rangle$  peut être exprimé comme l'évaluation de la forme linéaire associée à un vecteur sur l'autre vecteur, c'est-à-dire  $\phi_u(v) = 63$  et  $\phi_v(u) = 63$ .

Enfin, nous avons reformulé la similarité cosinus en utilisant ces formes linéaires duales :

$$\text{sim}(u, v) = \frac{\phi_u(v)}{\|u\|\|v\|} = \frac{\phi_v(u)}{\|u\|\|v\|}$$

Cet exercice démontre la connexion intrinsèque entre les concepts géométriques (norme, produit scalaire, similarité cosinus) et la structure algébrique de dualité dans les espaces euclidiens de dimension finie, un principe fondamental pour la compréhension des espaces de plongement en apprentissage automatique.

## Exercice 3

### 2.3 Exercice 03 (2 ★) : Géométrie de la similarité cosinus et formes linéaires associées

#### 2.3.1 Énoncé

Soit  $E = \mathbb{R}^n$  un espace vectoriel euclidien de dimension  $n \geq 1$ , muni du produit scalaire canonique  $\langle x, y \rangle = \sum_{i=1}^n x_i y_i$  pour  $x = (x_1, \dots, x_n)$  et  $y = (y_1, \dots, y_n)$  dans  $E$ . La norme associée est  $\|x\| = \sqrt{\langle x, x \rangle}$ . Pour deux vecteurs  $u, v \in E \setminus \{0\}$ , la similarité cosinus entre  $u$  et  $v$  est définie par  $\text{sim}(u, v) = \frac{\langle u, v \rangle}{\|u\|\|v\|}$ .

1. Montrer que pour tout  $u, v \in E \setminus \{0\}$ , on a  $\text{sim}(u, v) \in [-1, 1]$ .
2. Soit  $u \in E$  un vecteur non nul fixé. Décrire géométriquement l'ensemble  $S_u = \{v \in E \setminus \{0\} \mid \text{sim}(u, v) = 1\}$ .
3. Soit  $u \in E$  un vecteur non nul fixé. Décrire géométriquement l'ensemble  $S'_u = \{v \in E \setminus \{0\} \mid \text{sim}(u, v) = -1\}$ .
4. Soit  $u \in E$  un vecteur non nul fixé et  $\alpha \in (-1, 1)$  un scalaire. Décrire géométriquement l'ensemble  $H_{u, \alpha} = \{v \in E \setminus \{0\} \mid \text{sim}(u, v) = \alpha\}$ .
5. Pour un vecteur  $u \in E$  non nul, on définit la forme linéaire  $f_u : E \rightarrow \mathbb{R}$  par  $f_u(v) = \langle u, v \rangle$ . Montrer que l'ensemble  $H_{u, \alpha}$  (défini à la question 4) peut être caractérisé en termes de  $f_u$  et de la norme de  $v$ .

#### Topologie de la Sphère Unité

Il est crucial de noter que la distance cosinus  $D_C(u, v) = 1 - S_C(u, v)$  n'est pas une distance au sens métrique du terme, car elle ne respecte pas systématiquement l'inégalité triangulaire. Toutefois, si l'on restreint le domaine d'étude à la sphère unité  $\mathbb{S}^{d-1} = \{x \in \mathbb{R}^d \mid \|x\| = 1\}$ , la distance euclidienne s'écrit  $\|u - v\|^2 = \|u\|^2 + \|v\|^2 - 2\langle u, v \rangle = 2 - 2S_C(u, v) = 2D_C(u, v)$ . La distance cosinus induit donc la même topologie que la topologie induite par la norme euclidienne sur  $\mathbb{S}^{d-1}$ .

### 2.3.2 Correction Détaillée

#### Analyse et Stratégie

Cet exercice explore la notion de similarité cosinus, un concept central dans la conception de moteurs de recherche sémantiques et l'analyse de données, en l'abordant sous l'angle de la géométrie des espaces euclidiens et de l'algèbre linéaire. La difficulté de 2 étoiles indique que les questions requièrent une application rigoureuse des définitions et des propriétés fondamentales des espaces vectoriels munis d'un produit scalaire, sans nécessiter de théorèmes particulièrement avancés ou de calculs excessivement complexes.

La stratégie de résolution sera la suivante : 1. **Question 1** : La borne de la similarité cosinus est une conséquence directe de l'inégalité de Cauchy-Schwarz, un pilier de la théorie des espaces euclidiens. Il s'agira de l'appliquer correctement. 2. **Questions 2 et 3** : Les cas où la similarité cosinus atteint ses valeurs extrêmes (1 ou -1) correspondent à des situations géométriques spécifiques de colinéarité. L'analyse de l'égalité dans l'inégalité de Cauchy-Schwarz permettra de caractériser ces ensembles. 3. **Question 4** : Pour une valeur intermédiaire  $\alpha$ , la similarité cosinus est directement liée au cosinus de l'angle entre les vecteurs. L'objectif sera de traduire cette condition en une description géométrique, en distinguant les cas de dimension  $n$ . 4. **Question 5** : Cette dernière question vise à établir un lien formel entre la similarité cosinus et la notion de forme linéaire associée à un vecteur via le produit scalaire. Il s'agira de reformuler l'équation définissant l'ensemble  $H_{u,\alpha}$  en utilisant la notation de la forme linéaire  $f_u$ .

Tout au long de la résolution, une attention particulière sera portée à la rigueur des démonstrations, à la justification de chaque étape algébrique ou logique, et à la vérification explicite des hypothèses (par exemple, vecteurs non nuls pour éviter les divisions par zéro).

#### Résolution Pas-à-Pas

1. **Montrer que pour tout  $u, v \in E \setminus \{0\}$ , on a  $\text{sim}(u, v) \in [-1, 1]$ .** Soient  $u, v \in E \setminus \{0\}$  deux vecteurs non nuls de l'espace euclidien  $E = \mathbb{R}^n$ . La similarité cosinus est définie par  $\text{sim}(u, v) = \frac{\langle u, v \rangle}{\|u\| \|v\|}$ . L'espace  $E$  étant un espace euclidien, il est muni d'un produit scalaire  $\langle \cdot, \cdot \rangle$  et d'une norme associée  $\| \cdot \|$ . L'inégalité de Cauchy-Schwarz s'applique pour tout couple de vecteurs dans  $E$ . L'inégalité de Cauchy-Schwarz stipule que pour tout  $x, y \in E$ , on a  $|\langle x, y \rangle| \leq \|x\| \|y\|$ . Appliquons cette inégalité aux vecteurs  $u$  et  $v$  :

$$|\langle u, v \rangle| \leq \|u\| \|v\|$$

Par hypothèse,  $u$  et  $v$  sont des vecteurs non nuls. Par conséquent, leurs normes  $\|u\|$  et  $\|v\|$  sont strictement positives. Le produit  $\|u\| \|v\|$  est donc également strictement positif. Nous pouvons diviser l'inégalité par  $\|u\| \|v\|$  sans en changer le sens :

$$\frac{|\langle u, v \rangle|}{\|u\| \|v\|} \leq \frac{\|u\| \|v\|}{\|u\| \|v\|}$$

$$\frac{|\langle u, v \rangle|}{\|u\| \|v\|} \leq 1$$

Par définition de la valeur absolue,  $\frac{|\langle u, v \rangle|}{\|u\| \|v\|}$  est égal à  $\left| \frac{\langle u, v \rangle}{\|u\| \|v\|} \right|$ . Donc, nous obtenons :

$$|\text{sim}(u, v)| \leq 1$$

Cette inégalité est équivalente à la double inégalité suivante :

$$-1 \leq \text{sim}(u, v) \leq 1$$

Ainsi, pour tout  $u, v \in E \setminus \{0\}$ , la similarité cosinus  $\text{sim}(u, v)$  appartient bien à l'intervalle fermé  $[-1, 1]$ .

2. **Soit  $u \in E$  un vecteur non nul fixé. Décrire géométriquement l'ensemble  $S_u = \{v \in E \setminus \{0\} \mid \text{sim}(u, v) = 1\}$ .** L'ensemble  $S_u$  est défini par la condition  $\text{sim}(u, v) = 1$ . En utilisant la définition de la similarité cosinus, cette condition s'écrit :

$$\frac{\langle u, v \rangle}{\|u\|\|v\|} = 1$$

Puisque  $\|u\|\|v\|$  est strictement positif (car  $u \neq 0$  et  $v \neq 0$ ), nous pouvons multiplier les deux côtés de l'équation par  $\|u\|\|v\|$  :

$$\langle u, v \rangle = \|u\|\|v\|$$

Nous savons que l'égalité dans l'inégalité de Cauchy-Schwarz, c'est-à-dire  $|\langle u, v \rangle| = \|u\|\|v\|$ , est atteinte si et seulement si les vecteurs  $u$  et  $v$  sont linéairement dépendants. Cela signifie qu'il existe un scalaire  $\lambda \in \mathbb{R}$  tel que  $v = \lambda u$ . Substituons  $v = \lambda u$  dans l'équation  $\langle u, v \rangle = \|u\|\|v\|$  :

$$\langle u, \lambda u \rangle = \|u\|\|\lambda u\|$$

En utilisant les propriétés de linéarité du produit scalaire et de la norme :

$$\lambda \langle u, u \rangle = |\lambda| \|u\| \|u\|$$

$$\lambda \|u\|^2 = |\lambda| \|u\|^2$$

Puisque  $u \neq 0$ ,  $\|u\|^2$  est strictement positif. Nous pouvons diviser les deux côtés de l'équation par  $\|u\|^2$  :

$$\lambda = |\lambda|$$

L'égalité  $\lambda = |\lambda|$  est vraie si et seulement si  $\lambda \geq 0$ . De plus, la définition de  $S_u$  exige que  $v \neq 0$ . Si  $\lambda = 0$ , alors  $v = 0 \cdot u = 0$ , ce qui contredit la condition  $v \in E \setminus \{0\}$ . Par conséquent,  $\lambda$  doit être strictement positif. Ainsi, l'ensemble  $S_u$  est l'ensemble des vecteurs  $v$  qui sont des multiples scalaires strictement positifs de  $u$ . Géométriquement,  $S_u$  représente la demi-droite ouverte issue de l'origine et passant par le vecteur  $u$ . Tous les vecteurs de  $S_u$  sont colinéaires à  $u$  et ont la même direction que  $u$ .

3. **Soit  $u \in E$  un vecteur non nul fixé. Décrire géométriquement l'ensemble  $S'_u = \{v \in E \setminus \{0\} \mid \text{sim}(u, v) = -1\}$ .** L'ensemble  $S'_u$  est défini par la condition  $\text{sim}(u, v) = -1$ . En utilisant la définition de la similarité cosinus :

$$\frac{\langle u, v \rangle}{\|u\|\|v\|} = -1$$

Puisque  $\|u\|\|v\|$  est strictement positif, nous multiplions les deux côtés de l'équation par  $\|u\|\|v\|$  :

$$\langle u, v \rangle = -\|u\|\|v\|$$

Cette équation implique que  $|\langle u, v \rangle| = \|u\|\|v\|$  (car  $-x = |x|$  si  $x \leq 0$ ) et que  $\langle u, v \rangle$  est négatif. Comme à la question précédente, l'égalité dans l'inégalité de Cauchy-Schwarz implique que  $u$  et  $v$  sont linéairement dépendants, c'est-à-dire  $v = \lambda u$  pour un certain scalaire  $\lambda \in \mathbb{R}$ . Substituons  $v = \lambda u$  dans l'équation  $\langle u, v \rangle = -\|u\|\|v\|$  :

$$\langle u, \lambda u \rangle = -\|u\|\|\lambda u\|$$

$$\lambda \langle u, u \rangle = -|\lambda| \|u\| \|u\|$$

$$\lambda \|u\|^2 = -|\lambda| \|u\|^2$$

Puisque  $u \neq 0$ ,  $\|u\|^2$  est strictement positif. Nous pouvons diviser les deux côtés de l'équation par  $\|u\|^2$  :

$$\lambda = -|\lambda|$$

L'égalité  $\lambda = -|\lambda|$  est vraie si et seulement si  $\lambda \leq 0$ . De plus, la définition de  $S'_u$  exige que  $v \neq 0$ . Si  $\lambda = 0$ , alors  $v = 0 \cdot u = 0$ , ce qui contredit la condition  $v \in E \setminus \{0\}$ . Par conséquent,  $\lambda$  doit être strictement négatif. Ainsi, l'ensemble  $S'_u$  est l'ensemble des vecteurs  $v$  qui sont des multiples scalaires strictement négatifs de  $u$ . Géométriquement,  $S'_u$  représente la demi-droite ouverte issue de l'origine et passant par le vecteur  $-u$ . Tous les vecteurs de  $S'_u$  sont colinéaires à  $u$  et ont la direction opposée à  $u$ .

4. **Soit  $u \in E$  un vecteur non nul fixé et  $\alpha \in (-1, 1)$  un scalaire. Décrire géométriquement l'ensemble  $H_{u,\alpha} = \{v \in E \setminus \{0\} \mid \text{sim}(u, v) = \alpha\}$ .** L'ensemble  $H_{u,\alpha}$  est défini par la condition  $\text{sim}(u, v) = \alpha$ . En utilisant la définition de la similarité cosinus :

$$\frac{\langle u, v \rangle}{\|u\| \|v\|} = \alpha$$

Puisque  $\|u\| \|v\|$  est strictement positif, nous multiplions les deux côtés de l'équation par  $\|u\| \|v\|$  :

$$\langle u, v \rangle = \alpha \|u\| \|v\|$$

Dans un espace euclidien, l'angle non orienté  $\theta$  entre deux vecteurs non nuls  $u$  et  $v$  est défini par la relation  $\cos \theta = \frac{\langle u, v \rangle}{\|u\| \|v\|}$ . L'angle  $\theta$  est traditionnellement pris dans l'intervalle  $[0, \pi]$ . La condition  $\text{sim}(u, v) = \alpha$  est donc équivalente à  $\cos \theta = \alpha$ . Puisque  $\alpha \in (-1, 1)$ , il existe un unique angle  $\theta_0 \in (0, \pi)$  tel que  $\cos \theta_0 = \alpha$ . L'ensemble  $H_{u,\alpha}$  est donc l'ensemble des vecteurs  $v \in E \setminus \{0\}$  tels que l'angle entre  $u$  et  $v$  est égal à  $\theta_0$ .

Nous devons considérer la description géométrique en fonction de la dimension  $n$  de l'espace  $E$  :

- **Cas  $n = 1$  :** L'espace  $E = \mathbb{R}$ . Les vecteurs  $u$  et  $v$  sont des scalaires non nuls.  $\text{sim}(u, v) = \frac{uv}{|u||v|}$ . Si  $u$  et  $v$  ont le même signe,  $uv > 0$  et  $|u||v| = uv$ , donc  $\text{sim}(u, v) = 1$ . Si  $u$  et  $v$  ont des signes opposés,  $uv < 0$  et  $|u||v| = -uv$ , donc  $\text{sim}(u, v) = -1$ . Dans le cas  $n = 1$ , la similarité cosinus ne peut prendre que les valeurs 1 ou  $-1$ . Puisque  $\alpha \in (-1, 1)$ , aucune valeur de  $v$  ne peut satisfaire la condition  $\text{sim}(u, v) = \alpha$ . Par conséquent, pour  $n = 1$ , l'ensemble  $H_{u,\alpha}$  est vide.
- **Cas  $n = 2$  :** L'espace  $E = \mathbb{R}^2$ . L'ensemble des vecteurs  $v$  formant un angle  $\theta_0 \in (0, \pi)$  avec  $u$  est constitué de deux demi-droites distinctes issues de l'origine. Ces deux demi-droites sont symétriques par rapport à la droite orthogonale à  $u$  passant par l'origine. Elles ne contiennent pas l'origine car  $v \neq 0$ .
- **Cas  $n \geq 3$  :** L'espace  $E = \mathbb{R}^n$ . L'ensemble des vecteurs  $v$  formant un angle  $\theta_0 \in (0, \pi)$  avec  $u$  est un cône de révolution (sans le sommet, car  $v \neq 0$ ). L'axe de ce cône est la droite vectorielle engendrée par  $u$ , c'est-à-dire  $\text{Vect}(u)$ . Le demi-angle au sommet de ce cône est  $\theta_0 = \arccos(\alpha)$ .

En résumé, pour  $\alpha \in (-1, 1)$  :

- Si  $n = 1$ ,  $H_{u,\alpha} = \emptyset$ .
  - Si  $n = 2$ ,  $H_{u,\alpha}$  est l'union de deux demi-droites distinctes issues de l'origine.
  - Si  $n \geq 3$ ,  $H_{u,\alpha}$  est un cône de révolution d'axe  $\text{Vect}(u)$  et de demi-angle au sommet  $\arccos(\alpha)$ , privé de son sommet (l'origine).
5. **Pour un vecteur  $u \in E$  non nul, on définit la forme linéaire  $f_u : E \rightarrow \mathbb{R}$  par  $f_u(v) = \langle u, v \rangle$ . Montrer que l'ensemble  $H_{u,\alpha}$  (défini à la question 4) peut être caractérisé en termes de  $f_u$  et de la norme de  $v$ .** L'ensemble  $H_{u,\alpha}$  est défini comme :

$$H_{u,\alpha} = \{v \in E \setminus \{0\} \mid \text{sim}(u, v) = \alpha\}$$

D'après la résolution de la question 4, la condition  $\text{sim}(u, v) = \alpha$  est équivalente à l'équation :

$$\frac{\langle u, v \rangle}{\|u\| \|v\|} = \alpha$$

Puisque  $\|u\|\|v\|$  est strictement positif (car  $u \neq 0$  et  $v \neq 0$ ), nous pouvons multiplier les deux côtés de l'équation par  $\|u\|\|v\|$  :

$$\langle u, v \rangle = \alpha \|u\| \|v\|$$

Par définition, la forme linéaire  $f_u : E \rightarrow \mathbb{R}$  est donnée par  $f_u(v) = \langle u, v \rangle$ . Substituons cette définition dans l'équation précédente :

$$f_u(v) = \alpha \|u\| \|v\|$$

Ainsi, l'ensemble  $H_{u,\alpha}$  peut être caractérisé comme l'ensemble des vecteurs  $v \in E \setminus \{0\}$  qui satisfont la relation :

$$f_u(v) = \alpha \|u\| \|v\|$$

Cette caractérisation exprime la condition de similarité cosinus en reliant la valeur de la forme linéaire  $f_u(v)$  à la norme du vecteur  $v$ , pondérée par le scalaire  $\alpha$  et la norme du vecteur de référence  $u$ . Elle met en évidence que, pour un vecteur  $v$  donné, la similarité cosinus est directement proportionnelle à la valeur de la forme linéaire  $f_u(v)$  divisée par la norme de  $v$ .

## Conclusion

Cet exercice a permis d'approfondir la compréhension de la similarité cosinus, un concept fondamental en intelligence artificielle pour les moteurs de recherche sémantiques et l'analyse de données. Nous avons démontré sa borne naturelle entre -1 et 1, découlant de l'inégalité de Cauchy-Schwarz, et avons exploré sa riche interprétation géométrique.

Les cas extrêmes de similarité (1 et -1) correspondent à des vecteurs colinéaires de même ou de direction opposée, respectivement, formant des demi-droites. Pour une similarité cosinus  $\alpha \in (-1, 1)$ , l'ensemble des vecteurs satisfaisant cette condition se manifeste géométriquement comme un cône de révolution (privé de son sommet) dont l'axe est le vecteur de référence  $u$  et le demi-angle au sommet est  $\arccos(\alpha)$ , avec des cas dégénérés pour les dimensions inférieures. Enfin, nous avons établi un lien direct entre la similarité cosinus et la forme linéaire  $f_u(v) = \langle u, v \rangle$ , montrant que la condition de similarité peut être exprimée par  $f_u(v) = \alpha \|u\| \|v\|$ . Cette dernière caractérisation souligne la dualité inhérente aux espaces euclidiens, où chaque vecteur  $u$  peut être naturellement associé à une forme linéaire  $f_u$  par le produit scalaire, offrant une perspective algébrique sur une propriété géométrique.

## Exercice 4

### 2.4 Exercice 04 (2 ★) : Analyse de Similarité Sémantique et Transformations Linéaires dans un Espace de Plongement

#### 2.4.1 Énoncé

Soit  $E = \mathbb{R}^3$  l'espace vectoriel euclidien muni du produit scalaire canonique  $\langle x, y \rangle = x_1y_1 + x_2y_2 + x_3y_3$  pour  $x = (x_1, x_2, x_3)$  et  $y = (y_1, y_2, y_3)$ . La norme associée est  $\|x\| = \sqrt{\langle x, x \rangle}$ . Dans le contexte de l'apprentissage automatique, des vecteurs tels que  $u$  et  $v$  peuvent représenter des plongements (embeddings) sémantiques de mots ou de concepts.

On considère les vecteurs suivants dans  $E$  :  $u = (1, 1, 0)$   $v = (1, 0, 1)$

1. **Calcul de la Similarité Cosinus Initiale** : Calculez la similarité cosinus entre les vecteurs  $u$  et  $v$ . Rappelez la formule utilisée.

2. **Effet d'une Transformation Linéaire (Projection) :** Considérons une transformation linéaire  $L : E \rightarrow E$  représentée par la matrice  $M$  dans la base canonique de  $\mathbb{R}^3$  :

$$M = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 0 \end{pmatrix}$$

- Déterminez les vecteurs transformés  $u' = L(u)$  et  $v' = L(v)$ .
  - Calculez la similarité cosinus entre  $u'$  et  $v'$ .
  - Comparez la similarité cosinus obtenue en 2.b avec celle obtenue en 1. Interprétez géométriquement l'effet de  $L$  sur les vecteurs et sur leur similarité.
3. **Exploration des Formes Linéaires (Dualité) :** L'espace dual  $E^*$  de  $E$  est l'ensemble des formes linéaires de  $E$  dans  $\mathbb{R}$ . Pour tout vecteur  $w \in E$ , la fonction  $f_w : E \rightarrow \mathbb{R}$  définie par  $f_w(x) = \langle x, w \rangle$  est une forme linéaire.
- Soit  $w_1 = (1, 1, 0)$ . Calculez  $f_{w_1}(u)$  et  $f_{w_1}(v)$ .
  - Soit  $w_2 = (0, 0, 1)$ . Calculez  $f_{w_2}(u)$  et  $f_{w_2}(v)$ .
  - Interprétez les valeurs  $f_{w_1}(u)$ ,  $f_{w_1}(v)$ ,  $f_{w_2}(u)$ ,  $f_{w_2}(v)$  en termes de "caractéristiques sémantiques" si les vecteurs  $u, v, w_1, w_2$  représentent des concepts dans un espace de plongement.

## Formulation Rigoureuse de l'Espace Dual

Dans l'étude des requêtes  $q$ , chaque vecteur peut être identifié à une forme linéaire  $\varphi_q \in E^*$  telle que  $\varphi_q(x) = \langle q, x \rangle$ . La recherche sémantique s'assimile à la maximisation de  $\varphi_q$  sur la sphère unité. Le théorème de représentation de Riesz assure l'isomorphisme isométrique entre  $E$  et  $E^*$ , garantissant l'existence et l'unicité de ce prolongement.

### 2.4.2 Correction Détaillée

#### Analyse et Stratégie

L'exercice vise à évaluer la compréhension des concepts fondamentaux de la géométrie des espaces vectoriels euclidiens, en particulier la similarité cosinus, l'effet des transformations linéaires (projections) sur cette similarité, et l'introduction des formes linéaires via le produit scalaire (dualité).

Pour la première partie, nous appliquerons directement la définition de la similarité cosinus, qui implique le calcul du produit scalaire et des normes des vecteurs. Pour la deuxième partie, nous effectuerons une multiplication matricielle pour obtenir les vecteurs transformés, puis nous recalculerons la similarité cosinus. L'interprétation géométrique nécessitera de reconnaître la nature de la transformation  $L$ . Pour la troisième partie, nous utiliserons la définition de la forme linéaire  $f_w(x) = \langle x, w \rangle$  pour calculer les valeurs demandées. L'interprétation finale reliera ces valeurs au concept de "caractéristiques sémantiques" dans un espace de plongement. Toutes les étapes de calcul seront explicitées sans aucune omission.

#### Résolution Pas-à-Pas

1. **Calcul de la Similarité Cosinus Initiale :** La similarité cosinus entre deux vecteurs non nuls  $x$  et  $y$  dans un espace euclidien est définie par la formule :

$$\text{sim}(x, y) = \frac{\langle x, y \rangle}{\|x\| \|y\|}$$

où  $\langle x, y \rangle$  est le produit scalaire et  $\|x\|$  est la norme euclidienne de  $x$ .



Nous avons les vecteurs  $u = (1, 1, 0)$  et  $v = (1, 0, 1)$ . Calculons d'abord le produit scalaire  $\langle u, v \rangle$  :

$$\langle u, v \rangle = (1)(1) + (1)(0) + (0)(1) = 1 + 0 + 0 = 1$$

Ensuite, calculons les normes  $\|u\|$  et  $\|v\|$  :

$$\|u\| = \sqrt{\langle u, u \rangle} = \sqrt{(1)^2 + (1)^2 + (0)^2} = \sqrt{1 + 1 + 0} = \sqrt{2}$$

$$\|v\| = \sqrt{\langle v, v \rangle} = \sqrt{(1)^2 + (0)^2 + (1)^2} = \sqrt{1 + 0 + 1} = \sqrt{2}$$

Maintenant, nous pouvons calculer la similarité cosinus entre  $u$  et  $v$  :

$$\text{sim}(u, v) = \frac{1}{\sqrt{2} \cdot \sqrt{2}} = \frac{1}{2}$$

La similarité cosinus initiale entre  $u$  et  $v$  est  $\frac{1}{2}$ .

2. **Effet d'une Transformation Linéaire (Projection)** : La transformation linéaire  $L$  est représentée par la matrice  $M = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 0 \end{pmatrix}$ .

- a. **Détermination des vecteurs transformés  $u'$  et  $v'$**  : Pour un vecteur  $x = (x_1, x_2, x_3)$ ,  $L(x) = Mx$ . Pour  $u = (1, 1, 0)$  :

$$u' = L(u) = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 0 \end{pmatrix} \begin{pmatrix} 1 \\ 1 \\ 0 \end{pmatrix} = \begin{pmatrix} (1)(1) + (0)(1) + (0)(0) \\ (0)(1) + (1)(1) + (0)(0) \\ (0)(1) + (0)(1) + (0)(0) \end{pmatrix} = \begin{pmatrix} 1 \\ 1 \\ 0 \end{pmatrix}$$

Donc,  $u' = (1, 1, 0)$ .

Pour  $v = (1, 0, 1)$  :

$$v' = L(v) = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 0 \end{pmatrix} \begin{pmatrix} 1 \\ 0 \\ 1 \end{pmatrix} = \begin{pmatrix} (1)(1) + (0)(0) + (0)(1) \\ (0)(1) + (1)(0) + (0)(1) \\ (0)(1) + (0)(0) + (0)(1) \end{pmatrix} = \begin{pmatrix} 1 \\ 0 \\ 0 \end{pmatrix}$$

Donc,  $v' = (1, 0, 0)$ .

- b. **Calcul de la similarité cosinus entre  $u'$  et  $v'$**  : Nous avons  $u' = (1, 1, 0)$  et  $v' = (1, 0, 0)$ . Calculons le produit scalaire  $\langle u', v' \rangle$  :

$$\langle u', v' \rangle = (1)(1) + (1)(0) + (0)(0) = 1 + 0 + 0 = 1$$

Calculons les normes  $\|u'\|$  et  $\|v'\|$  :

$$\|u'\| = \sqrt{(1)^2 + (1)^2 + (0)^2} = \sqrt{1 + 1 + 0} = \sqrt{2}$$

$$\|v'\| = \sqrt{(1)^2 + (0)^2 + (0)^2} = \sqrt{1 + 0 + 0} = \sqrt{1} = 1$$

Calculons la similarité cosinus entre  $u'$  et  $v'$  :

$$\text{sim}(u', v') = \frac{\langle u', v' \rangle}{\|u'\| \|v'\|} = \frac{1}{\sqrt{2} \cdot 1} = \frac{1}{\sqrt{2}} = \frac{\sqrt{2}}{2}$$

La similarité cosinus entre  $u'$  et  $v'$  est  $\frac{\sqrt{2}}{2}$ .

- c. **Comparaison et interprétation** : La similarité cosinus initiale était  $\text{sim}(u, v) = \frac{1}{2}$ . La similarité cosinus après transformation est  $\text{sim}(u', v') = \frac{\sqrt{2}}{2}$ . Puisque  $\frac{\sqrt{2}}{2} \approx 0.707$  et  $\frac{1}{2} = 0.5$ , la similarité cosinus a augmenté après la transformation  $L$ .

Géométriquement, la matrice  $M$  correspond à une projection orthogonale sur le plan  $xy$  (le plan d'équation  $z = 0$ ). En effet, elle conserve les composantes  $x$  et  $y$  et annule la composante  $z$ . Le vecteur  $u = (1, 1, 0)$  est déjà dans le plan  $xy$ , donc  $L(u) = u$ . Le vecteur  $v = (1, 0, 1)$  a une composante  $z$  non nulle. Sa projection  $L(v) = (1, 0, 0)$  est le vecteur  $v$  “aplati” sur le plan  $xy$ . L'angle entre  $u$  et  $v$  était  $\arccos(1/2) = 60^\circ$ . L'angle entre  $u'$  et  $v'$  est  $\arccos(\sqrt{2}/2) = 45^\circ$ . La projection a rapproché les vecteurs en termes d'angle, car la composante  $z$  de  $v$  qui l'éloignait de  $u$  a été supprimée. Dans le contexte des plongements sémantiques, cela signifie que si la dimension  $z$  représentait une caractéristique non pertinente ou du “bruit” pour la similarité entre  $u$  et  $v$ , sa suppression a rendu les concepts  $u$  et  $v$  plus similaires dans l'espace de caractéristiques réduit.

3. **Exploration des Formes Linéaires (Dualité)** : Pour tout vecteur  $w \in E$ , la forme linéaire  $f_w : E \rightarrow \mathbb{R}$  est définie par  $f_w(x) = \langle x, w \rangle$ .

a. **Calcul de  $f_{w_1}(u)$  et  $f_{w_1}(v)$  pour  $w_1 = (1, 1, 0)$  :**

$$f_{w_1}(u) = \langle u, w_1 \rangle = \langle (1, 1, 0), (1, 1, 0) \rangle = (1)(1) + (1)(1) + (0)(0) = 1 + 1 + 0 = 2$$

$$f_{w_1}(v) = \langle v, w_1 \rangle = \langle (1, 0, 1), (1, 1, 0) \rangle = (1)(1) + (0)(1) + (1)(0) = 1 + 0 + 0 = 1$$

b. **Calcul de  $f_{w_2}(u)$  et  $f_{w_2}(v)$  pour  $w_2 = (0, 0, 1)$  :**

$$f_{w_2}(u) = \langle u, w_2 \rangle = \langle (1, 1, 0), (0, 0, 1) \rangle = (1)(0) + (1)(0) + (0)(1) = 0 + 0 + 0 = 0$$

$$f_{w_2}(v) = \langle v, w_2 \rangle = \langle (1, 0, 1), (0, 0, 1) \rangle = (1)(0) + (0)(0) + (1)(1) = 0 + 0 + 1 = 1$$

c. **Interprétation en termes de “caractéristiques sémantiques”** : Dans un espace de plongement sémantique, chaque dimension ou direction vectorielle peut correspondre à une caractéristique sémantique latente. Un vecteur  $w$  peut être vu comme représentant une “caractéristique” ou un “concept” spécifique. La valeur  $f_w(x) = \langle x, w \rangle$  mesure la projection de  $x$  sur  $w$ , ou plus généralement, l'alignement de  $x$  avec  $w$ . Une valeur élevée (positive) indique que  $x$  possède fortement la caractéristique représentée par  $w$ , tandis qu'une valeur faible ou nulle indique une faible présence ou une orthogonalité.

- $f_{w_1}(u) = 2$  : Le vecteur  $u$  est fortement aligné avec la caractéristique  $w_1$ . En fait,  $u$  est colinéaire à  $w_1$ , ce qui signifie que  $u$  incarne pleinement la caractéristique  $w_1$ .
- $f_{w_1}(v) = 1$  : Le vecteur  $v$  est également aligné avec la caractéristique  $w_1$ , mais à un degré moindre que  $u$ .
- $f_{w_2}(u) = 0$  : Le vecteur  $u$  est orthogonal à la caractéristique  $w_2$ . Cela signifie que  $u$  ne possède pas du tout la caractéristique  $w_2$  (ou que cette caractéristique est indépendante de  $u$ ).
- $f_{w_2}(v) = 1$  : Le vecteur  $v$  est aligné avec la caractéristique  $w_2$ . Il possède cette caractéristique à un certain degré.

Si, par exemple,  $u$  représente le mot “chien”,  $v$  le mot “chat”,  $w_1$  la caractéristique “animalité” et  $w_2$  la caractéristique “indépendance”, alors :

- “chien” ( $u$ ) a un score élevé pour “animalité” ( $w_1$ ).
- “chat” ( $v$ ) a un score pour “animalité” ( $w_1$ ) mais légèrement inférieur à “chien”.
- “chien” ( $u$ ) a un score nul pour “indépendance” ( $w_2$ ), suggérant qu'il n'est pas indépendant (ou que cette caractéristique n'est pas pertinente pour lui).
- “chat” ( $v$ ) a un score pour “indépendance” ( $w_2$ ), suggérant qu'il possède cette caractéristique.

Ces valeurs quantifient la pertinence ou la force d'une caractéristique sémantique donnée pour un concept représenté par un vecteur de plongement.

## Conclusion

Cet exercice a permis d'explorer la notion de similarité cosinus, un outil fondamental dans l'analyse des espaces de plongement sémantiques. Nous avons observé comment une transformation linéaire, en l'occurrence une projection, peut modifier la similarité entre des vecteurs en altérant leur géométrie dans l'espace. La similarité entre  $u$  et  $v$  est passée de  $1/2$  à  $\sqrt{2}/2$  après projection sur le plan  $z = 0$ , illustrant que la pertinence des dimensions peut influencer la perception de la similarité. Enfin, l'introduction des formes linéaires a permis de quantifier la présence de "caractéristiques sémantiques" spécifiques (représentées par les vecteurs  $w_1$  et  $w_2$ ) au sein des concepts  $u$  et  $v$ , offrant une perspective sur la dualité et l'interprétabilité des dimensions dans ces espaces.

## Exercice 5

### 2.5 Exercice 05 (3 ★) : Optimisation de la Similarité Cosinus et Dualité dans les Espaces de Plongement Sémantiques

#### 2.5.1 Énoncé

Soit  $E = \mathbb{R}^n$  un espace vectoriel euclidien de dimension  $n \geq 1$ , muni du produit scalaire standard  $\langle u, v \rangle = u^T v$  pour  $u, v \in E$ , et de la norme euclidienne associée  $\|u\| = \sqrt{\langle u, u \rangle}$ .

Dans le contexte des espaces de plongement (embedding spaces) pour la recherche sémantique, nous introduisons une matrice  $A \in \mathcal{M}_n(\mathbb{R})$  qui représente une "pondération sémantique". On suppose que  $A$  est une matrice symétrique définie positive.

1. Montrer que l'application  $(u, v) \mapsto \langle u, v \rangle_A = \langle u, Av \rangle = u^T Av$  définit un produit scalaire sur  $E$ . Nous noterons la norme associée  $\|u\|_A = \sqrt{\langle u, u \rangle_A}$ .
2. Soit  $q \in E$  un vecteur de requête (query vector) non nul et fixé. Nous recherchons un vecteur document  $d \in E$  qui maximise la similarité cosinus standard  $\cos(\theta(q, d)) = \frac{\langle q, d \rangle}{\|q\| \|d\|}$ , sous la contrainte que le vecteur document  $d$  possède une norme sémantiquement pondérée unitaire, c'est-à-dire  $\|d\|_A = 1$ . Déterminer le vecteur  $d^*$  qui maximise cette quantité et exprimer la valeur maximale atteinte en fonction de  $q$  et  $A$ .
3. Pour tout vecteur  $v \in E$ , on considère la forme linéaire  $L_v : E \rightarrow \mathbb{R}$  définie par  $L_v(u) = \langle u, v \rangle_A$ . En vertu du théorème de représentation de Riesz pour les espaces euclidiens, il existe un unique vecteur  $v' \in E$  tel que  $L_v(u) = \langle u, v' \rangle$  pour tout  $u \in E$ . Exprimer  $v'$  en fonction de  $v$  et  $A$ . Interpréter ce résultat dans le contexte de la dualité entre le produit scalaire standard et le produit scalaire sémantiquement pondéré.

#### Exégèse de l'Inégalité de Cauchy-Schwarz

L'inégalité fondamentale s'établit rigoureusement via le polynôme quadratique  $P(\lambda) = \|u + \lambda v\|^2$ . Par stricte positivité de la norme euclidienne,  $P(\lambda) = \|u\|^2 + 2\lambda \langle u, v \rangle + \lambda^2 \|v\|^2 \geq 0$ . Ce trinôme en  $\lambda$  conserve un signe constant, son discriminant réduit est donc nécessairement négatif ou nul :  $\Delta' = \langle u, v \rangle^2 - \|u\|^2 \|v\|^2 \leq 0$ , ce qui achève la formalisation.

#### 2.5.2 Correction Détaillée

##### Analyse et Stratégie

Cet exercice explore la géométrie des espaces de plongement sous l'influence d'une pondération sémantique représentée par une matrice symétrique définie positive  $A$ .

1. **Question 1 (Produit Scalaire) :** Il s'agit de vérifier les axiomes d'un produit scalaire : bilinéarité, symétrie et positivité définie. La symétrie et la positivité définie de  $A$  seront cruciales.
2. **Question 2 (Optimisation) :** Nous devons maximiser une fonction (la similarité cosinus standard) sous une contrainte (norme sémantiquement pondérée unitaire). La stratégie consistera à transformer le problème d'optimisation en un problème plus simple dans un espace où la contrainte devient une norme euclidienne standard. Pour cela, nous utiliserons la racine carrée de la matrice  $A$ , notée  $A^{1/2}$ , qui est également symétrique définie positive. Cette transformation permettra d'appliquer l'inégalité de Cauchy-Schwarz pour trouver le maximum.
3. **Question 3 (Dualité) :** Le théorème de Riesz établit une correspondance entre les formes linéaires continues et les vecteurs de l'espace. Ici, nous avons une forme linéaire définie par un produit scalaire non standard. L'objectif est de trouver le vecteur qui représente cette forme linéaire dans le cadre du produit scalaire standard. Cela implique une manipulation algébrique directe des définitions des produits scalaires.

### Résolution Pas-à-Pas

**Question 1 : Preuve que  $\langle u, v \rangle_A$  est un produit scalaire** Soient  $u, v, w \in E$  et  $\alpha, \beta \in \mathbb{R}$ .

1. **Bilinéarité :**

- Linéarité par rapport à la première variable :  $\langle \alpha u + \beta v, w \rangle_A = (\alpha u + \beta v)^T A w = (\alpha u^T + \beta v^T) A w = \alpha u^T A w + \beta v^T A w = \alpha \langle u, w \rangle_A + \beta \langle v, w \rangle_A$ .
- Linéarité par rapport à la deuxième variable :  $\langle u, \alpha v + \beta w \rangle_A = u^T A(\alpha v + \beta w) = u^T(\alpha A v + \beta A w) = \alpha u^T A v + \beta u^T A w = \alpha \langle u, v \rangle_A + \beta \langle u, w \rangle_A$ . L'application est bilinéaire.

2. **Symétrie :**  $\langle u, v \rangle_A = u^T A v$ . Puisque  $u^T A v$  est un scalaire, il est égal à sa propre transposée :  $u^T A v = (u^T A v)^T = v^T A^T u$ . Comme  $A$  est symétrique,  $A^T = A$ . Donc,  $v^T A^T u = v^T A u = \langle v, u \rangle_A$ . L'application est symétrique.

3. **Positivité définie :**  $\langle u, u \rangle_A = u^T A u$ . Puisque  $A$  est une matrice définie positive, par définition,  $u^T A u > 0$  pour tout  $u \in E, u \neq 0$ . De plus, si  $u = 0$ , alors  $\langle 0, 0 \rangle_A = 0^T A 0 = 0$ . Donc,  $\langle u, u \rangle_A \geq 0$  et  $\langle u, u \rangle_A = 0 \iff u = 0$ . L'application est définie positive.

Les trois propriétés étant vérifiées,  $\langle u, v \rangle_A$  est bien un produit scalaire sur  $E$ .

**Question 2 : Optimisation de la similarité cosinus standard sous contrainte de norme sémantique** Nous cherchons à maximiser  $\cos(\theta(q, d)) = \frac{\langle q, d \rangle}{\|q\| \|d\|}$  sous la contrainte  $\|d\|_A = 1$ . Puisque  $q$  est un vecteur non nul fixé,  $\|q\|$  est une constante positive. Maximiser  $\cos(\theta(q, d))$  est équivalent à maximiser  $\frac{\langle q, d \rangle}{\|d\|}$  (car le cosinus est positif pour le maximum, et  $\|d\|$  sera non nul).

La matrice  $A$  est symétrique définie positive. Il existe donc une unique matrice  $A^{1/2}$ , également symétrique définie positive, telle que  $(A^{1/2})^2 = A$ . De même,  $A^{-1/2} = (A^{1/2})^{-1}$  est symétrique définie positive.

Effectuons un changement de variable. Soit  $x = A^{1/2} d$ . Puisque  $A^{1/2}$  est inversible,  $d = A^{-1/2} x$ .

1. **Transformation de la contrainte :** La contrainte est  $\|d\|_A = 1$ , ce qui signifie  $\langle d, d \rangle_A = 1$ . Substituons  $d = A^{-1/2} x$  :  $\langle A^{-1/2} x, A^{-1/2} x \rangle_A = (A^{-1/2} x)^T A (A^{-1/2} x) = x^T (A^{-1/2})^T A A^{-1/2} x$ . Puisque  $A^{1/2}$  est symétrique,  $(A^{1/2})^T = A^{1/2}$ , et donc  $(A^{-1/2})^T = A^{-1/2}$ .  $= x^T A^{-1/2} A A^{-1/2} x$ . Comme  $A = A^{1/2} A^{1/2}$ , on a  $A^{-1/2} A A^{-1/2} = A^{-1/2} (A^{1/2} A^{1/2}) A^{-1/2} = (A^{-1/2} A^{1/2}) (A^{1/2} A^{-1/2}) = I \cdot I = I$ . Donc, la contrainte devient  $x^T I x = x^T x = \|x\|^2 = 1$ . Le problème est maintenant de maximiser une expression sous la contrainte  $\|x\| = 1$ .
2. **Transformation de la fonction objectif :** Nous voulons maximiser  $\frac{\langle q, d \rangle}{\|d\|}$ . Substituons  $d = A^{-1/2} x$  :

- Numérateur :  $\langle q, d \rangle = \langle q, A^{-1/2}x \rangle$ . Puisque  $A^{-1/2}$  est symétrique,  $\langle q, A^{-1/2}x \rangle = \langle A^{-1/2}q, x \rangle$ . Soit  $q' = A^{-1/2}q$ . Alors le numérateur est  $\langle q', x \rangle$ .
- Dénominateur :  $\|d\| = \|A^{-1/2}x\|$ .

Le problème d'optimisation devient : maximiser  $\frac{\langle q', x \rangle}{\|q'\| \|A^{-1/2}x\|}$  sous la contrainte  $\|x\| = 1$ . Par l'inégalité de Cauchy-Schwarz pour le produit scalaire standard :  $\langle q', x \rangle \leq \|q'\| \|x\|$ . Puisque  $\|x\| = 1$ , nous avons  $\langle q', x \rangle \leq \|q'\|$ . L'égalité est atteinte lorsque  $x$  est colinéaire à  $q'$ , c'est-à-dire  $x = \alpha q'$  pour un scalaire  $\alpha$ . Avec la contrainte  $\|x\| = 1$ , nous avons  $\|\alpha q'\| = 1 \implies |\alpha| \|q'\| = 1$ . Pour maximiser  $\langle q', x \rangle$ , nous choisissons  $\alpha = \frac{1}{\|q'\|}$  (pour que  $\langle q', x \rangle$  soit positif). Donc,  $x^* = \frac{q'}{\|q'\|}$ .

3. **Détermination de  $d^*$**  : Nous avons  $d^* = A^{-1/2}x^* = A^{-1/2} \left( \frac{q'}{\|q'\|} \right)$ . En substituant  $q' = A^{-1/2}q$  :  $d^* = A^{-1/2} \left( \frac{A^{-1/2}q}{\|A^{-1/2}q\|} \right) = \frac{A^{-1/2}A^{-1/2}q}{\|A^{-1/2}q\|} = \frac{A^{-1}q}{\|A^{-1}q\|}$ .

Vérifions le dénominateur  $\|A^{-1/2}q\|$ .  $\|A^{-1/2}q\|^2 = \langle A^{-1/2}q, A^{-1/2}q \rangle = (A^{-1/2}q)^T (A^{-1/2}q)$ . Puisque  $A^{-1/2}$  est symétrique,  $(A^{-1/2})^T = A^{-1/2}$ .  $= q^T A^{-1/2} A^{-1/2} q = q^T A^{-1} q = \langle q, A^{-1}q \rangle$ . Donc,  $\|A^{-1/2}q\| = \sqrt{\langle q, A^{-1}q \rangle}$ .

Le vecteur  $d^*$  qui maximise la similarité cosinus standard est  $d^* = \frac{A^{-1}q}{\sqrt{\langle q, A^{-1}q \rangle}}$ .

4. **Calcul de la valeur maximale** : La valeur maximale est  $\cos(\theta(q, d^*)) = \frac{\langle q, d^* \rangle}{\|q\| \|d^*\|}$ .

— Calculons le numérateur :  $\langle q, d^* \rangle = \left\langle q, \frac{A^{-1}q}{\sqrt{\langle q, A^{-1}q \rangle}} \right\rangle = \frac{1}{\sqrt{\langle q, A^{-1}q \rangle}} \langle q, A^{-1}q \rangle = \sqrt{\langle q, A^{-1}q \rangle}$ .

— Calculons le dénominateur  $\|d^*\|$  :  $\|d^*\| = \left\| \frac{A^{-1}q}{\sqrt{\langle q, A^{-1}q \rangle}} \right\| = \frac{1}{\sqrt{\langle q, A^{-1}q \rangle}} \|A^{-1}q\|$ .

En substituant ces expressions dans la formule du cosinus :  $\cos(\theta(q, d^*)) = \frac{\sqrt{\langle q, A^{-1}q \rangle}}{\|q\| \frac{1}{\sqrt{\langle q, A^{-1}q \rangle}} \|A^{-1}q\|} = \frac{\langle q, A^{-1}q \rangle}{\|q\| \|A^{-1}q\|}$ .

La valeur maximale de la similarité cosinus standard est  $\frac{\langle q, A^{-1}q \rangle}{\|q\| \|A^{-1}q\|}$ .

**Question 3 : Dualité et représentation de Riesz** Nous avons la forme linéaire  $L_v : E \rightarrow \mathbb{R}$  définie par  $L_v(u) = \langle u, v \rangle_A$ . Nous cherchons  $v' \in E$  tel que  $L_v(u) = \langle u, v' \rangle$  pour tout  $u \in E$ .

Par définition,  $L_v(u) = \langle u, Av \rangle$ . Nous voulons que  $\langle u, Av \rangle = \langle u, v' \rangle$  pour tout  $u \in E$ . Ceci implique que  $\langle u, Av - v' \rangle = 0$  pour tout  $u \in E$ . Par la propriété de non-dégénérescence du produit scalaire standard, cela signifie que  $Av - v' = 0$ . Donc,  $v' = Av$ .

**Interprétation** : Le vecteur  $v'$  qui représente la forme linéaire  $L_v$  (définie par le produit scalaire sémantiquement pondéré avec  $v$ ) dans l'espace euclidien standard est obtenu en appliquant l'opérateur de pondération sémantique  $A$  au vecteur original  $v$ . Cela signifie que la "direction" ou "orientation" sémantique de  $v$  (telle que perçue par le produit scalaire  $\langle \cdot, \cdot \rangle_A$ ) est transformée par  $A$  pour être représentée comme une direction dans l'espace euclidien standard. En d'autres termes, l'opérateur  $A$  agit comme un pont entre la géométrie sémantiquement pondérée et la géométrie euclidienne standard, en transformant les vecteurs pour qu'ils représentent la même forme linéaire. C'est une illustration concrète de la dualité où l'opérateur  $A$  (ou son inverse  $A^{-1}$ ) peut être vu comme un "changement de base" entre l'espace et son dual, ou entre différentes métriques sur le même espace.

## Conclusion

1. Nous avons rigoureusement démontré que l'application  $(u, v) \mapsto u^T Av$  définit un produit scalaire sur  $E$ , grâce aux propriétés de symétrie et de positivité définie de la matrice  $A$ .
2. Le vecteur document  $d^*$  qui maximise la similarité cosinus standard avec un vecteur de requête  $q$  sous la contrainte d'une norme sémantiquement pondérée unitaire ( $\|d\|_A = 1$ )

est donné par :

$$d^* = \frac{A^{-1}q}{\sqrt{\langle q, A^{-1}q \rangle}}$$

La valeur maximale de la similarité cosinus standard atteinte est :

$$\max_{d: \|d\|_A=1} \cos(\theta(q, d)) = \frac{\langle q, A^{-1}q \rangle}{\|q\| \|A^{-1}q\|}$$

Ce résultat montre que pour optimiser la similarité standard sous une contrainte sémantique, il faut “dé-pondérer” le vecteur de requête  $q$  par l’inverse de la matrice sémantique  $A$ .

3. Le vecteur  $v'$  qui représente la forme linéaire  $L_v(u) = \langle u, v \rangle_A$  dans le produit scalaire standard est  $v' = Av$ . Ce résultat illustre comment l’opérateur de pondération sémantique  $A$  transforme les vecteurs pour aligner la géométrie sémantiquement pondérée avec la géométrie euclidienne standard dans le contexte de la dualité.

## Exercice 6

### 2.6 Exercice 06 (3 ★) : Optimisation de la Représentativité Sémantique par Similarité Cosinus et Formes Quadratiques

#### 2.6.1 Énoncé

Soit  $E$  un espace vectoriel euclidien de dimension  $n \geq 1$ , muni du produit scalaire  $\langle \cdot, \cdot \rangle$  et de la norme associée  $\|\cdot\|$ . On dispose d’un ensemble de  $k$  vecteurs non nuls  $\mathbf{u}_1, \dots, \mathbf{u}_k \in E$ , représentant des “ancres sémantiques” ou des “caractéristiques de recherche”. Pour chaque  $i \in \{1, \dots, k\}$ , on définit le vecteur normalisé  $\mathbf{v}_i = \frac{\mathbf{u}_i}{\|\mathbf{u}_i\|}$ . Nous cherchons à déterminer un vecteur  $\mathbf{x} \in E$ , de norme unité (c’est-à-dire  $\|\mathbf{x}\| = 1$ ), qui maximise la somme des carrés des similarités cosinus avec les vecteurs  $\mathbf{u}_i$ . Ce vecteur  $\mathbf{x}$  peut être interprété comme une “représentation sémantique optimale” ou un “document idéal” par rapport aux ancres données.

1. Montrer que le problème revient à maximiser la fonction  $f(\mathbf{x}) = \sum_{i=1}^k \langle \mathbf{x}, \mathbf{v}_i \rangle^2$  sous la contrainte  $\|\mathbf{x}\| = 1$ .
2. Démontrer que la fonction  $f(\mathbf{x})$  peut s’écrire sous la forme  $f(\mathbf{x}) = \langle \mathbf{x}, M\mathbf{x} \rangle$  pour une certaine application linéaire symétrique  $M : E \rightarrow E$  que l’on explicitera. Préciser la nature de  $M$  (positive, définie positive, etc.).
3. Justifier l’existence d’un maximum pour  $f(\mathbf{x})$  sur la sphère unité  $S^{n-1} = \{\mathbf{x} \in E \mid \|\mathbf{x}\| = 1\}$ .
4. Déterminer la valeur maximale de  $f(\mathbf{x})$  et caractériser l’ensemble des vecteurs  $\mathbf{x}$  qui atteignent ce maximum.
5. Dans le cas particulier où  $E = \mathbb{R}^2$  muni du produit scalaire canonique, et les vecteurs normalisés sont  $\mathbf{v}_1 = \begin{pmatrix} 1 \\ 0 \end{pmatrix}$ ,  $\mathbf{v}_2 = \begin{pmatrix} \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} \end{pmatrix}$ ,  $\mathbf{v}_3 = \begin{pmatrix} 0 \\ 1 \end{pmatrix}$ , calculer la matrice de  $M$  dans la base canonique et trouver le vecteur  $\mathbf{x}$  optimal (à un signe près).

#### Projection sur les Sous-espaces

Le principe de similarité s’étend naturellement aux projections. Si  $V$  est un sous-espace vectoriel fermé de  $E$ , la projection orthogonale  $P_V(x)$  d’un vecteur  $x$  sur  $V$  minimise la distance  $\|x - y\|$  pour  $y \in V$ . La similarité cosinus permet de quantifier l’angle entre un document et un “sujet” défini par un sous-espace entier, élargissant la recherche sémantique.

## 2.6.2 Correction Détaillée

### Analyse et Stratégie

Le problème nous demande de maximiser une somme de carrés de similarités cosinus. La similarité cosinus entre deux vecteurs  $\mathbf{a}$  et  $\mathbf{b}$  est définie par  $\text{sim}(\mathbf{a}, \mathbf{b}) = \frac{\langle \mathbf{a}, \mathbf{b} \rangle}{\|\mathbf{a}\| \|\mathbf{b}\|}$ . La contrainte  $\|\mathbf{x}\| = 1$  simplifiera considérablement l'expression de la fonction à maximiser.

La première étape consistera à reformuler la fonction objectif en utilisant la définition des vecteurs normalisés  $\mathbf{v}_i$ . Ensuite, nous devons exprimer cette fonction sous la forme d'une forme quadratique  $\langle \mathbf{x}, M\mathbf{x} \rangle$ . Cela implique de construire l'opérateur linéaire symétrique  $M$  à partir des vecteurs  $\mathbf{v}_i$ . La nature de  $M$  (positive, définie positive) sera étudiée en examinant le signe de la forme quadratique associée.

Pour justifier l'existence d'un maximum, nous nous appuierons sur des résultats fondamentaux de l'analyse fonctionnelle sur les espaces euclidiens, notamment le théorème de Weierstrass (ou théorème des bornes atteintes) qui s'applique aux fonctions continues sur des ensembles compacts.

La détermination du maximum et des vecteurs qui l'atteignent relève de la théorie des formes quadratiques et des opérateurs linéaires symétriques. Le problème de la maximisation d'une forme quadratique  $\langle \mathbf{x}, M\mathbf{x} \rangle$  sous la contrainte  $\|\mathbf{x}\| = 1$  est un problème classique de valeurs propres (quotient de Rayleigh). Le maximum sera la plus grande valeur propre de  $M$ , et les vecteurs optimaux seront les vecteurs propres associés à cette valeur propre maximale, normalisés.

Enfin, la dernière partie est une application concrète de la théorie développée, nécessitant le calcul explicite de la matrice  $M$  et de ses éléments propres dans un cas bidimensionnel.

### Résolution Pas-à-Pas

**1. Reformulation du problème** Le problème consiste à maximiser la fonction  $g(\mathbf{x}) = \sum_{i=1}^k \left( \frac{\langle \mathbf{x}, \mathbf{u}_i \rangle}{\|\mathbf{x}\| \|\mathbf{u}_i\|} \right)^2$  sous la contrainte  $\|\mathbf{x}\| = 1$ . Puisque  $\|\mathbf{x}\| = 1$ , l'expression de la similarité cosinus au carré se simplifie :

$$\left( \frac{\langle \mathbf{x}, \mathbf{u}_i \rangle}{\|\mathbf{x}\| \|\mathbf{u}_i\|} \right)^2 = \frac{\langle \mathbf{x}, \mathbf{u}_i \rangle^2}{\|\mathbf{x}\|^2 \|\mathbf{u}_i\|^2} = \frac{\langle \mathbf{x}, \mathbf{u}_i \rangle^2}{1 \cdot \|\mathbf{u}_i\|^2} = \left\langle \mathbf{x}, \frac{\mathbf{u}_i}{\|\mathbf{u}_i\|} \right\rangle^2$$

En utilisant la définition  $\mathbf{v}_i = \frac{\mathbf{u}_i}{\|\mathbf{u}_i\|}$ , qui sont des vecteurs de norme unité, l'expression devient :

$$\langle \mathbf{x}, \mathbf{v}_i \rangle^2$$

Par conséquent, la fonction à maximiser sous la contrainte  $\|\mathbf{x}\| = 1$  est bien :

$$f(\mathbf{x}) = \sum_{i=1}^k \langle \mathbf{x}, \mathbf{v}_i \rangle^2$$

**2. Expression sous forme quadratique et propriétés de  $M$**  Soit  $(\mathbf{e}_1, \dots, \mathbf{e}_n)$  une base orthonormée de  $E$ . Tout vecteur  $\mathbf{x} \in E$  peut s'écrire  $\mathbf{x} = \sum_{j=1}^n x_j \mathbf{e}_j$ , où  $x_j = \langle \mathbf{x}, \mathbf{e}_j \rangle$ . De même, chaque  $\mathbf{v}_i$  peut s'écrire  $\mathbf{v}_i = \sum_{j=1}^n v_{ij} \mathbf{e}_j$ , où  $v_{ij} = \langle \mathbf{v}_i, \mathbf{e}_j \rangle$ . Le produit scalaire  $\langle \mathbf{x}, \mathbf{v}_i \rangle$  s'écrit alors :

$$\langle \mathbf{x}, \mathbf{v}_i \rangle = \left\langle \sum_{j=1}^n x_j \mathbf{e}_j, \sum_{l=1}^n v_{il} \mathbf{e}_l \right\rangle = \sum_{j=1}^n \sum_{l=1}^n x_j v_{il} \langle \mathbf{e}_j, \mathbf{e}_l \rangle = \sum_{j=1}^n x_j v_{ij}$$

Le carré de ce produit scalaire est :

$$\langle \mathbf{x}, \mathbf{v}_i \rangle^2 = \left( \sum_{j=1}^n x_j v_{ij} \right) \left( \sum_{l=1}^n x_l v_{il} \right) = \sum_{j=1}^n \sum_{l=1}^n x_j x_l v_{ij} v_{il}$$

En sommant sur  $i$  de 1 à  $k$ , nous obtenons :

$$f(\mathbf{x}) = \sum_{i=1}^k \sum_{j=1}^n \sum_{l=1}^n x_j x_l v_{ij} v_{il} = \sum_{j=1}^n \sum_{l=1}^n \left( \sum_{i=1}^k v_{ij} v_{il} \right) x_j x_l$$

Cette expression est une forme quadratique. On peut l'écrire sous la forme  $\langle \mathbf{x}, M\mathbf{x} \rangle$ , où  $M$  est une application linéaire de  $E$  dans  $E$ . Dans la base orthonormée  $(\mathbf{e}_1, \dots, \mathbf{e}_n)$ , la matrice associée à  $M$ , notée  $[M]$ , a pour coefficients  $M_{jl}$  :

$$M_{jl} = \sum_{i=1}^k v_{ij} v_{il}$$

On peut également exprimer  $M$  de manière plus abstraite. Pour tout  $\mathbf{y} \in E$ , l'opérateur  $M$  est défini par :

$$M\mathbf{y} = \sum_{i=1}^k \langle \mathbf{y}, \mathbf{v}_i \rangle \mathbf{v}_i$$

Vérifions que  $f(\mathbf{x}) = \langle \mathbf{x}, M\mathbf{x} \rangle$  avec cette définition de  $M$  :

$$\langle \mathbf{x}, M\mathbf{x} \rangle = \left\langle \mathbf{x}, \sum_{i=1}^k \langle \mathbf{x}, \mathbf{v}_i \rangle \mathbf{v}_i \right\rangle = \sum_{i=1}^k \langle \mathbf{x}, \langle \mathbf{x}, \mathbf{v}_i \rangle \mathbf{v}_i \rangle$$

Par linéarité du produit scalaire par rapport au second argument, on a  $\langle \mathbf{x}, c\mathbf{y} \rangle = c\langle \mathbf{x}, \mathbf{y} \rangle$ . Donc :

$$\langle \mathbf{x}, M\mathbf{x} \rangle = \sum_{i=1}^k \langle \mathbf{x}, \mathbf{v}_i \rangle \langle \mathbf{x}, \mathbf{v}_i \rangle = \sum_{i=1}^k \langle \mathbf{x}, \mathbf{v}_i \rangle^2 = f(\mathbf{x})$$

L'application linéaire  $M$  est donc bien définie par  $M\mathbf{y} = \sum_{i=1}^k \langle \mathbf{y}, \mathbf{v}_i \rangle \mathbf{v}_i$ .

**Nature de  $M$  : 1. Symétrie :** Pour montrer que  $M$  est symétrique, nous devons vérifier que  $\langle M\mathbf{y}, \mathbf{z} \rangle = \langle \mathbf{y}, M\mathbf{z} \rangle$  pour tous  $\mathbf{y}, \mathbf{z} \in E$ .

$$\begin{aligned} \langle M\mathbf{y}, \mathbf{z} \rangle &= \left\langle \sum_{i=1}^k \langle \mathbf{y}, \mathbf{v}_i \rangle \mathbf{v}_i, \mathbf{z} \right\rangle = \sum_{i=1}^k \langle \mathbf{y}, \mathbf{v}_i \rangle \langle \mathbf{v}_i, \mathbf{z} \rangle \\ \langle \mathbf{y}, M\mathbf{z} \rangle &= \left\langle \mathbf{y}, \sum_{i=1}^k \langle \mathbf{z}, \mathbf{v}_i \rangle \mathbf{v}_i \right\rangle = \sum_{i=1}^k \langle \mathbf{z}, \mathbf{v}_i \rangle \langle \mathbf{y}, \mathbf{v}_i \rangle \end{aligned}$$

Puisque  $\langle \mathbf{v}_i, \mathbf{z} \rangle = \langle \mathbf{z}, \mathbf{v}_i \rangle$  (symétrie du produit scalaire), on a bien  $\langle M\mathbf{y}, \mathbf{z} \rangle = \langle \mathbf{y}, M\mathbf{z} \rangle$ . Donc  $M$  est un opérateur symétrique.

2. **Positivité :** Un opérateur symétrique  $M$  est dit positif si  $\langle \mathbf{x}, M\mathbf{x} \rangle \geq 0$  pour tout  $\mathbf{x} \in E$ . Nous avons montré que  $\langle \mathbf{x}, M\mathbf{x} \rangle = f(\mathbf{x}) = \sum_{i=1}^k \langle \mathbf{x}, \mathbf{v}_i \rangle^2$ . Puisque  $\langle \mathbf{x}, \mathbf{v}_i \rangle^2 \geq 0$  pour chaque  $i$ , la somme est également non négative :

$$\langle \mathbf{x}, M\mathbf{x} \rangle \geq 0 \quad \text{pour tout } \mathbf{x} \in E$$

Donc  $M$  est un opérateur symétrique positif.

3. **Défini positif :** Un opérateur symétrique  $M$  est dit défini positif si  $\langle \mathbf{x}, M\mathbf{x} \rangle > 0$  pour tout  $\mathbf{x} \neq \mathbf{0}$ . Dans notre cas,  $\langle \mathbf{x}, M\mathbf{x} \rangle = 0$  si et seulement si  $\sum_{i=1}^k \langle \mathbf{x}, \mathbf{v}_i \rangle^2 = 0$ . Cela implique que  $\langle \mathbf{x}, \mathbf{v}_i \rangle = 0$  pour tout  $i \in \{1, \dots, k\}$ . Ceci signifie que  $\mathbf{x}$  est orthogonal à tous les vecteurs  $\mathbf{v}_i$ . Si les vecteurs  $\mathbf{v}_1, \dots, \mathbf{v}_k$  engendrent tout l'espace  $E$  (c'est-à-dire si  $\text{span}(\mathbf{v}_1, \dots, \mathbf{v}_k) = E$ ), alors le seul vecteur orthogonal à tous les  $\mathbf{v}_i$  est le vecteur nul  $\mathbf{0}$ . Dans ce cas,  $M$  serait défini positif. Cependant, si  $\text{span}(\mathbf{v}_1, \dots, \mathbf{v}_k) \neq E$ , alors il existe des vecteurs non nuls  $\mathbf{x}$  qui sont orthogonaux à tous les  $\mathbf{v}_i$ . Pour de tels vecteurs,  $\langle \mathbf{x}, M\mathbf{x} \rangle = 0$ . Par conséquent,  $M$  n'est pas nécessairement défini positif ; il est seulement positif.



**3. Justification de l'existence d'un maximum** La fonction  $f(\mathbf{x}) = \sum_{i=1}^k \langle \mathbf{x}, \mathbf{v}_i \rangle^2$  est une fonction polynomiale des coordonnées de  $\mathbf{x}$  dans n'importe quelle base orthonormée de  $E$ . Les fonctions polynomiales sont continues sur  $E$ . L'ensemble de contrainte est la sphère unité  $S^{n-1} = \{\mathbf{x} \in E \mid \|\mathbf{x}\| = 1\}$ . Dans un espace euclidien de dimension finie  $E$ , la sphère unité  $S^{n-1}$  est un ensemble fermé et borné. Par le théorème de Heine-Borel, tout ensemble fermé et borné dans un espace euclidien de dimension finie est compact. Donc  $S^{n-1}$  est un ensemble compact. Le théorème de Weierstrass (ou théorème des bornes atteintes) stipule que toute fonction continue sur un ensemble compact atteint son maximum et son minimum sur cet ensemble. Puisque  $f(\mathbf{x})$  est continue et  $S^{n-1}$  est compact, il existe au moins un vecteur  $\mathbf{x}_0 \in S^{n-1}$  tel que  $f(\mathbf{x}_0)$  est la valeur maximale de  $f$  sur  $S^{n-1}$ .

**4. Détermination de la valeur maximale et des vecteurs optimaux** Nous cherchons à maximiser  $f(\mathbf{x}) = \langle \mathbf{x}, M\mathbf{x} \rangle$  sous la contrainte  $\|\mathbf{x}\| = 1$ . Ceci est un problème classique de valeurs propres. Puisque  $M$  est un opérateur symétrique sur un espace euclidien de dimension finie, il existe une base orthonormée de  $E$  constituée de vecteurs propres de  $M$ . Soient  $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_n$  les valeurs propres de  $M$ , ordonnées par ordre décroissant. Pour tout  $\mathbf{x} \in S^{n-1}$ , on peut écrire  $\mathbf{x} = \sum_{j=1}^n c_j \mathbf{e}_j$ , où  $(\mathbf{e}_1, \dots, \mathbf{e}_n)$  est une base orthonormée de vecteurs propres de  $M$  correspondant aux valeurs propres  $\lambda_1, \dots, \lambda_n$ . Puisque  $\|\mathbf{x}\| = 1$ , nous avons  $\sum_{j=1}^n c_j^2 = 1$ . Alors :

$$\langle \mathbf{x}, M\mathbf{x} \rangle = \left\langle \sum_{j=1}^n c_j \mathbf{e}_j, M \left( \sum_{l=1}^n c_l \mathbf{e}_l \right) \right\rangle = \left\langle \sum_{j=1}^n c_j \mathbf{e}_j, \sum_{l=1}^n c_l \lambda_l \mathbf{e}_l \right\rangle$$

En utilisant l'orthonormalité de la base de vecteurs propres :

$$\langle \mathbf{x}, M\mathbf{x} \rangle = \sum_{j=1}^n c_j^2 \lambda_j$$

Puisque  $\lambda_1$  est la plus grande valeur propre, nous avons  $\lambda_j \leq \lambda_1$  pour tout  $j$ .

$$\sum_{j=1}^n c_j^2 \lambda_j \leq \sum_{j=1}^n c_j^2 \lambda_1 = \lambda_1 \sum_{j=1}^n c_j^2 = \lambda_1 \cdot 1 = \lambda_1$$

Ainsi, la valeur maximale de  $f(\mathbf{x})$  est  $\lambda_1$ , la plus grande valeur propre de  $M$ .

Les vecteurs  $\mathbf{x}$  qui atteignent ce maximum sont ceux pour lesquels l'inégalité  $\sum_{j=1}^n c_j^2 \lambda_j \leq \lambda_1$  devient une égalité. Cela se produit si et seulement si  $c_j^2 \lambda_j = c_j^2 \lambda_1$  pour tous les  $j$ . Si  $\lambda_j < \lambda_1$ , alors il faut que  $c_j = 0$ . Cela signifie que  $\mathbf{x}$  doit être une combinaison linéaire des vecteurs propres associés à la valeur propre  $\lambda_1$ . L'ensemble des vecteurs  $\mathbf{x}$  qui atteignent ce maximum est l'espace propre  $E_{\lambda_1}$  associé à la plus grande valeur propre  $\lambda_1$ , intersecté avec la sphère unité  $S^{n-1}$ . Autrement dit, ce sont les vecteurs propres de  $M$  associés à la plus grande valeur propre  $\lambda_1$ , normalisés à l'unité.

**5. Cas particulier dans  $\mathbb{R}^2$**  Dans  $E = \mathbb{R}^2$  muni du produit scalaire canonique, la base canonique est  $(\mathbf{e}_1, \mathbf{e}_2)$  où  $\mathbf{e}_1 = \begin{pmatrix} 1 \\ 0 \end{pmatrix}$  et  $\mathbf{e}_2 = \begin{pmatrix} 0 \\ 1 \end{pmatrix}$ . Les vecteurs normalisés sont donnés par :

$$\mathbf{v}_1 = \begin{pmatrix} 1 \\ 0 \end{pmatrix} \quad \mathbf{v}_2 = \begin{pmatrix} \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} \end{pmatrix} \quad \mathbf{v}_3 = \begin{pmatrix} 0 \\ 1 \end{pmatrix}$$

La matrice  $M$  est donnée par  $M = \sum_{i=1}^3 \mathbf{v}_i \mathbf{v}_i^T$ . Calculons chaque terme  $\mathbf{v}_i \mathbf{v}_i^T$  : Pour  $\mathbf{v}_1$  :

$$\mathbf{v}_1 \mathbf{v}_1^T = \begin{pmatrix} 1 \\ 0 \end{pmatrix} \begin{pmatrix} 1 & 0 \end{pmatrix} = \begin{pmatrix} 1 & 0 \\ 0 & 0 \end{pmatrix}$$

Pour  $\mathbf{v}_2$  :

$$\mathbf{v}_2 \mathbf{v}_2^T = \begin{pmatrix} \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} \end{pmatrix} \begin{pmatrix} \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \end{pmatrix} = \begin{pmatrix} \frac{1}{2} & \frac{1}{2} \\ \frac{1}{2} & \frac{1}{2} \end{pmatrix}$$

Pour  $\mathbf{v}_3$  :

$$\mathbf{v}_3 \mathbf{v}_3^T = \begin{pmatrix} 0 \\ 1 \end{pmatrix} \begin{pmatrix} 0 & 1 \end{pmatrix} = \begin{pmatrix} 0 & 0 \\ 0 & 1 \end{pmatrix}$$

Maintenant, nous sommes ces matrices pour obtenir  $M$  :

$$M = \begin{pmatrix} 1 & 0 \\ 0 & 0 \end{pmatrix} + \begin{pmatrix} \frac{1}{2} & \frac{1}{2} \\ \frac{1}{2} & \frac{1}{2} \end{pmatrix} + \begin{pmatrix} 0 & 0 \\ 0 & 1 \end{pmatrix} = \begin{pmatrix} 1 + \frac{1}{2} + 0 & 0 + \frac{1}{2} + 0 \\ 0 + \frac{1}{2} + 0 & 0 + \frac{1}{2} + 1 \end{pmatrix} = \begin{pmatrix} \frac{3}{2} & \frac{1}{2} \\ \frac{1}{2} & \frac{3}{2} \end{pmatrix}$$

La matrice  $M$  est  $\begin{pmatrix} \frac{3}{2} & \frac{1}{2} \\ \frac{1}{2} & \frac{3}{2} \end{pmatrix}$ .

Pour trouver le vecteur  $\mathbf{x}$  optimal, nous devons trouver la plus grande valeur propre de  $M$  et son vecteur propre associé. Le polynôme caractéristique de  $M$  est  $\det(M - \lambda I)$  :

$$\begin{aligned} \det \begin{pmatrix} \frac{3}{2} - \lambda & \frac{1}{2} \\ \frac{1}{2} & \frac{3}{2} - \lambda \end{pmatrix} &= \left( \frac{3}{2} - \lambda \right)^2 - \left( \frac{1}{2} \right)^2 \\ &= \left( \frac{3}{2} - \lambda - \frac{1}{2} \right) \left( \frac{3}{2} - \lambda + \frac{1}{2} \right) = (1 - \lambda)(2 - \lambda) \end{aligned}$$

Les valeurs propres sont  $\lambda_1 = 2$  et  $\lambda_2 = 1$ . La plus grande valeur propre est  $\lambda_1 = 2$ .

Cherchons le vecteur propre associé à  $\lambda_1 = 2$  :

$$(M - 2I)\mathbf{x} = \mathbf{0}$$

$$\begin{pmatrix} \frac{3}{2} - 2 & \frac{1}{2} \\ \frac{1}{2} & \frac{3}{2} - 2 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$$

$$\begin{pmatrix} -\frac{1}{2} & \frac{1}{2} \\ \frac{1}{2} & -\frac{1}{2} \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$$

Cela conduit au système d'équations :

$$-\frac{1}{2}x_1 + \frac{1}{2}x_2 = 0 \implies x_1 = x_2$$

$$\frac{1}{2}x_1 - \frac{1}{2}x_2 = 0 \implies x_1 = x_2$$

Les vecteurs propres associés à  $\lambda_1 = 2$  sont de la forme  $\begin{pmatrix} c \\ c \end{pmatrix}$  pour  $c \neq 0$ . Pour que le vecteur  $\mathbf{x}$  soit de norme unité, nous devons avoir  $\|\mathbf{x}\| = 1$  :

$$\left\| \begin{pmatrix} c \\ c \end{pmatrix} \right\|^2 = c^2 + c^2 = 2c^2 = 1 \implies c^2 = \frac{1}{2} \implies c = \pm \frac{1}{\sqrt{2}}$$

Donc, les vecteurs optimaux sont  $\mathbf{x} = \begin{pmatrix} \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} \end{pmatrix}$  et  $\mathbf{x} = \begin{pmatrix} -\frac{1}{\sqrt{2}} \\ -\frac{1}{\sqrt{2}} \end{pmatrix}$ . Le vecteur  $\mathbf{x}$  optimal (à un signe près) est  $\begin{pmatrix} \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} \end{pmatrix}$ .

## Conclusion

Le problème de la maximisation de la somme des carrés des similarités cosinus d'un vecteur de norme unité  $\mathbf{x}$  avec un ensemble de vecteurs sémantiques normalisés  $\mathbf{v}_i$  se ramène à la maximisation d'une forme quadratique  $f(\mathbf{x}) = \langle \mathbf{x}, M\mathbf{x} \rangle$  sur la sphère unité. L'opérateur  $M = \sum_{i=1}^k \mathbf{v}_i \mathbf{v}_i^T$  est un opérateur linéaire symétrique et positif.

L'existence d'un maximum est garantie par la continuité de  $f$  sur la sphère unité compacte. La valeur maximale de  $f(\mathbf{x})$  est la plus grande valeur propre de  $M$ , et les vecteurs  $\mathbf{x}$  qui atteignent ce maximum sont les vecteurs propres de  $M$  associés à cette plus grande valeur propre, normalisés à l'unité.

Dans le cas particulier de  $\mathbb{R}^2$  avec les vecteurs  $\mathbf{v}_1 = \begin{pmatrix} 1 \\ 0 \end{pmatrix}$ ,  $\mathbf{v}_2 = \begin{pmatrix} \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} \end{pmatrix}$ ,  $\mathbf{v}_3 = \begin{pmatrix} 0 \\ 1 \end{pmatrix}$ , la matrice  $M$  est  $\begin{pmatrix} \frac{3}{2} & \frac{1}{2} \\ \frac{1}{2} & \frac{3}{2} \end{pmatrix}$ . La plus grande valeur propre de  $M$  est  $\lambda_1 = 2$ . Le vecteur optimal (à un signe près) est le vecteur propre normalisé associé à  $\lambda_1 = 2$ , qui est  $\mathbf{x} = \begin{pmatrix} \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} \end{pmatrix}$ . Ce vecteur représente la direction qui maximise la "représentativité sémantique" par rapport aux ancrés données.

## Exercice 7

### 2.7 Exercice 07 (4 ★) : Optimisation de la Similarité Cosinus par Formes Linéaires Duales

#### 2.7.1 Énoncé

Soit  $(V, \langle \cdot, \cdot \rangle)$  un espace vectoriel euclidien de dimension finie  $n \geq 2$  sur  $\mathbb{R}$ . On note  $\| \cdot \|$  la norme associée à ce produit scalaire, définie par  $\|v\| = \sqrt{\langle v, v \rangle}$  pour tout  $v \in V$ . Soit  $V^*$  son espace dual, c'est-à-dire l'ensemble des formes linéaires de  $V$  dans  $\mathbb{R}$ .

1. Rappeler la définition de la similarité cosinus entre deux vecteurs non nuls  $u, v \in V$ .
2. Démontrer que l'application  $\Phi : V \rightarrow V^*$  définie par  $\Phi(v)(x) = \langle v, x \rangle$  pour tout  $v, x \in V$  est un isomorphisme linéaire.
3. Montrer que l'espace dual  $V^*$  peut être muni d'un produit scalaire  $\langle \cdot, \cdot \rangle_{V^*}$  tel que pour tout  $f, g \in V^*$ , si  $f = \Phi(u)$  et  $g = \Phi(v)$  pour  $u, v \in V$ , alors  $\langle f, g \rangle_{V^*} = \langle u, v \rangle$ . En déduire la norme associée  $\| \cdot \|_{V^*}$  sur  $V^*$ .
4. Soient  $q \in V$  et  $d \in V$  deux vecteurs non nuls et linéairement indépendants. On considère le problème d'optimisation suivant :

Maximiser  $f(q)$  sous les contraintes  $f \in V^*$ ,  $f(d) = 0$  et  $\|f\|_{V^*} = 1$ .

On note  $f_0$  une forme linéaire solution de ce problème.

- a. Justifier l'existence d'une solution  $f_0$ .
- b. Déterminer explicitement  $f_0$  en fonction de  $q$  et  $d$ .
- c. Calculer la valeur maximale  $f_0(q)$ .
- d. Interpréter géométriquement la forme linéaire  $f_0$  et la valeur maximale  $f_0(q)$  en relation avec la similarité cosinus.

## Complétude et Espace de Hilbert

L'utilisation de la similarité cosinus s'appuie implicitement sur le fait que  $\mathbb{R}^d$  est un espace de Hilbert. Bien que la dimension soit finie, la complétude de l'espace nous garantit que les suites

de Cauchy de vecteurs de plongement, générées par des algorithmes d'optimisation stochastique, convergent vers une limite bien définie dans l'espace.

## 2.7.2 Correction Détaillée

### Analyse et Stratégie

L'exercice explore la relation fondamentale entre la géométrie d'un espace euclidien de dimension finie, la notion de similarité cosinus, et la structure de son espace dual. La première partie de l'exercice vise à établir les fondations théoriques nécessaires : la définition de la similarité cosinus, la démonstration rigoureuse du théorème de représentation de Riesz (qui établit un isomorphisme canonique entre  $V$  et  $V^*$ ), et la construction du produit scalaire et de la norme induits sur l'espace dual  $V^*$ . Ces étapes sont cruciales pour poser un cadre mathématique solide pour le problème d'optimisation.

La deuxième partie de l'exercice est un problème d'optimisation sous contraintes. La stratégie principale pour le résoudre consistera à traduire ce problème, initialement formulé dans l'espace dual  $V^*$ , vers l'espace vectoriel d'origine  $V$  grâce à l'isomorphisme de Riesz. La contrainte  $f(d) = 0$  se transformera en une condition d'orthogonalité dans  $V$ . La contrainte de normalisation  $\|f\|_{V^*} = 1$  se traduira par une contrainte de normalisation de la norme dans  $V$ . Enfin, la fonction objectif  $f(q)$  se reformulera comme un produit scalaire dans  $V$ . Une fois le problème entièrement reformulé dans  $V$ , il deviendra un problème classique de maximisation d'un produit scalaire sous des contraintes d'orthogonalité et de norme, qui se résout typiquement par l'utilisation de projections orthogonales. L'interprétation géométrique finale permettra de relier la solution obtenue au concept de similarité cosinus et de comprendre sa pertinence dans un contexte de recherche sémantique, où l'on cherche à caractériser des aspects distincts ou pertinents d'une requête par rapport à des documents.

### Résolution Pas-à-Pas

1. **Définition de la similarité cosinus** Soient  $u, v \in V$  deux vecteurs non nuls. La similarité cosinus entre  $u$  et  $v$  est définie par le rapport du produit scalaire de  $u$  et  $v$  à la produit de leurs normes :

$$\text{sim}(u, v) = \frac{\langle u, v \rangle}{\|u\| \|v\|}$$

Cette valeur représente le cosinus de l'angle  $\theta$  entre les vecteurs  $u$  et  $v$ , où  $\theta \in [0, \pi]$ . Par l'inégalité de Cauchy-Schwarz, nous savons que  $|\langle u, v \rangle| \leq \|u\| \|v\|$ , ce qui implique que  $-1 \leq \text{sim}(u, v) \leq 1$ .

2. **Isomorphisme de Riesz** Démontrons que l'application  $\Phi : V \rightarrow V^*$  définie par  $\Phi(v)(x) = \langle v, x \rangle$  pour tout  $v, x \in V$  est un isomorphisme linéaire.
  - **Linéarité de  $\Phi$**  : Pour montrer que  $\Phi$  est linéaire, nous devons vérifier deux propriétés :

- a.  $\Phi(v_1 + v_2) = \Phi(v_1) + \Phi(v_2)$  pour tout  $v_1, v_2 \in V$ .
- b.  $\Phi(\lambda v_1) = \lambda \Phi(v_1)$  pour tout  $v_1 \in V$  et  $\lambda \in \mathbb{R}$ .

Pour la propriété (a), évaluons  $\Phi(v_1 + v_2)$  sur un vecteur arbitraire  $x \in V$  :

$$\Phi(v_1 + v_2)(x) = \langle v_1 + v_2, x \rangle$$

Par la bilinéarité du produit scalaire, nous avons :

$$\langle v_1 + v_2, x \rangle = \langle v_1, x \rangle + \langle v_2, x \rangle$$

Par la définition de  $\Phi$ , ceci est égal à :

$$\langle v_1, x \rangle + \langle v_2, x \rangle = \Phi(v_1)(x) + \Phi(v_2)(x)$$

Par la définition de l'addition de formes linéaires, nous avons :

$$\Phi(v_1)(x) + \Phi(v_2)(x) = (\Phi(v_1) + \Phi(v_2))(x)$$

Puisque cette égalité est vraie pour tout  $x \in V$ , nous avons  $\Phi(v_1 + v_2) = \Phi(v_1) + \Phi(v_2)$ .

Pour la propriété (b), évaluons  $\Phi(\lambda v_1)$  sur un vecteur arbitraire  $x \in V$  :

$$\Phi(\lambda v_1)(x) = \langle \lambda v_1, x \rangle$$

Par la bilinéarité du produit scalaire, nous avons :

$$\langle \lambda v_1, x \rangle = \lambda \langle v_1, x \rangle$$

Par la définition de  $\Phi$ , ceci est égal à :

$$\lambda \langle v_1, x \rangle = \lambda \Phi(v_1)(x)$$

Par la définition de la multiplication d'une forme linéaire par un scalaire, nous avons :

$$\lambda \Phi(v_1)(x) = (\lambda \Phi(v_1))(x)$$

Puisque cette égalité est vraie pour tout  $x \in V$ , nous avons  $\Phi(\lambda v_1) = \lambda \Phi(v_1)$ . Ainsi,  $\Phi$  est une application linéaire.

- **Injectivité de  $\Phi$**  : Pour montrer que  $\Phi$  est injective, nous devons montrer que son noyau est réduit au vecteur nul. C'est-à-dire, si  $\Phi(v) = 0_{V^*}$  (la forme linéaire nulle), alors  $v = 0_V$ . Si  $\Phi(v) = 0_{V^*}$ , cela signifie que pour tout  $x \in V$ ,  $\Phi(v)(x) = 0$ . Par la définition de  $\Phi$ , cela implique que  $\langle v, x \rangle = 0$  pour tout  $x \in V$ . En particulier, en choisissant  $x = v$ , nous obtenons  $\langle v, v \rangle = 0$ . Puisque le produit scalaire est défini positif,  $\langle v, v \rangle = 0$  implique que  $v = 0_V$ . Donc,  $\text{Ker}(\Phi) = \{0_V\}$ , ce qui prouve que  $\Phi$  est injective.
- **Surjectivité de  $\Phi$**  : Puisque  $V$  est un espace vectoriel de dimension finie  $n$ , son espace dual  $V^*$  a également pour dimension  $n$ . Nous avons  $\dim(V) = n$  et  $\dim(V^*) = n$ . Puisque  $\Phi : V \rightarrow V^*$  est une application linéaire injective entre deux espaces de même dimension finie, elle est nécessairement surjective. Pour être exhaustif, le théorème de représentation de Riesz pour les espaces euclidiens affirme que pour toute forme linéaire  $f \in V^*$ , il existe un unique vecteur  $v \in V$  tel que  $f(x) = \langle v, x \rangle$  pour tout  $x \in V$ . Pour prouver ce théorème, soit  $(e_1, \dots, e_n)$  une base orthonormée de  $V$ . Pour tout  $x \in V$ ,  $x = \sum_{i=1}^n \langle x, e_i \rangle e_i$ . Alors, pour toute forme linéaire  $f \in V^*$ ,  $f(x) = f(\sum_{i=1}^n \langle x, e_i \rangle e_i)$ . Par linéarité de  $f$ ,  $f(x) = \sum_{i=1}^n \langle x, e_i \rangle f(e_i)$ . Soit  $v = \sum_{i=1}^n f(e_i) e_i$ . Alors, en utilisant la bilinéarité du produit scalaire et l'orthonormalité de la base :

$$\langle v, x \rangle = \left\langle \sum_{i=1}^n f(e_i) e_i, x \right\rangle = \sum_{i=1}^n f(e_i) \langle e_i, x \rangle$$

Puisque  $\langle e_i, x \rangle = \langle x, e_i \rangle$  (symétrie du produit scalaire), nous avons :

$$\langle v, x \rangle = \sum_{i=1}^n f(e_i) \langle x, e_i \rangle = f(x)$$

Ainsi, pour tout  $f \in V^*$ , il existe un  $v \in V$  tel que  $f = \Phi(v)$ , ce qui prouve la surjectivité.

En conclusion,  $\Phi$  est un isomorphisme linéaire.

3. **Produit scalaire et norme sur  $V^*$**  Nous voulons munir  $V^*$  d'un produit scalaire  $\langle \cdot, \cdot \rangle_{V^*}$  tel que pour tout  $f, g \in V^*$ , si  $f = \Phi(u)$  et  $g = \Phi(v)$  pour  $u, v \in V$ , alors  $\langle f, g \rangle_{V^*} = \langle u, v \rangle$ .

Puisque  $\Phi$  est un isomorphisme, pour tout  $f \in V^*$ , il existe un unique  $u \in V$  tel que  $f = \Phi(u)$ , ce qui signifie  $u = \Phi^{-1}(f)$ . De même pour  $g \in V^*$ , il existe un unique  $v \in V$  tel que  $g = \Phi(v)$ , ce qui signifie  $v = \Phi^{-1}(g)$ . Nous pouvons donc définir l'application  $\langle \cdot, \cdot \rangle_{V^*} : V^* \times V^* \rightarrow \mathbb{R}$  par :

$$\langle f, g \rangle_{V^*} = \langle \Phi^{-1}(f), \Phi^{-1}(g) \rangle$$

Vérifions que cette application est bien un produit scalaire sur  $V^*$ .

— **Symétrie** : Pour tout  $f, g \in V^*$ ,

$$\langle f, g \rangle_{V^*} = \langle \Phi^{-1}(f), \Phi^{-1}(g) \rangle$$

Puisque  $\langle \cdot, \cdot \rangle$  est symétrique sur  $V$ , nous avons  $\langle \Phi^{-1}(f), \Phi^{-1}(g) \rangle = \langle \Phi^{-1}(g), \Phi^{-1}(f) \rangle$ . Donc,  $\langle f, g \rangle_{V^*} = \langle g, f \rangle_{V^*}$ .

— **Linéarité par rapport à la première variable** : Soient  $f_1, f_2, g \in V^*$  et  $\lambda \in \mathbb{R}$ .

$$\langle f_1 + f_2, g \rangle_{V^*} = \langle \Phi^{-1}(f_1 + f_2), \Phi^{-1}(g) \rangle$$

Puisque  $\Phi$  est linéaire, son inverse  $\Phi^{-1}$  est également linéaire. Donc  $\Phi^{-1}(f_1 + f_2) = \Phi^{-1}(f_1) + \Phi^{-1}(f_2)$ . Ainsi,

$$\langle f_1 + f_2, g \rangle_{V^*} = \langle \Phi^{-1}(f_1) + \Phi^{-1}(f_2), \Phi^{-1}(g) \rangle$$

Par la linéarité du produit scalaire sur  $V$  par rapport à la première variable :

$$\langle \Phi^{-1}(f_1) + \Phi^{-1}(f_2), \Phi^{-1}(g) \rangle = \langle \Phi^{-1}(f_1), \Phi^{-1}(g) \rangle + \langle \Phi^{-1}(f_2), \Phi^{-1}(g) \rangle$$

Par la définition de  $\langle \cdot, \cdot \rangle_{V^*}$ , ceci est égal à  $\langle f_1, g \rangle_{V^*} + \langle f_2, g \rangle_{V^*}$ . De même,

$$\langle \lambda f_1, g \rangle_{V^*} = \langle \Phi^{-1}(\lambda f_1), \Phi^{-1}(g) \rangle = \langle \lambda \Phi^{-1}(f_1), \Phi^{-1}(g) \rangle = \lambda \langle \Phi^{-1}(f_1), \Phi^{-1}(g) \rangle = \lambda \langle f_1, g \rangle_{V^*}$$

Donc,  $\langle \cdot, \cdot \rangle_{V^*}$  est linéaire par rapport à la première variable.

— **Définition positive** : Pour tout  $f \in V^*$ ,

$$\langle f, f \rangle_{V^*} = \langle \Phi^{-1}(f), \Phi^{-1}(f) \rangle$$

Puisque  $\langle \cdot, \cdot \rangle$  est défini positif sur  $V$ ,  $\langle \Phi^{-1}(f), \Phi^{-1}(f) \rangle \geq 0$ . De plus,  $\langle f, f \rangle_{V^*} = 0$  si et seulement si  $\langle \Phi^{-1}(f), \Phi^{-1}(f) \rangle = 0$ . Ceci implique  $\Phi^{-1}(f) = 0_V$  (par la propriété de définition positive du produit scalaire sur  $V$ ). Puisque  $\Phi^{-1}$  est un isomorphisme,  $\Phi^{-1}(f) = 0_V$  si et seulement si  $f = \Phi(0_V) = 0_{V^*}$ . Donc,  $\langle \cdot, \cdot \rangle_{V^*}$  est défini positif.

Ainsi,  $\langle \cdot, \cdot \rangle_{V^*}$  est bien un produit scalaire sur  $V^*$ .

La norme associée  $\| \cdot \|_{V^*}$  sur  $V^*$  est définie par  $\|f\|_{V^*} = \sqrt{\langle f, f \rangle_{V^*}}$ . En utilisant la définition du produit scalaire sur  $V^*$  :

$$\|f\|_{V^*} = \sqrt{\langle \Phi^{-1}(f), \Phi^{-1}(f) \rangle} = \|\Phi^{-1}(f)\|$$

Si  $f = \Phi(u)$ , alors  $\Phi^{-1}(f) = u$ . Donc,  $\|f\|_{V^*} = \|u\|$ . Cette norme est également appelée la norme d'opérateur pour les formes linéaires, car pour  $f \in V^*$ ,  $\|f\|_{V^*} = \sup_{x \in V, x \neq 0} \frac{|f(x)|}{\|x\|}$ . Pour le prouver, soit  $f = \Phi(u)$ . Alors  $f(x) = \langle u, x \rangle$ . Par l'inégalité de Cauchy-Schwarz,  $|f(x)| = |\langle u, x \rangle| \leq \|u\| \|x\|$ . Donc, pour  $x \neq 0$ ,  $\frac{|f(x)|}{\|x\|} \leq \|u\|$ . Cette borne supérieure est atteinte lorsque  $x$  est colinéaire à  $u$ . En prenant  $x = u$  (si  $u \neq 0$ ), on a  $\frac{|f(u)|}{\|u\|} = \frac{|\langle u, u \rangle|}{\|u\|} = \frac{\|u\|^2}{\|u\|} = \|u\|$ . Donc,  $\|f\|_{V^*} = \|u\| = \|\Phi^{-1}(f)\|$ .

4. **Problème d'optimisation** Soient  $q \in V$  et  $d \in V$  deux vecteurs non nuls et linéairement indépendants. On cherche à maximiser  $f(q)$  sous les contraintes  $f \in V^*$ ,  $f(d) = 0$  et  $\|f\|_{V^*} = 1$ .

a. **Justification de l'existence d'une solution**  $f_0$  L'ensemble des formes linéaires  $f \in V^*$  telles que  $\|f\|_{V^*} = 1$  est la sphère unité de  $V^*$ , notée  $S_{V^*} = \{f \in V^* \mid \|f\|_{V^*} = 1\}$ . Puisque  $V^*$  est un espace vectoriel de dimension finie,  $S_{V^*}$  est un ensemble fermé et borné, donc compact dans  $V^*$ . La contrainte  $f(d) = 0$  définit un sous-espace vectoriel de  $V^*$ , appelé l'annihilateur de  $d$ , noté  $(\text{span}\{d\})^\perp$ . C'est un sous-espace fermé de  $V^*$ . L'ensemble des contraintes est donc l'intersection de la sphère unité  $S_{V^*}$  et du sous-espace fermé  $(\text{span}\{d\})^\perp$ . Cette intersection est un ensemble fermé et borné, donc compact. Puisque  $d \neq 0$ ,  $\text{span}\{d\}$  est un sous-espace de dimension 1. Son annihilateur  $(\text{span}\{d\})^\perp$  est un sous-espace de  $V^*$  de dimension  $\dim(V^*) - \dim(\text{span}\{d\}) = n - 1$ . Puisque  $n \geq 2$ ,  $n - 1 \geq 1$ , donc  $(\text{span}\{d\})^\perp$  est non vide et contient des vecteurs non nuls. Par conséquent, l'intersection  $S_{V^*} \cap (\text{span}\{d\})^\perp$  est non vide. La fonction objectif  $J(f) = f(q)$  est une application linéaire de  $V^*$  dans  $\mathbb{R}$ . Toute application linéaire sur un espace de dimension finie est continue. Puisque nous maximisons une fonction continue sur un ensemble compact non vide, le théorème des valeurs extrêmes (théorème de Weierstrass) garantit l'existence d'une solution  $f_0$ .

b. **Détermination explicite de  $f_0$**  Nous allons traduire le problème dans l'espace  $V$  via l'isomorphisme  $\Phi$ . Soit  $f \in V^*$ . Il existe un unique  $v \in V$  tel que  $f = \Phi(v)$ . Les contraintes se traduisent comme suit :

- $f(d) = 0 \implies \Phi(v)(d) = 0 \implies \langle v, d \rangle = 0$ . Cela signifie que le vecteur  $v$  doit appartenir à l'orthogonal de  $d$ , noté  $d^\perp = \{x \in V \mid \langle x, d \rangle = 0\}$ .
- $\|f\|_{V^*} = 1 \implies \|\Phi(v)\|_{V^*} = 1$ . D'après la question 3, cela implique  $\|v\| = 1$ . L'objectif  $f(q)$  se traduit par :
- $f(q) = \Phi(v)(q) = \langle v, q \rangle$ .

Le problème d'optimisation devient donc :

$$\text{Maximiser } \langle v, q \rangle \text{ sous les contraintes } v \in V, v \in d^\perp \text{ et } \|v\| = 1.$$

Nous cherchons un vecteur unitaire  $v_0 \in d^\perp$  qui maximise  $\langle v, q \rangle$ . Soit  $P_{d^\perp}$  l'opérateur de projection orthogonale sur le sous-espace  $d^\perp$ . Pour tout  $v \in d^\perp$ , nous avons  $\langle v, q \rangle = \langle v, P_{d^\perp}(q) \rangle$ . En effet,  $q = P_{d^\perp}(q) + P_{\text{span}\{d\}}(q)$ , et puisque  $v \in d^\perp$ ,  $\langle v, P_{\text{span}\{d\}}(q) \rangle = 0$ . Par l'inégalité de Cauchy-Schwarz,  $|\langle v, P_{d^\perp}(q) \rangle| \leq \|v\| \|P_{d^\perp}(q)\|$ . Puisque  $\|v\| = 1$ , nous avons  $|\langle v, q \rangle| \leq \|P_{d^\perp}(q)\|$ . L'égalité est atteinte lorsque  $v$  est colinéaire à  $P_{d^\perp}(q)$  et dans la même direction. Donc, le vecteur  $v_0$  qui maximise  $\langle v, q \rangle$  doit être :

$$v_0 = \frac{P_{d^\perp}(q)}{\|P_{d^\perp}(q)\|}$$

Il est nécessaire de s'assurer que  $P_{d^\perp}(q) \neq 0_V$ . Le sous-espace  $d^\perp$  est l'orthogonal de la droite vectorielle engendrée par  $d$ . La projection orthogonale de  $q$  sur  $d^\perp$  est donnée par  $P_{d^\perp}(q) = q - P_{\text{span}\{d\}}(q)$ . La projection orthogonale de  $q$  sur  $\text{span}\{d\}$  est  $P_{\text{span}\{d\}}(q) = \frac{\langle q, d \rangle}{\langle d, d \rangle} d = \frac{\langle q, d \rangle}{\|d\|^2} d$ . Donc,  $P_{d^\perp}(q) = q - \frac{\langle q, d \rangle}{\|d\|^2} d$ . Si  $P_{d^\perp}(q) = 0_V$ , alors  $q = \frac{\langle q, d \rangle}{\|d\|^2} d$ . Cela signifie que  $q$  est colinéaire à  $d$ . Cependant, l'énoncé stipule que  $q$  et  $d$  sont linéairement indépendants. Par conséquent,  $P_{d^\perp}(q) \neq 0_V$ . Ainsi, le vecteur  $v_0$  est bien défini.

La forme linéaire  $f_0$  est alors  $\Phi(v_0)$ .

$$f_0 = \Phi \left( \frac{q - \frac{\langle q, d \rangle}{\|d\|^2} d}{\left\| q - \frac{\langle q, d \rangle}{\|d\|^2} d \right\|} \right)$$

Pour tout  $x \in V$ ,  $f_0(x) = \left\langle \frac{q - \frac{\langle q, d \rangle}{\|d\|^2} d}{\left\| q - \frac{\langle q, d \rangle}{\|d\|^2} d \right\|}, x \right\rangle$ .

c. **Calcul de la valeur maximale**  $f_0(q)$  La valeur maximale de  $f(q)$  est  $\langle v_0, q \rangle$ .

$$\langle v_0, q \rangle = \left\langle \frac{P_{d^\perp}(q)}{\|P_{d^\perp}(q)\|}, q \right\rangle$$

Puisque  $P_{d^\perp}(q) \in d^\perp$ , nous avons  $\langle P_{d^\perp}(q), d \rangle = 0$ . De plus, nous pouvons décomposer  $q$  en ses composantes orthogonales par rapport à  $d^\perp$  et  $\text{span}\{d\}$  :  $q = P_{d^\perp}(q) + P_{\text{span}\{d\}}(q)$ . Donc,

$$\langle v_0, q \rangle = \frac{1}{\|P_{d^\perp}(q)\|} \langle P_{d^\perp}(q), P_{d^\perp}(q) + P_{\text{span}\{d\}}(q) \rangle$$

Par l'orthogonalité de  $P_{d^\perp}(q)$  et  $P_{\text{span}\{d\}}(q)$ , nous avons  $\langle P_{d^\perp}(q), P_{\text{span}\{d\}}(q) \rangle = 0$ . Ainsi,

$$\langle v_0, q \rangle = \frac{1}{\|P_{d^\perp}(q)\|} \langle P_{d^\perp}(q), P_{d^\perp}(q) \rangle = \frac{\|P_{d^\perp}(q)\|^2}{\|P_{d^\perp}(q)\|} = \|P_{d^\perp}(q)\|$$

Calculons  $\|P_{d^\perp}(q)\|$  :

$$\|P_{d^\perp}(q)\|^2 = \left\| q - \frac{\langle q, d \rangle}{\|d\|^2} d \right\|^2$$

En développant la norme au carré :

$$\begin{aligned} \|P_{d^\perp}(q)\|^2 &= \left\langle q - \frac{\langle q, d \rangle}{\|d\|^2} d, q - \frac{\langle q, d \rangle}{\|d\|^2} d \right\rangle \\ &= \langle q, q \rangle - 2 \left\langle q, \frac{\langle q, d \rangle}{\|d\|^2} d \right\rangle + \left\langle \frac{\langle q, d \rangle}{\|d\|^2} d, \frac{\langle q, d \rangle}{\|d\|^2} d \right\rangle \\ &= \|q\|^2 - 2 \frac{\langle q, d \rangle}{\|d\|^2} \langle q, d \rangle + \left( \frac{\langle q, d \rangle}{\|d\|^2} \right)^2 \langle d, d \rangle \\ &= \|q\|^2 - 2 \frac{(\langle q, d \rangle)^2}{\|d\|^2} + \frac{(\langle q, d \rangle)^2}{\|d\|^4} \|d\|^2 \\ &= \|q\|^2 - 2 \frac{(\langle q, d \rangle)^2}{\|d\|^2} + \frac{(\langle q, d \rangle)^2}{\|d\|^2} \\ &= \|q\|^2 - \frac{(\langle q, d \rangle)^2}{\|d\|^2} \end{aligned}$$

Nous savons que la similarité cosinus entre  $q$  et  $d$  est  $\text{sim}(q, d) = \frac{\langle q, d \rangle}{\|q\| \|d\|}$ . Donc,  $\langle q, d \rangle = \|q\| \|d\| \text{sim}(q, d)$ . Substituons cette expression :

$$\begin{aligned} \|P_{d^\perp}(q)\|^2 &= \|q\|^2 - \frac{(\|q\| \|d\| \text{sim}(q, d))^2}{\|d\|^2} \\ &= \|q\|^2 - \frac{\|q\|^2 \|d\|^2 (\text{sim}(q, d))^2}{\|d\|^2} \\ &= \|q\|^2 - \|q\|^2 (\text{sim}(q, d))^2 \\ &= \|q\|^2 (1 - (\text{sim}(q, d))^2) \end{aligned}$$

Soit  $\theta$  l'angle entre  $q$  et  $d$ . Alors  $\text{sim}(q, d) = \cos(\theta)$ .

$$\|P_{d^\perp}(q)\|^2 = \|q\|^2 (1 - \cos^2(\theta)) = \|q\|^2 \sin^2(\theta)$$



Puisque  $q$  et  $d$  sont linéairement indépendants,  $\theta \neq 0$  et  $\theta \neq \pi$ . Par conséquent,  $\sin(\theta) \neq 0$ . De plus, pour  $\theta \in [0, \pi]$ ,  $\sin(\theta) \geq 0$ . Donc,  $\|P_{d^\perp}(q)\| = \sqrt{\|q\|^2 \sin^2(\theta)} = \|q\| \sin(\theta)$ .

La valeur maximale  $f_0(q)$  est donc  $\|q\| \sin(\theta)$ , où  $\theta$  est l'angle entre  $q$  et  $d$ .

d. **Interprétation géométrique et relation avec la similarité cosinus** La forme linéaire  $f_0 = \Phi(v_0)$  est associée au vecteur  $v_0 = \frac{P_{d^\perp}(q)}{\|P_{d^\perp}(q)\|}$ . Ce vecteur  $v_0$  est le vecteur unitaire dans  $V$  qui est orthogonal à  $d$  (car  $v_0 \in d^\perp$ ) et qui est le plus “aligné” avec  $q$  parmi tous les vecteurs unitaires orthogonaux à  $d$ . Géométriquement,  $P_{d^\perp}(q)$  est la composante de  $q$  qui est orthogonale à  $d$ . C’est le vecteur qui reste de  $q$  une fois que toute sa composante colinéaire à  $d$  a été retirée. La contrainte  $f_0(d) = 0$  signifie que la forme linéaire  $f_0$  “ignore” complètement le document  $d$ . Dans le contexte d’un moteur de recherche sémantique, cela pourrait signifier que  $f_0$  représente une “caractéristique sémantique” ou un “concept” qui n’est pas présent ou n’est pas pertinent pour le document  $d$ . La valeur maximale  $f_0(q)$  est  $\|P_{d^\perp}(q)\| = \|q\| \sin(\theta)$ . Nous avons établi que  $\sin(q, d) = \cos(\theta)$ . La valeur maximale  $f_0(q)$  peut donc s’écrire  $\|q\| \sqrt{1 - (\sin(q, d))^2}$ . Cette valeur représente la “force” ou la “magnitude” de la composante de  $q$  qui est orthogonalement distincte de  $d$ . C’est une mesure de la “nouveauité” ou de l’“information non redondante” de  $q$  par rapport à  $d$ , vue à travers le prisme de l’espace dual.

- Si  $q$  et  $d$  sont très similaires (c’est-à-dire  $\sin(q, d)$  est proche de 1, ce qui signifie que  $\theta$  est proche de 0), alors  $\sin(\theta)$  est proche de 0, et  $f_0(q)$  est proche de 0. Cela indique qu’il est difficile de trouver une forme linéaire qui distingue  $q$  de  $d$  tout en étant orthogonale à  $d$ , car  $q$  est presque colinéaire à  $d$ .
- Si  $q$  et  $d$  sont orthogonaux (c’est-à-dire  $\sin(q, d) = 0$ , ce qui signifie  $\theta = \pi/2$ ), alors  $\sin(\theta) = 1$ , et  $f_0(q) = \|q\|$ . Dans ce cas,  $P_{d^\perp}(q) = q$ , et  $v_0 = q/\|q\|$ . La forme linéaire  $f_0$  est alors  $\Phi(q/\|q\|)$ , et  $f_0(q) = \langle q/\|q\|, q \rangle = \|q\|$ . Cela signifie que la forme linéaire qui maximise  $f(q)$  tout en étant orthogonale à  $d$  est simplement la forme linéaire associée à la direction de  $q$  lui-même, car  $q$  est déjà orthogonal à  $d$ .

En résumé,  $f_0$  est la forme linéaire duale du vecteur unitaire qui représente la composante de  $q$  la plus “distincte” de  $d$  en termes d’orthogonalité. La valeur maximale  $f_0(q)$  quantifie cette “distinctivité” de  $q$  par rapport à  $d$  dans la direction orthogonale à  $d$ . Ce concept est pertinent pour la conception de moteurs de recherche sémantiques, où l’on pourrait vouloir identifier des aspects d’une requête qui sont uniques par rapport à des documents déjà connus ou jugés non pertinents, permettant ainsi une exploration plus fine de l’espace sémantique.

## Conclusion

Nous avons démontré que l’espace dual  $V^*$  d’un espace euclidien  $V$  est lui-même un espace euclidien, isomorphe à  $V$  via l’isomorphisme de Riesz  $\Phi$ . Ce cadre a permis de reformuler un problème d’optimisation dans  $V^*$  en un problème équivalent dans  $V$ .

Le problème d’optimisation consistant à maximiser  $f(q)$  sous les contraintes  $f(d) = 0$  et  $\|f\|_{V^*} = 1$  a été résolu. La forme linéaire  $f_0$  solution est donnée par :

$$f_0 = \Phi \left( \frac{q - \frac{\langle q, d \rangle}{\|d\|^2} d}{\left\| q - \frac{\langle q, d \rangle}{\|d\|^2} d \right\|} \right)$$

La valeur maximale  $f_0(q)$  est :

$$f_0(q) = \left\| q - \frac{\langle q, d \rangle}{\|d\|^2} d \right\| = \|q\| \sqrt{1 - \left( \frac{\langle q, d \rangle}{\|q\| \|d\|} \right)^2} = \|q\| \sin(\theta)$$

où  $\theta$  est l'angle entre les vecteurs  $q$  et  $d$ .

Géométriquement,  $f_0$  est la forme linéaire associée au vecteur unitaire  $v_0$  qui représente la direction de la projection orthogonale de  $q$  sur l'orthogonal de  $d$ . La valeur maximale  $f_0(q)$  est la norme de cette projection. Ce résultat quantifie la “partie” de la requête  $q$  qui est sémantiquement distincte du document  $d$ , mesurée dans une direction orthogonale à  $d$ . Plus  $q$  est orthogonal à  $d$ , plus cette “distinctivité” est grande, et plus  $f_0(q)$  est élevé. Inversement, plus  $q$  est similaire à  $d$ , plus  $f_0(q)$  est faible, indiquant une faible “distinctivité” dans la direction orthogonale à  $d$ . Cette analyse est cruciale pour la conception de moteurs de recherche sémantiques, où l'on pourrait vouloir identifier des aspects d'une requête qui sont uniques par rapport à des documents déjà connus ou jugés non pertinents, permettant ainsi une exploration plus fine de l'espace sémantique.

## Exercice 8

### 2.8 Exercice 08 (4 ★) : Optimisation de la Similarité Cosinus Quadratique et Géométrie des Espaces de Plongement

#### 2.8.1 Énoncé

Soit  $(E, \langle \cdot, \cdot \rangle)$  un espace vectoriel euclidien réel de dimension finie  $m \geq 1$ . On note  $\| \cdot \|$  la norme associée à l'espace euclidien. Soit  $S = \{v_1, v_2, \dots, v_N\}$  un ensemble fini de  $N$  vecteurs non nuls de  $E$ , où  $N \geq 1$ . Ces vecteurs peuvent être interprétés comme des plongements (embeddings) sémantiques de documents ou de concepts. Nous cherchons à trouver un vecteur unitaire  $x \in E$  (c'est-à-dire  $\|x\| = 1$ ) qui maximise la somme des carrés des similarités cosinus avec les vecteurs de l'ensemble  $S$ . La fonction objectif est définie par :

$$f(x) = \sum_{i=1}^N \left( \frac{\langle x, v_i \rangle}{\|x\| \|v_i\|} \right)^2$$

1. Montrer que le problème de maximisation de  $f(x)$  sous la contrainte  $\|x\| = 1$  est équivalent à la maximisation d'une forme quadratique  $x^T M x$  pour une certaine matrice symétrique  $M$ . Définir explicitement la matrice  $M$  et justifier ses propriétés (symétrie, semi-définie positive).
2. Caractériser le(s) vecteur(s)  $x$  qui maximise(nt)  $f(x)$  et déterminer la valeur maximale de  $f(x)$ .
3. Interpréter la matrice  $M$  et le(s) vecteur(s)  $x$  maximisant  $f(x)$  en termes de géométrie de l'espace de plongement et du concept de “direction sémantique principale”.
4. Soit  $E^*$  le dual de l'espace  $E$ . Pour chaque  $v_i \in E$ , on définit le fonctionnel linéaire  $\phi_i \in E^*$  par  $\phi_i(y) = \langle v_i, y \rangle$  pour tout  $y \in E$ . Reformuler le problème de maximisation en termes de fonctionnels linéaires. Établir la connexion entre la matrice  $M$  et la matrice de Gram des fonctionnels  $\psi_i = \mathcal{R}(u_i)$  où  $u_i = v_i / \|v_i\|$  et  $\mathcal{R} : E \rightarrow E^*$  est l'isomorphisme de Riesz.

#### Isométries et Conservation des Angles

Les opérateurs orthogonaux  $Q \in O(d)$  préservent le produit scalaire par définition :  $\langle Qu, Qv \rangle = \langle u, v \rangle$ . De ce fait, ils préservent également les normes :  $\|Qu\| = \|u\|$ . Conséquemment, la similarité cosinus est un invariant absolu sous l'action du groupe orthogonal  $O(d)$ . Une rotation globale de l'espace de plongement ne modifie pas les relations sémantiques.

## 2.8.2 Correction Détaillée

### Analyse et Stratégie

Le problème nous demande de maximiser une fonction  $f(x)$  qui est une somme de carrés de similarités cosinus, sous la contrainte que  $x$  est un vecteur unitaire. La première étape consistera à simplifier l'expression de  $f(x)$  en utilisant la contrainte  $\|x\| = 1$  et en normalisant les vecteurs  $v_i$ . Nous montrerons ensuite que cette expression se ramène à une forme quadratique  $x^T M x$ , où  $M$  est une matrice symétrique. La maximisation d'une forme quadratique sous contrainte unitaire est un problème classique de l'algèbre linéaire, résolu par la théorie spectrale des matrices symétriques (valeurs propres et vecteurs propres).

Pour l'interprétation géométrique, nous analyserons la structure de  $M$  et la signification des vecteurs propres principaux. Enfin, pour la partie sur la dualité, nous utiliserons l'isomorphisme de Riesz pour relier les vecteurs de  $E$  à leurs fonctionnels linéaires correspondants dans  $E^*$ . Nous reformulerons l'objectif en termes de ces fonctionnels et établirons un lien avec la matrice de Gram, en exploitant la relation entre les matrices  $A^T A$  et  $A A^T$ .

### Résolution Pas-à-Pas

**1. Transformation en forme quadratique** Soit  $f(x) = \sum_{i=1}^N \left( \frac{\langle x, v_i \rangle}{\|x\| \|v_i\|} \right)^2$ . Puisque nous cherchons à maximiser  $f(x)$  sous la contrainte  $\|x\| = 1$ , l'expression de  $f(x)$  se simplifie en :

$$f(x) = \sum_{i=1}^N \frac{\langle x, v_i \rangle^2}{\|v_i\|^2}$$

Les vecteurs  $v_i$  sont non nuls par hypothèse, donc  $\|v_i\| \neq 0$ . Définissons les vecteurs normalisés  $u_i = \frac{v_i}{\|v_i\|}$  pour  $i = 1, \dots, N$ . Ces vecteurs  $u_i$  sont unitaires, c'est-à-dire  $\|u_i\| = 1$ . L'expression de  $f(x)$  devient alors :

$$f(x) = \sum_{i=1}^N \langle x, u_i \rangle^2$$

Soit  $\{e_1, \dots, e_m\}$  une base orthonormée de  $E$ . Tout vecteur  $x \in E$  peut être représenté par ses coordonnées  $x = \sum_{j=1}^m x_j e_j$ , et de même pour  $u_i = \sum_{j=1}^m (u_i)_j e_j$ . Dans cette base, le produit scalaire  $\langle x, u_i \rangle$  s'écrit comme le produit matriciel  $x^T u_i$ , où  $x$  et  $u_i$  sont des vecteurs colonnes de leurs coordonnées. Alors  $\langle x, u_i \rangle^2 = (x^T u_i)^2 = (x^T u_i)(u_i^T x)$ . En substituant cela dans l'expression de  $f(x)$  :

$$f(x) = \sum_{i=1}^N (x^T u_i)(u_i^T x)$$

Par la linéarité de la somme et la distributivité du produit matriciel, nous pouvons réécrire ceci comme :

$$f(x) = x^T \left( \sum_{i=1}^N u_i u_i^T \right) x$$

Nous définissons la matrice  $M$  comme :

$$M = \sum_{i=1}^N u_i u_i^T$$

Chaque terme  $u_i u_i^T$  est une matrice de taille  $m \times m$ . La matrice  $u_i u_i^T$  est symétrique, car  $(u_i u_i^T)^T = (u_i^T)^T u_i^T = u_i u_i^T$ . Puisque  $M$  est une somme de matrices symétriques,  $M$  est elle-même une matrice symétrique. De plus, pour tout vecteur  $y \in E$ , la forme quadratique associée

à  $M$  est :

$$y^T M y = y^T \left( \sum_{i=1}^N u_i u_i^T \right) y = \sum_{i=1}^N y^T u_i u_i^T y = \sum_{i=1}^N (y^T u_i)(u_i^T y) = \sum_{i=1}^N \langle y, u_i \rangle^2$$

Puisque  $\langle y, u_i \rangle^2 \geq 0$  pour tout  $i$ , la somme  $\sum_{i=1}^N \langle y, u_i \rangle^2$  est toujours supérieure ou égale à zéro. Donc,  $y^T M y \geq 0$  pour tout  $y \in E$ . Cela signifie que  $M$  est une matrice semi-définie positive.

Le problème de maximisation de  $f(x)$  sous la contrainte  $\|x\| = 1$  est donc équivalent à la maximisation de la forme quadratique  $x^T M x$  sous la contrainte  $\|x\|^2 = x^T x = 1$ .

**2. Caractérisation du(des) vecteur(s) maximisant(s) et valeur maximale** Le problème de la maximisation d'une forme quadratique  $x^T M x$  sous la contrainte  $\|x\|^2 = 1$  pour une matrice symétrique  $M$  est un résultat fondamental de la théorie spectrale. Soient  $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_m$  les valeurs propres de  $M$ , ordonnées par ordre décroissant. Le théorème spectral pour les matrices symétriques garantit que toutes les valeurs propres sont réelles et qu'il existe une base orthonormée de  $E$  composée de vecteurs propres de  $M$ . Pour tout vecteur  $x$  unitaire, la valeur de  $x^T M x$  est bornée par la plus grande et la plus petite valeur propre de  $M$ . Plus précisément :

$$\lambda_m \leq x^T M x \leq \lambda_1$$

La valeur maximale de  $x^T M x$  est  $\lambda_1$ , la plus grande valeur propre de  $M$ . Le(s) vecteur(s)  $x$  qui atteigne(nt) ce maximum sont les vecteurs propres unitaires associés à cette plus grande valeur propre  $\lambda_1$ . Si  $\lambda_1$  est une valeur propre simple, alors il y a deux vecteurs unitaires qui maximisent  $f(x)$ , à savoir  $e_1$  et  $-e_1$ , où  $e_1$  est le vecteur propre unitaire associé à  $\lambda_1$ . Si  $\lambda_1$  est une valeur propre de multiplicité  $k > 1$ , alors tout vecteur unitaire appartenant au sous-espace propre  $E_{\lambda_1}$  (de dimension  $k$ ) maximise  $f(x)$ .

En résumé : \* La valeur maximale de  $f(x)$  est  $\lambda_{\max}(M)$ , la plus grande valeur propre de  $M$ .

\* Le(s) vecteur(s)  $x$  qui maximise(nt)  $f(x)$  sont les vecteurs propres unitaires de  $M$  associés à  $\lambda_{\max}(M)$ .

### 3. Interprétation géométrique

- **Interprétation de la matrice  $M$**  : La matrice  $M = \sum_{i=1}^N u_i u_i^T$  est une somme de matrices de projection orthogonale. Chaque terme  $u_i u_i^T$  est la matrice de projection orthogonale sur la droite vectorielle engendrée par le vecteur unitaire  $u_i$ .  $M$  peut être vue comme une matrice qui agrège les directions des vecteurs normalisés  $u_i$ . Elle capture la “variance” ou la “dispersion” des directions des documents dans l'espace de plongement. Si les vecteurs  $u_i$  sont fortement alignés dans une certaine direction,  $M$  aura une grande valeur propre dans cette direction. Si l'on considère la matrice  $A$  de taille  $N \times m$  dont la  $i$ -ème ligne est le vecteur  $u_i^T$  (transposé du vecteur colonne  $u_i$ ), alors  $M = A^T A$ . Cette construction est similaire à celle de la matrice de covariance dans l'Analyse en Composantes Principales (PCA), mais appliquée aux directions des vecteurs plutôt qu'à leurs positions absolues (et sans centrage).
- **Interprétation du(des) vecteur(s)  $x$  maximisant(s)** : Le(s) vecteur(s)  $x$  qui maximise(nt)  $f(x)$  sont les vecteurs propres unitaires associés à la plus grande valeur propre de  $M$ . Cette direction  $x$  est celle le long de laquelle la somme des carrés des projections des vecteurs  $u_i$  est maximale. En d'autres termes,  $x$  représente la “direction principale” ou la “direction sémantique dominante” de l'ensemble des documents  $S$ . C'est la direction dans l'espace de plongement qui est la plus fortement alignée avec l'ensemble des documents normalisés. Dans le contexte d'un moteur de recherche sémantique, ce vecteur  $x$  pourrait être utilisé comme un “représentant” ou un “prototype” sémantique pour le groupe de documents  $S$ . Un nouveau document ou une nouvelle requête pourrait être comparé à  $x$  pour évaluer sa similarité globale avec l'ensemble  $S$ .

**4. Dualité et connexion avec la matrice de Gram** Soit  $E^*$  le dual de  $E$ . Puisque  $E$  est un espace euclidien de dimension finie, il existe un isomorphisme canonique entre  $E$  et  $E^*$ , connu sous le nom d'isomorphisme de Riesz. L'isomorphisme de Riesz  $\mathcal{R} : E \rightarrow E^*$  est défini par  $\mathcal{R}(v)(y) = \langle v, y \rangle$  pour tout  $v, y \in E$ . Pour chaque  $v_i \in E$ , le fonctionnel  $\phi_i \in E^*$  est donné par  $\phi_i(y) = \langle v_i, y \rangle$ . De même, pour les vecteurs normalisés  $u_i = v_i / \|v_i\|$ , nous définissons les fonctionnels  $\psi_i = \mathcal{R}(u_i) \in E^*$ , de sorte que  $\psi_i(y) = \langle u_i, y \rangle$ .

Le problème de maximisation est  $f(x) = \sum_{i=1}^N \langle x, u_i \rangle^2$  sous la contrainte  $\|x\| = 1$ . En utilisant la définition de  $\psi_i$ , nous pouvons réécrire l'objectif comme :

$$f(x) = \sum_{i=1}^N (\psi_i(x))^2$$

L'isomorphisme de Riesz permet également de définir un produit scalaire sur  $E^*$ . Pour  $\chi, \zeta \in E^*$ , on définit  $\langle \chi, \zeta \rangle_{E^*} = \langle \mathcal{R}^{-1}(\chi), \mathcal{R}^{-1}(\zeta) \rangle_E$ . La norme associée dans  $E^*$  est  $\|\chi\|_{E^*} = \|\mathcal{R}^{-1}(\chi)\|_E$ . Ainsi, la contrainte  $\|x\| = 1$  est équivalente à  $\|\mathcal{R}(x)\|_{E^*} = 1$ . Soit  $\chi = \mathcal{R}(x) \in E^*$ . Alors  $x = \mathcal{R}^{-1}(\chi)$ . L'expression  $\psi_i(x)$  peut être réécrite en utilisant le produit scalaire dans  $E^*$  :

$$\psi_i(x) = \langle u_i, x \rangle_E = \langle \mathcal{R}^{-1}(\psi_i), \mathcal{R}^{-1}(\chi) \rangle_E = \langle \psi_i, \chi \rangle_{E^*}$$

Donc, le problème de maximisation peut être reformulé dans l'espace dual  $E^*$  comme : Maximiser  $\sum_{i=1}^N \langle \psi_i, \chi \rangle_{E^*}^2$  sous la contrainte  $\|\chi\|_{E^*} = 1$ . Ceci est exactement le même type de problème que celui initial, mais formulé dans l'espace dual  $E^*$  avec les fonctionnels  $\psi_i$  et la variable d'optimisation  $\chi$ .

**Connexion entre  $M$  et la matrice de Gram des fonctionnels  $\psi_i$**  : Soit  $\{e_1, \dots, e_m\}$  une base orthonormée de  $E$ . Soit  $A$  la matrice de taille  $N \times m$  dont la  $i$ -ème ligne est le vecteur de coordonnées de  $u_i$  dans cette base, c'est-à-dire  $A_{ij} = (u_i)_j$ . Alors, comme établi précédemment,  $M = A^T A$ .

La matrice de Gram  $G$  des fonctionnels  $\{\psi_1, \dots, \psi_N\}$  est une matrice de taille  $N \times N$  dont les entrées sont  $G_{jk} = \langle \psi_j, \psi_k \rangle_{E^*}$ . En utilisant la définition du produit scalaire dans  $E^*$  et l'isomorphisme de Riesz :

$$G_{jk} = \langle \mathcal{R}^{-1}(\psi_j), \mathcal{R}^{-1}(\psi_k) \rangle_E = \langle u_j, u_k \rangle_E$$

Dans la base orthonormée,  $\langle u_j, u_k \rangle_E = u_j^T u_k$ . Considérons le produit matriciel  $AA^T$  :

$$(AA^T)_{jk} = \sum_{l=1}^m A_{jl}(A^T)_{lk} = \sum_{l=1}^m A_{jl}A_{kl} = \sum_{l=1}^m (u_j)_l(u_k)_l = u_j^T u_k$$

Donc, la matrice de Gram  $G$  des fonctionnels  $\psi_i$  est  $G = AA^T$ .

Nous avons  $M = A^T A$  et  $G = AA^T$ . Il est un résultat connu de l'algèbre linéaire que les matrices  $A^T A$  et  $AA^T$  ont les mêmes valeurs propres non nulles. Par conséquent, la valeur maximale de  $f(x)$ , qui est  $\lambda_{\max}(M)$ , est également la plus grande valeur propre de la matrice de Gram  $G$ . Si  $y \in \mathbb{R}^N$  est un vecteur propre de  $G$  associé à la valeur propre  $\lambda_{\max}(G)$ , alors  $Gy = \lambda_{\max}(G)y$ , ce qui signifie  $AA^T y = \lambda_{\max}(G)y$ . En multipliant par  $A^T$  à gauche, on obtient  $A^T AA^T y = \lambda_{\max}(G)A^T y$ . Puisque  $M = A^T A$ , cela donne  $M(A^T y) = \lambda_{\max}(G)(A^T y)$ . Ainsi,  $A^T y$  est un vecteur propre de  $M$  associé à la valeur propre  $\lambda_{\max}(G)$ . Le vecteur  $x$  qui maximise  $f(x)$  est alors donné par la normalisation de  $A^T y$  :

$$x = \frac{A^T y}{\|A^T y\|}$$

où  $y$  est un vecteur propre unitaire de  $G$  associé à sa plus grande valeur propre. Cette relation offre une méthode alternative pour trouver le vecteur  $x$ , potentiellement plus efficace si  $N < m$  (car  $G$  est de taille  $N \times N$  tandis que  $M$  est de taille  $m \times m$ ).

## Conclusion

Nous avons montré que le problème de maximisation de la somme des carrés des similarités cosinus d'un vecteur unitaire  $x$  avec un ensemble de vecteurs de plongement  $S = \{v_1, \dots, v_N\}$  se ramène à la maximisation d'une forme quadratique  $x^T M x$  sous la contrainte  $\|x\| = 1$ . La matrice  $M = \sum_{i=1}^N u_i u_i^T$  (où  $u_i = v_i / \|v_i\|$ ) est symétrique et semi-définie positive.

Le(s) vecteur(s)  $x$  qui maximise(nt) cette fonction sont les vecteurs propres unitaires de  $M$  associés à sa plus grande valeur propre  $\lambda_{\max}(M)$ . La valeur maximale de la fonction objectif est  $\lambda_{\max}(M)$ .

Géométriquement, la matrice  $M$  agrège les directions des vecteurs de plongement normalisés, et le vecteur  $x$  maximisant représente la “direction sémantique principale” de l'ensemble des documents, c'est-à-dire la direction qui capture le mieux l'orientation moyenne des plongements normalisés.

Enfin, en utilisant l'isomorphisme de Riesz, nous avons reformulé le problème dans l'espace dual  $E^*$ . La matrice  $M$  est liée à la matrice de Gram  $G = A A^T$  des fonctionnels  $\psi_i = \mathcal{R}(u_i)$  par la relation  $M = A^T A$ , où  $A$  est la matrice dont les lignes sont les coordonnées des  $u_i$ . Les matrices  $M$  et  $G$  partagent les mêmes valeurs propres non nulles, et le vecteur  $x$  maximisant peut être obtenu à partir du vecteur propre principal de  $G$ .

Ce cadre mathématique fournit une base solide pour identifier des directions sémantiques dominantes dans des collections de plongements, ce qui est fondamental pour la conception de moteurs de recherche sémantiques et l'analyse de clusters de documents.

## Exercice 9

### 2.9 Exercice 09 (5 ★) : Optimisation de la Pertinence Sémantique Généralisée dans les Espaces de Plongement

#### 2.9.1 Énoncé

Soit  $(E, \langle \cdot, \cdot \rangle)$  un espace vectoriel euclidien réel de dimension finie  $n \geq 1$ . On note  $\|\cdot\|$  la norme euclidienne associée. Soit  $A \in \mathcal{L}(E)$  un opérateur linéaire auto-adjoint et positif défini. Soit  $F$  un sous-espace vectoriel de  $E$  de dimension  $k \geq 1$ . Soit  $q \in E \setminus \{0\}$  un vecteur de requête fixe.

Pour tout  $x \in E \setminus \{0\}$ , nous définissons une fonction de pertinence sémantique généralisée  $R(x)$  par :

$$R(x) = \frac{\langle q, x \rangle^2}{\langle x, A x \rangle}$$

L'objectif de cet exercice est de déterminer le vecteur  $x_0 \in F \setminus \{0\}$  (à un facteur d'échelle près) qui maximise  $R(x)$  sur  $F$ , et de calculer la valeur maximale de  $R(x)$ .

#### 1. Propriétés de l'opérateur $A$ et du produit scalaire induit.

- a) Prouver que la forme bilinéaire  $B(u, v) = \langle u, A v \rangle$  définit un produit scalaire sur  $E$ . On notera ce produit scalaire  $(\cdot, \cdot)_A$  et la norme associée  $\|\cdot\|_A$ .
- b) Justifier que  $R(x)$  est bien définie et positive pour tout  $x \in E \setminus \{0\}$ .
- c) Montrer qu'il existe un unique opérateur  $A^{1/2} \in \mathcal{L}(E)$  tel que  $(A^{1/2})^2 = A$ , et que  $A^{1/2}$  est auto-adjoint et positif défini.

#### 2. Transformation du problème d'optimisation.

- a) En utilisant l'opérateur  $A^{1/2}$ , effectuer un changement de variable  $y = A^{1/2} x$ . Expliciter  $x$  en fonction de  $y$ .
- b) Montrer que la maximisation de  $R(x)$  pour  $x \in F \setminus \{0\}$  est équivalente à la maximisation d'une expression de la forme  $\frac{\langle q', y \rangle^2}{\|y\|^2}$  pour un certain vecteur  $q' \in E$  et  $y$  appartenant à un sous-espace  $F' \subseteq E$ . Expliciter  $q'$  et  $F'$ .

### 3. Détermination du vecteur optimal et de la valeur maximale.

- a) En utilisant le résultat de la question 2.b) et l'inégalité de Cauchy-Schwarz, déterminer le vecteur  $y_0 \in F' \setminus \{0\}$  (à un facteur d'échelle près) qui maximise l'expression  $\frac{\langle q', y \rangle^2}{\|y\|^2}$ . Exprimer  $y_0$  en fonction de  $q'$  et de la projection orthogonale  $P_{F'}$  sur  $F'$  (par rapport au produit scalaire standard  $\langle \cdot, \cdot \rangle$ ).
- b) En déduire le vecteur  $x_0 \in F \setminus \{0\}$  (à un facteur d'échelle près) qui maximise  $R(x)$ .
- c) Calculer la valeur maximale  $R_{max}$  de  $R(x)$ .
- d) Interpréter géométriquement  $x_0$  et  $R_{max}$  en termes de "proximité" dans l'espace  $(E, (\cdot, \cdot)_A)$ .

## Matrice de Gram et Indépendance Linéaire

Étant donné un ensemble de vecteurs  $\{u_1, \dots, u_k\}$ , leur matrice de Gram  $G$  a pour coefficients  $G_{i,j} = \langle u_i, u_j \rangle$ . La normalisation de la matrice de Gram donne directement la matrice des similarités cosinus. Si  $G$  est inversible, la famille est libre, prouvant que les concepts sémantiques correspondants ne sont pas colinéaires.

### 2.9.2 Correction Détaillée

#### Analyse et Stratégie

Le problème nous demande de maximiser une fonction de pertinence  $R(x)$  définie comme le rapport d'une forme quadratique (liée au produit scalaire standard) et d'une autre forme quadratique (liée à l'opérateur  $A$ ). L'opérateur  $A$  est auto-adjoint et positif défini, ce qui est une information cruciale.

La stratégie générale sera la suivante : 1. **Caractériser le produit scalaire induit par  $A$**  : La première étape consiste à montrer que  $B(u, v) = \langle u, Av \rangle$  est bien un produit scalaire. Cela nous permettra de comprendre la structure de l'espace de "plongement sémantique" induit par  $A$ . 2. **Utiliser l'opérateur racine carrée  $A^{1/2}$**  : L'existence et les propriétés de  $A^{1/2}$  sont fondamentales pour simplifier l'expression de  $R(x)$ . Cet opérateur permet de "diagonaliser" la forme quadratique au dénominateur et de la ramener à une norme euclidienne standard après un changement de variable. 3. **Changement de variable et projection** : En effectuant un changement de variable  $y = A^{1/2}x$ , nous transformerons le problème d'optimisation original en un problème de maximisation d'un rapport de formes quadratiques plus simple, qui peut être résolu par l'inégalité de Cauchy-Schwarz et la notion de projection orthogonale. 4. **Retour à l'espace original et interprétation** : Une fois le vecteur optimal  $y_0$  trouvé dans l'espace transformé, nous le retransformerons en  $x_0$  dans l'espace original  $E$ . Enfin, nous interpréterons géométriquement le résultat en termes de dualité et de géométrie des espaces de plongement, en utilisant le produit scalaire  $(\cdot, \cdot)_A$ .

#### Résolution Pas-à-Pas

##### 1. Propriétés de l'opérateur $A$ et du produit scalaire induit.

- a) Prouvons que la forme bilinéaire  $B(u, v) = \langle u, Av \rangle$  définit un produit scalaire sur  $E$ . Pour qu'une forme bilinéaire soit un produit scalaire, elle doit satisfaire les propriétés suivantes :
  - **Bilinearité** : Pour  $u, v, w \in E$  et  $\alpha \in \mathbb{R}$  :
    - $B(u, \alpha v + w) = \langle u, A(\alpha v + w) \rangle = \langle u, \alpha Av + Aw \rangle$ . Par linéarité du produit scalaire  $\langle \cdot, \cdot \rangle$  dans la deuxième composante, on a :  $B(u, \alpha v + w) = \alpha \langle u, Av \rangle + \langle u, Aw \rangle = \alpha B(u, v) + B(u, w)$ .

- $B(\alpha u + w, v) = \langle \alpha u + w, Av \rangle$ . Par linéarité du produit scalaire  $\langle \cdot, \cdot \rangle$  dans la première composante, on a :  $B(\alpha u + w, v) = \alpha \langle u, Av \rangle + \langle w, Av \rangle = \alpha B(u, v) + B(w, v)$ . La bilinéarité est donc vérifiée.
- **Symétrie** : Pour  $u, v \in E$  :  $B(u, v) = \langle u, Av \rangle$ . Puisque  $A$  est auto-adjoint, par définition,  $\langle u, Av \rangle = \langle Au, v \rangle$ . Par symétrie de la forme bilinéaire du produit scalaire  $\langle \cdot, \cdot \rangle$ , on a  $\langle Au, v \rangle = \langle v, Au \rangle$ . Donc  $B(u, v) = \langle v, Au \rangle = B(v, u)$ . La symétrie est donc vérifiée.
- **Positivité définie** : Pour  $u \in E$  :  $B(u, u) = \langle u, Au \rangle$ . Puisque  $A$  est positif défini, par définition,  $\langle u, Au \rangle > 0$  pour tout  $u \neq 0$ , et  $\langle 0, A0 \rangle = 0$ . La positivité définie est donc vérifiée. En conclusion,  $B(u, v) = \langle u, Av \rangle$  définit bien un produit scalaire sur  $E$ . Nous le noterons  $(\cdot, \cdot)_A$ , et la norme associée  $\| \cdot \|_A = \sqrt{(u, u)_A} = \sqrt{\langle u, Au \rangle}$ .
- b) Justifions que  $R(x)$  est bien définie et positive pour tout  $x \in E \setminus \{0\}$ . Le numérateur est  $\langle q, x \rangle^2$ . C'est le carré d'un nombre réel, donc il est toujours  $\geq 0$ . Le dénominateur est  $\langle x, Ax \rangle$ . D'après la question 1.a), puisque  $A$  est positif défini,  $\langle x, Ax \rangle > 0$  pour tout  $x \in E \setminus \{0\}$ . Ainsi, pour tout  $x \in E \setminus \{0\}$ , le dénominateur est non nul et strictement positif. La fonction  $R(x)$  est donc bien définie et  $R(x) \geq 0$ .
- c) Montrons qu'il existe un unique opérateur  $A^{1/2} \in \mathcal{L}(E)$  tel que  $(A^{1/2})^2 = A$ , et que  $A^{1/2}$  est auto-adjoint et positif défini. Puisque  $E$  est un espace euclidien de dimension finie et  $A$  est un opérateur auto-adjoint, d'après le théorème spectral, il existe une base orthonormée de  $E$ , disons  $(e_1, \dots, e_n)$ , constituée de vecteurs propres de  $A$ . Soient  $\lambda_1, \dots, \lambda_n$  les valeurs propres correspondantes. Puisque  $A$  est positif défini, pour tout  $x \neq 0$ ,  $\langle x, Ax \rangle > 0$ . En particulier, pour chaque vecteur propre  $e_i$ ,  $\langle e_i, Ae_i \rangle = \langle e_i, \lambda_i e_i \rangle = \lambda_i \langle e_i, e_i \rangle = \lambda_i \|e_i\|^2 = \lambda_i$ . Donc  $\lambda_i > 0$  pour tout  $i = 1, \dots, n$ . Nous pouvons alors définir l'opérateur  $A^{1/2}$  sur cette base de vecteurs propres par  $A^{1/2}e_i = \sqrt{\lambda_i}e_i$  pour chaque  $i$ .
- **Existence** : L'opérateur  $A^{1/2}$  est bien défini par sa restriction à une base.
- **Propriété**  $(A^{1/2})^2 = A$  : Pour tout  $e_i$ ,  $(A^{1/2})^2 e_i = A^{1/2}(A^{1/2}e_i) = A^{1/2}(\sqrt{\lambda_i}e_i) = \sqrt{\lambda_i}A^{1/2}e_i = \sqrt{\lambda_i}(\sqrt{\lambda_i}e_i) = \lambda_i e_i = Ae_i$ . Puisque  $(A^{1/2})^2$  et  $A$  agissent de la même manière sur une base, ils sont égaux.
- **Auto-adjoint** : Pour  $u = \sum u_i e_i$  et  $v = \sum v_i e_i$  :  $\langle u, A^{1/2}v \rangle = \langle \sum u_i e_i, \sum v_j \sqrt{\lambda_j} e_j \rangle = \sum_i \sum_j u_i v_j \sqrt{\lambda_j} \langle e_i, e_j \rangle = \sum_i u_i v_i \sqrt{\lambda_i}$ .  $\langle A^{1/2}u, v \rangle = \langle \sum u_i \sqrt{\lambda_i} e_i, \sum v_j e_j \rangle = \sum_i \sum_j u_i \sqrt{\lambda_i} v_j \langle e_i, e_j \rangle = \sum_i u_i \sqrt{\lambda_i} v_i$ . Donc  $\langle u, A^{1/2}v \rangle = \langle A^{1/2}u, v \rangle$ , ce qui prouve que  $A^{1/2}$  est auto-adjoint.
- **Positif défini** : Pour tout  $u = \sum u_i e_i \neq 0$  :  $\langle u, A^{1/2}u \rangle = \sum_i u_i^2 \sqrt{\lambda_i}$ . Puisque  $u \neq 0$ , au moins un  $u_i \neq 0$ . Puisque tous les  $\sqrt{\lambda_i} > 0$ , on a  $\sum_i u_i^2 \sqrt{\lambda_i} > 0$ . Donc  $A^{1/2}$  est positif défini.
- **Unicité** : Supposons qu'il existe un autre opérateur  $B \in \mathcal{L}(E)$  tel que  $B^2 = A$ ,  $B$  auto-adjoint et positif défini. Alors  $B$  est diagonalisable dans une base orthonormée avec des valeurs propres positives. Soit  $u$  un vecteur propre de  $B$  avec valeur propre  $\mu$ . Alors  $Bu = \mu u$ , et  $B^2 u = \mu^2 u$ . Puisque  $B^2 = A$ ,  $Au = \mu^2 u$ . Donc  $u$  est aussi un vecteur propre de  $A$  avec valeur propre  $\mu^2$ . Puisque les valeurs propres de  $A$  sont  $\lambda_i$ , alors  $\mu^2$  doit être l'une des  $\lambda_i$ . Donc  $\mu = \sqrt{\lambda_i}$  (puisque  $\mu > 0$ ). Ainsi,  $B$  doit avoir les mêmes valeurs propres que  $A^{1/2}$  et les mêmes espaces propres. Par conséquent,  $B = A^{1/2}$ .

## 2. Transformation du problème d'optimisation.

- a) Utilisons l'opérateur  $A^{1/2}$  pour un changement de variable. Puisque  $A^{1/2}$  est positif défini, toutes ses valeurs propres  $\sqrt{\lambda_i}$  sont strictement positives. Cela implique que  $A^{1/2}$  est inversible. Son inverse, noté  $A^{-1/2}$ , est également auto-adjoint et positif défini. Posons  $y = A^{1/2}x$ . Alors  $x = (A^{1/2})^{-1}y = A^{-1/2}y$ .
- b) Montrons l'équivalence de la maximisation. Substituons  $x = A^{-1/2}y$  dans l'expression de  $R(x)$  :
- **Dénominateur** :  $\langle x, Ax \rangle = \langle A^{-1/2}y, A(A^{-1/2}y) \rangle$ . Puisque  $A = (A^{1/2})^2$ , on a



$A(A^{-1/2}y) = A^{1/2}(A^{1/2}A^{-1/2}y) = A^{1/2}y$ . Donc  $\langle x, Ax \rangle = \langle A^{-1/2}y, A^{1/2}y \rangle$ . Puisque  $A^{1/2}$  est auto-adjoint,  $\langle A^{-1/2}y, A^{1/2}y \rangle = \langle y, (A^{-1/2})^* A^{1/2}y \rangle = \langle y, A^{-1/2}A^{1/2}y \rangle = \langle y, Iy \rangle = \langle y, y \rangle = \|y\|^2$ . Ainsi, le dénominateur devient  $\|y\|^2$ .

- **Numérateur** :  $\langle q, x \rangle^2 = \langle q, A^{-1/2}y \rangle^2$ . Posons  $q' = A^{-1/2}q$ . Alors le numérateur devient  $\langle q', y \rangle^2$ . La fonction de pertinence  $R(x)$  se transforme en  $R'(y) = \frac{\langle q', y \rangle^2}{\|y\|^2}$ . Le vecteur  $x$  appartient au sous-espace  $F$ . Donc  $y = A^{1/2}x$  appartient au sous-espace  $F' = A^{1/2}(F)$ .  $F'$  est bien un sous-espace vectoriel de  $E$  car  $A^{1/2}$  est un opérateur linéaire et  $F$  est un sous-espace. La maximisation de  $R(x)$  pour  $x \in F \setminus \{0\}$  est donc équivalente à la maximisation de  $R'(y) = \frac{\langle q', y \rangle^2}{\|y\|^2}$  pour  $y \in F' \setminus \{0\}$ , avec  $q' = A^{-1/2}q$  et  $F' = A^{1/2}(F)$ .

### 3. Détermination du vecteur optimal et de la valeur maximale.

- a) Déterminons  $y_0 \in F' \setminus \{0\}$  qui maximise  $\frac{\langle q', y \rangle^2}{\|y\|^2}$ . L'expression à maximiser est  $\frac{\langle q', y \rangle^2}{\|y\|^2}$ . D'après l'inégalité de Cauchy-Schwarz, pour tout  $y \in F'$ , on a  $\langle q', y \rangle^2 \leq \|q'\|^2 \|y\|^2$ . Donc  $\frac{\langle q', y \rangle^2}{\|y\|^2} \leq \|q'\|^2$ . L'égalité est atteinte si et seulement si  $y$  est colinéaire à  $q'$ . Cependant,  $y$  doit également appartenir à  $F'$ . Par conséquent, la maximisation de  $\frac{\langle q', y \rangle^2}{\|y\|^2}$  pour  $y \in F' \setminus \{0\}$  est atteinte lorsque  $y$  est colinéaire à la projection orthogonale de  $q'$  sur  $F'$ . Soit  $P_{F'}$  l'opérateur de projection orthogonale sur  $F'$  par rapport au produit scalaire standard  $\langle \cdot, \cdot \rangle$ . Le vecteur  $y_0$  (à un facteur d'échelle près) qui maximise l'expression est  $y_0 = P_{F'}(q')$ . La valeur maximale de l'expression est alors  $\frac{\langle q', P_{F'}(q') \rangle^2}{\|P_{F'}(q')\|^2}$ . Puisque  $P_{F'}(q')$  est la projection orthogonale de  $q'$  sur  $F'$ , on a  $\langle q', P_{F'}(q') \rangle = \langle P_{F'}(q') + (q' - P_{F'}(q')), P_{F'}(q') \rangle = \langle P_{F'}(q'), P_{F'}(q') \rangle + \langle q' - P_{F'}(q'), P_{F'}(q') \rangle$ . Par définition de la projection orthogonale,  $q' - P_{F'}(q')$  est orthogonal à  $F'$ , donc  $\langle q' - P_{F'}(q'), P_{F'}(q') \rangle = 0$ . Ainsi,  $\langle q', P_{F'}(q') \rangle = \|P_{F'}(q')\|^2$ . La valeur maximale est donc  $\frac{(\|P_{F'}(q')\|^2)^2}{\|P_{F'}(q')\|^2} = \|P_{F'}(q')\|^2$ . Si  $P_{F'}(q') = 0$ , alors  $q'$  est orthogonal à  $F'$ , et la valeur maximale est 0. Dans ce cas, tout  $y \in F' \setminus \{0\}$  donne une valeur de 0.
- b) Déduisons le vecteur optimal  $x_0 \in F \setminus \{0\}$ . Nous avons  $y_0 = P_{F'}(q')$ . En utilisant la relation  $x = A^{-1/2}y$ , nous obtenons :  $x_0 = A^{-1/2}y_0 = A^{-1/2}P_{F'}(q')$ . En substituant  $q' = A^{-1/2}q$  et  $F' = A^{1/2}(F)$  :  $x_0 = A^{-1/2}P_{A^{1/2}(F)}(A^{-1/2}q)$ . Ce vecteur  $x_0$  est défini à un facteur d'échelle près.
- c) Calculons la valeur maximale  $R_{max}$  de  $R(x)$ . La valeur maximale de  $R'(y)$  est  $\|P_{F'}(q')\|^2$ . Donc,  $R_{max} = \|P_{F'}(q')\|^2$ . En substituant  $q' = A^{-1/2}q$  et  $F' = A^{1/2}(F)$  :  $R_{max} = \|P_{A^{1/2}(F)}(A^{-1/2}q)\|^2$ .
- d) Interprétons géométriquement  $x_0$  et  $R_{max}$  en termes de "proximité" dans l'espace  $(E, (\cdot, \cdot)_A)$ . Rappelons que le problème est de maximiser  $R(x) = \frac{\langle q, x \rangle^2}{\langle x, Ax \rangle}$  pour  $x \in F \setminus \{0\}$ . Nous avons montré que  $(\cdot, \cdot)_A$  est un produit scalaire sur  $E$ . Considérons la forme linéaire  $f_q : E \rightarrow \mathbb{R}$  définie par  $f_q(x) = \langle q, x \rangle$ . D'après le théorème de représentation de Riesz pour le produit scalaire  $(\cdot, \cdot)_A$ , il existe un unique vecteur  $v_q \in E$  tel que  $f_q(x) = (x, v_q)_A$  pour tout  $x \in E$ . C'est-à-dire  $\langle q, x \rangle = \langle x, Av_q \rangle$ . Par symétrie de la forme bilinéaire du produit scalaire standard,  $\langle q, x \rangle = \langle Av_q, x \rangle$ . Puisque cette égalité doit être vraie pour tout  $x \in E$ , on doit avoir  $q = Av_q$ . Puisque  $A$  est inversible (car positif défini),  $v_q = A^{-1}q$ . Ainsi, la fonction de pertinence peut s'écrire :  $R(x) = \frac{(x, A^{-1}q)_A^2}{\|x\|_A^2}$ . Cette expression est le carré du cosinus de l'angle entre  $x$  et  $A^{-1}q$  dans l'espace euclidien  $(E, (\cdot, \cdot)_A)$ . Plus précisément, si  $\theta_A(x, A^{-1}q)$  est l'angle entre  $x$  et  $A^{-1}q$  dans l'espace  $(E, (\cdot, \cdot)_A)$ , alors  $R(x) = \cos^2(\theta_A(x, A^{-1}q))$ . Maximiser  $R(x)$  revient donc à maximiser  $\cos^2(\theta_A(x, A^{-1}q))$ , ce qui est équivalent à minimiser l'angle  $\theta_A(x, A^{-1}q)$ . Le vecteur  $x_0 \in F \setminus \{0\}$  qui minimise l'angle avec  $A^{-1}q$  (dans l'espace  $(E, (\cdot, \cdot)_A)$ ) est la projection orthogonale de  $A^{-1}q$  sur  $F$ .

par rapport au produit scalaire  $(\cdot, \cdot)_A$ . On note cette projection  $P_F^A(A^{-1}q)$ . Donc,  $x_0 = P_F^A(A^{-1}q)$  (à un facteur d'échelle près). La valeur maximale  $R_{max}$  est alors  $\cos^2(\theta_A(P_F^A(A^{-1}q), A^{-1}q))$ . Puisque  $P_F^A(A^{-1}q)$  est la projection de  $A^{-1}q$  sur  $F$ , l'angle entre  $P_F^A(A^{-1}q)$  et  $A^{-1}q$  est le plus petit possible. La valeur maximale est  $\|P_F^A(A^{-1}q)\|_A^2$ . En effet, si  $x_0 = P_F^A(A^{-1}q)$ , alors  $(x_0, A^{-1}q)_A = (x_0, x_0)_A = \|x_0\|_A^2$ . Donc  $R_{max} = \frac{\|x_0\|_A^4}{\|x_0\|_A^2} = \|x_0\|_A^2$ . Géométriquement,  $x_0$  est le vecteur dans le sous-espace  $F$  qui est le “plus proche” de  $A^{-1}q$  en termes d'angle dans la géométrie définie par l'opérateur  $A$ .  $R_{max}$  représente le carré de la norme de cette projection dans la métrique  $A$ .

## Conclusion

Le vecteur  $x_0 \in F \setminus \{0\}$  qui maximise la fonction de pertinence sémantique généralisée  $R(x) = \frac{\langle q, x \rangle^2}{\langle x, Ax \rangle}$  est donné par :

$$x_0 = A^{-1/2} P_{A^{1/2}(F)}(A^{-1/2}q)$$

où  $P_{A^{1/2}(F)}$  est l'opérateur de projection orthogonale sur le sous-espace  $A^{1/2}(F)$  par rapport au produit scalaire euclidien standard  $\langle \cdot, \cdot \rangle$ .

La valeur maximale de  $R(x)$  est :

$$R_{max} = \|P_{A^{1/2}(F)}(A^{-1/2}q)\|^2$$

Géométriquement,  $x_0$  est le vecteur (à un facteur d'échelle près) dans le sous-espace  $F$  qui minimise l'angle avec le vecteur  $A^{-1}q$  dans l'espace euclidien  $(E, (\cdot, \cdot)_A)$ , où  $(\cdot, \cdot)_A$  est le produit scalaire défini par  $\langle u, Av \rangle$ . La valeur maximale  $R_{max}$  est le carré de la norme de cette projection  $A$ -orthogonale de  $A^{-1}q$  sur  $F$ , c'est-à-dire  $\|P_F^A(A^{-1}q)\|_A^2$ .

## Exercice 10

### 2.10 Exercice 10 (5 ★) : Opérateur de Cohérence Sémantique et Dualité dans les Espaces de Plongement

#### 2.10.1 Énoncé

Soit  $(V, \langle \cdot, \cdot \rangle)$  un espace vectoriel euclidien de dimension finie  $n \geq 1$ . Soit  $U = \{u_1, \dots, u_k\}$  un ensemble de  $k$  vecteurs non nuls de  $V$ , représentant des “concepts sémantiques” ou des “points d'intérêt” dans un espace de plongement. On suppose, sans perte de généralité, que les vecteurs sont normalisés, c'est-à-dire  $\|u_i\| = 1$  pour tout  $i \in \{1, \dots, k\}$ .

On définit l'opérateur linéaire  $T : V \rightarrow V$  par :

$$T(x) = \sum_{i=1}^k \langle x, u_i \rangle u_i$$

Cet opérateur modélise la “cohérence sémantique” d'un vecteur  $x$  par rapport à l'ensemble  $U$ .

1. Démontrer que  $T$  est un opérateur auto-adjoint.
2. Caractériser le noyau  $\text{Ker}(T)$  et l'image  $\text{Im}(T)$  de  $T$ . Montrer que  $\text{Im}(T) = \text{span}(u_1, \dots, u_k)$ .
3. Soit  $q \in V$  un vecteur non nul. On définit la “mesure de cohérence sémantique” de  $q$  par rapport à  $U$  comme  $C(q) = \frac{\langle q, Tq \rangle}{\|q\|^2}$ .

- a. Montrer que  $C(q) = \sum_{i=1}^k \left( \frac{\langle q, u_i \rangle}{\|q\|} \right)^2$ . Interpréter cette quantité en termes de similarité cosinus.
  - b. Démontrer que les valeurs propres de  $T$  sont réelles et que  $0 \leq \lambda \leq k$  pour toute valeur propre  $\lambda$  de  $T$ .
  - c. Montrer que le maximum de  $C(q)$  sur  $V \setminus \{0\}$  est la plus grande valeur propre de  $T$ . Caractériser les vecteurs  $q$  qui atteignent ce maximum.
4. Soit  $V^*$  le dual de  $V$ . On rappelle que l'application de Riesz  $\Phi : V \rightarrow V^*$  définie par  $\Phi(y)(x) = \langle x, y \rangle$  est un isomorphisme d'espaces vectoriels.
- a. Pour chaque  $u_j \in U$ , on définit la forme linéaire  $f_j = \Phi(u_j) \in V^*$ . Montrer que  $f_j(x) = \langle x, u_j \rangle$ .
  - b. On définit l'opérateur  $T^* : V^* \rightarrow V^*$  par  $T^*(f)(x) = f(T(x))$  pour tout  $f \in V^*$  et  $x \in V$ . Montrer que  $T^*$  est l'opérateur adjoint de  $T$  au sens de la dualité.
  - c. Exprimer  $T^*(f_j)$  en fonction des  $f_i$  et des coefficients de la matrice de Gram  $G_{ij} = \langle u_i, u_j \rangle$ .
  - d. Montrer que  $T^*$  est auto-adjoint par rapport à la forme bilinéaire canonique sur  $V^* \times V^*$  définie par  $\langle f, g \rangle_{V^*} = \langle \Phi^{-1}(f), \Phi^{-1}(g) \rangle_V$ .
  - e. Relier les valeurs propres et les vecteurs propres de  $T^*$  à ceux de  $T$ .

## Concentration de la Mesure en Haute Dimension

Dans le cas où  $d \rightarrow \infty$ , le phénomène de concentration de la mesure stipule que deux vecteurs aléatoires générés uniformément sur la sphère unité  $\mathbb{S}^{d-1}$  seront presque orthogonaux avec une très forte probabilité. La similarité cosinus espérée tendra vers 0, ce qui a des implications profondes pour la malédiction de la dimension dans les réseaux de neurones.

### 2.10.2 Correction Détaillée

#### Analyse et Stratégie

Cet exercice explore les propriétés d'un opérateur linéaire défini à partir d'un ensemble de vecteurs dans un espace euclidien, en le reliant aux concepts de cohérence sémantique, de similarité cosinus et de dualité. La difficulté réside dans la rigueur des démonstrations et la manipulation des concepts abstraits de l'algèbre linéaire avancée.

La première partie (question 1 et 2) se concentre sur les propriétés fondamentales de l'opérateur  $T$  : son auto-adjonction, son noyau et son image. L'auto-adjonction est cruciale car elle garantit la réalité des valeurs propres et l'existence d'une base orthonormée de vecteurs propres, simplifiant l'analyse spectrale. La caractérisation du noyau et de l'image permet de comprendre la structure de l'opérateur et sa relation avec le sous-espace engendré par les vecteurs  $u_i$ .

La deuxième partie (question 3) introduit une mesure de cohérence sémantique, qui est une forme quadratique associée à  $T$ . L'analyse de cette forme quadratique nous mènera naturellement aux valeurs propres de  $T$ . Le théorème variationnel de Rayleigh-Ritz sera implicitement utilisé pour relier le maximum de cette mesure à la plus grande valeur propre. L'interprétation en termes de similarité cosinus est directe et fondamentale pour le contexte de la recherche sémantique.

La troisième partie (question 4) aborde la dualité. Nous utiliserons l'isomorphisme de Riesz pour relier l'espace  $V$  à son dual  $V^*$ . Nous définirons l'opérateur adjoint  $T^*$  sur  $V^*$  et étudierons ses propriétés, notamment son auto-adjonction par rapport à la forme bilinéaire induite sur  $V^*$ . Enfin, nous établirons la correspondance entre les valeurs propres et vecteurs propres de  $T$  et  $T^*$ , démontrant ainsi une symétrie fondamentale entre l'opérateur et son dual.

### Résolution Pas-à-Pas

1. **Démontrer que  $T$  est un opérateur auto-adjoint.** Un opérateur  $T : V \rightarrow V$  est auto-adjoint si  $\langle T(x), y \rangle = \langle x, T(y) \rangle$  pour tous  $x, y \in V$ . Calculons  $\langle T(x), y \rangle$  :

$$\langle T(x), y \rangle = \left\langle \sum_{i=1}^k \langle x, u_i \rangle u_i, y \right\rangle$$

Par la linéarité du produit scalaire par rapport à sa première composante (pour des scalaires réels) :

$$\langle T(x), y \rangle = \sum_{i=1}^k \langle x, u_i \rangle \langle u_i, y \rangle$$

Maintenant, calculons  $\langle x, T(y) \rangle$  :

$$\langle x, T(y) \rangle = \left\langle x, \sum_{j=1}^k \langle y, u_j \rangle u_j \right\rangle$$

Par la linéarité du produit scalaire par rapport à sa seconde composante (pour des scalaires réels) :

$$\langle x, T(y) \rangle = \sum_{j=1}^k \langle y, u_j \rangle \langle x, u_j \rangle$$

Puisque le produit scalaire est symétrique dans un espace euclidien (réel),  $\langle y, u_j \rangle = \langle u_j, y \rangle$ .

$$\langle x, T(y) \rangle = \sum_{j=1}^k \langle u_j, y \rangle \langle x, u_j \rangle$$

En réordonnant les termes et en changeant l'indice de sommation de  $j$  à  $i$  (ce qui est permis car c'est un indice muet) :

$$\langle x, T(y) \rangle = \sum_{i=1}^k \langle x, u_i \rangle \langle u_i, y \rangle$$

Nous avons donc  $\langle T(x), y \rangle = \langle x, T(y) \rangle$  pour tous  $x, y \in V$ . Par conséquent,  $T$  est un opérateur auto-adjoint.

2. **Caractériser le noyau  $\text{Ker}(T)$  et l'image  $\text{Im}(T)$  de  $T$ . Montrer que  $\text{Im}(T) = \text{span}(u_1, \dots, u_k)$ .**

— **Caractérisation de  $\text{Ker}(T)$  :** Un vecteur  $x \in V$  appartient au noyau de  $T$ , noté  $\text{Ker}(T)$ , si et seulement si  $T(x) = 0_V$ .

$$T(x) = \sum_{i=1}^k \langle x, u_i \rangle u_i = 0_V$$

Prenons le produit scalaire de cette équation avec  $x$  :

$$\left\langle \sum_{i=1}^k \langle x, u_i \rangle u_i, x \right\rangle = \langle 0_V, x \rangle$$

Par linéarité du produit scalaire :

$$\sum_{i=1}^k \langle x, u_i \rangle \langle u_i, x \rangle = 0$$

Puisque  $\langle u_i, x \rangle = \langle x, u_i \rangle$  (symétrie du produit scalaire) :

$$\sum_{i=1}^k (\langle x, u_i \rangle)^2 = 0$$

Chaque terme  $(\langle x, u_i \rangle)^2$  est le carré d'un nombre réel, donc il est non négatif. La somme de termes non négatifs est nulle si et seulement si chaque terme est nul.

$$(\langle x, u_i \rangle)^2 = 0 \quad \text{pour tout } i \in \{1, \dots, k\}$$

Ceci implique  $\langle x, u_i \rangle = 0$  pour tout  $i \in \{1, \dots, k\}$ . Donc,  $x \in \text{Ker}(T)$  si et seulement si  $x$  est orthogonal à tous les vecteurs  $u_i$ . Ceci signifie que  $x$  appartient à l'orthogonal du sous-espace engendré par l'ensemble  $U$ . Soit  $L = \text{span}(u_1, \dots, u_k)$ . Alors  $\text{Ker}(T) = L^\perp$ .

— **Caractérisation de  $\text{Im}(T)$  :** L'image de  $T$ , notée  $\text{Im}(T)$ , est l'ensemble des vecteurs  $y \in V$  tels que  $y = T(x)$  pour un certain  $x \in V$ . Par définition de  $T(x)$  :

$$y = T(x) = \sum_{i=1}^k \langle x, u_i \rangle u_i$$

Cette expression montre que tout vecteur  $y$  dans l'image de  $T$  est une combinaison linéaire des vecteurs  $u_1, \dots, u_k$  (avec les coefficients  $\langle x, u_i \rangle$ ). Par conséquent,  $\text{Im}(T) \subseteq \text{span}(u_1, \dots, u_k)$ . Soit  $L = \text{span}(u_1, \dots, u_k)$ . Nous avons donc  $\text{Im}(T) \subseteq L$ .

Puisque  $T$  est un opérateur linéaire sur un espace euclidien de dimension finie, et  $T$  est auto-adjoint (démontré en question 1), nous savons que  $\text{Im}(T) = (\text{Ker}(T))^\perp$ . En utilisant notre résultat pour  $\text{Ker}(T)$  :

$$\text{Im}(T) = (L^\perp)^\perp$$

Dans un espace euclidien de dimension finie, pour tout sous-espace  $L$ , l'orthogonal de l'orthogonal de  $L$  est  $L$  lui-même, c'est-à-dire  $(L^\perp)^\perp = L$ . Donc,  $\text{Im}(T) = L = \text{span}(u_1, \dots, u_k)$ .

3. Soit  $q \in V$  un vecteur non nul. On définit la “mesure de cohérence sémantique” de  $q$  par rapport à  $U$  comme  $C(q) = \frac{\langle q, Tq \rangle}{\|q\|^2}$ .

a. Montrer que  $C(q) = \sum_{i=1}^k \left( \frac{\langle q, u_i \rangle}{\|q\|} \right)^2$ . Interpréter cette quantité en termes de similarité cosinus. Par définition de  $T$  :

$$\langle q, Tq \rangle = \left\langle q, \sum_{i=1}^k \langle q, u_i \rangle u_i \right\rangle$$

Par la linéarité du produit scalaire par rapport à sa seconde composante :

$$\langle q, Tq \rangle = \sum_{i=1}^k \langle q, u_i \rangle \langle q, u_i \rangle = \sum_{i=1}^k (\langle q, u_i \rangle)^2$$

En substituant cette expression dans la définition de  $C(q)$  :

$$C(q) = \frac{\sum_{i=1}^k (\langle q, u_i \rangle)^2}{\|q\|^2}$$

Nous pouvons réécrire chaque terme de la somme en divisant par  $\|q\|^2$  :

$$C(q) = \sum_{i=1}^k \frac{(\langle q, u_i \rangle)^2}{\|q\|^2} = \sum_{i=1}^k \left( \frac{\langle q, u_i \rangle}{\|q\|} \right)^2$$

Interprétation en termes de similarité cosinus : La similarité cosinus entre deux vecteurs non nuls  $a$  et  $b$  est définie par  $\cos(\theta(a, b)) = \frac{\langle a, b \rangle}{\|a\| \|b\|}$ . Dans notre cas, les vecteurs  $u_i$  sont normalisés, c'est-à-dire  $\|u_i\| = 1$ . Ainsi, la similarité cosinus entre  $q$  et  $u_i$  est  $\cos(\theta(q, u_i)) = \frac{\langle q, u_i \rangle}{\|q\| \|u_i\|} = \frac{\langle q, u_i \rangle}{\|q\|}$ . Par conséquent,  $C(q) = \sum_{i=1}^k (\cos(\theta(q, u_i)))^2$ . Cette quantité représente la somme des carrés des similarités cosinus entre le vecteur de requête  $q$  et chacun des vecteurs de concept sémantique  $u_i$ . Une valeur élevée de  $C(q)$  indique que  $q$  est “cohérent” ou “pertinent” par rapport à l'ensemble des concepts  $U$ , car il a une forte similarité avec plusieurs d'entre eux.

- b. **Démontrer que les valeurs propres de  $T$  sont réelles et que  $0 \leq \lambda \leq k$  pour toute valeur propre  $\lambda$  de  $T$ .** Puisque  $T$  est un opérateur auto-adjoint sur un espace euclidien (réel) de dimension finie (démontré en question 1), toutes ses valeurs propres sont nécessairement réelles. C'est un théorème fondamental de la théorie spectrale des opérateurs auto-adjoints.

Soit  $\lambda$  une valeur propre de  $T$  et  $q$  un vecteur propre associé, avec  $q \neq 0_V$ . Par définition,  $T(q) = \lambda q$ . En utilisant la définition de  $C(q)$  :

$$C(q) = \frac{\langle q, Tq \rangle}{\|q\|^2} = \frac{\langle q, \lambda q \rangle}{\|q\|^2}$$

Par la propriété de linéarité du produit scalaire par rapport à sa seconde composante :

$$C(q) = \frac{\lambda \langle q, q \rangle}{\|q\|^2} = \frac{\lambda \|q\|^2}{\|q\|^2} = \lambda$$

D'après la question 3.a, nous savons que  $C(q) = \sum_{i=1}^k \left( \frac{\langle q, u_i \rangle}{\|q\|} \right)^2$ . Puisque chaque terme  $\left( \frac{\langle q, u_i \rangle}{\|q\|} \right)^2$  est le carré d'un nombre réel, il est non négatif. La somme de termes non négatifs est non négative. Donc  $C(q) \geq 0$ . Par conséquent,  $\lambda \geq 0$ .

Pour la borne supérieure, nous utilisons l'inégalité de Cauchy-Schwarz : pour tous  $x, y \in V$ ,  $|\langle x, y \rangle| \leq \|x\| \|y\|$ . Appliquons-la à  $\langle q, u_i \rangle$  :  $|\langle q, u_i \rangle| \leq \|q\| \|u_i\|$ . Puisque  $\|u_i\| = 1$  par hypothèse, nous avons  $|\langle q, u_i \rangle| \leq \|q\|$ . En élevant au carré :  $(\langle q, u_i \rangle)^2 \leq (\|q\|)^2$ . En divisant par  $\|q\|^2$  (qui est non nul car  $q \neq 0_V$ ) :

$$\left( \frac{\langle q, u_i \rangle}{\|q\|} \right)^2 \leq 1$$

En sommant sur  $i$  de 1 à  $k$  :

$$C(q) = \sum_{i=1}^k \left( \frac{\langle q, u_i \rangle}{\|q\|} \right)^2 \leq \sum_{i=1}^k 1 = k$$

Puisque  $\lambda = C(q)$ , nous avons  $\lambda \leq k$ . En combinant les deux inégalités, nous obtenons  $0 \leq \lambda \leq k$  pour toute valeur propre  $\lambda$  de  $T$ .

- c. **Montrer que le maximum de  $C(q)$  sur  $V \setminus \{0\}$  est la plus grande valeur propre de  $T$ . Caractériser les vecteurs  $q$  qui atteignent ce maximum.** La quantité  $C(q) = \frac{\langle q, Tq \rangle}{\|q\|^2}$  est le quotient de Rayleigh de l'opérateur  $T$ . Pour un opérateur auto-adjoint  $T$  sur un espace euclidien de dimension finie, le théorème variationnel de Rayleigh-Ritz stipule que le maximum du quotient de Rayleigh est égal à la plus grande valeur propre de  $T$ . Soit  $\lambda_{\max}$  la plus grande valeur propre de  $T$ . Alors  $\max_{q \in V \setminus \{0\}} C(q) = \lambda_{\max}$ .

Pour caractériser les vecteurs  $q$  qui atteignent ce maximum, nous utilisons la décomposition spectrale. Puisque  $T$  est auto-adjoint, il existe une base orthonormée de

vecteurs propres  $\{e_1, \dots, e_n\}$  de  $V$  telle que  $T(e_j) = \lambda_j e_j$  pour chaque  $j \in \{1, \dots, n\}$ . Nous pouvons ordonner les valeurs propres de manière décroissante :  $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_n$ . Ainsi,  $\lambda_{\max} = \lambda_1$ . Tout vecteur  $q \in V$  peut être écrit comme une combinaison linéaire de ces vecteurs propres :  $q = \sum_{j=1}^n \alpha_j e_j$  pour des scalaires  $\alpha_j \in \mathbb{R}$ . Alors  $\|q\|^2 = \langle q, q \rangle = \left\langle \sum_{j=1}^n \alpha_j e_j, \sum_{l=1}^n \alpha_l e_l \right\rangle$ . Par bilinéarité du produit scalaire et orthogonalité de la base  $\{e_j\}$  ( $\langle e_j, e_l \rangle = \delta_{jl}$ ) :

$$\|q\|^2 = \sum_{j=1}^n \sum_{l=1}^n \alpha_j \alpha_l \langle e_j, e_l \rangle = \sum_{j=1}^n \alpha_j^2$$

De même,  $\langle q, Tq \rangle = \left\langle \sum_{j=1}^n \alpha_j e_j, T \left( \sum_{l=1}^n \alpha_l e_l \right) \right\rangle = \left\langle \sum_{j=1}^n \alpha_j e_j, \sum_{l=1}^n \alpha_l \lambda_l e_l \right\rangle$ .

$$\langle q, Tq \rangle = \sum_{j=1}^n \sum_{l=1}^n \alpha_j \alpha_l \lambda_l \langle e_j, e_l \rangle = \sum_{j=1}^n \alpha_j^2 \lambda_j$$

Donc, le quotient de Rayleigh est :

$$C(q) = \frac{\sum_{j=1}^n \alpha_j^2 \lambda_j}{\sum_{j=1}^n \alpha_j^2}$$

Puisque  $\lambda_j \leq \lambda_1$  pour tout  $j \in \{1, \dots, n\}$  :

$$\sum_{j=1}^n \alpha_j^2 \lambda_j \leq \sum_{j=1}^n \alpha_j^2 \lambda_1 = \lambda_1 \sum_{j=1}^n \alpha_j^2$$

Ainsi,  $C(q) \leq \frac{\lambda_1 \sum_{j=1}^n \alpha_j^2}{\sum_{j=1}^n \alpha_j^2} = \lambda_1$ . Le maximum de  $C(q)$  est donc  $\lambda_1 = \lambda_{\max}$ .

Ce maximum est atteint lorsque l'égalité  $\sum_{j=1}^n \alpha_j^2 \lambda_j = \lambda_1 \sum_{j=1}^n \alpha_j^2$  est vérifiée. Ceci est équivalent à  $\sum_{j=1}^n \alpha_j^2 (\lambda_1 - \lambda_j) = 0$ . Puisque  $\lambda_1 - \lambda_j \geq 0$  et  $\alpha_j^2 \geq 0$  pour tout  $j$ , cette somme est nulle si et seulement si chaque terme est nul :  $\alpha_j^2 (\lambda_1 - \lambda_j) = 0$  pour tout  $j$ . Cela signifie que si  $\lambda_j < \lambda_1$ , alors  $\alpha_j$  doit être nul. Par conséquent,  $q$  doit être une combinaison linéaire des vecteurs propres associés à la valeur propre  $\lambda_1$ . Autrement dit,  $q$  doit appartenir au sous-espace propre  $E_{\lambda_1} = \text{Ker}(T - \lambda_1 I)$ . Les vecteurs  $q$  qui atteignent ce maximum sont les vecteurs propres non nuls de  $T$  associés à la plus grande valeur propre  $\lambda_{\max}$ .

4. Soit  $V^*$  le dual de  $V$ . On rappelle que l'application de Riesz  $\Phi : V \rightarrow V^*$  définie par  $\Phi(y)(x) = \langle x, y \rangle$  est un isomorphisme d'espaces vectoriels.

- a. Pour chaque  $u_j \in U$ , on définit la forme linéaire  $f_j = \Phi(u_j) \in V^*$ . Montrer que  $f_j(x) = \langle x, u_j \rangle$ . Par définition de l'application de Riesz  $\Phi$ , pour tout vecteur  $y \in V$ ,  $\Phi(y)$  est la forme linéaire dans  $V^*$  qui, appliquée à un vecteur  $x \in V$ , donne le produit scalaire  $\langle x, y \rangle$ . En remplaçant  $y$  par  $u_j$ , nous obtenons la forme linéaire  $f_j = \Phi(u_j)$ . Donc, pour tout  $x \in V$  :

$$f_j(x) = \Phi(u_j)(x) = \langle x, u_j \rangle$$

Ceci est la relation demandée.

- b. On définit l'opérateur  $T^* : V^* \rightarrow V^*$  par  $T^*(f)(x) = f(T(x))$  pour tout  $f \in V^*$  et  $x \in V$ . Montrer que  $T^*$  est l'opérateur adjoint de  $T$  au sens de la dualité. L'opérateur adjoint (ou transposé) d'un opérateur linéaire  $T : V \rightarrow V$  est traditionnellement noté  $T^t$  ou  $T^*$ . Il est défini comme l'opérateur  $T^* : V^* \rightarrow V^*$  tel que

pour tout  $f \in V^*$  et tout  $x \in V$ , l'évaluation de la forme linéaire  $T^*(f)$  sur  $x$  est égale à l'évaluation de la forme linéaire  $f$  sur le vecteur  $T(x)$ . La définition donnée dans l'énoncé,  $(T^*(f))(x) = f(T(x))$ , correspond précisément à cette définition standard de l'opérateur transposé (ou adjoint dual) de  $T$ . Par conséquent,  $T^*$  est bien l'opérateur adjoint de  $T$  au sens de la dualité.

- c. **Exprimer  $T^*(f_j)$  en fonction des  $f_i$  et des coefficients de la matrice de Gram  $G_{ij} = \langle u_i, u_j \rangle$ .** Nous voulons exprimer la forme linéaire  $T^*(f_j)$ . Par définition de  $T^*$  :

$$(T^*(f_j))(x) = f_j(T(x)) \quad \text{pour tout } x \in V$$

Substituons l'expression de  $T(x)$  :

$$(T^*(f_j))(x) = f_j\left(\sum_{i=1}^k \langle x, u_i \rangle u_i\right)$$

Puisque  $f_j$  est une forme linéaire, elle est linéaire. Nous pouvons sortir la somme et les scalaires  $\langle x, u_i \rangle$  :

$$(T^*(f_j))(x) = \sum_{i=1}^k \langle x, u_i \rangle f_j(u_i)$$

D'après la question 4.a,  $f_j(u_i) = \langle u_i, u_j \rangle$ . Nous reconnaissons  $\langle u_i, u_j \rangle$  comme le coefficient  $G_{ij}$  de la matrice de Gram  $G$ .

$$(T^*(f_j))(x) = \sum_{i=1}^k \langle x, u_i \rangle G_{ij}$$

Nous savons également que  $\langle x, u_i \rangle = f_i(x)$  d'après la question 4.a.

$$(T^*(f_j))(x) = \sum_{i=1}^k G_{ij} f_i(x)$$

Puisque cette égalité est vraie pour tout  $x \in V$ , les formes linéaires sont égales :

$$T^*(f_j) = \sum_{i=1}^k G_{ij} f_i$$

Ceci exprime  $T^*(f_j)$  comme une combinaison linéaire des formes linéaires  $f_i$ , où les coefficients sont les éléments de la  $j$ -ième colonne de la matrice de Gram  $G$ .

- d. **Montrer que  $T^*$  est auto-adjoint par rapport à la forme bilinéaire canonique sur  $V^* \times V^*$  définie par  $\langle f, g \rangle_{V^*} = \langle \Phi^{-1}(f), \Phi^{-1}(g) \rangle_V$ .** Pour montrer que  $T^*$  est auto-adjoint par rapport à la forme bilinéaire  $\langle \cdot, \cdot \rangle_{V^*}$ , nous devons montrer que  $\langle T^*(f), g \rangle_{V^*} = \langle f, T^*(g) \rangle_{V^*}$  pour tous  $f, g \in V^*$ . Soient  $y_f = \Phi^{-1}(f)$  et  $y_g = \Phi^{-1}(g)$ . Puisque  $\Phi$  est un isomorphisme,  $y_f$  et  $y_g$  sont des vecteurs uniques dans  $V$ . Par définition de  $\Phi$ , nous avons  $f(x) = \langle x, y_f \rangle$  et  $g(x) = \langle x, y_g \rangle$  pour tout  $x \in V$ .

Calculons le membre de gauche de l'égalité à démontrer :

$$\langle T^*(f), g \rangle_{V^*} = \langle \Phi^{-1}(T^*(f)), \Phi^{-1}(g) \rangle_V$$

Nous devons d'abord exprimer  $\Phi^{-1}(T^*(f))$ . Par définition de  $T^*(f)$ ,  $(T^*(f))(x) = f(T(x))$ . En utilisant l'expression de  $f(x) = \langle x, y_f \rangle$  :

$$(T^*(f))(x) = \langle T(x), y_f \rangle$$



Puisque  $T$  est auto-adjoint (démontré en question 1), nous avons  $\langle T(x), y_f \rangle = \langle x, T(y_f) \rangle$ . Donc,  $(T^*(f))(x) = \langle x, T(y_f) \rangle$ . Par définition de l'application de Riesz  $\Phi$ , la forme linéaire  $x \mapsto \langle x, T(y_f) \rangle$  est précisément  $\Phi(T(y_f))$ . Ainsi,  $T^*(f) = \Phi(T(y_f))$ . En appliquant l'isomorphisme inverse  $\Phi^{-1}$  des deux côtés :

$$\Phi^{-1}(T^*(f)) = T(y_f)$$

En substituant  $y_f = \Phi^{-1}(f)$ , nous obtenons :

$$\Phi^{-1}(T^*(f)) = T(\Phi^{-1}(f))$$

Maintenant, nous pouvons reprendre le calcul du membre de gauche :

$$\langle T^*(f), g \rangle_{V^*} = \langle T(\Phi^{-1}(f)), \Phi^{-1}(g) \rangle_V$$

Puisque  $T$  est auto-adjoint sur  $V$ , nous pouvons échanger les arguments du produit scalaire en appliquant  $T$  à l'autre argument :

$$\langle T(\Phi^{-1}(f)), \Phi^{-1}(g) \rangle_V = \langle \Phi^{-1}(f), T(\Phi^{-1}(g)) \rangle_V$$

En utilisant le même raisonnement que précédemment,  $T(\Phi^{-1}(g)) = \Phi^{-1}(T^*(g))$ .

$$\langle \Phi^{-1}(f), T(\Phi^{-1}(g)) \rangle_V = \langle \Phi^{-1}(f), \Phi^{-1}(T^*(g)) \rangle_V$$

Par définition de la forme bilinéaire sur  $V^*$  :

$$\langle \Phi^{-1}(f), \Phi^{-1}(T^*(g)) \rangle_V = \langle f, T^*(g) \rangle_{V^*}$$

Nous avons donc montré que  $\langle T^*(f), g \rangle_{V^*} = \langle f, T^*(g) \rangle_{V^*}$  pour tous  $f, g \in V^*$ . Par conséquent,  $T^*$  est auto-adjoint par rapport à la forme bilinéaire canonique sur  $V^*$ .

- e. **Relier les valeurs propres et les vecteurs propres de  $T^*$  à ceux de  $T$ .** Soit  $\lambda$  une valeur propre de  $T$  et  $q$  un vecteur propre associé, tel que  $T(q) = \lambda q$  avec  $q \neq 0_V$ . Considérons la forme linéaire  $f_q = \Phi(q) \in V^*$ . Puisque  $q \neq 0_V$  et  $\Phi$  est un isomorphisme,  $f_q$  est une forme linéaire non nulle dans  $V^*$ . Appliquons l'opérateur  $T^*$  à  $f_q$  :

$$(T^*(f_q))(x) = f_q(T(x)) \quad \text{pour tout } x \in V$$

En utilisant la définition de  $f_q(y) = \langle y, q \rangle$  :

$$(T^*(f_q))(x) = \langle T(x), q \rangle$$

Puisque  $T$  est auto-adjoint (démontré en question 1),  $\langle T(x), q \rangle = \langle x, T(q) \rangle$ .

$$(T^*(f_q))(x) = \langle x, T(q) \rangle$$

Nous savons que  $T(q) = \lambda q$  (car  $q$  est un vecteur propre de  $T$  associé à  $\lambda$ ) :

$$(T^*(f_q))(x) = \langle x, \lambda q \rangle$$

Par linéarité du produit scalaire par rapport à sa seconde composante :

$$(T^*(f_q))(x) = \lambda \langle x, q \rangle$$

Et nous reconnaissons  $\langle x, q \rangle = f_q(x)$ .

$$(T^*(f_q))(x) = \lambda f_q(x)$$

Puisque cette égalité est vraie pour tout  $x \in V$ , les formes linéaires sont égales :

$$T^*(f_q) = \lambda f_q$$

Ceci montre que si  $\lambda$  est une valeur propre de  $T$ , alors  $\lambda$  est aussi une valeur propre de  $T^*$ . De plus, si  $q$  est un vecteur propre de  $T$  associé à  $\lambda$ , alors  $f_q = \Phi(q)$  est un vecteur propre de  $T^*$  associé à la même valeur propre  $\lambda$ .

Réciproquement, soit  $\mu$  une valeur propre de  $T^*$  et  $f \in V^*$  un vecteur propre associé, tel que  $T^*(f) = \mu f$  avec  $f \neq 0_{V^*}$ . Soit  $y_f = \Phi^{-1}(f) \in V$ . Puisque  $f \neq 0_{V^*}$  et  $\Phi^{-1}$  est un isomorphisme,  $y_f$  est un vecteur non nul dans  $V$ . Nous avons montré en question 4.d que  $\Phi^{-1}(T^*(f)) = T(\Phi^{-1}(f))$ . Appliquons l'isomorphisme  $\Phi^{-1}$  à l'équation  $T^*(f) = \mu f$  :

$$\Phi^{-1}(T^*(f)) = \Phi^{-1}(\mu f)$$

Puisque  $\Phi^{-1}$  est linéaire,  $\Phi^{-1}(\mu f) = \mu \Phi^{-1}(f)$ .

$$T(\Phi^{-1}(f)) = \mu \Phi^{-1}(f)$$

En substituant  $y_f = \Phi^{-1}(f)$  :

$$T(y_f) = \mu y_f$$

Ceci montre que si  $\mu$  est une valeur propre de  $T^*$ , alors  $\mu$  est aussi une valeur propre de  $T$ . De plus, si  $f$  est un vecteur propre de  $T^*$  associé à  $\mu$ , alors  $y_f = \Phi^{-1}(f)$  est un vecteur propre de  $T$  associé à la même valeur propre  $\mu$ .

En conclusion, les opérateurs  $T$  et  $T^*$  ont le même ensemble de valeurs propres. De plus, l'isomorphisme de Riesz  $\Phi$  établit une correspondance bijective entre les sous-espaces propres de  $T$  et ceux de  $T^*$  : si  $E_\lambda$  est le sous-espace propre de  $T$  associé à la valeur propre  $\lambda$ , alors  $\Phi(E_\lambda)$  est le sous-espace propre de  $T^*$  associé à la même valeur propre  $\lambda$ .

## Conclusion

Nous avons rigoureusement analysé les propriétés d'un opérateur de cohérence sémantique  $T$  défini sur un espace euclidien  $V$ . Nous avons établi que  $T$  est auto-adjoint, ce qui garantit la réalité de ses valeurs propres et l'existence d'une base orthonormée de vecteurs propres. Son noyau est l'orthogonal du sous-espace engendré par les vecteurs de concept  $u_i$ , et son image est précisément ce sous-espace.

La mesure de cohérence sémantique  $C(q)$  a été explicitée comme la somme des carrés des similarités cosinus entre une requête  $q$  et les concepts  $u_i$ . Nous avons démontré que les valeurs propres de  $T$  sont bornées entre 0 et  $k$ , et que le maximum de  $C(q)$  est la plus grande valeur propre de  $T$ , atteinte par les vecteurs propres associés. Cela fournit une méthode pour trouver les requêtes "les plus cohérentes" avec un ensemble de concepts.

Enfin, nous avons exploré la dualité en caractérisant l'opérateur transposé  $T^*$  sur le dual  $V^*$ . Nous avons montré que  $T^*$  est également auto-adjoint par rapport à la forme bilinéaire induite sur  $V^*$ . Une correspondance bijective a été établie entre les valeurs propres et les vecteurs propres de  $T$  et  $T^*$  via l'isomorphisme de Riesz, soulignant la symétrie fondamentale entre un opérateur et son dual dans un espace euclidien. Ces résultats fournissent un cadre théorique solide pour la compréhension et l'optimisation des mécanismes de recherche sémantique basés sur la similarité cosinus dans des espaces de plongement.

# Chapitre 3

## Travaux Pratiques

### TP 1

#### 3.1 TP 01 : Géométrie des Espaces Vectoriels et Similarité Cosinus : Un Moteur de Recherche Sémantique Minimaliste et Problème d'Algèbre Linéaire

##### 3.1.1 Objectif Mathématique

Ce Travail Pratique (TP) explore la dualité et la géométrie des espaces de plongement (embedding spaces) à travers l'implémentation "from scratch" de la similarité cosinus. Nous modéliserons des documents textuels comme des vecteurs dans un espace de haute dimension (approche Bag-of-Words), où la direction de ces vecteurs capture leur "sens" sémantique. La similarité cosinus, mesurant l'angle entre deux vecteurs, devient alors une métrique de similarité sémantique.

Le TP illustrera les concepts fondamentaux de l'algèbre linéaire : 1. **Espaces Vectoriels Réels** : Les documents et requêtes sont représentés comme des vecteurs dans  $\mathbb{R}^n$ . 2. **Produit Scalaire (Dot Product)** : Mesure de la projection d'un vecteur sur un autre, base de la notion d'angle. 3. **Norme Euclidienne (Magnitude)** : Longueur d'un vecteur, nécessaire pour la normalisation. 4. **Similarité Cosinus** : Définie par  $\cos(\theta) = \frac{\mathbf{A} \cdot \mathbf{B}}{\|\mathbf{A}\| \|\mathbf{B}\|}$ , elle quantifie la similarité directionnelle entre deux vecteurs, indépendamment de leur magnitude. 5. **Géométrie des Espaces** : L'angle entre vecteurs comme indicateur de proximité sémantique.

En complément, nous aborderons un problème d'algèbre de l'X, en l'occurrence la **projection orthogonale d'un vecteur sur un autre**. Ce concept est fondamental en géométrie euclidienne et en optimisation, et s'appuie directement sur les opérations vectorielles implémentées. La projection orthogonale d'un vecteur  $\mathbf{v}$  sur un vecteur non nul  $\mathbf{u}$  est donnée par  $\text{proj}_{\mathbf{u}} \mathbf{v} = \frac{\mathbf{u} \cdot \mathbf{v}}{\|\mathbf{u}\|^2} \mathbf{u}$ . Elle représente la composante de  $\mathbf{v}$  qui est parallèle à  $\mathbf{u}$ .

##### Analyse Algorithmique Strictement Bornée

Le calcul séquentiel de  $\sum_{i=1}^d u_i v_i$  exige une complexité temporelle stricte de  $\mathcal{O}(d)$ , où  $d = \dim(E)$ . La normalisation des vecteurs maintient une empreinte spatiale de  $\mathcal{O}(1)$  supplémentaire. L'efficacité en Python pur repose sur les itérateurs.

##### 3.1.2 Implémentation Python Pure

```
1 \CommentTok{\# {-}{-}{-} Partie 1 : Fonctions Mathématiques de Base (
   From Scratch) {-}{-}{-}}
2
3 \KeywordTok{def}\NormalTok{ square\_root}(n, epsilon)\OperatorTok{=}\
   FloatTok{1e{-}9}\NormalTok{ :}
```

```

4 \CommentTok{""}
5 \CommentTok{ Calcule la racine carrée d\textquotesingle{}un nombre
  non négatif en utilisant la méthode de Newton.}
6 \CommentTok{ Implémentation "from scratch" sans math.sqrt.}
7 \CommentTok{""}
8 \ControlFlowTok{if}\NormalTok{ n }\OperatorTok{\textless{}} \
  DecValTok{0}\NormalTok{:}
9 \ControlFlowTok{raise} \PreprocessorTok{ValueError}\NormalTok{
  {(}\StringTok{"Cannot compute square root of a negative
  number."}\NormalTok{)}
10 \ControlFlowTok{if}\NormalTok{ n }\OperatorTok{==} \DecValTok{0}\
  NormalTok{:}
11 \ControlFlowTok{return} \FloatTok{0.0}
12 \NormalTok{ x }\OperatorTok{=}\NormalTok{ n }\OperatorTok{/} \
  FloatTok{2.0} \CommentTok{ \# Première estimation}
13 \ControlFlowTok{while} \VariableTok{True}\NormalTok{:}
14 \NormalTok{ next\_x }\OperatorTok{=}\FloatTok{0.5} \OperatorTok{*}\NormalTok{
  (x }\OperatorTok{+}\NormalTok{ n }\OperatorTok{/}\NormalTok{ x)}
15 \ControlFlowTok{if} \BuiltInTok{abs}\NormalTok{(x }\OperatorTok{-}
  next\_x)\OperatorTok{\textless{}}\
  NormalTok{ epsilon:}
16 \ControlFlowTok{return} \NormalTok{ next\_x}
17 \NormalTok{ x }\OperatorTok{=}\NormalTok{ next\_x}
18
19 \CommentTok{ \# Assertions pour square\_root}
20 \ControlFlowTok{assert} \BuiltInTok{abs}\NormalTok{(square\_root(}
  DecValTok{4}\NormalTok{)}\OperatorTok{-}\FloatTok{2.0}\NormalTok{)}\
  \OperatorTok{\textless{}}\FloatTok{1e{-}7}\NormalTok{, }\StringTok{"square\_root(4) should be 2.0"}
21 \ControlFlowTok{assert} \BuiltInTok{abs}\NormalTok{(square\_root(}
  DecValTok{9}\NormalTok{)}\OperatorTok{-}\FloatTok{3.0}\NormalTok{)}\
  \OperatorTok{\textless{}}\FloatTok{1e{-}7}\NormalTok{, }\StringTok{"square\_root(9) should be 3.0"}
22 \ControlFlowTok{assert} \BuiltInTok{abs}\NormalTok{(square\_root(}
  DecValTok{0}\NormalTok{)}\OperatorTok{-}\FloatTok{0.0}\NormalTok{)}\
  \OperatorTok{\textless{}}\FloatTok{1e{-}7}\NormalTok{, }\StringTok{"square\_root(0) should be 0.0"}
23 \ControlFlowTok{assert} \BuiltInTok{abs}\NormalTok{(square\_root(}
  FloatTok{25.0}\NormalTok{)}\OperatorTok{-}\FloatTok{5.0}\NormalTok{)}\
  \OperatorTok{\textless{}}\FloatTok{1e{-}7}\NormalTok{, }\StringTok{"square\_root(25.0) should be 5.0"}
24 \ControlFlowTok{assert} \BuiltInTok{abs}\NormalTok{(square\_root(}
  DecValTok{2}\NormalTok{)}\OperatorTok{-}\FloatTok{1.41421356237}\NormalTok{)}\
  \OperatorTok{\textless{}}\FloatTok{1e{-}7}\NormalTok{, }\StringTok{"square\_root(2) should be approx 1.414"}
25 \ControlFlowTok{try}\NormalTok{:}
26 \NormalTok{ square\_root(}\OperatorTok{-}1)\DecValTok{1}\NormalTok{)}\
27 \ControlFlowTok{assert} \VariableTok{False}\NormalTok{, }\StringTok{"square\_root(-1) should raise ValueError"}
28 \ControlFlowTok{except} \PreprocessorTok{ValueError}\NormalTok{:}
29 \ControlFlowTok{assert} \VariableTok{True}\NormalTok{, }\StringTok{"square\_root(-1) correctly raised ValueError"}
30 \BuiltInTok{print}\NormalTok{(}\StringTok{"square\_root assertions
  passed."}\NormalTok{)}
31
32 \KeywordTok{def} \NormalTok{ vector\_add(v1, v2):}
33 \CommentTok{"Additionne deux vecteurs de même dimension."}

```

```

34 \ControlFlowTok{if} \BuiltInTok{len}\NormalTok{(v1) }\OperatorTok
    {!=} \BuiltInTok{len}\NormalTok{(v2):}
35 \ControlFlowTok{raise} \PreprocessorTok{ValueError}\NormalTok
    {(}\StringTok{"Vectors must have the same dimension."}\
    NormalTok{)}
36 \ControlFlowTok{return}\NormalTok{ [v1[i] ]\OperatorTok{+}\NormalTok
    { v2[i] }\ControlFlowTok{for}\NormalTok{ i }\KeywordTok{in} \
    BuiltInTok{range}\NormalTok{(}\BuiltInTok{len}\NormalTok{(v1))}]
37
38 \KeywordTok{def}\NormalTok{ scalar\_multiply(scalar, v):}
39 \CommentTok{"\"\"\"Multiplie un vecteur par un scalaire.\"\""}
40 \ControlFlowTok{return}\NormalTok{ [scalar ]\OperatorTok{*}\
    NormalTok{ x }\ControlFlowTok{for}\NormalTok{ x }\KeywordTok{in}\
    NormalTok{ v}]
41
42 \KeywordTok{def}\NormalTok{ dot\_product(v1, v2):}
43 \CommentTok{"\"\"\"Calcule le produit scalaire (dot product) de deux
    vecteurs.\"\""}
44 \ControlFlowTok{if} \BuiltInTok{len}\NormalTok{(v1) }\OperatorTok
    {!=} \BuiltInTok{len}\NormalTok{(v2):}
45 \ControlFlowTok{raise} \PreprocessorTok{ValueError}\NormalTok
    {(}\StringTok{"Vectors must have the same dimension."}\
    NormalTok{)}
46 \ControlFlowTok{return} \BuiltInTok{sum}\NormalTok{(v1[i] }\
    OperatorTok{*}\NormalTok{ v2[i] }\ControlFlowTok{for}\NormalTok{ i }\
    KeywordTok{in} \BuiltInTok{range}\NormalTok{(}\BuiltInTok{len}
    \NormalTok{(v1)))}
47
48 \KeywordTok{def}\NormalTok{ vector\_magnitude(v):}
49 \CommentTok{"\"\"\"Calcule la norme Euclidienne (magnitude) d\
    textquotesingle{un vecteur.\"\""}
50 \ControlFlowTok{return}\NormalTok{ square\_root(dot\_product(v, v))}
51
52 \KeywordTok{def}\NormalTok{ normalize\_vector(v):}
53 \CommentTok{"\"\"\"Normalise un vecteur (le transforme en vecteur
    unitaire).\"\""}
54 \NormalTok{ magnitude }\OperatorTok{=}\NormalTok{ vector\_magnitude(v
    )}
55 \ControlFlowTok{if}\NormalTok{ magnitude }\OperatorTok{==} \
    DecValTok{0}\NormalTok{:}
56 \ControlFlowTok{return}\NormalTok{ [}\FloatTok{0.0}\NormalTok{ }\
    OperatorTok{*} \BuiltInTok{len}\NormalTok{(v) }\CommentTok
    {\# Vecteur nul reste nul}
57 \ControlFlowTok{return}\NormalTok{ scalar\_multiply(}\FloatTok{1.0}
    \OperatorTok{/}\NormalTok{ magnitude, v)}
58
59 \CommentTok{\# Assertions pour les opérations vectorielles}
60 \NormalTok{v\_a }\OperatorTok{=}\NormalTok{ [}\DecValTok{1}\NormalTok{ }\DecValTok{2}\NormalTok{ }\DecValTok{3}\NormalTok{ },
    }\DecValTok{4}\NormalTok{ }\DecValTok{5}\NormalTok{ }\DecValTok{6}\NormalTok{ }
61 \NormalTok{v\_b }\OperatorTok{=}\NormalTok{ [}\DecValTok{4}\NormalTok{ }\DecValTok{5}\NormalTok{ }\DecValTok{6}\NormalTok{ }\DecValTok{7}\NormalTok{ }\DecValTok{8}\NormalTok{ }\DecValTok{9}\NormalTok{ },
    }\DecValTok{10}\NormalTok{ }\DecValTok{11}\NormalTok{ }\DecValTok{12}\NormalTok{ }
62 \NormalTok{v\_c }\OperatorTok{=}\NormalTok{ [}\DecValTok{0}\NormalTok{ }\DecValTok{0}\NormalTok{ }\DecValTok{0}\NormalTok{ }\DecValTok{0}\NormalTok{ }\DecValTok{0}\NormalTok{ }\DecValTok{0}\NormalTok{ },
    }\DecValTok{0}\NormalTok{ }\DecValTok{0}\NormalTok{ }\DecValTok{0}\NormalTok{ }\DecValTok{0}\NormalTok{ }\DecValTok{0}\NormalTok{ }
63 \NormalTok{v\_d }\OperatorTok{=}\NormalTok{ [}\DecValTok{3}\NormalTok{ }\DecValTok{4}\NormalTok{ }\DecValTok{5}\NormalTok{ }\DecValTok{6}\NormalTok{ }\DecValTok{7}\NormalTok{ }\DecValTok{8}\NormalTok{ },
    }\DecValTok{9}\NormalTok{ }\DecValTok{10}\NormalTok{ }\DecValTok{11}\NormalTok{ }
64
65 \ControlFlowTok{assert}\NormalTok{ vector\_add(v\_a, v\_b) }\OperatorTok
    {==}\NormalTok{ [}\DecValTok{5}\NormalTok{ }\DecValTok{6}\NormalTok{ }\DecValTok{7}\NormalTok{ }\DecValTok{8}\NormalTok{ }\DecValTok{9}\NormalTok{ }\DecValTok{10}\NormalTok{ },
    }\DecValTok{11}\NormalTok{ }\DecValTok{12}\NormalTok{ }\DecValTok{13}\NormalTok{ }

```

```

    {, }\DecValTok{9}\NormalTok{[, }\StringTok{"vector\_add failed"}
66 \ControlFlowTok{assert}\NormalTok{ scalar\_multiply()\DecValTok{2}\
    NormalTok{, v\_a) }\OperatorTok{==}\NormalTok{ [\DecValTok{2}\
    NormalTok{, }\DecValTok{4}\NormalTok{[, }\DecValTok{6}\NormalTok{[, }\StringTok{"scalar\_multiply failed"}
67 \ControlFlowTok{assert}\NormalTok{ dot\_product(v\_a, v\_b) }\
    OperatorTok{==} \DecValTok{32}\NormalTok{[, }\StringTok{"dot\_product
    failed"} \CommentTok{\# 1*4 + 2*5 + 3*6 = 4 + 10 + 18 = 32}
68 \ControlFlowTok{assert} \BuiltInTok{abs}\NormalTok{(vector\_magnitude(v
    _d) }\OperatorTok{{-}} \FloatTok{5.0}\NormalTok{) }\OperatorTok{\
    textless{}} \FloatTok{1e{-}7}\NormalTok{[, }\StringTok{"vector\
    _magnitude failed for [3,4]"} \CommentTok{\# sqrt(3\^{2} + 4\^{2}) =
    sqrt(9+16) = sqrt(25) = 5}
69 \NormalTok{normalized\_v\_d }\OperatorTok{=}\NormalTok{ normalize\
    _vector([\DecValTok{3}\NormalTok{[, }\DecValTok{4}\NormalTok{])}
70 \ControlFlowTok{assert} \BuiltInTok{abs}\NormalTok{(normalized\_v\_d[\DecValTok{0}\NormalTok{]\
    }\OperatorTok{{-}} \FloatTok{0.6}\NormalTok{) }\OperatorTok{\textless{}} \FloatTok{1e{-}7} \KeywordTok{and} \
    BuiltInTok{abs}\NormalTok{(normalized\_v\_d[\DecValTok{1}\NormalTok{]\
    }\OperatorTok{{-}} \FloatTok{0.8}\NormalTok{) }\OperatorTok{\
    textless{}} \FloatTok{1e{-}7}\NormalTok{[, }\StringTok{"normalize\
    _vector failed"}
71 \ControlFlowTok{assert}\NormalTok{ normalize\_vector(v\_c) }\OperatorTok{
    ==}\NormalTok{ [\FloatTok{0.0}\NormalTok{[, }\FloatTok{0.0}\
    NormalTok{, }\FloatTok{0.0}\NormalTok{[, }\StringTok{"normalize\
    _vector of zero vector failed"}
72 \ControlFlowTok{try}\NormalTok{:}
73 \NormalTok{ dot\_product(v\_a, v\_d)}
74 \ControlFlowTok{assert} \VariableTok{False}\NormalTok{[, }\StringTok{
    "dot\_product with different dimensions should raise ValueError"}
75 \ControlFlowTok{except} \PreprocessorTok{ValueError}\NormalTok{:}
76 \ControlFlowTok{assert} \VariableTok{True}\NormalTok{[, }\StringTok{
    "dot\_product with different dimensions correctly raised
    ValueError"}
77 \BuiltInTok{print}\NormalTok{(\StringTok{"Vector operations assertions
    passed."}\NormalTok{)}
78
79 \KeywordTok{def}\NormalTok{ cosine\_similarity(v1, v2):}
80 \CommentTok{"""}
81 \CommentTok{    Calcule la similarité cosinus entre deux vecteurs.}
82 \CommentTok{    Retourne 0.0 si l'un des vecteurs est
    nul.}
83 \CommentTok{"""}
84 \ControlFlowTok{if} \BuiltInTok{len}\NormalTok{(v1) }\OperatorTok{
    !=} \BuiltInTok{len}\NormalTok{(v2):}
85 \ControlFlowTok{raise} \PreprocessorTok{ValueError}\NormalTok{
    {(\StringTok{"Vectors must have the same dimension."}\
    NormalTok{)}
86
87 \NormalTok{ dot\_p }\OperatorTok{=}\NormalTok{ dot\_product(v1, v2)}
88 \NormalTok{ mag\_v1 }\OperatorTok{=}\NormalTok{ vector\_magnitude(v1)
    }
89 \NormalTok{ mag\_v2 }\OperatorTok{=}\NormalTok{ vector\_magnitude(v2)
    }
90
91 \ControlFlowTok{if}\NormalTok{ mag\_v1 }\OperatorTok{==} \DecValTok
    {0} \KeywordTok{or}\NormalTok{ mag\_v2 }\OperatorTok{==} \
    DecValTok{0}\NormalTok{:}

```

```

92 \ControlFlowTok{return} \FloatTok{0.0} \CommentTok{\# La
    similarité avec un vecteur nul est indéfinie ou souvent
    considérée comme 0.0}
93
94 \ControlFlowTok{return}\NormalTok{ dot\_p }\OperatorTok{/}\NormalTok{
    { (mag\_v1 }\OperatorTok{*}\NormalTok{ mag\_v2)}
95
96 \CommentTok{\# Assertions pour cosine\_similarity}
97 \NormalTok{v\_e }\OperatorTok{=}\NormalTok{ [ ]\DecValTok{1}\NormalTok{ { ,
    }\DecValTok{0}\NormalTok{ { }
98 \NormalTok{v\_f }\OperatorTok{=}\NormalTok{ [ ]\DecValTok{0}\NormalTok{ { ,
    }\DecValTok{1}\NormalTok{ { }
99 \NormalTok{v\_g }\OperatorTok{=}\NormalTok{ [ ]\DecValTok{1}\NormalTok{ { ,
    }\DecValTok{1}\NormalTok{ { }
100 \NormalTok{v\_h }\OperatorTok{=}\NormalTok{ [ ]\OperatorTok{{-}}\
    DecValTok{1}\NormalTok{ { , }\OperatorTok{{-}}\DecValTok{1}\NormalTok{ { }
101
102 \ControlFlowTok{assert} \BuiltInTok{abs}\NormalTok{ {(cosine\_similarity(v
    \_e, v\_e) }\OperatorTok{{-}} \FloatTok{1.0}\NormalTok{ { } \
    OperatorTok{\textless{}} \FloatTok{1e{-}7}\NormalTok{ { , }\StringTok{"
    Cosine similarity with itself should be 1.0"}
103 \ControlFlowTok{assert} \BuiltInTok{abs}\NormalTok{ {(cosine\_similarity(v
    \_e, v\_f) }\OperatorTok{{-}} \FloatTok{0.0}\NormalTok{ { } \
    OperatorTok{\textless{}} \FloatTok{1e{-}7}\NormalTok{ { , }\StringTok{"
    Cosine similarity of orthogonal vectors should be 0.0"}
104 \ControlFlowTok{assert} \BuiltInTok{abs}\NormalTok{ {(cosine\_similarity(v
    \_g, v\_h) }\OperatorTok{{-}}\NormalTok{ { (}\OperatorTok{{-}}\FloatTok{
    1.0}\NormalTok{ { }) }\OperatorTok{\textless{}} \FloatTok{1e{-}7}\
    NormalTok{ { , }\StringTok{"Cosine similarity of opposite vectors should
    be {-}1.0"}
105 \ControlFlowTok{assert} \BuiltInTok{abs}\NormalTok{ {(cosine\_similarity(v
    \_g, v\_e) }\OperatorTok{{-}}\NormalTok{ { (}\FloatTok{1.0} \
    OperatorTok{/}\NormalTok{ { square\_root(}\DecValTok{2}\NormalTok{ { }) )
    }\OperatorTok{\textless{}} \FloatTok{1e{-}7}\NormalTok{ { , }\StringTok{
    "Cosine similarity of [1,1] and [1,0] failed"}
106 \ControlFlowTok{assert} \BuiltInTok{abs}\NormalTok{ {(cosine\_similarity
    ([ ]\DecValTok{0}\NormalTok{ { , }\DecValTok{0}\NormalTok{ { } , [ ]\DecValTok
    {1}\NormalTok{ { , }\DecValTok{1}\NormalTok{ { } ) }\OperatorTok{{-}} \
    FloatTok{0.0}\NormalTok{ { } }\OperatorTok{\textless{}} \FloatTok{1e
    {-}7}\NormalTok{ { , }\StringTok{"Cosine similarity with zero vector
    should be 0.0"}
107 \BuiltInTok{print}\NormalTok{ {(}\StringTok{"cosine\_similarity assertions
    passed."}\NormalTok{ { }
108
109 \CommentTok{\# {-}{-}{-} Partie 2 : Moteur de Recherche Sémantique
    Minimaliste {-}{-}{-}}
110
111 \KeywordTok{def}\NormalTok{ build\_vocabulary(documents):}
112 \CommentTok{"""}
113 \CommentTok{    Construit un vocabulaire unique à partir d\
    textquotesingle{ }une liste de documents.}
114 \CommentTok{    Retourne un dictionnaire \{mot: index\}.}
115 \CommentTok{"""}
116 \NormalTok{ vocabulary }\OperatorTok{=}\NormalTok{ { }\}
117 \NormalTok{ word\_index }\OperatorTok{=}\NormalTok{ \DecValTok{0}
118 \ControlFlowTok{for}\NormalTok{ doc }\KeywordTok{in}\NormalTok{ documents:}

```

```

119 \CommentTok{\# Simple tokenisation : divise par les espaces et
    convertit en minuscules}
120 \ControlFlowTok{for}\NormalTok{ word }\KeywordTok{in}\NormalTokTok{
    doc.lower().split():}
121 \ControlFlowTok{if}\NormalTok{ word }\KeywordTok{not} \
    KeywordTok{in}\NormalTok{ vocabulary:}
122 \NormalTok{
    vocabulary[word] }\OperatorTok{=}\NormalTokTok{
    word\_index}
123 \NormalTok{
    word\_index }\OperatorTok{+=} \DecValTok{1}
124 \ControlFlowTok{return}\NormalTok{ vocabulary}
125
126 \KeywordTok{def}\NormalTok{ document\_to\_vector(document, vocabulary):}
127 \CommentTok{"""}
128 \CommentTok{    Convertit un document en un vecteur Bag{-}of{-}Words (
    BoW) basé sur le vocabulaire.}
129 \CommentTok{    Chaque élément du vecteur représente la fréquence d\
    textquotesingle{}un mot dans le document.}
130 \CommentTok{"""}
131 \NormalTok{
    vector }\OperatorTok{=}\NormalTok{ []}\DecValTok{0}\
    NormalTok{[] }\OperatorTok{*} \BuiltInTok{len}\NormalTok{(vocabulary)}
132 \ControlFlowTok{for}\NormalTok{ word }\KeywordTok{in}\NormalTok{
    document.lower().split():}
133 \ControlFlowTok{if}\NormalTok{ word }\KeywordTok{in}\NormalTok{
    vocabulary:}
134 \NormalTok{
    vector[vocabulary[word]] }\OperatorTok{+=} \
    DecValTok{1}
135 \ControlFlowTok{return}\NormalTok{ vector}
136
137 \KeywordTok{def}\NormalTok{ search\_documents(query\_text, documents,
    top\_k)\OperatorTok{=}\DecValTok{3}\NormalTok{():}
138 \CommentTok{"""}
139 \CommentTok{    Effectue une recherche sémantique basée sur la similarit
    é cosinus.}
140 \CommentTok{    Retourne une liste de tuples (similarité, document) trié
    e par similarité décroissante.}
141 \CommentTok{"""}
142 \CommentTok{\# 1. Construire le vocabulaire global à partir de tous
    les documents et de la requête}
143 \NormalTok{
    all\_texts }\OperatorTok{=}\NormalTok{ documents }\
    OperatorTok{+}\NormalTok{ [query\_text]}
144 \NormalTok{
    vocabulary }\OperatorTok{=}\NormalTok{ build\_vocabulary(
    all\_texts)}
145
146 \CommentTok{\# 2. Convertir tous les documents en vecteurs BoW}
147 \NormalTok{
    document\_vectors }\OperatorTok{=}\NormalTok{ []}
148 \ControlFlowTok{for}\NormalTok{ doc }\KeywordTok{in}\NormalTok{
    documents:}
149 \NormalTok{
    document\_vectors.append(document\_to\_vector(doc,
    vocabulary))}
150
151 \CommentTok{\# 3. Convertir la requête en vecteur BoW}
152 \NormalTok{
    query\_vector }\OperatorTok{=}\NormalTok{ document\_to\_
    _vector(query\_text, vocabulary)}
153
154 \CommentTok{\# 4. Calculer la similarité cosinus entre la requête et
    chaque document}
155 \NormalTok{
    similarities }\OperatorTok{=}\NormalTok{ []}

```



```

156 \ControlFlowTok{for}\NormalTok{ i, doc\_vec }\KeywordTok{in} \
    BuiltInTok{enumerate}\NormalTok{((document\_vectors):}
157 \NormalTok{
    sim }\OperatorTok{=}\NormalTok{ cosine\_similarity(}
    query\_vector, doc\_vec)}
158 \NormalTok{
    similarities.append((sim, documents[i]))}
159
160 \CommentTok{\# 5. Trier par similarité et retourner les top\_k ré
    sultats}
161 \NormalTok{
    similarities.sort(key)\OperatorTok{=}\KeywordTok{lambda}\
    NormalTok{ x: x[]\DecValTok{0}\NormalTok{[], reverse}\OperatorTok{=}\
    VariableTok{True}\NormalTok{)}
162 \ControlFlowTok{return}\NormalTok{ similarities[:top\_k]}
163
164 \CommentTok{\# Assertions pour le moteur de recherche sémantique}
165 \NormalTok{corpus }\OperatorTok{=}\NormalTok{ []}
166 \StringTok{"Le chat dort sur le tapis."}\NormalTok{,,}
167 \StringTok{"Le chien joue avec la balle."}\NormalTok{,,}
168 \StringTok{"Un chat noir et blanc."}\NormalTok{,,}
169 \StringTok{"Le tapis est doux."}\NormalTok{,,}
170 \StringTok{"La balle est ronde."}
171 \NormalTok{[]}
172
173 \NormalTok{vocab }\OperatorTok{=}\NormalTok{ build\_vocabulary(corpus)}
174 \ControlFlowTok{assert} \StringTok{"chat"} \KeywordTok{in}\NormalTok{ vocab }
    \KeywordTok{and} \StringTok{"tapis"} \KeywordTok{in}\NormalTok{ vocab , }
    \StringTok{"Vocabulary should contain key words"}
175 \ControlFlowTok{assert} \BuiltInTok{len}\NormalTok{((vocab) }\OperatorTok{
    \textgreater{}} \DecValTok{5}\NormalTok{, )}\StringTok{"Vocabulary
    should have multiple words"}
176
177 \NormalTok{doc\_vec\_0 }\OperatorTok{=}\NormalTok{ document\_to\_vector(}
    corpus[]\DecValTok{0}\NormalTok{[], vocab)}
178 \ControlFlowTok{assert} \BuiltInTok{sum}\NormalTok{((doc\_vec\_0) }\
    OperatorTok{=}\NormalTok{ \BuiltInTok{len}\NormalTok{((corpus[]\DecValTok{0}\
    NormalTok{[]).split()), )}\StringTok{"Document vector sum should match
    word count"}
179 \ControlFlowTok{assert}\NormalTok{ doc\_vec\_0[vocab[]\StringTok{"chat"}
    }\NormalTok{[] }\OperatorTok{=}\NormalTok{ \DecValTok{1}\NormalTok{, )}\
    StringTok{"Vector for \textquotesingle{}chat\textquotesingle{} count
    failed"}
180
181 \CommentTok{\# Test de recherche}
182 \NormalTok{query\_1 }\OperatorTok{=}\StringTok{"un chat doux"}
183 \NormalTok{results\_1 }\OperatorTok{=}\NormalTok{ search\_documents(}
    query\_1, corpus, top\_k}\OperatorTok{=}\NormalTok{ \DecValTok{2}\NormalTok{)}
184
185 \CommentTok{\# Vérifions que les documents contenant "chat" ou "doux"
    sont bien classés.}
186 \CommentTok{\# L'ordre exact peut varier légèrement en
    fonction de la composition du vocabulaire}
187 \CommentTok{\# et des mots communs, mais les documents pertinents
    doivent être en tête.}
188 \ControlFlowTok{assert}\NormalTok{ results\_1[]\DecValTok{0}\NormalTok{
    []\DecValTok{0}\NormalTok{[] }\OperatorTok{\textgreater{}}\
    NormalTok{ results\_1[]\DecValTok{1}\NormalTok{[]\DecValTok{0}\
    NormalTok{[], }\StringTok{"Results should be sorted by similarity"}
189 \ControlFlowTok{assert} \BuiltInTok{any}\NormalTok{({}\StringTok{"chat"}
    \KeywordTok{in}\NormalTok{ res[]\DecValTok{1}\NormalTok{[]}.lower() )\

```

```

ControlFlowTok{for}\NormalTok{ res }\KeywordTok{in}\NormalTokTok{
  results\_1), }\StringTok{"Top results should contain \textquotesingle
  {}chat\textquotesingle{} or related terms"}
190 \ControlFlowTok{assert} \BuiltInTok{any}\NormalTokTok{({}\StringTok{"doux"}
  \KeywordTok{in}\NormalTokTok{ res []\DecValTok{1}\NormalTokTok{.lower() }\
  KeywordTok{or} \StringTok{"tapis"} \KeywordTok{in}\NormalTokTok{ res []\
  DecValTok{1}\NormalTokTok{.lower() }\ControlFlowTok{for}\NormalTokTok{ res
  }\KeywordTok{in}\NormalTokTok{ results\_1), }\StringTok{"Top results
  should contain \textquotesingle{}doux\textquotesingle{} or related
  terms"}
191 \ControlFlowTok{assert}\NormalTokTok{ results\_1 []\DecValTok{0}\NormalTokTok{
  {} []\DecValTok{0}\NormalTokTok{ } \OperatorTok{\textgreater}\FloatTok{
  0.0}\NormalTokTok{, }\StringTok{"Similarity should be positive for
  relevant documents"}
192 \BuiltInTok{print}\NormalTokTok{({}\StringTok{"Semantic search assertions
  passed."}\NormalTokTok{)}
193
194 \CommentTok{\# {-}{-}{-} Partie 3 : Problème d\textquotesingle{}Algèbre
  de l\textquotesingle{}X : Projection Orthogonale {-}{-}{-}}
195
196 \KeywordTok{def}\NormalTokTok{ orthogonal\_projection(u, v):}
197   \CommentTok{"""}
198   \CommentTok{    Calcule la projection orthogonale du vecteur v sur le
  vecteur u.}
199   \CommentTok{    proj\_u(v) = (u . v / ||u||^2) * u}
200   \CommentTok{    """}
201   \ControlFlowTok{if} \BuiltInTok{len}\NormalTokTok{(u) }\OperatorTok{!=}
  \BuiltInTok{len}\NormalTokTok{(v):}
202   \ControlFlowTok{raise} \PreprocessorTok{ValueError}\NormalTokTok{
  {({}\StringTok{"Vectors must have the same dimension."}\
  NormalTok{)} }
203
204 \NormalTokTok{    dot\_uu }\OperatorTok{=}\NormalTokTok{ dot\_product(u, u)}
205   \ControlFlowTok{if}\NormalTokTok{ dot\_uu }\OperatorTok{=}\DecValTok{
  0}\NormalTokTok{:}
206   \ControlFlowTok{raise} \PreprocessorTok{ValueError}\NormalTokTok{
  {({}\StringTok{"Cannot project onto a zero vector."}\NormalTokTok{
  {} )}
207
208 \NormalTokTok{    scalar\_factor }\OperatorTok{=}\NormalTokTok{ dot\_product(u
  , v) }\OperatorTok{/}\NormalTokTok{ dot\_uu}
209   \ControlFlowTok{return}\NormalTokTok{ scalar\_multiply(scalar\_factor,
  u)}
210
211 \CommentTok{\# Assertions pour la projection orthogonale}
212 \NormalTokTok{u1 }\OperatorTok{=}\NormalTokTok{ []\DecValTok{1}\NormalTokTok{, }\
  DecValTok{0}\NormalTokTok{]}
213 \NormalTokTok{v1 }\OperatorTok{=}\NormalTokTok{ []\DecValTok{2}\NormalTokTok{, }\
  DecValTok{2}\NormalTokTok{]}
214 \NormalTokTok{proj1 }\OperatorTok{=}\NormalTokTok{ orthogonal\_projection(u1,
  v1)}
215 \CommentTok{\# La projection de [2,2] sur l\textquotesingle{}axe des x
  ([1,0]) est [2,0]}
216 \ControlFlowTok{assert}\NormalTokTok{ proj1 }\OperatorTok{=}\NormalTokTok{
  []\FloatTok{2.0}\NormalTokTok{, }\FloatTok{0.0}\NormalTokTok{, }\StringTok{
  "Projection of [2,2] onto [1,0] should be [2,0]"}
217

```

```

218 \NormalTok{u2 }\OperatorTok{=}\NormalTok{[ ]\DecValTok{1}\NormalTok{, }\DecValTok{1}\NormalTok{[]}}
219 \NormalTok{v2 }\OperatorTok{=}\NormalTok{[ ]\DecValTok{0}\NormalTok{, }\DecValTok{1}\NormalTok{[]}}
220 \NormalTok{proj2 }\OperatorTok{=}\NormalTok{orthogonal\_projection(u2, v2)}
221 \CommentTok{\# u.v = (1*0 + 1*1) = 1}
222 \CommentTok{\# ||u||^2 = (1*1 + 1*1) = 2}
223 \CommentTok{\# scalar\_factor = 1/2}
224 \CommentTok{\# proj2 = 0.5 * [1,1] = [0.5, 0.5]}
225 \ControlFlowTok{assert}\NormalTok{proj2 }\OperatorTok{=}\NormalTok{[ ]\FloatTok{0.5}\NormalTok{, }\FloatTok{0.5}\NormalTok{[]}, }\StringTok{"Projection of [0,1] onto [1,1] should be [0.5, 0.5]"}
226
227 \CommentTok{\# Vérification d\textquotesingle{}orthogonalité : le vecteur (v {-} proj\_u(v)) doit être orthogonal à u.}
228 \CommentTok{\# Leur produit scalaire doit être proche de zéro.}
229 \NormalTok{diff\_v2\_proj2 }\OperatorTok{=}\NormalTok{vector\_add(v2, scalar\_multiply()\OperatorTok{-}\DecValTok{1}\NormalTok{, proj2))}\CommentTok{\# v2 {-} proj2}
230 \ControlFlowTok{assert}\BuiltInTok{abs}\NormalTok{(dot\_product(diff\_v2\_proj2, u2)) }\OperatorTok{\textless{}}\FloatTok{1e{-}7}\NormalTok{, }\StringTok{"Orthogonality check failed for proj2"}
231
232 \CommentTok{\# Projection d\textquotesingle{}un vecteur sur lui{-}même}
233 \NormalTok{u3 }\OperatorTok{=}\NormalTok{[ ]\DecValTok{3}\NormalTok{, }\DecValTok{4}\NormalTok{[]}}
234 \NormalTok{proj3 }\OperatorTok{=}\NormalTok{orthogonal\_projection(u3, u3)}
235 \ControlFlowTok{assert}\NormalTok{proj3 }\OperatorTok{=}\NormalTok{[ ]\FloatTok{3.0}\NormalTok{, }\FloatTok{4.0}\NormalTok{[]}, }\StringTok{"Projection of u onto u should be u"}
236
237 \CommentTok{\# Projection d\textquotesingle{}un vecteur orthogonal}
238 \NormalTok{u4 }\OperatorTok{=}\NormalTok{[ ]\DecValTok{1}\NormalTok{, }\DecValTok{0}\NormalTok{[]}}
239 \NormalTok{v4 }\OperatorTok{=}\NormalTok{[ ]\DecValTok{0}\NormalTok{, }\DecValTok{5}\NormalTok{[]}}
240 \NormalTok{proj4 }\OperatorTok{=}\NormalTok{orthogonal\_projection(u4, v4)}
241 \ControlFlowTok{assert}\NormalTok{proj4 }\OperatorTok{=}\NormalTok{[ ]\FloatTok{0.0}\NormalTok{, }\FloatTok{0.0}\NormalTok{[]}, }\StringTok{"Projection of orthogonal vector should be zero vector"}
242
243 \ControlFlowTok{try}\NormalTok{:}
244 \NormalTok{orthogonal\_projection([ ]\DecValTok{0}\NormalTok{, }\DecValTok{0}\NormalTok{[]}, [ ]\DecValTok{1}\NormalTok{, }\DecValTok{1}\NormalTok{[])}
245 \ControlFlowTok{assert}\VariableTok{False}\NormalTok{, }\StringTok{"Projection onto zero vector should raise ValueError"}
246 \ControlFlowTok{except}\PreprocessorTok{ValueError}\NormalTok{:}
247 \ControlFlowTok{assert}\VariableTok{True}\NormalTok{, }\StringTok{"Projection onto zero vector correctly raised ValueError"}
248 \BuiltInTok{print}\NormalTok{()}\StringTok{"Orthogonal projection assertions passed."}\NormalTok{}
249
250 \BuiltInTok{print}\NormalTok{()}\StringTok{"}\CharTok{\textbackslash{}n}\StringTok{All TP sections completed and assertions passed!"}\NormalTok{}

```

## TP 2

### 3.2 TP 02 : Géométrie des Espaces de Plongement et Similarité Cosinus : Dualité et Problème Algébrique

#### 3.2.1 Objectif Mathématique

Ce Travail Pratique explore la conception théorique d'un moteur de recherche sémantique en se basant sur la **similarité cosinus** et la **géométrie des espaces de plongement (embeddings)**. Les mots, phrases ou documents sont représentés comme des vecteurs dans un espace multidimensionnel, où la proximité sémantique est traduite par la proximité géométrique des vecteurs. La similarité cosinus mesure l'angle entre deux vecteurs, un angle faible indiquant une forte similarité.

Nous aborderons la **dualité** en illustrant comment un "vecteur de requête" peut être interprété comme un élément de l'espace dual (une forme linéaire) qui projette les "vecteurs de document" sur une valeur scalaire (leur pertinence). La géométrie des espaces est mise en lumière par les opérations vectorielles fondamentales, la projection orthogonale et la reconstruction à partir de bases orthonormées.

Enfin, nous résoudrons un **problème d'algèbre de l'X** en deux parties : 1. Démontrer la décomposition d'un vecteur en sa projection sur un autre et un résidu orthogonal, illustrant la décomposition d'un espace vectoriel en sous-espaces orthogonaux. 2. Reconstruire un vecteur à partir de ses coordonnées dans une base orthonormée, soulignant le rôle fondamental du produit scalaire pour obtenir ces coordonnées et la facilité de manipulation dans de tels espaces.

#### Formalisation Temporelle de l'Indexation

La création d'un index inversé sur  $N$  documents et  $W$  termes présente une complexité de construction du vocabulaire de  $\mathcal{O}(W)$ , tandis que le calcul de la matrice des poids est  $\mathcal{O}(N \times |V|)$  où  $|V|$  est le cardinal du vocabulaire unique.

#### 3.2.2 Implémentation Python Pure

```

251 \ImportTok{import}\NormalTok{ math }\CommentTok{ \# Utilisation de math.
      sqrt pour les opérations numériques fondamentales.}
252
253 \CommentTok{ \# {-}{-}{-} Opérations Vectorielles de Base (Implémentation
      From Scratch) {-}{-}{-} }
254
255 \KeywordTok{def}\NormalTok{ dot\_product(v1, v2):}
256     \CommentTok{"""}
257     \CommentTok{    Calcule le produit scalaire de deux vecteurs.}
258     \CommentTok{    Les vecteurs sont représentés par des listes de nombres
      .}
259     \CommentTok{    Précondition: Les vecteurs doivent avoir la même
      dimension.}
260     \CommentTok{    """}
261     \ControlFlowTok{if} \BuiltInTok{len}\NormalTok{(v1) }\OperatorTok{
      !=} \BuiltInTok{len}\NormalTok{(v2):}
262     \ControlFlowTok{raise} \PreprocessorTok{ValueError}\NormalTok{
      {(\StringTok{"Les vecteurs doivent avoir la même dimension
      pour le produit scalaire."}\NormalTok{)}}

```

```

263
264 \NormalTok{      result }\OperatorTok{=} \DecValTok{0}
265   \ControlFlowTok{for}\NormalTok{ i }\KeywordTok{in} \BuiltInTok{range}
    }\NormalTok{({}\BuiltInTok{len}\NormalTok{({v1}))}:}
266 \NormalTok{      result }\OperatorTok{+=}\NormalTok{ v1[i] }\
    OperatorTok{*}\NormalTok{ v2[i]}
267   \ControlFlowTok{return}\NormalTok{ result}
268
269 \KeywordTok{def}\NormalTok{ vector\_magnitude(v):}
270   \CommentTok{"""}
271 \CommentTok{    Calcule la magnitude (norme euclidienne L2) d\
    textquotesingle{un vecteur.}
272 \CommentTok{    ||v|| = sqrt(v . v)}
273 \CommentTok{    """}
274   \ControlFlowTok{return}\NormalTok{ math.sqrt(dot\_product(v, v))}
275
276 \KeywordTok{def}\NormalTok{ scalar\_multiply(scalar, vector):}
277   \CommentTok{"""}
278 \CommentTok{    Multiplie un vecteur par un scalaire.}
279 \CommentTok{    """}
280   \ControlFlowTok{return}\NormalTok{ [scalar }\OperatorTok{*}\
    NormalTok{ x }\ControlFlowTok{for}\NormalTok{ x }\KeywordTok{in}\
    NormalTok{ vector}]
281
282 \KeywordTok{def}\NormalTok{ vector\_add(v1, v2):}
283   \CommentTok{"""}
284 \CommentTok{    Additionne deux vecteurs.}
285 \CommentTok{    Précondition: Les vecteurs doivent avoir la même
    dimension.}
286 \CommentTok{    """}
287   \ControlFlowTok{if} \BuiltInTok{len}\NormalTok{({v1}) }\OperatorTok{
    !=} \BuiltInTok{len}\NormalTok{({v2}):}
288   \ControlFlowTok{raise} \PreprocessorTok{ValueError}\NormalTok{
    {({}\StringTok{"Les vecteurs doivent avoir la même dimension
    pour l'addition."}\NormalTok{)}}
289   \ControlFlowTok{return}\NormalTok{ [v1[i] }\OperatorTok{+}\NormalTok{
    v2[i] }\ControlFlowTok{for}\NormalTok{ i }\KeywordTok{in} \
    BuiltInTok{range}\NormalTok{({}\BuiltInTok{len}\NormalTok{({v1}))}]
290
291 \KeywordTok{def}\NormalTok{ vector\_subtract(v1, v2):}
292   \CommentTok{"""}
293 \CommentTok{    Soustrait v2 de v1.}
294 \CommentTok{    Précondition: Les vecteurs doivent avoir la même
    dimension.}
295 \CommentTok{    """}
296   \ControlFlowTok{if} \BuiltInTok{len}\NormalTok{({v1}) }\OperatorTok{
    !=} \BuiltInTok{len}\NormalTok{({v2}):}
297   \ControlFlowTok{raise} \PreprocessorTok{ValueError}\NormalTok{
    {({}\StringTok{"Les vecteurs doivent avoir la même dimension
    pour la soustraction."}\NormalTok{)}}
298   \ControlFlowTok{return}\NormalTok{ [v1[i] }\OperatorTok{-}\NormalTok{
    v2[i] }\ControlFlowTok{for}\NormalTok{ i }\KeywordTok{in} \
    BuiltInTok{range}\NormalTok{({}\BuiltInTok{len}\NormalTok{({v1}
    ))}]
299
300 \KeywordTok{def}\NormalTok{ normalize\_vector(v):}
301   \CommentTok{"""}

```

```

302 \CommentTok{    Normalise un vecteur pour obtenir un vecteur unitaire (
    de magnitude 1).}
303 \CommentTok{    Précondition: Le vecteur ne doit pas être le vecteur nul
    .}
304 \CommentTok{    """}
305 \NormalTok{    mag }\OperatorTok{=}\NormalTok{ vector\_magnitude(v)}
306 \ControlFlowTok{if}\NormalTok{ mag }\OperatorTok{==}\DecValTok{0}\
    NormalTok{:}
307 \ControlFlowTok{raise} \PreprocessorTok{ValueError}\NormalTok{
    {(\}\StringTok{"Impossible de normaliser un vecteur nul."}\
    NormalTok{)} }
308 \ControlFlowTok{return}\NormalTok{ scalar\_multiply(\FloatTok{1.0}
    \OperatorTok{/}\NormalTok{ mag, v)}
309
310 \CommentTok{\# {-}{-}{-} Similarité Cosinus pour la Recherche Sémantique
    {-}{-}{-}}
311
312 \KeywordTok{def}\NormalTok{ cosine\_similarity(v1, v2):}
313 \CommentTok{"""}
314 \CommentTok{    Calcule la similarité cosinus entre deux vecteurs.}
315 \CommentTok{    cos(theta) = (v1 . v2) / (||v1|| * ||v2||)}
316 \CommentTok{    Retourne 0.0 si l'un des vecteurs est
    nul.}
317 \CommentTok{    """}
318 \NormalTok{    dot\_prod }\OperatorTok{=}\NormalTok{ dot\_product(v1, v2
    )}
319 \NormalTok{    mag\_v1 }\OperatorTok{=}\NormalTok{ vector\_magnitude(v1)
    }
320 \NormalTok{    mag\_v2 }\OperatorTok{=}\NormalTok{ vector\_magnitude(v2)
    }
321
322 \ControlFlowTok{if}\NormalTok{ mag\_v1 }\OperatorTok{==}\DecValTok{0}
    \KeywordTok{or}\NormalTok{ mag\_v2 }\OperatorTok{==}\DecValTok{0}\NormalTok{:}
323 \ControlFlowTok{return} \FloatTok{0.0} \CommentTok{\# La
    similarité est indéfinie ou considérée comme nulle si un
    vecteur est nul.}
324
325 \ControlFlowTok{return}\NormalTok{ dot\_prod }\OperatorTok{/}\
    NormalTok{ (mag\_v1 }\OperatorTok{*}\NormalTok{ mag\_v2)}
326
327 \CommentTok{\# {-}{-}{-} Problème d'Algèbre de l'
    textquotesingle{X} : Projection et Base Orthonormée {-}{-}{-}}
328
329 \KeywordTok{def}\NormalTok{ project\_vector(u, v):}
330 \CommentTok{"""}
331 \CommentTok{    Calcule la projection orthogonale du vecteur u sur le
    vecteur v.}
332 \CommentTok{    proj\_v(u) = ((u . v) / ||v||^2) * v}
333 \CommentTok{    Précondition: Le vecteur v ne doit pas être le vecteur
    nul.}
334 \CommentTok{    """}
335 \ControlFlowTok{if}\NormalTok{ vector\_magnitude(v) }\OperatorTok{=}\DecValTok{0}\NormalTok{:}
336 \ControlFlowTok{raise} \PreprocessorTok{ValueError}\NormalTok{
    {(\}\StringTok{"Impossible de projeter sur un vecteur nul."}\
    NormalTok{)} }
337

```

```

338 \NormalTok{ dot\_uv }\OperatorTok{=}\NormalTok{ dot\_product(u, v)}
339 \NormalTok{ mag\_v\_squared }\OperatorTok{=}\NormalTok{ dot\_product(}
    v, v) }\CommentTok{\# ||v||^2}
340
341 \NormalTok{ scalar }\OperatorTok{=}\NormalTok{ dot\_uv }\OperatorTok{=}
    {/}\NormalTok{ mag\_v\_squared}
342 \ControlFlowTok{return}\NormalTok{ scalar\_multiply(scalar, v)}
343
344 \KeywordTok{def}\NormalTok{ reconstruct\_from\_orthonormal\_basis(vector}
    , orthonormal\_basis):}
345 \CommentTok{"""}
346 \CommentTok{    Reconstitue un vecteur à partir de ses coefficients par}
    rapport à une base orthonormée.}
347 \CommentTok{    Pour une base orthonormée  $\{b_i\}$ , un vecteur  $v$  peut être}
    exprimé comme :}
348 \CommentTok{     $v = \sum (v \cdot b_i) \cdot b_i$ }
349 \CommentTok{    Les coefficients  $(v \cdot b_i)$  sont les coordonnées de  $v$  dans}
    cette base.}
350 \CommentTok{    Précondition: orthonormal\_basis}
    textquotesingle doit être une liste de vecteurs unitaires et}
    mutuellement orthogonaux.}
351 \CommentTok{"""}
352 \ControlFlowTok{if} \KeywordTok{not}\NormalTok{ orthonormal\_basis:}
353 \ControlFlowTok{return}\NormalTok{ []\FloatTok{0.0}\NormalTok{ []}
    }\OperatorTok{*}\BuiltInTok{len}\NormalTok{(vector) }\CommentTok{\# Retourne un vecteur nul si la base est vide.}
354
355 \CommentTok{\# Initialise le vecteur reconstruit avec des zéros, de}
    la même dimension que le vecteur original.}
356 \NormalTok{ reconstructed\_vector }\OperatorTok{=}\NormalTok{ []\FloatTok{0.0}\NormalTok{ []}
    }\OperatorTok{*}\BuiltInTok{len}\NormalTok{(vector)}
357
358 \ControlFlowTok{for} \NormalTok{ b\_i }\KeywordTok{in} \NormalTok{ orthonormal\_basis:}
359 \ControlFlowTok{if} \BuiltInTok{len}\NormalTok{(b\_i)}
    \OperatorTok{!=}\BuiltInTok{len}\NormalTok{(vector):}
360 \ControlFlowTok{raise} \PreprocessorTok{ValueError}\NormalTok{ ("Les vecteurs de la base doivent}
    avoir la même dimension que le vecteur à reconstruire.")\NormalTok{ }
361
362 \CommentTok{\# Le coefficient est le produit scalaire du vecteur}
    avec le vecteur de base.}
363 \CommentTok{\# Ceci illustre la dualité : le vecteur de base  $b_i$ }
    agit comme une forme linéaire  $f_{b_i}(v) = v \cdot b_i$ }
364 \CommentTok{\# qui extrait la composante de  $v$  le long de  $b_i$ .}
365 \NormalTok{ coefficient }\OperatorTok{=}\NormalTok{ dot\_product(}
    vector, b\_i)}
366
367 \CommentTok{\# Multiplie le vecteur de base par son coefficient}
    et l'ajoute au vecteur reconstruit.}
368 \NormalTok{ scaled\_b\_i }\OperatorTok{=}\NormalTok{ scalar\_multiply(coefficient, b\_i)}
369 \NormalTok{ reconstructed\_vector }\OperatorTok{=}\NormalTok{ vector\_add(reconstructed\_vector, scaled\_b\_i)}
370
371 \ControlFlowTok{return}\NormalTok{ reconstructed\_vector}

```

```

372
373 \CommentTok{\# {-}{-}{-} Cas de Test et Assertions de Validation Mathé
    matique {-}{-}{-}}
374
375 \CommentTok{\# Précision pour les comparaisons de nombres flottants}
376 \NormalTok{EPSILON }\OperatorTok{=} \FloatTok{1e{-}9}
377
378 \CommentTok{\# Test 1 : Opérations Vectorielles de Base}
379 \BuiltInTok{print}\NormalTok{({}\StringTok{"{-}{-}{-} Test 1 : Opérations
    Vectorielles de Base {-}{-}{-}"}\NormalTok{{})}
380 \NormalTok{v\_a }\OperatorTok{=} \NormalTok{[}\DecValTok{1}\NormalTok{,}\NormalTok{ }\DecValTok{2}\NormalTok{,}\NormalTok{ }\DecValTok{3}\NormalTok{]}\NormalTok{{}}
381 \NormalTok{v\_b }\OperatorTok{=} \NormalTok{[}\DecValTok{4}\NormalTok{,}\NormalTok{ }\DecValTok{5}\NormalTok{,}\NormalTok{ }\DecValTok{6}\NormalTok{]}\NormalTok{{}}
382 \NormalTok{v\_c }\OperatorTok{=} \NormalTok{[}\DecValTok{0}\NormalTok{,}\NormalTok{ }\DecValTok{0}\NormalTok{,}\NormalTok{ }\DecValTok{0}\NormalTok{]}\NormalTok{{}}
383 \NormalTok{v\_d }\OperatorTok{=} \NormalTok{[}\FloatTok{1.0}\NormalTok{ }\OperatorTok{/}\NormalTok{ math.sqrt(}\DecValTok{2}\NormalTok{)}\NormalTok{{}}\NormalTok{ }\FloatTok{1.0}\NormalTok{ }\OperatorTok{/}\NormalTok{ math.sqrt(}\DecValTok{2}\NormalTok{)}\NormalTok{{}}
    \CommentTok{\# Vecteur unitaire}
384
385 \ControlFlowTok{assert}\NormalTok{dot\_product(v\_a, v\_b) }\OperatorTok{=} \DecValTok{32}\NormalTok{{}}\StringTok{"Test 1.1:
    Produit scalaire [1,2,3].[4,5,6] = 32"}
386 \ControlFlowTok{assert}\NormalTok{dot\_product(v\_a, v\_a) }\OperatorTok{=} \DecValTok{14}\NormalTok{{}}\StringTok{"Test 1.2:
    Produit scalaire de v\_a avec lui{-}même = 14"}
387 \ControlFlowTok{assert} \BuiltInTok{abs}\NormalTok{(vector\_magnitude(v\_
    a) }\OperatorTok{{-}})\NormalTok{ math.sqrt(}\DecValTok{14}\NormalTok{)}\NormalTok{{}}\NormalTok{ }\StringTok{"Test
    1.3: Magnitude de v\_a"}
388 \ControlFlowTok{assert}\NormalTok{vector\_magnitude(v\_c) }\OperatorTok{=} \DecValTok{0}\NormalTok{{}}\StringTok{"Test 1.4: Magnitude du
    vecteur nul"}
389 \ControlFlowTok{assert}\NormalTok{scalar\_multiply(}\DecValTok{2}\NormalTok{ }\NormalTok{v\_a) }\OperatorTok{=} \NormalTok{[}\DecValTok{2}\NormalTok{ }\DecValTok{4}\NormalTok{ }\DecValTok{6}\NormalTok{]}\NormalTok{{}}\StringTok{"Test 1.5: Multiplication scalaire 2 * [1,2,3]"}
390 \ControlFlowTok{assert}\NormalTok{vector\_add(v\_a, v\_b) }\OperatorTok{=} \NormalTok{[}\DecValTok{5}\NormalTok{ }\DecValTok{7}\NormalTok{ }\DecValTok{9}\NormalTok{]}\NormalTok{{}}\StringTok{"Test 1.6: Addition
    vectorielle [1,2,3] + [4,5,6]"}
391 \ControlFlowTok{assert}\NormalTok{vector\_subtract(v\_b, v\_a) }\OperatorTok{=} \NormalTok{[}\DecValTok{3}\NormalTok{ }\DecValTok{3}\NormalTok{ }\DecValTok{3}\NormalTok{]}\NormalTok{{}}\StringTok{"Test 1.7:
    Soustraction vectorielle [4,5,6] {-} [1,2,3]"}
392 \ControlFlowTok{assert} \BuiltInTok{abs}\NormalTok{(vector\_magnitude(
    normalize\_vector(v\_a) ) }\OperatorTok{{-}})\FloatTok{1.0}\NormalTok{{}}\NormalTok{ }\StringTok{"Test
    1.8: Normalisation de v\_a"}
393 \ControlFlowTok{assert} \BuiltInTok{abs}\NormalTok{(vector\_magnitude(v\_
    d) ) }\OperatorTok{{-}})\FloatTok{1.0}\NormalTok{{}}\NormalTok{ }\StringTok{"Test 1.9: Magnitude d\
    textquotesingle{un vecteur unitaire"}
394 \BuiltInTok{print}\NormalTok{({}\StringTok{"Test 1 réussi."}\NormalTok{{})}
395
396 \CommentTok{\# Test 2 : Similarité Cosinus}

```



```

397 \BuiltInTok{print}\NormalTok{(\StringTok{"{-}{-}{-} Test 2 : Similarité
    Cosinus {-}{-}{-}}\NormalTok{)}
398 \NormalTok{doc1 }\OperatorTok{=}\NormalTok{[ ]\DecValTok{1}\NormalTok{,
    }\DecValTok{1}\NormalTok{, }\DecValTok{0}\NormalTok{ }\CommentTok{\#
    "pomme rouge"}
399 \NormalTok{doc2 }\OperatorTok{=}\NormalTok{[ ]\DecValTok{1}\NormalTok{,
    }\DecValTok{0}\NormalTok{, }\DecValTok{1}\NormalTok{ }\CommentTok{\#
    "pomme verte"}
400 \NormalTok{doc3 }\OperatorTok{=}\NormalTok{[ ]\DecValTok{0}\NormalTok{,
    }\DecValTok{1}\NormalTok{, }\DecValTok{1}\NormalTok{ }\CommentTok{\#
    "rouge verte"}
401 \NormalTok{doc4 }\OperatorTok{=}\NormalTok{[ ]\OperatorTok{{-}}\
    DecValTok{1}\NormalTok{, }\OperatorTok{{-}}\DecValTok{1}\NormalTok{,
    }\DecValTok{0}\NormalTok{ }\CommentTok{\# "pas pomme pas rouge" (
    opposé de doc1)}
402
403 \CommentTok{\# Similarité entre doc1 et doc2 :  $(1*1 + 1*0 + 0*1) / (\text{sqrt}(2) * \text{sqrt}(2)) = 1 / 2 = 0.5$ }
404 \ControlFlowTok{assert} \BuiltInTok{abs}\NormalTok{(cosine\_similarity(
    doc1, doc2) }\OperatorTok{{-}}\FloatTok{0.5}\NormalTok{) }\
    OperatorTok{\textless{}}\NormalTok{EPSILON, }\StringTok{"Test 2.1:
    Cosine sim (doc1, doc2)"}
405 \CommentTok{\# Similarité entre doc1 et doc1 : doit être 1.0}
406 \ControlFlowTok{assert} \BuiltInTok{abs}\NormalTok{(cosine\_similarity(
    doc1, doc1) }\OperatorTok{{-}}\FloatTok{1.0}\NormalTok{) }\
    OperatorTok{\textless{}}\NormalTok{EPSILON, }\StringTok{"Test 2.2:
    Cosine sim (doc1, doc1)"}
407 \CommentTok{\# Similarité entre vecteurs orthogonaux (ex: [1,0] et
    [0,1]) : doit être 0.0}
408 \NormalTok{ortho\_v1 }\OperatorTok{=}\NormalTok{[ ]\DecValTok{1}\
    NormalTok{, }\DecValTok{0}\NormalTok{ }\
409 \NormalTok{ortho\_v2 }\OperatorTok{=}\NormalTok{[ ]\DecValTok{0}\
    NormalTok{, }\DecValTok{1}\NormalTok{ }\
410 \ControlFlowTok{assert} \BuiltInTok{abs}\NormalTok{(cosine\_similarity(
    ortho\_v1, ortho\_v2) }\OperatorTok{{-}}\FloatTok{0.0}\NormalTok{) }\
    OperatorTok{\textless{}}\NormalTok{EPSILON, }\StringTok{"Test 2.3:
    Cosine sim (orthogonaux)"}
411 \CommentTok{\# Similarité avec un vecteur nul : doit être 0.0}
412 \ControlFlowTok{assert}\NormalTok{cosine\_similarity(doc1, v\_c) }\
    OperatorTok{=}\FloatTok{0.0}\NormalTok{, }\StringTok{"Test 2.4:
    Cosine sim avec vecteur nul"}
413 \CommentTok{\# Similarité entre vecteurs opposés : doit être {-}1.0}
414 \ControlFlowTok{assert} \BuiltInTok{abs}\NormalTok{(cosine\_similarity(
    doc1, doc4) }\OperatorTok{{-}}\NormalTok{[ ]\OperatorTok{{-}}\
    FloatTok{1.0}\NormalTok{) }\OperatorTok{\textless{}}\NormalTok{EPSILON, }\StringTok{"Test 2.5: Cosine sim (opposés)"}
415 \BuiltInTok{print}\NormalTok{(\StringTok{"Test 2 réussi."}\NormalTok{)}
416
417 \CommentTok{\# Test 3 : Problème d\textquotesingle{}Algèbre de 1\
    textquotesingle{}X {-} Partie 1 : Projection et Orthogonalité}
418 \BuiltInTok{print}\NormalTok{(\StringTok{"{-}{-}{-} Test 3 : Problème d
    \textquotesingle{}Algèbre de 1\textquotesingle{}X {-} Projection et
    Orthogonalité {-}{-}{-}}\NormalTok{)}
419 \NormalTok{u\_vec }\OperatorTok{=}\NormalTok{[ ]\DecValTok{3}\NormalTok{,
    }\DecValTok{4}\NormalTok{ }\CommentTok{\# Vecteur à projeter}
420 \NormalTok{v\_vec }\OperatorTok{=}\NormalTok{[ ]\DecValTok{1}\NormalTok{,
    }\DecValTok{0}\NormalTok{ }\CommentTok{\# Vecteur sur lequel
    projeter (axe des x)}

```

```

421 \NormalTok{proj\_u\_v }\OperatorTok{=}\NormalTok{ project\_vector(u\_vec
, v\_vec)}
422 \CommentTok{\# La projection de [3,4] sur [1,0] est [3,0]}
423 \ControlFlowTok{assert}\NormalTok{ proj\_u\_v }\OperatorTok{=}\NormalTok{
    NormalTok{ []\FloatTok{3.0}\NormalTok{, }\FloatTok{0.0}\NormalTok{[]},
    }\StringTok{"Test 3.1: Projection simple de [3,4] sur [1,0]"}
424
425 \NormalTok{residual\_vec }\OperatorTok{=}\NormalTok{ vector\_subtract(u\_
_vec, proj\_u\_v)}
426 \CommentTok{\# Le résidu [0, 4] doit être orthogonal à v\_vec [1, 0]}
427 \ControlFlowTok{assert} \BuiltInTok{abs}\NormalTok{((dot\_product(
    residual\_vec, v\_vec)) }\OperatorTok{\textless{}}\NormalTok{ EPSILON
, }\StringTok{"Test 3.2: Le résidu doit être orthogonal au vecteur de
    projection."})
428
429 \NormalTok{u\_vec\_2 }\OperatorTok{=}\NormalTok{ []\DecValTok{1}\NormalTok{
    NormalTok{, }\DecValTok{1}\NormalTok{[]}}
430 \NormalTok{v\_vec\_2 }\OperatorTok{=}\NormalTok{ []\DecValTok{2}\NormalTok{
    NormalTok{, }\DecValTok{0}\NormalTok{[]}}
431 \CommentTok{\# proj\_v2(u2) = ((u2 . v2) / ||v2||^2) * v2}
432 \CommentTok{\# u2 . v2 = 1*2 + 1*0 = 2}
433 \CommentTok{\# ||v2||^2 = 2*2 + 0*0 = 4}
434 \CommentTok{\# scalaire = 2/4 = 0.5}
435 \CommentTok{\# proj = 0.5 * [2, 0] = [1.0, 0.0]}
436 \NormalTok{proj\_u\_v\_2 }\OperatorTok{=}\NormalTok{ project\_vector(u\_
_vec\_2, v\_vec\_2)}
437 \ControlFlowTok{assert}\NormalTok{ proj\_u\_v\_2 }\OperatorTok{=}\NormalTok{
    NormalTok{ []\FloatTok{1.0}\NormalTok{, }\FloatTok{0.0}\NormalTok{[]},
    }\StringTok{"Test 3.3: Projection de [1,1] sur [2,0]"}
438 \NormalTok{residual\_vec\_2 }\OperatorTok{=}\NormalTok{ vector\_subtract
(u\_vec\_2, proj\_u\_v\_2) }\CommentTok{\# [0, 1]}
439 \ControlFlowTok{assert} \BuiltInTok{abs}\NormalTok{((dot\_product(
    residual\_vec\_2, v\_vec\_2)) }\OperatorTok{\textless{}}\NormalTok{ EPSILON, }\StringTok{"Test 3.4: Le résidu doit être orthogonal au
    vecteur de projection (cas général)."}
440 \BuiltInTok{print}\NormalTok{((}\StringTok{"Test 3 réussi."}\NormalTok{))}
441
442 \CommentTok{\# Test 4 : Problème d'Algèbre de l'
    textquotesingle{X {-} Partie 2 : Reconstruction à partir d'
    textquotesingle{une Base Orthonormée}
443 \BuiltInTok{print}\NormalTok{((}\StringTok{"{-}{-}{-} Test 4 : Problème d'
    \textquotesingle{Algèbre de l'\textquotesingle{X {-} Reconstruction
    Base Orthonormée {-}{-}{-}"}\NormalTok{))}
444 \CommentTok{\# Création d'une base orthonormée
    canonique pour R^3}
445 \NormalTok{e1 }\OperatorTok{=}\NormalTok{ []\FloatTok{1.0}\NormalTok{,
    }\FloatTok{0.0}\NormalTok{, }\FloatTok{0.0}\NormalTok{[]}}
446 \NormalTok{e2 }\OperatorTok{=}\NormalTok{ []\FloatTok{0.0}\NormalTok{,
    }\FloatTok{1.0}\NormalTok{, }\FloatTok{0.0}\NormalTok{[]}}
447 \NormalTok{e3 }\OperatorTok{=}\NormalTok{ []\FloatTok{0.0}\NormalTok{,
    }\FloatTok{0.0}\NormalTok{, }\FloatTok{1.0}\NormalTok{[]}}
448 \NormalTok{ortho\_basis\_3d }\OperatorTok{=}\NormalTok{ [e1, e2, e3]}
449
450 \CommentTok{\# Vérification que la base est bien orthonormée}
451 \ControlFlowTok{for}\NormalTok{ i }\KeywordTok{in} \BuiltInTok{range}\NormalTok{
    NormalTok{(\BuiltInTok{len}\NormalTok{(ortho\_basis\_3d)):}
452 \ControlFlowTok{assert} \BuiltInTok{abs}\NormalTok{(vector\_
    _magnitude(ortho\_basis\_3d[i]) }\OperatorTok{{-}} \FloatTok{

```

```

{1.0}\NormalTok{) }\OperatorTok{\textless{}}\NormalTok{ EPSILON,
}\SpecialStringTok{f"Test 4.1.}\SpecialCharTok{\{\}\NormalTok{i}\}
SpecialCharTok{\}\SpecialStringTok{: Vecteur de base }\
SpecialCharTok{\}\NormalTok{i}\SpecialCharTok{\}\}
SpecialStringTok{ n\textquotesingle{est pas unitaire."}
453 \ControlFlowTok{for}\NormalTok{ j }\KeywordTok{in} \BuiltInTok{range
}\NormalTok{(i }\OperatorTok{+} \DecValTok{1}\NormalTok{, }\
BuiltInTok{len}\NormalTok{ (ortho\_basis\_3d)) :}
454 \ControlFlowTok{assert} \BuiltInTok{abs}\NormalTok{(dot\_product
(ortho\_basis\_3d[i], ortho\_basis\_3d[j])) }\OperatorTok{\
textless{}}\NormalTok{ EPSILON, }\SpecialStringTok{f"Test
4.2.}\SpecialCharTok{\{\}\NormalTok{i}\SpecialCharTok{\}\}
SpecialStringTok{.}\SpecialCharTok{\{\}\NormalTok{j}\}
SpecialCharTok{\}\SpecialStringTok{: Vecteurs de base }\
SpecialCharTok{\}\NormalTok{i}\SpecialCharTok{\}\}
SpecialStringTok{ et }\SpecialCharTok{\{\}\NormalTok{j}\}
SpecialCharTok{\}\SpecialStringTok{ ne sont pas orthogonaux.
"}
455
456 \NormalTok{test\_vector }\OperatorTok{=}\NormalTok{ []\DecValTok{5}\
NormalTok{, }\OperatorTok{-}\DecValTok{2}\NormalTok{, }\DecValTok
{7}\NormalTok{[]}
457 \NormalTok{reconstructed }\OperatorTok{=}\NormalTok{ reconstruct\_from\
\_orthonormal\_basis(test\_vector, ortho\_basis\_3d)}
458
459 \CommentTok{\# Vérification que le vecteur reconstruit est
approximativement égal au vecteur original}
460 \ControlFlowTok{for}\NormalTok{ i }\KeywordTok{in} \BuiltInTok{range}\
NormalTok{(}\BuiltInTok{len}\NormalTok{(test\_vector)) :}
461 \ControlFlowTok{assert} \BuiltInTok{abs}\NormalTok{(reconstructed[i]
)\OperatorTok{-}\NormalTok{ test\_vector[i]) }\OperatorTok{\
textless{}}\NormalTok{ EPSILON, }\SpecialStringTok{f"Test 4.3: La
reconstruction a échoué à l\textquotesingle{indice }\
SpecialCharTok{\}\NormalTok{i}\SpecialCharTok{\}\}
SpecialStringTok{."}
462
463 \CommentTok{\# Autre base orthonormée (rotée) en 2D}
464 \NormalTok{sqrt2\_inv }\OperatorTok{=}\FloatTok{1.0} \OperatorTok{/}\
NormalTok{ math.sqrt(}\DecValTok{2}\NormalTok{)}
465 \NormalTok{u1\_basis }\OperatorTok{=}\NormalTok{ [sqrt2\_inv, sqrt2\_inv
]}
466 \NormalTok{u2\_basis }\OperatorTok{=}\NormalTok{ []\OperatorTok{-}\}
NormalTok{sqrt2\_inv, sqrt2\_inv]}
467 \NormalTok{ortho\_basis\_2d }\OperatorTok{=}\NormalTok{ [u1\_basis, u2\
\_basis]}
468
469 \CommentTok{\# Vérification de l\textquotesingle{orthonormalité de la
base 2D}}
470 \ControlFlowTok{assert} \BuiltInTok{abs}\NormalTok{(vector\_magnitude(u1
\_basis) }\OperatorTok{-}\FloatTok{1.0}\NormalTok{) }\OperatorTok{\
textless{}}\NormalTok{ EPSILON, }\StringTok{"Test 4.4: u1\_basis n\
textquotesingle{est pas unitaire."}
471 \ControlFlowTok{assert} \BuiltInTok{abs}\NormalTok{(vector\_magnitude(u2
\_basis) }\OperatorTok{-}\FloatTok{1.0}\NormalTok{) }\OperatorTok{\
textless{}}\NormalTok{ EPSILON, }\StringTok{"Test 4.5: u2\_basis n\
textquotesingle{est pas unitaire."}
472 \ControlFlowTok{assert} \BuiltInTok{abs}\NormalTok{(dot\_product(u1\
\_basis, u2\_basis)) }\OperatorTok{\textless{}}\NormalTok{ EPSILON, }\

```

```

StringTok{"Test 4.6: u1\_basis et u2\_basis ne sont pas orthogonaux."
}
473
474 \NormalTok{test\_vector\_2d }\OperatorTok{=}\NormalTok{ [ ]\DecValTok{3}\
NormalTok{, }\DecValTok{4}\NormalTok{[]}\
475 \NormalTok{reconstructed\_2d }\OperatorTok{=}\NormalTok{ reconstruct\
\_from\_orthonormal\_basis(test\_vector\_2d, ortho\_basis\_2d)}\
476
477 \ControlFlowTok{for}\NormalTok{ i }\KeywordTok{in} \BuiltInTok{range}\
NormalTok{({}\BuiltInTok{len}\NormalTok{ (test\_vector\_2d)) :}\
478 \ControlFlowTok{assert} \BuiltInTok{abs}\NormalTok{ (reconstructed\
\_2d[i] }\OperatorTok{{-}}\NormalTok{ test\_vector\_2d[i] ) }\
OperatorTok{\textless{}}\NormalTok{ EPSILON, }\SpecialStringTok{f
"Test 4.7: La reconstruction 2D a échoué à l\textquotesingle{}
indice }\SpecialCharTok{\}\NormalTok{i}\SpecialCharTok{\}}\
SpecialStringTok{."}\
479 \BuiltInTok{print}\NormalTok{({}\StringTok{"Test 4 réussi."}\NormalTok{)}\
480
481 \BuiltInTok{print}\NormalTok{({}\StringTok{"}\CharTok{\textbackslash{}n}\
StringTok{Tous les tests de validation mathématique ont réussi !"}\
NormalTok{)}\

```

## TP 3

### 3.3 TP 03 : Géométrie des Espaces de Plongement et Recherche Sémantique par Similarité Cosinus

#### 3.3.1 Objectif Mathématique

Ce Travail Pratique explore la conception théorique d'un moteur de recherche sémantique en Python pur, en se concentrant sur la similarité cosinus. Il vise à illustrer la **dualité** et la **géométrie des espaces de plongement (embedding spaces)**, où les documents et les requêtes sont représentés comme des vecteurs. La similarité cosinus, mesurant l'angle entre ces vecteurs, est une manifestation directe de cette géométrie.

Nous aborderons également un problème d'**algèbre de l'X** simplifié : le raffinement itératif d'un vecteur de requête. Ce problème consiste à ajuster la direction d'un vecteur de requête dans l'espace de plongement pour maximiser sa similarité avec un ensemble de documents "positifs" tout en minimisant sa similarité avec un ensemble de documents "négatifs". Cela démontre comment des opérations algébriques (addition vectorielle, multiplication scalaire, normalisation) peuvent être utilisées pour naviguer et optimiser des positions dans un espace vectoriel, reflétant l'influence de formes linéaires (les "directions" positives/négatives) sur le vecteur de requête.

#### Stabilité Numérique de la Pondération

Le lissage logarithmique de l'IDF  $\log(1 + \frac{N}{df(t)})$  provient formellement des singularités mathématiques. Numri

#### 3.3.2 Implémentation Python Pure

“python import math

### 3.4 — Fonctions Utilitaires de Base (implémentées from scratch)

`def tokenize(text) :` “ ” Tokenise une chaîne de caractères en une liste de mots. Convertit en minuscules et supprime la ponctuation simple. “ ” `clean_text =` “ ” `for char in text :` `if 'a' <= char <= 'z' or 'A' <= char <= 'Z' or '0' <= char <= '9' or char == ' ' :` `clean_text += char` `else :` `clean_text += ' '` # Remplace la ponctuation par un espace `return [word for word in clean_text.lower().split() if word]`

`def count_words(tokens) :` “ ” Compte la fréquence de chaque mot dans une liste de tokens. Retourne un dictionnaire {mot : fréquence}. “ ” `counts = {}` `for word in tokens :` `counts[word] = counts.get(word, 0) + 1` `return counts`

`def dot_product(vec1, vec2) :` “ ” Calcule le produit scalaire de deux vecteurs. Les vecteurs sont représentés comme des listes de nombres. “ ” `if len(vec1) != len(vec2) :` `raise ValueError("Les vecteurs doivent avoir la même dimension pour le produit scalaire.")`

```
1 result = 0
2 for i in range(len(vec1)):
3     result += vec1[i] * vec2[i]
4 return result
```

`def vector_magnitude(vec) :` “ ” Calcule la magnitude (norme L2) d'un vecteur. “ ” `sum_sq = 0` `for x in vec :` `sum_sq += x * x` `return math.sqrt(sum_sq)`

`def cosine_similarity(vec1, vec2) :` “ ” Calcule la similarité cosinus entre deux vecteurs. Retourne 0.0 si l'un des vecteurs est nul pour éviter la division par zéro. “ ” `if not vec1 or not vec2 :` `return 0.0`

```
1 num = dot_product(vec1, vec2)
2 den1 = vector_magnitude(vec1)
3 den2 = vector_magnitude(vec2)
4
5 if den1 == 0.0 or den2 == 0.0:
6     return 0.0
7
8 return num / (den1 * den2)
```

`def vector_add(vec1, vec2) :` “ ” Additionne deux vecteurs. “ ” `if len(vec1) != len(vec2) :` `raise ValueError("Les vecteurs doivent avoir la même dimension pour l'addition.")`

```
1 result = []
2 for i in range(len(vec1)):
3     result.append(vec1[i] + vec2[i])
4 return result
```

`def scalar_multiply(vec, scalar) :` “ ” Multiplie un vecteur par un scalaire. “ ” `result = []` `for x in vec :` `result.append(x * scalar)` `return result`

`def normalize_vector(vec) :` “ ” Normalise un vecteur à une norme L2 de 1. Retourne un vecteur nul si la magnitude est 0. “ ” `mag = vector_magnitude(vec)` `if mag == 0.0 :` `return [0.0] * len(vec)`

```
1 return scalar_multiply(vec, 1.0 / mag)
```

### 3.5 — Vectorisation TF-IDF (implémentée from scratch) —

`def compute_tf(document_tokens) :` “ ” Calcule la fréquence des termes (TF) pour un document. Retourne un dictionnaire {mot : tf\_score}. “ ” `tf = {}` `word_counts = count_words(document_tokens)`

total\_words = len(document\_tokens) if total\_words == 0 : return tf for word, count in word\_counts.items() :  
tf[word] = count / total\_words return tf

def compute\_idf(corpus\_documents\_tokens) : “” Calcule la fréquence inverse des documents (IDF) pour l'ensemble du corpus. Retourne un dictionnaire {mot : idf\_score}. “” idf = {} num\_documents = len(corpus\_documents\_tokens)

```

1 doc_freq = {}
2 for doc_tokens in corpus_documents_tokens:
3     unique_words_in_doc = {}
4     for word in doc_tokens:
5         unique_words_in_doc[word] = True
6     for word in unique_words_in_doc:
7         doc_freq[word] = doc_freq.get(word, 0) + 1
8
9 for word, freq in doc_freq.items():
10     idf[word] = math.log(num_documents / (1.0 + freq)) # Ajout de 1 pour
11     lisser
12 return idf

```

def build\_vocabulary(corpus\_documents\_tokens) : “” Construit le vocabulaire global à partir de tous les documents tokenisés. Retourne une liste triée de mots uniques. “” vocab\_set = {} for doc\_tokens in corpus\_documents\_tokens : for word in doc\_tokens : vocab\_set[word] = True return sorted(list(vocab\_set.keys())) # Utilise sorted() qui est une fonction built-in

def compute\_tfidf\_vector(tf\_scores, idf\_scores, vocabulary) : “” Construit un vecteur TF-IDF pour un document donné. “” vector = [0.0] \* len(vocabulary) for i, word in enumerate(vocabulary) : tf = tf\_scores.get(word, 0.0) idf = idf\_scores.get(word, 0.0) vector[i] = tf \* idf return vector

def build\_corpus\_vectors(corpus) : “” Prétraite un corpus pour générer les vecteurs TF-IDF pour chaque document. Retourne une liste de vecteurs et le vocabulaire global. “” tokenized\_corpus = [tokenize(doc) for doc in corpus]

```

1 vocabulary = build_vocabulary(tokenized_corpus)
2 idf_scores = compute_idf(tokenized_corpus)
3
4 document_vectors = []
5 for doc_tokens in tokenized_corpus:
6     tf_scores = compute_tf(doc_tokens)
7     tfidf_vec = compute_tfidf_vector(tf_scores, idf_scores, vocabulary)
8     document_vectors.append(tfidf_vec)
9
10 return document_vectors, vocabulary, idf_scores

```

### 3.6 — Moteur de Recherche Sémantique —

def search(query, document\_vectors, vocabulary, idf\_scores, top\_k=3) : “” Effectue une recherche sémantique basée sur la similarité cosinus. “” query\_tokens = tokenize(query) query\_tf = compute\_tf(query\_tokens) query\_vector = compute\_tfidf\_vector(query\_tf, idf\_scores, vocabulary)

```

1 normalized_query_vector = normalize_vector(query_vector)
2
3 similarities = []
4 for i, doc_vec in enumerate(document_vectors):
5     normalized_doc_vec = normalize_vector(doc_vec)
6     sim = cosine_similarity(normalized_query_vector, normalized_doc_vec)
7     similarities.append((sim, i))

```

```

8
9 # Tri par sélection pour rester "from scratch"
10 n = len(similarities)
11 for i in range(n):
12     max_idx = i
13     for j in range(i + 1, n):
14         if similarities[j][0] > similarities[max_idx][0]:
15             max_idx = j
16     similarities[i], similarities[max_idx] = similarities[max_idx],
17     similarities[i]
18 return similarities[:top_k]

```

### 3.7 — Problème d'Algèbre de l'X : Raffinement de Requête —

def refine\_query\_vector(initial\_query\_vec, pos\_docs\_vecs, neg\_docs\_vecs, learning\_rate, iterations): “” Raffine un vecteur de requête pour maximiser la similarité avec des documents “positifs” et minimiser avec des documents “négatifs”. Illustre la manipulation géométrique dans l'espace de plongement.

```

1 initial_query_vec: Le vecteur de requête initial.
2 pos_docs_vecs: Liste de vecteurs de documents positifs.
3 neg_docs_vecs: Liste de vecteurs de documents négatifs.
4 learning_rate: Taux d'apprentissage pour l'ajustement.
5 iterations: Nombre d'itérations pour le raffinement.
6 """
7 current_query_vec = list(initial_query_vec) # Copie pour ne pas modifier
8 l'original
9 current_query_vec = normalize_vector(current_query_vec)
10
11 # Normaliser les vecteurs d'entrée pour que les ajustements soient basés
12 sur la direction
13 pos_docs_vecs_norm = [normalize_vector(v) for v in pos_docs_vecs]
14 neg_docs_vecs_norm = [normalize_vector(v) for v in neg_docs_vecs]
15
16 for _ in range(iterations):
17     # Calculer la direction moyenne des documents positifs
18     pos_direction = [0.0] * len(current_query_vec)
19     if pos_docs_vecs_norm:
20         for p_vec in pos_docs_vecs_norm:
21             pos_direction = vector_add(pos_direction, p_vec)
22         pos_direction = scalar_multiply(pos_direction, 1.0 / len(
23             pos_docs_vecs_norm))
24
25     # Calculer la direction moyenne des documents négatifs
26     neg_direction = [0.0] * len(current_query_vec)
27     if neg_docs_vecs_norm:
28         for n_vec in neg_docs_vecs_norm:
29             neg_direction = vector_add(neg_direction, n_vec)
30         neg_direction = scalar_multiply(neg_direction, 1.0 / len(
31             neg_docs_vecs_norm))
32
33     # Le vecteur de correction pousse la requête vers les positifs et l'
34     éloigne des négatifs.
35     # Cela peut être vu comme l'application d'une forme linéaire dans l'
36     espace dual

```

```

31     # qui guide le mouvement du vecteur de requête dans l'espace
    original.
32     correction_vector = vector_add(pos_direction, scalar_multiply(
        neg_direction, -1.0))
33
34     # Appliquer la correction et normaliser le vecteur de requête
35     current_query_vec = vector_add(current_query_vec, scalar_multiply(
        correction_vector, learning_rate))
36     current_query_vec = normalize_vector(current_query_vec)
37
38 return current_query_vec

```

### 3.8 — Exécution Principale et Assertions de Validation —

if name == "main" : print("— Démarrage du TP : Géométrie des Espaces de Plongement et Recherche Sémantique —")

```

1  # --- Section 1: Tests des fonctions utilitaires de base ---
2  print("\n[TESTS] Fonctions utilitaires de base...")
3  vec_a = [1, 2, 3]
4  vec_b = [4, 5, 6]
5  vec_c = [0, 0, 0]
6
7  assert tokenize("Hello, world! This is a test.") == ['hello', 'world', 'this', 'is', 'a', 'test'], "Test tokenize échoué"
8  assert count_words(['hello', 'world', 'hello']) == {'hello': 2, 'world': 1}, "Test count_words échoué"
9  assert dot_product(vec_a, vec_b) == 32, "Test dot_product échoué" # 1*4 + 2*5 + 3*6 = 4 + 10 + 18 = 32
10 assert abs(vector_magnitude(vec_a) - math.sqrt(14)) < 1e-9, "Test vector_magnitude échoué"
11 assert abs(cosine_similarity(vec_a, vec_a) - 1.0) < 1e-9, "Test cosine_similarity (identique) échoué"
12 assert abs(cosine_similarity(vec_a, vec_c) - 0.0) < 1e-9, "Test cosine_similarity (nul) échoué"
13 assert vector_add(vec_a, vec_b) == [5, 7, 9], "Test vector_add échoué"
14 assert scalar_multiply(vec_a, 2) == [2, 4, 6], "Test scalar_multiply échoué"
15
16 norm_vec_a = normalize_vector(vec_a)
17 assert abs(vector_magnitude(norm_vec_a) - 1.0) < 1e-9, "Test normalize_vector échoué"
18 assert normalize_vector(vec_c) == [0.0, 0.0, 0.0], "Test normalize_vector (nul) échoué"
19 print("Tests des fonctions utilitaires : OK")
20
21 # --- Section 2: Tests de la vectorisation TF-IDF ---
22 print("\n[TESTS] Vectorisation TF-IDF...")
23 corpus_docs = [
24     "Le chat dort sur le tapis.",
25     "Le chien joue avec la balle.",
26     "Le chat et le chien sont des animaux."
27 ]
28
29 tokenized_corpus_for_test = [tokenize(doc) for doc in corpus_docs]
30
31 vocab = build_vocabulary(tokenized_corpus_for_test)

```



```

32 assert vocab == ['animaux', 'avec', 'balle', 'chat', 'chien', 'des', 'dort', 'et', 'joue', 'la', 'le', 'sont', 'sur', 'tapis'], "Test build_vocabulary échoué"
33
34 tf_doc1 = compute_tf(tokenized_corpus_for_test[0])
35 assert abs(tf_doc1['le'] - 2/5) < 1e-9, "Test compute_tf échoué pour 'le'"
36 assert abs(tf_doc1['chat'] - 1/5) < 1e-9, "Test compute_tf échoué pour 'chat'"
37
38 idf_scores = compute_idf(tokenized_corpus_for_test)
39 assert abs(idf_scores['le'] - math.log(3.0 / (1.0 + 3.0))) < 1e-9, "Test compute_idf échoué pour 'le'"
40 assert abs(idf_scores['tapis'] - math.log(3.0 / (1.0 + 1.0))) < 1e-9, "Test compute_idf échoué pour 'tapis'"
41
42 doc_vectors, global_vocab, full_idf_scores = build_corpus_vectors(corpus_docs)
43 assert len(doc_vectors) == 3, "Nombre de vecteurs de documents incorrect"
44 assert len(doc_vectors[0]) == len(global_vocab), "Dimension des vecteurs incorrecte"
45
46 chat_idx = global_vocab.index('chat')
47 # 'chat' est dans doc1 et doc3, donc doc_freq['chat'] = 2. IDF('chat') = log(3 / (1+2)) = log(1) = 0.0
48 assert abs(doc_vectors[0][chat_idx] - 0.0) < 1e-9, "Test TF-IDF 'chat' dans doc1 échoué"
49
50 tapis_idx = global_vocab.index('tapis')
51 # TF('tapis', doc1) = 1/5. IDF('tapis') = log(3 / (1+1)) = log(1.5)
52 expected_tfidf_tapis = (1/5) * math.log(1.5)
53 assert abs(doc_vectors[0][tapis_idx] - expected_tfidf_tapis) < 1e-9, "Test TF-IDF 'tapis' dans doc1 échoué"
54
55 print("Tests de la vectorisation TF-IDF : OK")
56
57 # --- Section 3: Tests du moteur de recherche sémantique ---
58 print("\n[TESTS] Moteur de recherche sémantique...")
59
60 query_search = "chat et chien"
61 results = search(query_search, doc_vectors, global_vocab, full_idf_scores, top_k=2)
62
63 assert results[0][1] == 2, "Le document 3 (index 2) devrait être le plus pertinent."
64 assert results[1][1] == 0, "Le document 1 (index 0) devrait être le deuxième plus pertinent."
65 assert results[0][0] >= results[1][0], "Les similarités ne sont pas triées correctement."
66
67 print("Tests du moteur de recherche sémantique : OK")
68
69 # --- Section 4: Tests du problème d'algèbre de l'X (Raffinement de requête) ---
70 print("\n[TESTS] Problème d'algèbre de l'X : Raffinement de requête...")
71
72 # Vecteurs de base (normalisés pour la clarté)

```

```

73 v_a = normalize_vector([1.0, 0.0, 0.0]) # Concept 'a'
74 v_b = normalize_vector([0.0, 1.0, 0.0]) # Concept 'b'
75 v_c = normalize_vector([0.0, 0.0, 1.0]) # Concept 'c'
76
77 initial_query = v_a # Notre requête initiale est purement 'a'
78
79 # Documents positifs: contiennent 'a' et 'b'
80 pos_docs = [normalize_vector([1.0, 1.0, 0.0]), normalize_vector([1.0,
    2.0, 0.0])]
81 # Documents négatifs: contiennent 'c'
82 neg_docs = [normalize_vector([0.0, 0.0, 1.0]), normalize_vector([0.0,
    0.0, 2.0])]
83
84 initial_sim_pos_avg = 0.0
85 for p_vec in pos_docs:
86     initial_sim_pos_avg += cosine_similarity(initial_query, p_vec)
87 initial_sim_pos_avg /= len(pos_docs) if pos_docs else 1.0
88
89 initial_sim_neg_avg = 0.0
90 for n_vec in neg_docs:
91     initial_sim_neg_avg += cosine_similarity(initial_query, n_vec)
92 initial_sim_neg_avg /= len(neg_docs) if neg_docs else 1.0
93
94 print(f" Similarité initiale moyenne avec positifs: {
    initial_sim_pos_avg:.4f}")
95 print(f" Similarité initiale moyenne avec négatifs: {
    initial_sim_neg_avg:.4f}")
96
97 refined_query = refine_query_vector(initial_query, pos_docs, neg_docs,
    learning_rate=0.5, iterations=10)
98
99 refined_sim_pos_avg = 0.0
100 for p_vec in pos_docs:
101     refined_sim_pos_avg += cosine_similarity(refined_query, p_vec)
102 refined_sim_pos_avg /= len(pos_docs) if pos_docs else 1.0
103
104 refined_sim_neg_avg = 0.0
105 for n_vec in neg_docs:
106     refined_sim_neg_avg += cosine_similarity(refined_query, n_vec)
107 refined_sim_neg_avg /= len(neg_docs) if neg_docs else 1.0
108
109 print(f" Similarité raffinée moyenne avec positifs: {
    refined_sim_pos_avg:.4f}")
110 print(f" Similarité raffinée moyenne avec négatifs: {
    refined_sim_neg_avg:.4f}")
111
112 assert refined_sim_pos_avg >= initial_sim_pos_avg - 1e-9, "La similarité
    avec les positifs n'a pas augmenté ou est restée stable."
113 assert refined_sim_neg_avg <= initial_sim_neg_avg + 1e-9, "La similarité
    avec les négatifs n'a pas diminué ou est restée stable."
114 assert abs(vector_magnitude(refined_query) - 1.0) < 1e-9, "Le vecteur
    raffiné n'est pas normalisé."
115
116 sim_refined_with_b = cosine_similarity(refined_query, v_b)
117 sim_initial_with_b = cosine_similarity(initial_query, v_b)
118 assert sim_refined_with_b > sim_initial_with_b, "La similarité avec le
    concept 'b' n'a pas augmenté."
119

```

```

120 sim_refined_with_c = cosine_similarity(refined_query, v_c)
121 sim_initial_with_c = cosine_similarity(initial_query, v_c)
122 assert sim_refined_with_c < sim_initial_with_c, "La similarité avec le
    concept 'c' n'a pas diminué."
123
124 print("Tests du problème d'algèbre de l'X : OK")
125
126 print("\n--- Tous les tests sont passés avec succès ! ---")

```

## TP 4

### 3.9 TP 04 : Moteur de Recherche Sémantique par Similarité Cosinus et Algèbre Linéaire Fondamentale

#### 3.9.1 Objectif Mathématique

Ce TP vise à explorer la conception théorique d'un moteur de recherche sémantique en implémentant les concepts fondamentaux de la similarité cosinus. Nous aborderons la vectorisation de texte via TF-IDF, la géométrie des espaces de plongement (implicitement par la représentation vectorielle des documents), et la dualité des vecteurs. En complément, un problème d'algèbre linéaire de niveau "X" sera résolu, illustrant la projection orthogonale de vecteurs, renforçant ainsi la compréhension des opérations vectorielles essentielles.

#### Structure de Données Creuses (Sparse)

Une implémentation optimale de la représentation vectorielle des documents s'appuie sur la nature creuse de la matrice document-terme. L'utilisation de dictionnaires Python confère un avantage structurel limitant les opérations du produit scalaire aux seules intersections non nulles, réduisant la complexité pratique bien en deçà de la borne théorique  $\mathcal{O}(|V|)$ .

#### 3.9.2 Implémentation Python Pure

“python import math

### 3.10 — Part 1 : Text Processing and Vectorization (TF-IDF from scratch) —

def tokenize(text) : “” Tokenizes a given text into a list of lowercase words, removing punctuation. “” cleaned\_text = “” for char in text : # Keep letters, numbers, and spaces. Replace other characters with space. if 'a' <= char <= 'z' or 'A' <= char <= 'Z' or '0' <= char <= '9' or char == ' ' : cleaned\_text += char else : cleaned\_text += ' ' # Replace punctuation with space to separate words

```

1 tokens = []
2 current_token = ""
3 for char in cleaned_text.lower():
4     if char == ' ':
5         if current_token: # Add token if not empty
6             tokens.append(current_token)
7             current_token = ""
8     else:
9         current_token += char
10 if current_token: # Add the last token if any

```

```

11     tokens.append(current_token)
12 return tokens

```

def count\_term\_frequency(tokens) : “ ” Counts the frequency of each term in a list of tokens. Returns a dictionary {term : count}. “ ” term\_freq = {} for token in tokens : term\_freq[token] = term\_freq.get(token, 0) + 1 return term\_freq

def compute\_tf(term\_freqs) : “ ” Calculates Term Frequency (TF) for a document.  $TF(t, d) = (\text{Number of times term } t \text{ appears in document } d) / (\text{Total number of terms in document } d)$ . Returns a dictionary {term : tf\_score}. “ ” total\_terms = sum(term\_freqs.values()) if total\_terms == 0 : return {} tf\_scores = {} for term, count in term\_freqs.items() : tf\_scores[term] = count / total\_terms return tf\_scores

def compute\_idf(documents\_term\_freqs) : “ ” Calculates Inverse Document Frequency (IDF) for a collection of documents.  $IDF(t) = \log_e(\text{Total number of documents} / \text{Number of documents with term } t)$ . A smoothing factor (+1) is applied to avoid division by zero and log(0). Returns a dictionary {term : idf\_score}. “ ” total\_documents = len(documents\_term\_freqs) if total\_documents == 0 : return {}

```

1 doc_count_per_term = {}
2 for doc_freqs in documents_term_freqs:
3     for term in doc_freqs:
4         doc_count_per_term[term] = doc_count_per_term.get(term, 0) + 1
5
6 idf_scores = {}
7 for term, doc_count in doc_count_per_term.items():
8     # Add 1 to numerator and denominator to avoid division by zero and
9     # log(0)
10    # and to prevent common terms from having an IDF of 0.
11    idf_scores[term] = math.log((total_documents + 1) / (doc_count + 1))
12    + 1
13
14 return idf_scores

```

def compute\_tfidf(tf\_scores, idf\_scores) : “ ” Calculates TF-IDF scores for a document.  $TF\text{-}IDF(t, d) = TF(t, d) * IDF(t)$ . Returns a dictionary {term : tfidf\_score}. “ ” tfidf\_scores = {} for term, tf in tf\_scores.items() : # If a term is not in IDF scores (e.g., it appeared in a document but not in the corpus for IDF calculation), # its IDF is effectively 0, making TF-IDF 0. tfidf\_scores[term] = tf \* idf\_scores.get(term, 0.0) return tfidf\_scores

def build\_vocabulary(documents\_term\_freqs) : “ ” Builds a global vocabulary from a collection of documents. Returns a sorted list of unique terms. “ ” vocabulary\_set = set() for doc\_freqs in documents\_term\_freqs : for term in doc\_freqs : vocabulary\_set.add(term) return sorted(list(vocabulary\_set))

def vectorize(tfidf\_scores, vocabulary) : “ ” Converts TF-IDF scores into a dense vector based on a global vocabulary. “ ” vector = [0.0] \* len(vocabulary) for i, term in enumerate(vocabulary) : vector[i] = tfidf\_scores.get(term, 0.0) return vector

### 3.11 — Part 2 : Cosine Similarity (from scratch) —

def dot\_product(vec1, vec2) : “ ” Calculates the dot product of two vectors. Assumes vectors are of the same length. “ ” if len(vec1) != len(vec2) : raise ValueError(“Vectors must have the same length for dot product.”)

```

1 result = 0.0
2 for i in range(len(vec1)):
3     result += vec1[i] * vec2[i]
4 return result

```

```
def vector_norm(vec) : """ Calculates the Euclidean norm (L2 norm) of a vector. ||v|| =
sqrt(v1^2 + v2^2 + ... + vn^2) """ sum_sq = 0.0 for x in vec : sum_sq += x * x return
math.sqrt(sum_sq)
```

```
def cosine_similarity(vec1, vec2) : """ Calculates the cosine similarity between two vectors.
cos(theta) = (vec1 . vec2) / (||vec1|| * ||vec2||) Returns 0.0 if either vector has a zero norm to
avoid division by zero. """ norm1 = vector_norm(vec1) norm2 = vector_norm(vec2)
```

```
1 if norm1 == 0.0 or norm2 == 0.0:
2     return 0.0 # Return 0.0 for zero vectors, indicating no similarity.
3
4 return dot_product(vec1, vec2) / (norm1 * norm2)
```

### 3.12 — Part 3 : Semantic Search Engine (basic) —

```
class SemanticSearchEngine : def init(self, documents) : self.documents = documents self.document_tokens
= [tokenize(doc) for doc in documents] self.document_term_freqs = [count_term_frequency(tokens)
for tokens in self.document_tokens] self.vocabulary = build_vocabulary(self.document_term_freqs)
self.idf_scores = compute_idf(self.document_term_freqs) self.document_vectors = self._index_documents()
```

```
1 def _index_documents(self):
2     """
3     Indexes all documents by converting them into TF-IDF vectors.
4     """
5     vectors = []
6     for doc_freqs in self.document_term_freqs:
7         tf_scores = compute_tf(doc_freqs)
8         tfidf_scores = compute_tfidf(tf_scores, self.idf_scores)
9         vectors.append(vectorize(tfidf_scores, self.vocabulary))
10    return vectors
11
12 def search(self, query, top_k=3):
13    """
14    Searches the indexed documents for the given query and returns
15    the top_k most similar documents.
16    """
17    query_tokens = tokenize(query)
18    query_term_freqs = count_term_frequency(query_tokens)
19    query_tf_scores = compute_tf(query_term_freqs)
20    query_tfidf_scores = compute_tfidf(query_tf_scores, self.idf_scores)
21    query_vector = vectorize(query_tfidf_scores, self.vocabulary)
22
23    if vector_norm(query_vector) == 0: # Query is empty or contains only
        unknown words
24        return []
25
26    similarities = []
27    for i, doc_vector in enumerate(self.document_vectors):
28        sim = cosine_similarity(query_vector, doc_vector)
29        similarities.append((sim, self.documents[i]))
30
31    # Sort by similarity in descending order.
32    # Python's built-in sort is used for convenience; a custom sort (e.g
        ., bubble sort)
33    # could be implemented from scratch if strictly required for sorting
        logic.
34    similarities.sort(key=lambda x: x[0], reverse=True)
35
```

```
36 return similarities[:top_k]
```

### 3.13 — Part 4 : Problème d'Algèbre de l'X (Projection Orthogonale) —

def orthogonal\_projection(u, v) : “” Calcule la projection orthogonale du vecteur u sur le vecteur v. Formule :  $\text{proj}_v(u) = ((u \cdot v) / ||v||^2) * v$

```
1 Args:
2     u (list): Le vecteur à projeter.
3     v (list): Le vecteur sur lequel projeter.
4
5 Returns:
6     list: Le vecteur résultant de la projection.
7
8 Raises:
9     ValueError: Si les vecteurs n'ont pas la même longueur.
10 """
11 if len(u) != len(v):
12     raise ValueError("Les vecteurs doivent avoir la même longueur.")
13
14 norm_v_squared = dot_product(v, v) # ||v||^2
15
16 if norm_v_squared == 0.0:
17     # If v is the zero vector, the projection of any u onto v is the
18     # zero vector.
19     return [0.0] * len(u)
20
21 scalar_factor = dot_product(u, v) / norm_v_squared
22
23 projection = []
24 for x in v:
25     projection.append(scalar_factor * x)
26 return projection
```

### 3.14 — Assertions de Validation —

```
print("— Tests Part 1 : Text Processing and Vectorization —") text1 = "Bonjour le monde, ceci est un test." tokens1 = tokenize(text1) assert tokens1 == ['bonjour', 'le', 'monde', 'ceci', 'est', 'un', 'test'], f"Tokenize failed : {tokens1}" print(f"Tokenize test passed : {tokens1}")
```

```
term_freq1 = count_term_frequency(tokens1) assert term_freq1 == {'bonjour' : 1, 'le' : 1, 'monde' : 1, 'ceci' : 1, 'est' : 1, 'un' : 1, 'test' : 1}, f"Term frequency failed : {term_freq1}" print(f"Term frequency test passed : {term_freq1}")
```

```
tf_scores1 = compute_tf(term_freq1) assert abs(tf_scores1['bonjour'] - (1/7)) < 1e-9, f"TF failed : {tf_scores1}" print(f"TF test passed : {tf_scores1}")
```

```
documents = [ "La science est la connaissance.", "La technologie est l'application de la science.", "L'ingénierie est l'art de l'application de la technologie." ] doc_tokens = [tokenize(doc) for doc in documents] doc_term_freqs = [count_term_frequency(tokens) for tokens in doc_tokens] vocab = build_vocabulary(doc_term_freqs) expected_vocab = ['application', 'art', 'connaissance', 'de', 'est', 'ingénierie', 'la', 'le', 'science', 'technologie'] assert vocab == expected_vocab, f"Vocabulary failed : {vocab}" print(f"Vocabulary test passed : {vocab}")
```

```
idf_scores = compute_idf(doc_term_freqs) # IDF('la') = log_e((3+1)/(3+1)) + 1 = log_e(1) + 1 = 1.0 # IDF('science') = log_e((3+1)/(2+1)) + 1 = log_e(4/3) + 1 approx 0.287 +
```

```

1 = 1.287 assert abs(idf_scores['la'] - 1.0) < 1e-9, f"IDF 'la' failed : {idf_scores['la']}" assert
abs(idf_scores['science'] - (math.log(4/3) + 1)) < 1e-9, f"IDF 'science' failed : {idf_scores['science']}"
print(f"IDF test passed : {idf_scores}")
tf_doc1 = compute_tf(doc_term_freqs[0]) tfidf_doc1 = compute_tfidf(tf_doc1, idf_scores)
vec_doc1 = vectorize(tfidf_doc1, vocab) # TF('science', doc1) = 1/4 # IDF('science') =
math.log(4/3) + 1 # TFIDF('science', doc1) = (1/4) * (math.log(4/3) + 1) expected_tfidf_science_doc1
= (1/4) * (math.log(4/3) + 1) science_index = vocab.index('science') assert abs(vec_doc1[science_index]
- expected_tfidf_science_doc1) < 1e-9, f"Vectorization TFIDF 'science' failed : {vec_doc1[science_index]}"
print(f"Vectorization test passed for doc1 : {vec_doc1}")
print("— Tests Part 2 : Cosine Similarity —") v1 = [1.0, 1.0, 0.0] v2 = [1.0, 0.0, 1.0] v3 =
[1.0, 1.0, 0.0] # Same as v1 v4 = [0.0, 0.0, 0.0] # Zero vector
assert dot_product(v1, v2) == 1.0, f"Dot product failed : {dot_product(v1, v2)}" assert
dot_product(v1, v3) == 2.0, f"Dot product failed : {dot_product(v1, v3)}" print(f"Dot product
test passed : {dot_product(v1, v2)}")
assert abs(vector_norm(v1) - math.sqrt(2.0)) < 1e-9, f"Vector norm failed : {vector_norm(v1)}"
assert abs(vector_norm(v4) - 0.0) < 1e-9, f"Vector norm of zero vector failed : {vector_norm(v4)}"
print(f"Vector norm test passed : {vector_norm(v1)}")
sim_v1_v2 = cosine_similarity(v1, v2) expected_sim_v1_v2 = 1.0 / (math.sqrt(2.0) *
math.sqrt(2.0)) # 1 / 2 = 0.5 assert abs(sim_v1_v2 - 0.5) < 1e-9, f"Cosine similarity v1, v2
failed : {sim_v1_v2}" print(f"Cosine similarity v1, v2 test passed : {sim_v1_v2}")
sim_v1_v3 = cosine_similarity(v1, v3) assert abs(sim_v1_v3 - 1.0) < 1e-9, f"Cosine si-
milarity v1, v3 failed : {sim_v1_v3}" # Identical vectors print(f"Cosine similarity v1, v3 test
passed : {sim_v1_v3}")
sim_v1_v4 = cosine_similarity(v1, v4) assert abs(sim_v1_v4 - 0.0) < 1e-9, f"Cosine simi-
larity with zero vector failed : {sim_v1_v4}" print(f"Cosine similarity v1, v4 (zero vector) test
passed : {sim_v1_v4}")
print("— Tests Part 3 : Semantic Search Engine —") search_docs = [ "Le chat dort sur le
tapis.", "Le chien joue avec la balle.", "Un chat noir et blanc est mignon.", "Le tapis est doux."]
engine = SemanticSearchEngine(search_docs)
assert len(engine.document_vectors) == len(search_docs), "Search engine indexing failed :
incorrect number of vectors." assert len(engine.vocabulary) > 0, "Search engine vocabulary is
empty." print(f"Search engine indexed {len(engine.document_vectors)} documents.")
query = "chat mignon" results = engine.search(query, top_k=2) assert len(results) == 2,
f"Search results count failed : {len(results)}" assert "chat noir et blanc est mignon" in re-
sults[0][1].lower(), f"Top result incorrect : {results[0][1]}" assert "chat dort sur le tapis" in re-
sults[1][1].lower(), f"Second result incorrect : {results[1][1]}" print(f"Search query '{query}' re-
sults : {results}")
query_no_match = "xyz non-existent" results_no_match = engine.search(query_no_match)
assert len(results_no_match) == 0, f"Search with no match should return empty : {results_no_match}"
print(f"Search query '{query_no_match}' results (expected empty) : {results_no_match}")
print("— Tests Part 4 : Problème d'Algèbre de l'X (Projection Orthogonale) —") u_vec =
[1.0, 2.0, 3.0] v_vec = [1.0, 0.0, 0.0] # Projection onto x-axis
proj_u_on_v = orthogonal_projection(u_vec, v_vec) assert len(proj_u_on_v) == 3,
f"Projection vector length incorrect : {len(proj_u_on_v)}" assert abs(proj_u_on_v[0] - 1.0)
< 1e-9 and abs(proj_u_on_v[1] - 0.0) < 1e-9 and abs(proj_u_on_v[2] - 0.0) < 1e-9, f"Pro-
jection [1,0,0] failed : {proj_u_on_v}" print(f"Projection of {u_vec} onto {v_vec} passed :
{proj_u_on_v}")
u_vec2 = [3.0, 4.0] v_vec2 = [1.0, 1.0] # Projection onto y=x line # u.v = 3*1 + 4*1 = 7 #
||v||^2 = 1^2 + 1^2 = 2 # scalar = 7/2 = 3.5 # proj = 3.5 * [1,1] = [3.5, 3.5] proj_u2_on_v2
= orthogonal_projection(u_vec2, v_vec2) assert abs(proj_u2_on_v2[0] - 3.5) < 1e-9 and
abs(proj_u2_on_v2[1] - 3.5) < 1e-9, f"Projection [3.5,3.5] failed : {proj_u2_on_v2}" print(f"Projection

```

```

of {u_vec2} onto {v_vec2} passed : {proj_u2_on_v2}"
    u_vec3 = [5.0, 0.0] v_vec3 = [0.0, 0.0] # Zero vector proj_u3_on_v3 = orthogonal_projection(u_vec3,
v_vec3) assert abs(proj_u3_on_v3[0] - 0.0) < 1e-9 and abs(proj_u3_on_v3[1] - 0.0) < 1e-9,
f"Projection onto zero vector failed : {proj_u3_on_v3}" print(f"Projection onto zero vector
passed : {proj_u3_on_v3}")
    u_vec4 = [1.0, 2.0] v_vec4 = [0.0, 1.0] # u.v = 2 # ||v||^2 = 1 # scalar = 2 # proj = 2 * [0,1]
= [0,2] proj_u4_on_v4 = orthogonal_projection(u_vec4, v_vec4) assert abs(proj_u4_on_v4[0]
- 0.0) < 1e-9 and abs(proj_u4_on_v4[1] - 2.0) < 1e-9, f"Projection [0,2] failed : {proj_u4_on_v4}"
print(f"Projection of {u_vec4} onto {v_vec4} passed : {proj_u4_on_v4}")

```

### 3.15 Test for different lengths (should raise ValueError)

```

try : orthogonal_projection([1,2], [1,2,3]) assert False, "ValueError not raised for different
vector lengths." except ValueError as e : assert str(e) == "Les vecteurs doivent avoir la même
longueur.", "Incorrect ValueError message." print("Projection with different lengths correctly rai-
sed ValueError.")
print("assertions passed!")

```

## TP 5

### 3.16 TP 05 : Conception Théorique d'un Moteur de Recherche Sémantique : Géométrie des Espaces de Plongement et Al- gèbre Linéaire Fondamentale

#### 3.16.1 Objectif Mathématique

Ce TP vise à explorer les fondements mathématiques de la recherche sémantique et de l'algèbre linéaire, en se concentrant sur la géométrie des espaces vectoriels et la dualité. Nous implémenterons "from scratch" les opérations vectorielles de base, la similarité cosinus pour mesurer la proximité sémantique dans des espaces de plongement simplifiés (Bag-of-Words), et le processus d'orthogonalisation de Gram-Schmidt. Ce dernier illustrera la construction de bases orthogonales, concept clé pour comprendre la structure et les projections dans les espaces vectoriels, et résoudra un problème d'algèbre linéaire typique des concours. L'objectif est de comprendre comment les concepts de distance angulaire (similarité cosinus) et de transformation de base (Gram-Schmidt) sont essentiels à la manipulation et à l'interprétation des données vectorielles, notamment dans le contexte des plongements sémantiques. La dualité est abordée implicitement par l'interprétation du produit scalaire comme l'application d'une forme linéaire, permettant de projeter un vecteur sur un autre ou de mesurer leur alignement.

#### Normalisation L2 et Conditionnement

L'étape systématique de normalisation L2  $v \mapsto \frac{v}{\|v\|_2}$  agit comme un conditionneur garantissant que tous les points résident sur la variété riemannienne  $\mathbb{S}^{|V|-1}$ . La recherche du plus proche voisin devient équivalente au problème du MIPS (Maximum Inner Product Search), simplifiant drastiquement l'inférence.

#### 3.16.2 Implémentation Python Pure

```

482 \ImportTok{import}\NormalTok{ math}
483

```



```

484 \CommentTok{\# {-}{-}{-} Partie 1 : Opérations Vectorielles
      Fondamentales (From Scratch) {-}{-}{-}}
485
486 \KeywordTok{def}\NormalTok{ dot\_product(v1, v2):}
487   \CommentTok{"""}
488   \CommentTok{    Calcule le produit scalaire de deux vecteurs.}
489   \CommentTok{    Précondition: Les vecteurs doivent avoir la même
      dimension.}
490   \CommentTok{"""}
491   \ControlFlowTok{if} \BuiltInTok{len}\NormalTok{(v1) }\OperatorTok{ } \OperatorTok{
      !=} \BuiltInTok{len}\NormalTok{(v2):}
492   \ControlFlowTok{raise} \PreprocessorTok{ValueError}\NormalTok{
      {(}\StringTok{"Les vecteurs doivent avoir la même dimension
      pour le produit scalaire."}\NormalTok{)} }
493 \NormalTok{    result }\OperatorTok{=} \DecValTok{0}
494   \ControlFlowTok{for}\NormalTok{ i }\KeywordTok{in} \BuiltInTok{range}
      {(}\NormalTok{(}\BuiltInTok{len}\NormalTok{(v1))):}
495 \NormalTok{    result }\OperatorTok{+=}\NormalTok{ v1[i] }\
      OperatorTok{*}\NormalTok{ v2[i]}
496   \ControlFlowTok{return}\NormalTok{ result}
497
498 \KeywordTok{def}\NormalTok{ vector\_magnitude(v):}
499   \CommentTok{"""}
500   \CommentTok{    Calcule la magnitude (norme euclidienne) d\
      textquotesingle{un vecteur.}
501   \CommentTok{"""}
502 \NormalTok{    sum\_sq }\OperatorTok{=} \DecValTok{0}
503   \ControlFlowTok{for}\NormalTok{ x }\KeywordTok{in} \NormalTok{ v:}
504 \NormalTok{    sum\_sq }\OperatorTok{+=}\NormalTok{ x }\OperatorTok{
      *} \NormalTok{ x}
505   \ControlFlowTok{return}\NormalTok{ math.sqrt(sum\_sq)}
506
507 \KeywordTok{def}\NormalTok{ normalize\_vector(v):}
508   \CommentTok{"""}
509   \CommentTok{    Normalise un vecteur pour obtenir un vecteur unitaire.}
510   \CommentTok{"""}
511 \NormalTok{    mag }\OperatorTok{=}\NormalTok{ vector\_magnitude(v)}
512   \ControlFlowTok{if}\NormalTok{ mag }\OperatorTok{==} \DecValTok{0}\
      NormalTok{:}
513   \CommentTok{\# Un vecteur nul ne peut pas être normalisé.
      Retourne une copie du vecteur nul.}
514   \ControlFlowTok{return}\NormalTok{ [}\FloatTok{0.0}\NormalTok{] }\OperatorTok{*} \BuiltInTok{len}\NormalTok{(v)}
515   \ControlFlowTok{return}\NormalTok{ [x }\OperatorTok{/}\NormalTok{ mag }\ControlFlowTok{for} \NormalTok{ x }\KeywordTok{in} \NormalTok{ v]}
516
517 \KeywordTok{def}\NormalTok{ scalar\_multiply(scalar, v):}
518   \CommentTok{"""}
519   \CommentTok{    Multiplie un vecteur par un scalaire.}
520   \CommentTok{"""}
521   \ControlFlowTok{return}\NormalTok{ [scalar }\OperatorTok{*} \NormalTok{ x }\ControlFlowTok{for} \NormalTok{ x }\KeywordTok{in} \NormalTok{ v]}
522
523 \KeywordTok{def}\NormalTok{ vector\_subtract(v1, v2):}
524   \CommentTok{"""}
525   \CommentTok{    Soustrait le vecteur v2 du vecteur v1 (v1 {-} v2).}

```

```

526 \CommentTok{ Précondition: Les vecteurs doivent avoir la même
dimension.}
527 \CommentTok{ "" }
528 \ControlFlowTok{if} \BuiltInTok{len}\NormalTok{(v1) }\OperatorTok
{!=} \BuiltInTok{len}\NormalTok{(v2):}
529 \ControlFlowTok{raise} \PreprocessorTok{ValueError}\NormalTok
{(\StringTok{"Les vecteurs doivent avoir la même dimension
pour la soustraction."}\NormalTok{})}
530 \ControlFlowTok{return}\NormalTok{ [v1[i] ]\OperatorTok{{-}}\
NormalTok{ v2[i] }}\ControlFlowTok{for}\NormalTok{ i }\KeywordTok{f
in} \BuiltInTok{range}\NormalTok{((\BuiltInTok{len}\NormalTok{(v1
)))]}
531
532 \CommentTok{\# {-}{-}{-} Assertions pour les opérations vectorielles
{-}{-}{-}}
533 \BuiltInTok{print}\NormalTok{((\StringTok{"{-}{-}{-} Tests des opé
rations vectorielles {-}{-}{-}"}\NormalTok{}))}
534 \NormalTok{v\_a }\OperatorTok{=}\NormalTok{[ ]\DecValTok{1}\NormalTok{[,
]\DecValTok{2}\NormalTok{[, ]\DecValTok{3}\NormalTok{[,]}}
535 \NormalTok{v\_b }\OperatorTok{=}\NormalTok{[ ]\DecValTok{4}\NormalTok{[,
]\DecValTok{5}\NormalTok{[, ]\DecValTok{6}\NormalTok{[,]}}
536 \NormalTok{v\_zero }\OperatorTok{=}\NormalTok{[ ]\DecValTok{0}\NormalTok{[,
]\DecValTok{0}\NormalTok{[, ]\DecValTok{0}\NormalTok{[,]}}
537 \NormalTok{v\_neg }\OperatorTok{=}\NormalTok{[ ]\OperatorTok{{-}}\
DecValTok{1}\NormalTok{[, ]\OperatorTok{{-}}\DecValTok{2}\NormalTok{[,
]\OperatorTok{{-}}\DecValTok{3}\NormalTok{[,]}}
538
539 \ControlFlowTok{assert}\NormalTok{ dot\_product(v\_a, v\_b) }\
OperatorTok{==}\DecValTok{32}\NormalTok{[, ]\SpecialStringTok{f"
Erreur produit scalaire: }\SpecialCharTok{\{}\NormalTok{dot\_product(
v\_a, v\_b)}\SpecialCharTok{\}}\SpecialStringTok{"}
540 \ControlFlowTok{assert} \BuiltInTok{abs}\NormalTok{(vector\_magnitude(v\
_a) )\OperatorTok{{-}}\NormalTok{ math.sqrt()\DecValTok{14}\NormalTok{
})} \OperatorTok{\textless{}} \FloatTok{1e{-}9}\NormalTok{[, ]\
SpecialStringTok{f"Erreur magnitude: }\SpecialCharTok{\{}\NormalTok{vec
tor\_magnitude(v\_a)}\SpecialCharTok{\}}\SpecialStringTok{"}
541 \ControlFlowTok{assert} \BuiltInTok{abs}\NormalTok{(normalize\_vector(v\
_a)[\DecValTok{0}\NormalTok{[]] )\OperatorTok{{-}}\NormalTok{ (}\
DecValTok{1} \OperatorTok{/}\NormalTok{ math.sqrt()\DecValTok{14}\
NormalTok{)})} \OperatorTok{\textless{}} \FloatTok{1e{-}9}\NormalTok{[, ]\
SpecialStringTok{f"Erreur normalisation: }\SpecialCharTok{\{}\
NormalTok{normalize\_vector(v\_a)[\DecValTok{0}\NormalTok{[]]}\
SpecialCharTok{\}}\SpecialStringTok{"}
542 \ControlFlowTok{assert}\NormalTok{ scalar\_multiply()\DecValTok{2}\
NormalTok{[, v\_a] }\OperatorTok{==}\NormalTok{[ ]\DecValTok{2}\
NormalTok{[, ]\DecValTok{4}\NormalTok{[, ]\DecValTok{6}\NormalTok{[,]}, ]\
SpecialStringTok{f"Erreur multiplication scalaire: }\SpecialCharTok
{\{}\NormalTok{scalar\_multiply()\DecValTok{2}\NormalTok{[, v\_a)}\
SpecialCharTok{\}}\SpecialStringTok{"}
543 \ControlFlowTok{assert}\NormalTok{ vector\_subtract(v\_b, v\_a) }\
OperatorTok{==}\NormalTok{[ ]\DecValTok{3}\NormalTok{[, ]\DecValTok
{3}\NormalTok{[, ]\DecValTok{3}\NormalTok{[,]}, ]\SpecialStringTok{f"
Erreur soustraction vectorielle: }\SpecialCharTok{\{}\NormalTok{vec
tor\_subtract(v\_b, v\_a)}\SpecialCharTok{\}}\SpecialStringTok{"}
544 \ControlFlowTok{assert}\NormalTok{ dot\_product(v\_a, v\_zero) }\
OperatorTok{==}\DecValTok{0}\NormalTok{[, ]\StringTok{"Produit
scalaire avec vecteur nul doit être 0"}

```

```

545 \ControlFlowTok{assert}\NormalTok{ vector\_magnitude(v\_zero) }\
    OperatorTok{==}\DecValTok{0}\NormalTok{, }\StringTok{"Magnitude d\
    textquotesingle{}un vecteur nul doit être 0"}
546 \ControlFlowTok{assert}\NormalTok{ normalize\_vector(v\_zero) }\
    OperatorTok{==}\NormalTok{ []}\FloatTok{0.0}\NormalTok{, }\FloatTok
    {0.0}\NormalTok{, }\FloatTok{0.0}\NormalTok{[] , }\StringTok{"
    Normalisation d\textquotesingle{}un vecteur nul"}
547 \ControlFlowTok{assert}\NormalTok{ dot\_product(v\_a, v\_neg) }\
    OperatorTok{==}\OperatorTok{{-}}\DecValTok{14}\NormalTok{, }\
    StringTok{"Produit scalaire avec vecteur négatif"}
548 \BuiltInTok{print}\NormalTok{({}\StringTok{"Tests des opérations
    vectorielles passés avec succès."}\NormalTok{)}}
549
550 \CommentTok{\# {-}{-}{-} Partie 2 : Similarité Cosinus pour la Recherche
    Sémantique {-}{-}{-}}
551
552 \KeywordTok{def}\NormalTok{ cosine\_similarity(v1, v2):}
553     \CommentTok{"""}
554     \CommentTok{    Calcule la similarité cosinus entre deux vecteurs.}
555     \CommentTok{    Retourne 0 si l\textquotesingle{}un des vecteurs est nul
    .}
556     \CommentTok{    """}
557     \NormalTok{ mag1 }\OperatorTok{=}\NormalTok{ vector\_magnitude(v1)}
558     \NormalTok{ mag2 }\OperatorTok{=}\NormalTok{ vector\_magnitude(v2)}
559
560     \ControlFlowTok{if}\NormalTok{ mag1 }\OperatorTok{=}\DecValTok{0}
    \KeywordTok{or}\NormalTok{ mag2 }\OperatorTok{=}\DecValTok{0}\
    NormalTok{:}
561     \ControlFlowTok{return}\FloatTok{0.0} \CommentTok{\#
    Convention pour les vecteurs nuls}
562
563     \ControlFlowTok{return}\NormalTok{ dot\_product(v1, v2) }\
    OperatorTok{/}\NormalTok{ (mag1 }\OperatorTok{*}\NormalTok{ mag2)
    }
564
565 \CommentTok{\# {-}{-}{-} Assertions pour la similarité cosinus
    {-}{-}{-}}
566 \BuiltInTok{print}\NormalTok{({}\StringTok{"}\CharTok{\textbackslash{}n}\
    StringTok{{-}{-}{-} Tests de la similarité cosinus {-}{-}{-}}\
    NormalTok{)}}
567 \NormalTok{v\_parallel }\OperatorTok{=}\NormalTok{ []}\DecValTok{2}\
    NormalTok{, }\DecValTok{4}\NormalTok{, }\DecValTok{6}\NormalTok{[] }\
    CommentTok{\# Parallèle à v\_a}
568 \NormalTok{v\_orthogonal\_true }\OperatorTok{=}\NormalTok{ []}\DecValTok
    {1}\NormalTok{, }\DecValTok{1}\NormalTok{, }\OperatorTok{{-}}\
    DecValTok{1}\NormalTok{[] }\CommentTok{\# 1*1 + 2*1 + 3*(-1) = 0}
569
570 \ControlFlowTok{assert} \BuiltInTok{abs}\NormalTok{((cosine\_similarity(v
    \_a, v\_a) }\OperatorTok{{-}}}\FloatTok{1.0}\NormalTok{) )}\
    OperatorTok{\textless{}}\FloatTok{1e{-}9}\NormalTok{, }\
    SpecialStringTok{f"Erreur similarité cosinus (même vecteur): }\
    SpecialCharTok{\{}\NormalTok{cosine\_similarity(v\_a, v\_a)}\
    SpecialCharTok{\}}\SpecialStringTok{"}
571 \ControlFlowTok{assert} \BuiltInTok{abs}\NormalTok{((cosine\_similarity(v
    \_a, v\_parallel) }\OperatorTok{{-}}}\FloatTok{1.0}\NormalTok{) )}\
    OperatorTok{\textless{}}\FloatTok{1e{-}9}\NormalTok{, }\
    SpecialStringTok{f"Erreur similarité cosinus (vecteurs parallèles):
    }\SpecialCharTok{\{}\NormalTok{cosine\_similarity(v\_a, v\_parallel)

```

```

    }\SpecialCharTok{\}}\SpecialStringTok{"}
572 \ControlFlowTok{assert} \BuiltInTok{abs}\NormalTok{(cosine\_similarity(v
    \_a, v\_orthogonal\_true) }\OperatorTok{{-}} \FloatTok{0.0}\NormalTok{
    {) }\OperatorTok{\textless{}} \FloatTok{1e{-}9}\NormalTok{, }\
    SpecialStringTok{f"Erreur similarité cosinus (vecteurs orthogonaux):
    }\SpecialCharTok{\}\NormalTok{cosine\_similarity(v\_a, v\_orthogonal
    \_true)}\SpecialCharTok{\}}\SpecialStringTok{"}
573 \ControlFlowTok{assert}\NormalTok{ cosine\_similarity(v\_a, v\_zero) }\
    OperatorTok{==} \FloatTok{0.0}\NormalTok{, }\StringTok{"Similarité
    cosinus avec vecteur nul doit être 0"}
574 \ControlFlowTok{assert} \BuiltInTok{abs}\NormalTok{(cosine\_similarity(v
    \_a, v\_neg) }\OperatorTok{{-}}\NormalTok{(}\OperatorTok{{-}}\
    FloatTok{1.0}\NormalTok{)}) }\OperatorTok{\textless{}} \FloatTok{1e
    {-}9}\NormalTok{, }\SpecialStringTok{f"Erreur similarité cosinus (
    vecteurs opposés): }\SpecialCharTok{\}\NormalTok{cosine\_similarity(
    v\_a, v\_neg)}\SpecialCharTok{\}}\SpecialStringTok{"}
575 \BuiltInTok{print}\NormalTok{(}\StringTok{"Tests de la similarité
    cosinus passés avec succès."}\NormalTok{)}
576
577 \CommentTok{\# {-}{-}{-} Partie 3 : Implémentation Simplifiée d\
    textquotesingle{ }Espaces de Plongement (Bag{-}of{-}Words) {-}{-}{-}}
578
579 \KeywordTok{def}\NormalTok{ tokenize(text):}
580     \CommentTok{"""}
581     \CommentTok{    Tokenise un texte en mots, convertit en minuscules et
    filtre les caractères non alphabétiques.}
582     \CommentTok{"""}
583     \CommentTok{\# Simple tokenisation: supprime la ponctuation et
    divise par espace}
584 \NormalTok{    clean\_text }\OperatorTok{=} \StringTok{\textquotesingle
    { }\textquotesingle{}}\NormalTok{.join(c.lower() }\ControlFlowTok{if}\
    NormalTok{ c.isalpha() }\KeywordTok{or}\NormalTok{ c.isspace() }\
    ControlFlowTok{else} \StringTok{\textquotesingle{ } \textquotesingle{
    }} \ControlFlowTok{for}\NormalTok{ c }\KeywordTok{in}\NormalTok{ text)}
585     \ControlFlowTok{return}\NormalTok{ [word }\ControlFlowTok{for}\
    NormalTok{ word }\KeywordTok{in}\NormalTok{ clean\_text.split()
    }\ControlFlowTok{if}\NormalTok{ word]}
586
587 \KeywordTok{def}\NormalTok{ build\_vocabulary(documents):}
588     \CommentTok{"""}
589     \CommentTok{    Construit un vocabulaire unique à partir d\
    textquotesingle{ }une liste de documents.}
590     \CommentTok{    Retourne un dictionnaire \{mot: index\}.}
591     \CommentTok{"""}
592 \NormalTok{    unique\_words }\OperatorTok{=}\NormalTok{ { }}
593 \NormalTok{    index }\OperatorTok{=} \DecValTok{0}
594     \ControlFlowTok{for}\NormalTok{ doc }\KeywordTok{in}\NormalTok{ documents:}
595         \ControlFlowTok{for}\NormalTok{ word }\KeywordTok{in}\NormalTok{ tokenize(doc):}
596             \ControlFlowTok{if}\NormalTok{ word }\KeywordTok{not} \
    KeywordTok{in}\NormalTok{ unique\_words:}
597 \NormalTok{                unique\_words[word] }\OperatorTok{=}\
    NormalTok{ index}
598 \NormalTok{                index }\OperatorTok{+=} \DecValTok{1}
599     \ControlFlowTok{return}\NormalTok{ unique\_words}
600

```

```

601 \KeywordTok{def}\NormalTok{ document\_to\_vector(document , vocabulary):}
602   \CommentTok{"""}
603 \CommentTok{    Convertit un document en vecteur Bag{-}of{-}Words (
604   comptes de fréquence).}
605 \CommentTok{    """}
606 \NormalTok{    vector }\OperatorTok{=}\NormalTok{ [ ]\DecValTok{0}\
607   NormalTok{ ] }\OperatorTok{*} \BuiltInTok{len}\NormalTok{(vocabulary)}
608   \ControlFlowTok{for}\NormalTok{ word }\KeywordTok{in}\NormalTok{ tokenize(document):}
609   \ControlFlowTok{if}\NormalTok{ word }\KeywordTok{in}\NormalTok{ vocabulary:}
610   \NormalTok{    vector[vocabulary[word]] }\OperatorTok{+=} \
611   DecValTok{1}
612   \ControlFlowTok{return}\NormalTok{ vector}
613
614 \KeywordTok{def}\NormalTok{ semantic\_search\_engine(query , documents):}
615   \CommentTok{"""}
616 \CommentTok{    Moteur de recherche sémantique simplifié utilisant la
617   similarité cosinus.}
618 \CommentTok{    """}
619 \CommentTok{\# Inclure la requête et tous les documents pour
620   construire un vocabulaire global}
621 \NormalTok{    all\_texts }\OperatorTok{=}\NormalTok{ documents }\
622   OperatorTok{+}\NormalTok{ [query]}
623 \NormalTok{    vocabulary }\OperatorTok{=}\NormalTok{ build\_vocabulary(
624   all\_texts)}
625
626 \NormalTok{    query\_vector }\OperatorTok{=}\NormalTok{ document\_to\_
627   _vector(query , vocabulary)}
628
629 \NormalTok{    results }\OperatorTok{=}\NormalTok{ [ ]}
630   \ControlFlowTok{for}\NormalTok{ i, doc\_text }\KeywordTok{in} \
631   BuiltInTok{enumerate}\NormalTok{(documents):}
632 \NormalTok{    doc\_vector }\OperatorTok{=}\NormalTok{ document\_to\_
633   _vector(doc\_text , vocabulary)}
634 \NormalTok{    similarity }\OperatorTok{=}\NormalTok{ cosine\_
635   _similarity(query\_vector , doc\_vector)}
636 \NormalTok{    results.append((doc\_text , similarity))}
637
638   \CommentTok{\# Trie les résultats par similarité décroissante}
639 \NormalTok{    results.sort(key)\OperatorTok{=}\KeywordTok{lambda}\
640   NormalTok{ x: x[ ]\DecValTok{1}\NormalTok{ , reverse}\OperatorTok{=}\
641   VariableTok{True}\NormalTok{}}
642   \ControlFlowTok{return}\NormalTok{ results}
643
644 \CommentTok{\# {-}{-}{-} Assertions pour le moteur de recherche sé
645   mantique {-}{-}{-}}
646 \BuiltInTok{print}\NormalTok{({}\StringTok{"}\CharTok{\textbackslash{n}}\
647   StringTok{{-}{-}{-} Tests du moteur de recherche sémantique {-}{-}{-}
648   ")\NormalTok{}}
649 \NormalTok{documents }\OperatorTok{=}\NormalTok{ [ ]}
650   \StringTok{"Le chat dort sur le tapis."}\NormalTok{ ,}
651   \StringTok{"Un chien court dans le parc."}\NormalTok{ ,}
652   \StringTok{"Le chat noir est mignon."}\NormalTok{ ,}
653   \StringTok{"Le parc est grand et vert."}
654 \NormalTok{ ]}
655 \NormalTok{query }\OperatorTok{=}\StringTok{"chat mignon"}
656

```

```

641 \CommentTok{\# Test de tokenisation}
642 \ControlFlowTok{assert}\NormalTok{ tokenize()\StringTok{"Le Chat, dort!"
}\NormalTok{}} \OperatorTok{==}\NormalTok{ []\StringTok{\
textquotesingle{}\le\textquotesingle{}}\NormalTok{, }\StringTok{\
textquotesingle{}}chat\textquotesingle{}}\NormalTok{, }\StringTok{\
textquotesingle{}}dort\textquotesingle{}}\NormalTok{[]}, }\
SpecialStringTok{f"Erreur tokenisation: }\SpecialCharTok{\{\}\
NormalTok{tokenize()\StringTok{\textquotesingle{}}Le Chat, dort!\
textquotesingle{}}\NormalTok{}}\SpecialCharTok{\}\}\SpecialStringTok{"
}
643
644 \CommentTok{\# Test de vocabulaire}
645 \NormalTok{vocab }\OperatorTok{=}\NormalTok{ build\_vocabulary(documents
)}
646 \NormalTok{expected\_vocab\_size }\OperatorTok{=} \BuiltInTok{len}\
NormalTok{({}\BuiltInTok{set}\NormalTok{({word }\ControlFlowTok{for}\
NormalTok{ doc }\KeywordTok{in}\NormalTok{ documents }\ControlFlowTok{
for}\NormalTok{ word }\KeywordTok{in}\NormalTok{ tokenize(doc)))}
647 \ControlFlowTok{assert} \BuiltInTok{len}\NormalTok{({vocab}) }\OperatorTok{
==}\NormalTok{ expected\_vocab\_size, }\SpecialStringTok{f"Erreur
taille vocabulaire: }\SpecialCharTok{\{\}\BuiltInTok{len}\NormalTok{({
vocab})}\SpecialCharTok{\}\}\SpecialStringTok{ vs }\SpecialCharTok{\{\}\
NormalTok{expected\_vocab\_size}\SpecialCharTok{\}\}\SpecialStringTok{
"}}
648
649 \CommentTok{\# Test de vectorisation (vérification de la somme des
comptes)}
650 \NormalTok{doc\_vec\_chat\_dort }\OperatorTok{=}\NormalTok{ document\_to
\_vector()\StringTok{"Le chat dort"}\NormalTok{, vocab)}
651 \ControlFlowTok{assert} \BuiltInTok{sum}\NormalTok{({doc\_vec\_chat\_dort
}) }\OperatorTok{==} \DecValTok{3}\NormalTok{, }\SpecialStringTok{f"
Erreur somme vectorisation: }\SpecialCharTok{\{\}\BuiltInTok{sum}\
NormalTok{({doc\_vec\_chat\_dort})}\SpecialCharTok{\}\}\SpecialStringTok{
{"}}
652
653 \CommentTok{\# Test de recherche}
654 \NormalTok{search\_results }\OperatorTok{=}\NormalTok{ semantic\_search\
\_engine(query, documents)}
655 \CommentTok{\# Le document "Le chat noir est mignon." devrait être le
plus pertinent.}
656 \ControlFlowTok{assert}\NormalTok{ search\_results[]\DecValTok{0}\
NormalTok{[]}\DecValTok{0}\NormalTok{[]} }\OperatorTok{==} \StringTok{"
Le chat noir est mignon."}\NormalTok{, }\SpecialStringTok{f"Erreur
ordre de recherche: }\SpecialCharTok{\{\}\NormalTok{search\_results[]\
DecValTok{0}\NormalTok{[]}\DecValTok{0}\NormalTok{[]}\SpecialCharTok
{\}\}\SpecialStringTok{"}}
657 \ControlFlowTok{assert}\NormalTok{ search\_results[]\DecValTok{0}\
NormalTok{[]}\DecValTok{1}\NormalTok{[]} }\OperatorTok{\textgreater{}}\
NormalTok{ search\_results[]\DecValTok{1}\NormalTok{[]}\DecValTok{1}\
NormalTok{, }\StringTok{"Le document le plus pertinent n\
textquotesingle{}}a pas la plus haute similarité."}
658 \BuiltInTok{print}\NormalTok{({}\StringTok{"Tests du moteur de recherche
sémantique passés avec succès."}\NormalTok{)}}
659
660 \CommentTok{\# {-}{-}{-} Partie 4 : Problème d\textquotesingle{}}Algèbre
de l\textquotesingle{}}X : Orthogonalisation de Gram{-}{-}Schmidt
{-}{-}{-}}
661

```

```

662 \KeywordTok{def}\NormalTok{ project(v, u):}
663   \CommentTok{"""}
664 \CommentTok{    Calcule la projection orthogonale du vecteur v sur le
        vecteur u.}
665 \CommentTok{    """}
666   \ControlFlowTok{if}\NormalTok{ vector\_magnitude(u) }\OperatorTok{
        ==}\NormalTok{ \DecValTok{0}}\NormalTok{:}
667   \ControlFlowTok{return}\NormalTok{ [}\NormalTok{ }\FloatTok{0.0}\NormalTok{ }\OperatorTok{
        *}\NormalTok{ \BuiltInTok{len}}\NormalTok{(u) }\CommentTok{
        {\# Projection sur un vecteur nul est un vecteur nul}
668
669   \CommentTok{\# proj\_u(v) = (v . u / ||u||^2) * u}
670 \NormalTok{ scalar\_factor }\OperatorTok{=}\NormalTok{ dot\_product(
        v, u) }\OperatorTok{/}\NormalTok{ dot\_product(u, u)}
671 \ControlFlowTok{return}\NormalTok{ scalar\_multiply(scalar\_factor,
        u)}
672
673 \KeywordTok{def}\NormalTok{ gram\_schmidt(vectors):}
674   \CommentTok{"""}
675 \CommentTok{    Applique le processus d\textquotesingle}
        orthogonalisation de Gram-Schmidt à un ensemble de vecteurs.}
676 \CommentTok{    Retourne une base orthonormée.}
677 \CommentTok{    Précondition: Les vecteurs d\textquotesingle}
        entrée sont traités séquentiellement. Les vecteurs}
678 \CommentTok{    linéairement dépendants des précédents seront ignorés (r
        ésumant en un vecteur nul).}
679 \CommentTok{    """}
680   \ControlFlowTok{if}\NormalTok{ }\KeywordTok{not}\NormalTok{ vectors:}
681   \ControlFlowTok{return}\NormalTok{ []}
682
683 \NormalTok{ orthonormal\_basis }\OperatorTok{=}\NormalTok{ []}
684 \ControlFlowTok{for}\NormalTok{ v }\KeywordTok{in}\NormalTok{ vectors:}
685   \CommentTok{\# Initialise le vecteur orthogonal potentiel avec
        le vecteur original}
686 \NormalTok{ u }\OperatorTok{=}\NormalTok{ \BuiltInTok{list}}\NormalTok{(v) }\CommentTok{
        {\# Crée une copie mutable}
687
688   \CommentTok{\# Soustrait les projections sur les vecteurs déjà
        orthogonalisés}
689   \ControlFlowTok{for}\NormalTok{ basis\_vec }\KeywordTok{in}\NormalTok{
        orthonormal\_basis:}
690 \NormalTok{ proj\_v\_basis\_vec }\OperatorTok{=}\NormalTok{ project(
        v, basis\_vec)}
691 \NormalTok{ u }\OperatorTok{=}\NormalTok{ vector\_subtract(u,
        proj\_v\_basis\_vec)}
692
693   \CommentTok{\# Normalise le vecteur résultant s\textquotesingle}
        il n\textquotesingle est pas nul}
694 \NormalTok{ mag\_u }\OperatorTok{=}\NormalTok{ vector\_magnitude(
        u)}
695   \ControlFlowTok{if}\NormalTok{ mag\_u }\OperatorTok{\textgreater}
        \FloatTok{1e-9}\NormalTok{:} \CommentTok{\# Utilise une
        petite tolérance pour éviter les divisions par zéro dues aux
        erreurs de flottants}
696 \NormalTok{ orthonormal\_basis.append(normalize\_vector(u))}
697   \CommentTok{\# Si mag\_u est proche de zéro, cela signifie que
        le vecteur est linéairement dépendant}

```

```

698 \CommentTok{\# des vecteurs précédents, et il est ignoré.}
699
700 \ControlFlowTok{return}\NormalTok{ orthonormal\_basis}
701
702 \CommentTok{\# {-}{-}{-} Assertions pour Gram{-}Schmidt {-}{-}{-}}
703 \BuiltInTok{print}\NormalTok{({}\StringTok{"}\CharTok{\textbackslash}\n}\
StringTok{{-}{-}{-} Tests de Gram{-}Schmidt {-}{-}{-}}\NormalTok{)}
704
705 \CommentTok{\# Cas 1: Vecteurs orthogonaux initiaux (devraient juste être normalisés)}
706 \NormalTok{v1\_gs }\OperatorTok{=}\NormalTok{[ ]\DecValTok{1}\NormalTok{ {, }\DecValTok{0}\NormalTok{[]}}
707 \NormalTok{v2\_gs }\OperatorTok{=}\NormalTok{[ ]\DecValTok{0}\NormalTok{ {, }\DecValTok{1}\NormalTok{[]}}
708 \NormalTok{basis1 }\OperatorTok{=}\NormalTok{gram\_schmidt([v1\_gs, v2\_gs])}
709 \ControlFlowTok{assert} \BuiltInTok{len}\NormalTok{((basis1) )}\
OperatorTok{=}\DecValTok{2}\NormalTok{ {, }\StringTok{"Gram{-}Schmidt
devrait produire 2 vecteurs pour 2 entrées indépendantes."}}
710 \ControlFlowTok{assert} \BuiltInTok{abs}\NormalTok{(vector\_magnitude(
basis1 []\DecValTok{0}\NormalTok{[])) }\OperatorTok{{-}} \FloatTok{1.0}\NormalTok{)}
\OperatorTok{{-}} \FloatTok{1e{-}9}\NormalTok{ {, }\StringTok{"Le premier vecteur de base n\textquotesingle{}est pas
unitaire."}}
711 \ControlFlowTok{assert} \BuiltInTok{abs}\NormalTok{(vector\_magnitude(
basis1 []\DecValTok{1}\NormalTok{[])) }\OperatorTok{{-}} \FloatTok{1.0}\NormalTok{)}
\OperatorTok{{-}} \FloatTok{1e{-}9}\NormalTok{ {, }\StringTok{"Le second vecteur de base n\textquotesingle{}est pas
unitaire."}}
712 \ControlFlowTok{assert} \BuiltInTok{abs}\NormalTok{(dot\_product(basis1
[]\DecValTok{0}\NormalTok{[] , basis1 []\DecValTok{1}\NormalTok{[])) }\OperatorTok{{-}} \FloatTok{1e{-}9}\NormalTok{ {, }\StringTok{"
Les vecteurs de base ne sont pas orthogonaux."}}
713 \ControlFlowTok{assert} \BuiltInTok{abs}\NormalTok{(basis1 []\DecValTok
{0}\NormalTok{[] []\DecValTok{0}\NormalTok{[] }\OperatorTok{{-}} \FloatTok{1.0}\NormalTok{)}
\OperatorTok{{-}} \FloatTok{1e{-}9} \KeywordTok{and} \BuiltInTok{abs}\NormalTok{(basis1 []\DecValTok
{0}\NormalTok{[] []\DecValTok{1}\NormalTok{[] }\OperatorTok{{-}} \FloatTok{0.0}\NormalTok{)}
\OperatorTok{{-}} \FloatTok{1e{-}9}\NormalTok{ {, }\StringTok{"Le premier vecteur n\textquotesingle{}
est pas correct."}}
714 \ControlFlowTok{assert} \BuiltInTok{abs}\NormalTok{(basis1 []\DecValTok
{1}\NormalTok{[] []\DecValTok{0}\NormalTok{[] }\OperatorTok{{-}} \FloatTok{0.0}\NormalTok{)}
\OperatorTok{{-}} \FloatTok{1e{-}9} \KeywordTok{and} \BuiltInTok{abs}\NormalTok{(basis1 []\DecValTok
{1}\NormalTok{[] []\DecValTok{1}\NormalTok{[] }\OperatorTok{{-}} \FloatTok{1.0}\NormalTok{)}
\OperatorTok{{-}} \FloatTok{1e{-}9}\NormalTok{ {, }\StringTok{"Le second vecteur n\textquotesingle{}
est pas correct."}}
715
716 \CommentTok{\# Cas 2: Vecteurs non orthogonaux}
717 \NormalTok{v3\_gs }\OperatorTok{=}\NormalTok{[ ]\DecValTok{1}\NormalTok{ {, }\DecValTok{1}\NormalTok{[]}}
718 \NormalTok{v4\_gs }\OperatorTok{=}\NormalTok{[ ]\DecValTok{2}\NormalTok{ {, }\DecValTok{0}\NormalTok{[]}}
719 \NormalTok{basis2 }\OperatorTok{=}\NormalTok{gram\_schmidt([v3\_gs, v4\_gs])}

```



```

720 \ControlFlowTok{assert} \BuiltInTok{len}\NormalTok{(basis2) }\
    OperatorTok{==}\DecValTok{2}\NormalTok{, }\StringTok{"Gram{-}Schmidt
    devrait produire 2 vecteurs pour 2 entrées indépendantes."}
721 \ControlFlowTok{assert} \BuiltInTok{abs}\NormalTok{(vector\_magnitude(
    basis2[]\DecValTok{0}\NormalTok{[])) }\OperatorTok{{-}} \FloatTok{1.0}\
    NormalTok{) }\OperatorTok{\textless{}} \FloatTok{1e{-}9}\NormalTok{, }
    }\StringTok{"Le premier vecteur de base n\textquotesingle{}est pas
    unitaire."}
722 \ControlFlowTok{assert} \BuiltInTok{abs}\NormalTok{(vector\_magnitude(
    basis2[]\DecValTok{1}\NormalTok{[])) }\OperatorTok{{-}} \FloatTok{1.0}\
    NormalTok{) }\OperatorTok{\textless{}} \FloatTok{1e{-}9}\NormalTok{, }
    }\StringTok{"Le second vecteur de base n\textquotesingle{}est pas
    unitaire."}
723 \ControlFlowTok{assert} \BuiltInTok{abs}\NormalTok{(dot\_product(basis2
    []\DecValTok{0}\NormalTok{[], basis2[]\DecValTok{1}\NormalTok{[])) }\
    OperatorTok{\textless{}} \FloatTok{1e{-}9}\NormalTok{, }\
    SpecialStringTok{f"Les vecteurs de base ne sont pas orthogonaux: }\
    SpecialCharTok{\{\}\NormalTok{dot\_product(basis2[]\DecValTok{0}\
    NormalTok{[], basis2[]\DecValTok{1}\NormalTok{[])}\SpecialCharTok{\}\}\
    SpecialStringTok{"}
724
725 \CommentTok{\# Vérification des valeurs spécifiques pour basis2}
726 \NormalTok{expected\_basis2\_0 }\OperatorTok{=}\NormalTok{normalize\
    _vector([]\DecValTok{1}\NormalTok{, }\DecValTok{1}\NormalTok{[])}
727 \NormalTok{expected\_basis2\_1 }\OperatorTok{=}\NormalTok{normalize\
    _vector([]\DecValTok{1}\NormalTok{, }\OperatorTok{{-}}\DecValTok{1}\
    NormalTok{[])}
728 \ControlFlowTok{for}\NormalTok{i }\KeywordTok{in}\ \BuiltInTok{range}\
    NormalTok{(\}\BuiltInTok{len}\NormalTok{(expected\_basis2\_0)):}
729 \ControlFlowTok{assert} \BuiltInTok{abs}\NormalTok{(basis2[]\
    DecValTok{0}\NormalTok{[])[i] }\OperatorTok{{-}}\NormalTok{expected\_basis2\_0[i]
    }\OperatorTok{\textless{}} \FloatTok{1e
    {-}9}\NormalTok{, }\SpecialStringTok{f"Erreur Gram{-}Schmidt
    basis2[0]: }\SpecialCharTok{\{\}\NormalTok{basis2[]\DecValTok{0}\
    NormalTok{[]}\SpecialCharTok{\}\}\SpecialStringTok{ vs }\
    SpecialCharTok{\{\}\NormalTok{expected\_basis2\_0}\SpecialCharTok
    {\}\}\SpecialStringTok{"}
730 \ControlFlowTok{assert} \BuiltInTok{abs}\NormalTok{(basis2[]\
    DecValTok{1}\NormalTok{[])[i] }\OperatorTok{{-}}\NormalTok{expected\_basis2\_1[i]
    }\OperatorTok{\textless{}} \FloatTok{1e
    {-}9}\NormalTok{, }\SpecialStringTok{f"Erreur Gram{-}Schmidt
    basis2[1]: }\SpecialCharTok{\{\}\NormalTok{basis2[]\DecValTok{1}\
    NormalTok{[]}\SpecialCharTok{\}\}\SpecialStringTok{ vs }\
    SpecialCharTok{\{\}\NormalTok{expected\_basis2\_1}\SpecialCharTok
    {\}\}\SpecialStringTok{"}
731
732 \CommentTok{\# Cas 3: Vecteurs en 3D}
733 \NormalTok{v5\_gs }\OperatorTok{=}\NormalTok{[]\DecValTok{1}\NormalTok{, }\DecValTok{0}\NormalTok{[]}
734 \NormalTok{v6\_gs }\OperatorTok{=}\NormalTok{[]\DecValTok{1}\NormalTok{, }\DecValTok{1}\NormalTok{[]}
735 \NormalTok{v7\_gs }\OperatorTok{=}\NormalTok{[]\DecValTok{0}\NormalTok{, }\DecValTok{1}\NormalTok{[]}
736 \NormalTok{basis3 }\OperatorTok{=}\NormalTok{gram\_schmidt([v5\_gs, v6\
    _gs, v7\_gs])}
737 \ControlFlowTok{assert} \BuiltInTok{len}\NormalTok{(basis3) }\
    OperatorTok{==}\DecValTok{3}\NormalTok{, }\StringTok{"Gram{-}Schmidt
    devrait produire 3 vecteurs pour 3 entrées indépendantes."}

```

```

738 \ControlFlowTok{for}\NormalTok{ i }\KeywordTok{in} \BuiltInTok{range}\
    NormalTok{(}\DecValTok{3}\NormalTok{):}
739 \ControlFlowTok{assert} \BuiltInTok{abs}\NormalTok{(vector\
    _magnitude(basis3[i]) }\OperatorTok{-}\} \FloatTok{1.0}\NormalTok{(}
    ) }\OperatorTok{\textless{}} \FloatTok{1e{-}9}\NormalTok{, }\
    SpecialStringTok{f"Vecteur }\SpecialCharTok{\{\}\NormalTok{i}\
    SpecialCharTok{\}\}\SpecialStringTok{ de basis3 n\textquotesingle
    {est pas unitaire."}
740 \ControlFlowTok{for}\NormalTok{ j }\KeywordTok{in} \BuiltInTok{range}
    }\NormalTok{(i }\OperatorTok{+}\} \DecValTok{1}\NormalTok{, }\
    DecValTok{3}\NormalTok{):}
741 \ControlFlowTok{assert} \BuiltInTok{abs}\NormalTok{(dot\_product
    (basis3[i], basis3[j])) }\OperatorTok{\textless{}} \FloatTok
    {1e{-}9}\NormalTok{, }\SpecialStringTok{f"Vecteurs }\
    SpecialCharTok{\{\}\NormalTok{i}\SpecialCharTok{\}\}\
    SpecialStringTok{ et }\SpecialCharTok{\{\}\NormalTok{j}\
    SpecialCharTok{\}\}\SpecialStringTok{ de basis3 ne sont pas
    orthogonaux."}
742
743 \CommentTok{\# Cas 4: Vecteurs linéairement dépendants (un vecteur nul
    ou multiple d\textquotesingle{un précédent))}
744 \NormalTok{v8\_gs }\OperatorTok{=}\NormalTok{[ }\DecValTok{1}\NormalTok{, }\
    DecValTok{0}\NormalTok{]}
745 \NormalTok{v9\_gs }\OperatorTok{=}\NormalTok{[ }\DecValTok{2}\NormalTok{, }\
    DecValTok{0}\NormalTok{] }\CommentTok{\# Linéairement dépendant
    de v8\_gs}
746 \NormalTok{basis4 }\OperatorTok{=}\NormalTok{gram\_schmidt([v8\_gs, v9\
    _gs])}
747 \ControlFlowTok{assert} \BuiltInTok{len}\NormalTok{(basis4) }\
    OperatorTok{==}\DecValTok{1}\NormalTok{, }\StringTok{"Gram{-}Schmidt
    devrait ignorer les vecteurs linéairement dépendants."}
748 \ControlFlowTok{assert} \BuiltInTok{abs}\NormalTok{(basis4[ }\DecValTok
    {0}\NormalTok{[ }\DecValTok{0}\NormalTok{] }\OperatorTok{-}\} \
    FloatTok{1.0}\NormalTok{(}
    ) }\OperatorTok{\textless{}} \FloatTok{1e
    {-}9} \KeywordTok{and} \BuiltInTok{abs}\NormalTok{(basis4[ }\DecValTok
    {0}\NormalTok{[ }\DecValTok{1}\NormalTok{] }\OperatorTok{-}\} \
    FloatTok{0.0}\NormalTok{(}
    ) }\OperatorTok{\textless{}} \FloatTok{1e
    {-}9}\NormalTok{, }\StringTok{"Le vecteur de base n\textquotesingle{
    est pas correct."}
749
750 \BuiltInTok{print}\NormalTok{(}\StringTok{"Tests de Gram{-}Schmidt passé
    s avec succès."}\NormalTok{)}
751
752 \BuiltInTok{print}\NormalTok{(}\StringTok{"}\CharTok{\textbackslash{n}\
    StringTok{{-}{-}{-} Démonstration du Moteur de Recherche Sémantique
    {-}{-}{-}}\NormalTok{)}
753 \NormalTok{documents\_demo }\OperatorTok{=}\NormalTok{[ }
754 \StringTok{"La science des données est un domaine passionnant."}\
    NormalTok{,}
755 \StringTok{"L\textquotesingle{apprentissage automatique ré
    volutionne l\textquotesingle{intelligence artificielle."}\
    NormalTok{,}
756 \StringTok{"Les mathématiques sont fondamentales pour la compré
    hension de l\textquotesingle{IA."}\NormalTok{,}
757 \StringTok{"Un chat noir dort paisiblement sur le canapé."}\
    NormalTok{,}
758 \StringTok{"Le deep learning est une branche de l\textquotesingle{
    apprentissage automatique."}

```

```

759 \NormalTok{}}
760 \NormalTok{query\_demo } \OperatorTok{=} \StringTok{"mathématiques et"}
      intelligence artificielle"}
761 \NormalTok{results\_demo } \OperatorTok{=}\NormalTok{ semantic\_search\_}
      _engine(query\_demo , documents\_demo)}
762
763 \BuiltInTok{print}\NormalTok{({}\SpecialStringTok{f"}\CharTok{\}
      textbackslash{}n}\SpecialStringTok{Requête: \textquotesingle{}}\}
      SpecialCharTok{\{\}\NormalTok{query\_demo}\SpecialCharTok{\}\}
      SpecialStringTok{\textquotesingle{}}"}\NormalTok{)}
764 \BuiltInTok{print}\NormalTok{({}\StringTok{"Résultats de recherche ("}
      document, similarité cosinus):"}\NormalTok{)}
765 \ControlFlowTok{for}\NormalTok{ doc , sim }\KeywordTok{in}\NormalTok{ results\_demo:}
766   \BuiltInTok{print}\NormalTok{({}\SpecialStringTok{f" {-} Sim: }\}
      SpecialCharTok{\{\}\NormalTok{sim}\SpecialCharTok{:.4f}\}\}
      SpecialStringTok{ | Doc: \textquotesingle{}}\SpecialCharTok{\{\}\}
      NormalTok{doc}\SpecialCharTok{\}\}SpecialStringTok{\}
      textquotesingle{}}"}\NormalTok{)}
767
768 \BuiltInTok{print}\NormalTok{({}\StringTok{"}\CharTok{\}textbackslash{}n}\}
      StringTok{{-}{-}{-} Démonstration de Gram{-}Schmidt {-}{-}{-}}"}\}
      NormalTok{)}
769 \NormalTok{vectors\_demo } \OperatorTok{=}\NormalTok{ [[}\DecValTok{1}\}
      NormalTok{, }\DecValTok{1}\NormalTok{, }\DecValTok{1}\NormalTok{, }\DecValTok{1}\NormalTok{, }\DecValTok{1}\}
      ,
      [}\DecValTok{1}\NormalTok{, }\DecValTok{0}\NormalTok{, }\DecValTok{0}\NormalTok{, }\DecValTok{0}\NormalTok{, }\DecValTok{0}\}
      ,
      [}\DecValTok{0}\NormalTok{, }\DecValTok{0}\NormalTok{, }\DecValTok{0}\NormalTok{, }\DecValTok{0}\NormalTok{, }\DecValTok{0}\}
      ,
      [}\DecValTok{0}\NormalTok{, }\DecValTok{0}\NormalTok{, }\DecValTok{0}\NormalTok{, }\DecValTok{0}\NormalTok{, }\DecValTok{0}\}
      ]]}
770 \BuiltInTok{print}\NormalTok{({}\SpecialStringTok{f"Vecteurs originaux:"}
      }\SpecialCharTok{\{\}\NormalTok{vectors\_demo}\SpecialCharTok{\}\}
      SpecialStringTok{"}\NormalTok{)}
771 \NormalTok{orthonormal\_basis\_demo } \OperatorTok{=}\NormalTok{ gram\_}
      _schmidt(vectors\_demo)}
772 \BuiltInTok{print}\NormalTok{({}\SpecialStringTok{f"Base orthonormée"}
      obtenue par Gram{-}Schmidt: }\SpecialCharTok{\{\}\NormalTok{ orthonormal\_}
      _basis\_demo}\SpecialCharTok{\}\}SpecialStringTok{"}\NormalTok{)}
773
774 \CommentTok{\# Vérification des propriétés de la base orthonormée}
775 \BuiltInTok{print}\NormalTok{({}\StringTok{"}\CharTok{\}textbackslash{}n}\}
      StringTok{Vérification de la base orthonormée:"}\NormalTok{)}
776 \ControlFlowTok{for}\NormalTok{ i , u\_i }\KeywordTok{in}\NormalTok{ enumerate(orthonormal\_}
      _basis\_demo):}
777   \BuiltInTok{print}\NormalTok{({}\SpecialStringTok{f" Vecteur }\}
      SpecialCharTok{\{\}\NormalTok{i}\SpecialCharTok{\}\}
      SpecialStringTok{: }\SpecialCharTok{\{\}\NormalTok{u\_i}\}
      SpecialCharTok{\}\}SpecialStringTok{"}\NormalTok{)}
778   \BuiltInTok{print}\NormalTok{({}\SpecialStringTok{f" Magnitude: }\}
      SpecialCharTok{\{\}\NormalTok{vector\_magnitude(u\_i)\}
      SpecialCharTok{:.4f}\}\}SpecialStringTok{( attendue: 1.0)}"}\}
      NormalTok{)}
779   \ControlFlowTok{for}\NormalTok{ j , u\_j }\KeywordTok{in}\NormalTok{ enumerate(orthonormal\_}
      _basis\_demo):}
780     \ControlFlowTok{if}\NormalTok{ i }\OperatorTok{\textless{}}\}
      NormalTok{ j:}
781       \BuiltInTok{print}\NormalTok{({}\SpecialStringTok{f""}
      Produit scalaire avec vecteur }\SpecialCharTok{\{\}\}
      NormalTok{j}\SpecialCharTok{\}\}SpecialStringTok{: }\}

```

```
SpecialCharTok{\{\}\NormalTok{dot\_product(u\_i, u\_j)}\
SpecialCharTok{:.4f\}\}\SpecialStringTok{ (attendu: 0.0) "
}\NormalTok{)}
```