

LIVRABLE IA T6 : FORMALISATION DE LA DIVERGENCE DE KULLBACK-LEIBLER

Cours magistral, exercices corrigés et travaux pratiques

Charles EDOU NZE

17 septembre 2026

Table des matières

I	Cours Magistral	2
1	Formalisation Mathématique de l'Information	2
2	Formalisation	2
2.1	Définition via les densités	2
2.2	Exemples Concrets Immédiats	2
2.3	Propriétés Fondamentales	3
3	Démonstrations	3
3.1	Démonstration de la positivité (via l'inégalité de Jensen)	3
4	Exercices d'Application	4
4.1	Exercice 1 : KL entre deux Gaussiennes	4
4.2	Exercice 2 : Niveau Avancé (Lien avec l'Entropie Croisée)	4
5	Application en Intelligence Artificielle	4
6	Liens Sémantiques	4
II	Exercices d'Application et de Concours	5
III	Travaux Pratiques et Simulations Algorithmiques	8

Première partie

Cours Magistral

1 Formalisation Mathématique de l'Information

La divergence de Kullback-Leibler (ou entropie relative) est une mesure asymétrique de la dissimilitude entre deux distributions de probabilités P et Q . Issu de la théorie de l'information (Shannon, 1948), ce concept quantifie l'excès d'information ou la pénalité asymptotique subie lorsque la distribution Q est utilisée pour approximer la véritable distribution P .

En intelligence artificielle, la divergence de Kullback-Leibler est fondamentale. Elle sert de fonction objectif dans la minimisation de l'erreur d'approximation lors de l'entraînement de modèles génératifs (tels que les auto-encodeurs variationnels ou les modèles de diffusion) et constitue le fondement mathématique de la fonction de perte cross-Entropy.

2 Formalisation

Soit $(\mathcal{X}, \mathcal{F}, \lambda)$ un espace mesuré (généralement $\mathbb{R}^n$ avec la mesure de Lebesgue). Soient P et Q deux mesures de probabilité sur cet espace.

2.1 Définition via les densités

Supposons que P et Q admettent des densités p et q par rapport à λ .

2.2 Exemples Concrets Immédiats

Exemple 1 : Divergence entre deux pièces de monnaie (Variables de Bernoulli)
Soit P la loi d'une pièce biaisée avec $p = 0.8$ (pile) et $1 - p = 0.2$ (face). Soit Q la loi d'une pièce équilibrée $q = 0.5$.

$$D_{KL}(P||Q) = 0.8 \ln \left(\frac{0.8}{0.5} \right) + 0.2 \ln \left(\frac{0.2}{0.5} \right) \approx 0.8 \times 0.470 + 0.2 \times (-0.916) = 0.376 - 0.183 = 0.193$$

L'asymétrie est visible si on calcule $D_{KL}(Q||P)$:

$$D_{KL}(Q||P) = 0.5 \ln \left(\frac{0.5}{0.8} \right) + 0.5 \ln \left(\frac{0.5}{0.2} \right) = 0.5 \times (-0.470) + 0.5 \times 0.916 = 0.223$$

Ainsi, $D_{KL}(P||Q) \neq D_{KL}(Q||P)$.

Exemple 2 : Divergence nulle pour des distributions identiques Si $P = Q$ (par exemple $p = 0.5, q = 0.5$), alors :

$$D_{KL}(P||P) = 0.5 \ln(1) + 0.5 \ln(1) = 0$$

Exemple 3 : Divergence infinie (support non inclus) Si $P(X = 1) = 1$ et $Q(X = 1) = 0$, alors :

$$D_{KL}(P||Q) = 1 \ln \left(\frac{1}{0} \right) = +\infty$$

Cela illustre l'absolue continuité requise : P doit être absolument continue par rapport à Q ($P \ll Q$).

Exemple 4 : Deux lois uniformes Soient $P = \mathcal{U}([0, 1])$ et $Q = \mathcal{U}([0, 2])$. Pour $x \in [0, 1]$, $p(x) = 1$ et $q(x) = 0.5$.

$$D_{KL}(P||Q) = \int_0^1 1 \ln\left(\frac{1}{0.5}\right) dx = \ln(2) \approx 0.693$$

À l'inverse, pour $x \in]1, 2]$, $p(x) = 0$ et $q(x) = 0.5$. Comme $p(x) > 0$ sur un ensemble où $q(x) = 0$ n'arrive pas, mais pour $D_{KL}(Q||P)$, on intègre sur $[0, 2]$. Sur $]1, 2]$, $p(x) = 0$, d'où $D_{KL}(Q||P) = +\infty$.

Exemple 5 : Divergence KL entre deux Gaussiennes univariées Soient $P = \mathcal{N}(\mu_1, \sigma_1^2)$ et $Q = \mathcal{N}(\mu_2, \sigma_2^2)$. La formule analytique rigoureuse donne :

$$D_{KL}(P||Q) = \ln\left(\frac{\sigma_2}{\sigma_1}\right) + \frac{\sigma_1^2 + (\mu_1 - \mu_2)^2}{2\sigma_2^2} - \frac{1}{2}$$

Si $\mu_1 = 0, \sigma_1 = 1$ et $\mu_2 = 2, \sigma_2 = 1$:

$$D_{KL}(P||Q) = \ln(1) + \frac{1 + 4}{2} - 0.5 = 2.0$$

Cette forme quadratique par rapport aux moyennes explique l'efficacité de la KL pour approcher des gaussiennes.

⌋ **Définition (Divergence de Kullback-Leibler)** : ⌋ On définit la divergence KL de Q par rapport à P par l'intégrale de Lebesgue : ⌋

$$D_{KL}(P||Q) = \int_{\mathcal{X}} p(x) \ln\left(\frac{p(x)}{q(x)}\right) d\lambda(x)$$

⌋ *Condition* : On suppose que P est absolument continue par rapport à Q ($P \ll Q$), c'est-à-dire que $q(x) = 0 \implies p(x) = 0$. Sinon, la divergence est $+\infty$.

2.3 Propriétés Fondamentales

⌋ **Inégalité de Gibbs (Positivité)** : ⌋ Pour toutes distributions de probabilité P et Q : ⌋

$$D_{KL}(P||Q) \geq 0$$

⌋ Avec égalité $D_{KL}(P||Q) = 0$ si et seulement si $P = Q$ presque partout.

⌋ **Asymétrie** : Attention, en général $D_{KL}(P||Q) \neq D_{KL}(Q||P)$. Ce n'est donc pas une "distance" au sens métrique du terme (Jalon 51).

3 Démonstrations

3.1 Démonstration de la positivité (via l'inégalité de Jensen)

1. **Réécriture** : $D_{KL}(P||Q) = \int p(x) [-\ln(q(x)/p(x))] d\lambda(x) = \mathbb{E}_P[-\ln(Q/P)]$. 2. **Utilisation de la convexité** : La fonction $\phi(u) = -\ln(u)$ est strictement convexe sur $]0, +\infty[$. 3. **Inégalité de Jensen** : Pour toute variable aléatoire U et fonction convexe ϕ :

$$\mathbb{E}[\phi(U)] \geq \phi(\mathbb{E}[U])$$

4. **Application** : Posons $U = q(X)/p(X)$ où $X \sim P$.

$$D_{KL}(P||Q) = \mathbb{E}_P[\phi(U)] \geq \phi(\mathbb{E}_P[U])$$

5. Calcul de l'espérance de U :

$$\mathbb{E}_P[U] = \int p(x) \frac{q(x)}{p(x)} d\lambda(x) = \int q(x) d\lambda(x) = 1$$

(car Q est une probabilité). 6. **Conclusion** : $D_{KL}(P\|Q) \geq \phi(1) = -\ln(1) = 0$. La positivité est démontrée.

4 Exercices d'Application

4.1 Exercice 1 : KL entre deux Gaussiennes

Énoncé : Calculer $D_{KL}(P\|Q)$ pour $P = \mathcal{N}(\mu_1, \sigma^2)$ et $Q = \mathcal{N}(\mu_2, \sigma^2)$. **Correction Détaillée** :
1. **Log-ratio** : $\ln(p(x)/q(x)) = \frac{1}{2\sigma^2}[(x - \mu_2)^2 - (x - \mu_1)^2]$. 2. **Développement** : $(x - \mu_2)^2 - (x - \mu_1)^2 = x^2 - 2x\mu_2 + \mu_2^2 - (x^2 - 2x\mu_1 + \mu_1^2) = 2x(\mu_1 - \mu_2) + \mu_2^2 - \mu_1^2$. 3. **Intégration par rapport à P** : $\mathbb{E}_P[x] = \mu_1$. $D_{KL} = \frac{1}{2\sigma^2}[2\mu_1(\mu_1 - \mu_2) + \mu_2^2 - \mu_1^2] = \frac{1}{2\sigma^2}[\mu_1^2 - 2\mu_1\mu_2 + \mu_2^2]$. 4. **Résultat** : $D_{KL}(P\|Q) = \frac{(\mu_1 - \mu_2)^2}{2\sigma^2}$. La divergence augmente avec le carré de la distance entre les moyennes.

4.2 Exercice 2 : Niveau Avancé (Lien avec l'Entropie Croisée)

Énoncé : Montrer que minimiser la Cross-Entropy entre des données et un modèle revient à minimiser la divergence KL. **Correction Détaillée** : $H(P, Q) = -\int p(x) \ln q(x) dx$. On remarque que $D_{KL}(P\|Q) = \int p \ln p - \int p \ln q = -H(P) + H(P, Q)$. Comme l'entropie des données $H(P)$ est constante par rapport aux paramètres du modèle, minimiser $H(P, Q)$ est équivalent à minimiser D_{KL} .

5 Application en Intelligence Artificielle

- **Le Pont Théorique** : La divergence KL est la fonction de perte par défaut pour tous les modèles probabilistes. Elle fait le lien entre la **Théorie de la Mesure** et la **Théorie de l'Information**. - **Exemple Concret** : - **Variational Auto-Encoders (VAE)** : La fonction de coût est la somme d'une erreur de reconstruction et d'un terme KL qui force la distribution latente à être proche d'une Gaussienne standard. - **Apprentissage par Renforcement (PPO)** : L'algorithme Proximal Policy Optimization utilise une contrainte KL pour éviter que la nouvelle politique ne s'éloigne trop de l'ancienne, garantissant ainsi une mise à jour stable. - **Classification Multi-classe** : Le calcul de la perte Softmax est rigoureusement une minimisation de la divergence KL entre la distribution "one-hot" des étiquettes et les probabilités prédites par le réseau.

6 Liens Sémantiques

- **Concepts Précédents requis** : Jalon 71 (Théorèmes de Fubini-Tonelli).md, Jalon 66 (Construction de l'intégrale de Lebesgue pour les fonctions mesurables positives.).md - **Concepts Futurs dépendants** : Jalon 85 (Axiomes de Kolmogorov).md, Jalon 140 (Classifieur de Bayes optimal).md

Deuxième partie

Exercices d'Application et de Concours

Exercice 1 : Divergence KL entre deux variables de Bernoulli ★★

Énoncé

Soient P et Q deux distributions de Bernoulli de paramètres p et q . Démontrez la positivité stricte de $D_{KL}(P||Q)$ pour $p \neq q$.

Correction

Par définition, $D_{KL}(P||Q) = p \ln\left(\frac{p}{q}\right) + (1-p) \ln\left(\frac{1-p}{1-q}\right)$. L'inégalité log de Gibbs $x \ln(x/y) \geq x - y$ implique que cette somme est $\geq (p - q) + ((1-p) - (1-q)) = 0$. L'égalité n'est atteinte que si $p = q$.

Exercice 2 : Asymétrie de la divergence KL ★★

Énoncé

Avec $P \sim \mathcal{B}(0.1)$ et $Q \sim \mathcal{B}(0.9)$, calculez $D_{KL}(P||Q)$ et $D_{KL}(Q||P)$.

Correction

$D_{KL}(P||Q) = 0.1 \ln(1/9) + 0.9 \ln(9) \approx -0.22 + 1.97 = 1.75$. $D_{KL}(Q||P) = 0.9 \ln(9) + 0.1 \ln(1/9) \approx 1.75$, ici la symétrie est accidentelle due à $p = 1 - q$. Prenons $P \sim \mathcal{B}(0.2)$, $Q \sim \mathcal{B}(0.5)$: $D_{KL}(P||Q) = 0.2 \ln(0.4) + 0.8 \ln(1.6) \approx -0.18 + 0.37 = 0.19$. $D_{KL}(Q||P) = 0.5 \ln(2.5) + 0.5 \ln(0.625) \approx 0.45 - 0.23 = 0.22$. L'asymétrie est claire.

Exercice 3 : KL entre lois normales (même variance) ★★★

Énoncé

Calculez $D_{KL}(\mathcal{N}(\mu_1, \sigma^2)||\mathcal{N}(\mu_2, \sigma^2))$.

Correction

La formule donne $\ln(1) + \frac{\sigma^2 + (\mu_1 - \mu_2)^2}{2\sigma^2} - 0.5 = \frac{(\mu_1 - \mu_2)^2}{2\sigma^2}$. La divergence est proportionnelle au carré de la distance euclidienne des moyennes, divisé par la variance.

Exercice 4 : Entropie croisée et divergence KL ★★★

Énoncé

Montrez que $H(P, Q) = H(P) + D_{KL}(P||Q)$.

Correction

$H(P, Q) = -\sum P(x) \ln Q(x) = -\sum P(x) \ln P(x) + \sum P(x) \ln\left(\frac{P(x)}{Q(x)}\right) = H(P) + D_{KL}(P||Q)$. Minimiser l'entropie croisée revient à minimiser la KL par rapport à Q si P est fixe.

Exercice 5 : Inégalité de Pinsker (introduction) ★★★

Énoncé

Rappelez l'inégalité de Pinsker liant la variation totale et la divergence KL.

Correction

L'inégalité s'écrit $\delta(P, Q) \leq \sqrt{\frac{1}{2} D_{KL}(P||Q)}$. Elle contrôle l'erreur absolue de probabilité globale.

Exercice 6 : KL pour des lois exponentielles ★★*

Énoncé

Calculez $D_{KL}(Exp(\lambda_1)||Exp(\lambda_2))$.

Correction

$$\int_0^\infty \lambda_1 e^{-\lambda_1 x} \ln\left(\frac{\lambda_1 e^{-\lambda_1 x}}{\lambda_2 e^{-\lambda_2 x}}\right) dx = \ln\left(\frac{\lambda_1}{\lambda_2}\right) + \frac{\lambda_2 - \lambda_1}{\lambda_1}.$$

Exercice 7 : Divergence KL et vraisemblance ★★★

Énoncé

Montrez que la maximisation de la log-vraisemblance équivaut à minimiser la divergence KL empirique.

Correction

Soit P_{emp} la distribution empirique. $D_{KL}(P_{emp}||Q_\theta) = \sum P_{emp}(x) \ln \frac{P_{emp}(x)}{Q_\theta(x)}$. Minimiser ceci par rapport à θ revient à maximiser $\sum P_{emp}(x) \ln Q_\theta(x) = \frac{1}{N} \sum_{i=1}^N \ln Q_\theta(x_i)$, qui est la log-vraisemblance.

Exercice 8 : Divergence de Jensen-Shannon ★★★

Énoncé

Définissez la divergence de Jensen-Shannon et vérifiez sa symétrie.

Correction

$JSD(P||Q) = \frac{1}{2} D_{KL}(P||M) + \frac{1}{2} D_{KL}(Q||M)$ où $M = \frac{1}{2}(P + Q)$. Par construction, elle est symétrique.

Exercice 9 : Propriété d'additivité ★★★

Énoncé

Montrez que $D_{KL}(P_1 \times P_2||Q_1 \times Q_2) = D_{KL}(P_1||Q_1) + D_{KL}(P_2||Q_2)$.

Correction

Le logarithme du produit des probabilités est la somme des logarithmes. L'intégrale double se sépare par linéarité et par le fait que les marginales intègrent à 1.

Exercice 10 : Borne inférieure de Cramer-Rao ★★★★★

Énoncé

En utilisant la divergence KL, démontrez que l'information de Fisher quantifie la courbure locale de l'espace des distributions.

Correction

Par développement de Taylor de $D_{KL}(P_\theta || P_{\theta+d\theta})$, le terme d'ordre 1 est nul, et le terme d'ordre 2 correspond à la matrice d'information de Fisher.

Troisième partie

Travaux Pratiques et Simulations Algorithmiques

TP 1 : Calcul de KL Bernoulli

```
1 import math
2 def kl_bernoulli(p, q):
3     if p == 0: return math.log(1 / (1 - q))
4     if p == 1: return math.log(1 / q)
5     return p * math.log(p / q) + (1 - p) * math.log((1 - p) / (1 - q))
6
7 assert abs(kl_bernoulli(0.5, 0.5)) < 1e-6
8 assert kl_bernoulli(0.8, 0.5) > 0
```

TP 2 : KL Gaussienne

```
1 import math
2 def kl_gaussian(mu1, sig1, mu2, sig2):
3     return math.log(sig2 / sig1) + (sig1**2 + (mu1 - mu2)**2) / (2 *
4         sig2**2) - 0.5
5
6 assert abs(kl_gaussian(0, 1, 0, 1)) < 1e-6
7 assert kl_gaussian(0, 1, 2, 1) == 2.0
```

TP 3 : Asymétrie

```
1 import math
2 def kl_bernoulli(p, q):
3     return p * math.log(p / q) + (1 - p) * math.log((1 - p) / (1 - q))
4
5 pq = kl_bernoulli(0.2, 0.5)
6 qp = kl_bernoulli(0.5, 0.2)
7 assert abs(pq - qp) > 1e-6
```

TP 4 : Entropie croisée

```
1 import math
2 def cross_entropy(p, q):
3     return -(p * math.log(q) + (1 - p) * math.log(1 - q))
4
5 def entropy(p):
6     return -(p * math.log(p) + (1 - p) * math.log(1 - p))
7
8 def kl(p, q):
9     return p * math.log(p / q) + (1 - p) * math.log((1 - p) / (1 - q))
10
11 ce = cross_entropy(0.3, 0.6)
12 h_plus_kl = entropy(0.3) + kl(0.3, 0.6)
13 assert abs(ce - h_plus_kl) < 1e-6
```

TP 5 : Jensen-Shannon

```
1 import math
2 def kl(p, q):
3     return p * math.log(p / q) + (1 - p) * math.log((1 - p) / (1 - q))
4
5 def jsd(p, q):
6     m = 0.5 * (p + q)
7     return 0.5 * kl(p, m) + 0.5 * kl(q, m)
8
9 assert abs(jsd(0.2, 0.8) - jsd(0.8, 0.2)) < 1e-6
```