INDÉPENDANCE D'ÉVÉNEMENTS ET DE VARIABLES ALÉATOIRES

Cours magistral, exercices corrigés et travaux pratiques

Charles EDOU NZE

11 octobre 2026

Table des matières

I Cours Magistral **2**

1 Introduction à l'Indépendance Stochastique **2**

2 Définitions, Théorèmes & Exemples **2**
2.1 Indépendance d'Événements 3
2.2 Indépendance de Tribus et de Variables Aléatoires 3

3 Démonstrations **4**
3.1 Démonstration 1 : Indépendance et Produit des Espérances 4

4 Applications en Mathématiques, Physique et Intelligence Artificielle **6**
4.1 Modélisation en Mécanique Statistique 6
4.2 Hypothèse I.I.D. en Apprentissage Automatique 6
4.3 Dropout dans les Réseaux de Neurones 6
4.4 Algorithme de Naïve Bayes 6

II Exercices d'Application et de Concours **7**

III Travaux Pratiques et Simulations Algorithmiques **12**

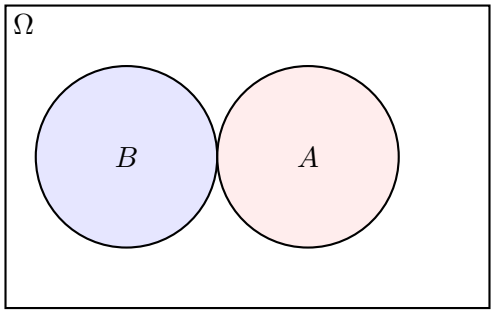
Première partie

Cours Magistral

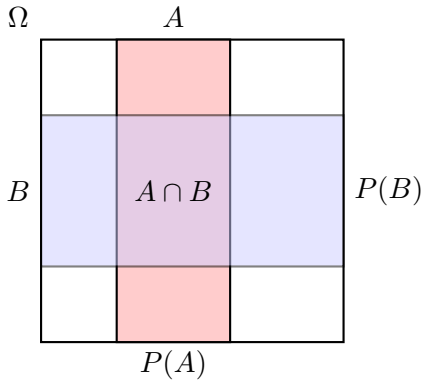
1 Introduction à l'Indépendance Stochastique

L'idée d'indépendance trouve ses racines dans les premiers travaux sur les jeux de hasard, formalisés par Pascal, Fermat, et plus tard par Bernoulli, De Moivre, et Laplace. Historiquement, l'indépendance traduit une réalité physique fondamentale : l'absence de causalité ou d'influence mutuelle entre deux expériences distinctes. Si deux dés sont lancés simultanément à des kilomètres de distance, le résultat du premier n'a matériellement aucune influence sur le résultat du second.

La formalisation moderne de l'indépendance s'intègre naturellement dans l'axiomatique de Kolmogorov (1933). Dans ce cadre de théorie de la mesure, l'indépendance n'est plus seulement une intuition physique, mais une propriété purement algébrique sur la mesure de probabilité des intersections d'ensembles. L'indépendance permet de construire des modèles probabilistes complexes par composition d'expériences simples, justifiant des résultats fondamentaux tels que la Loi des Grands Nombres et le Théorème Central Limite. C'est l'outil mathématique par excellence pour lutter contre la "malédiction de la dimensionnalité", en réduisant l'étude de l'espace global à ses composantes marginales.



Pour visualiser l'indépendance, on peut représenter l'espace des probabilités comme un carré de côté 1, où l'événement A occupe une bande verticale de largeur $P(A)$ et l'événement B une bande horizontale de hauteur $P(B)$. L'intersection $A \cap B$ forme un rectangle d'aire $P(A)P(B)$.



2 Définitions, Théorèmes & Exemples

Soit $(\Omega, \mathcal{F}, P)$ un espace probabilisé.

2.1 Indépendance d'Événements

Définition 1 : Indépendance de deux événements Deux événements $A, B \in \mathcal{F}$ sont dits indépendants (pour la probabilité P) si :

$$P(A \cap B) = P(A)P(B)$$

Si $P(B) > 0$, l'indépendance équivaut à affirmer que la probabilité conditionnelle $P(A|B) = \frac{P(A \cap B)}{P(B)}$ est égale à $P(A)$. Le fait que B soit réalisé ne modifie pas la probabilité de réalisation de A.

Exemple Concret 1 (Tirage de cartes) : On tire une carte au hasard dans un jeu de 52 cartes.

- A : "La carte tirée est un As" $\implies P(A) = \frac{4}{52} = \frac{1}{13}$
- B : "La carte tirée est un Cœur" $\implies P(B) = \frac{13}{52} = \frac{1}{4}$
- $A \cap B$: "La carte tirée est l'As de Cœur" $\implies P(A \cap B) = \frac{1}{52}$ On vérifie que $P(A)P(B) = \frac{1}{13} \times \frac{1}{4} = \frac{1}{52} = P(A \cap B)$. Les événements A et B sont indépendants. La proportion d'As parmi les cœurs est la même que la proportion d'As dans le jeu entier.

Exemple Concret 2 (Indépendance vs Incompatibilité) : Deux événements A et B incompatibles (disjoints, $A \cap B = \emptyset$) et de probabilités non nulles ne sont *jamais* indépendants. En effet, $P(A \cap B) = 0$, mais $P(A)P(B) > 0$. Si A se réalise, on a la certitude que B ne s'est pas réalisé. Ils sont donc fortement dépendants.

Définition 2 : Mutuelle indépendance Une famille d'événements $(A_i)_{i \in I}$ est mutuellement indépendante si pour toute sous-famille finie $J \subset I$:

$$P\left(\bigcap_{j \in J} A_j\right) = \prod_{j \in J} P(A_j)$$

Exemple Concret 3 (Indépendance deux à deux $\neq$ mutuelle indépendance) : On lance deux pièces équilibrées indépendantes. $\Omega = \{(P,P), (P,F), (F,P), (F,F)\}$. Chaque issue a une probabilité de $1/4$.

- A_1 : "La première pièce donne Face" $\implies P(A_1) = 1/2$.
- A_2 : "La deuxième pièce donne Face" $\implies P(A_2) = 1/2$.
- A_3 : "Les deux pièces donnent le même résultat" $\implies \{(P,P), (F,F)\}$, $P(A_3) = 2/4 = 1/2$. Vérifions l'indépendance deux à deux : $P(A_1 \cap A_2) = P(\{(F,F)\}) = 1/4 = P(A_1)P(A_2)$. $P(A_1 \cap A_3) = P(\{(F,F)\}) = 1/4 = P(A_1)P(A_3)$. $P(A_2 \cap A_3) = P(\{(F,F)\}) = 1/4 = P(A_2)P(A_3)$. Les événements sont indépendants deux à deux. Cependant, pour l'intersection globale : $A_1 \cap A_2 \cap A_3 = \{(F,F)\}$, donc $P(A_1 \cap A_2 \cap A_3) = 1/4$. Mais le produit donne $P(A_1)P(A_2)P(A_3) = 1/8 \neq 1/4$. La famille n'est donc *pas* mutuellement indépendante.

2.2 Indépendance de Tribus et de Variables Aléatoires

Définition 3 : Indépendance de tribus Des tribus $\mathcal{B}_1, \ldots, \mathcal{B}_n$ incluses dans $\mathcal{F}$ sont indépendantes si pour tout choix d'événements $B_i \in \mathcal{B}_i$, la famille d'événements $(B_1, \ldots, B_n)$ est mutuellement indépendante.

Définition 4 : Indépendance de variables aléatoires Des variables aléatoires $X_1, \ldots, X_n$ (à valeurs dans des espaces mesurables $(E_i, \mathcal{E}_i)$) sont indépendantes si les tribus qu'elles engendrent, $\sigma(X_i) = \{X_i^{-1}(B) \mid B \in \mathcal{E}_i\}$, sont indépendantes. De façon équivalente, pour tous boréliens $B_1, \ldots, B_n$:

$$P(X_1 \in B_1, \ldots, X_n \in B_n) = \prod_{i=1}^{n} P(X_i \in B_i)$$

Exemple Concret 4 (Variables discrètes) : Soit X et Y deux variables de loi de Bernoulli de paramètre p et q. Elles sont indépendantes si et seulement si pour tout $x, y \in \{0, 1\}$, $P(X = x, Y = y) = P(X = x)P(Y = y)$.

Exemple Concret 5 (Loi conjointe et produit tensoriel) : L'indépendance de X et Y signifie que la loi du couple (X, Y) est la mesure produit des lois marginales : $P_{(X,Y)} = P_X \otimes P_Y$. Si X et Y admettent des densités de probabilité respectives f_X et f_Y, elles sont indépendantes si et seulement si la densité du couple (X, Y) est donnée par le produit $f_{(X,Y)}(x, y) = f_X(x)f_Y(y)$ presque partout.

> **Théorème (Indépendance et Espérance) :** Soient X et Y deux variables aléatoires réelles indépendantes et intégrables (ou positives). Alors le produit XY est intégrable (ou d'espérance bien définie) et :
>
> $$\mathbb{E}[XY] = \mathbb{E}[X]\mathbb{E}[Y]$$

Exemple Concret 6 (Covariance nulle) : La covariance de X et Y est définie par $\mathrm{Cov}(X, Y) = \mathbb{E}[XY] - \mathbb{E}[X]\mathbb{E}[Y]$. Si X et Y sont indépendantes, leur covariance est strictement nulle. Elles sont dites non corrélées.

Exemple Concret 7 (Covariance nulle $\not\Rightarrow$ Indépendance) : Soit X une variable uniformément distribuée sur $\{-1, 0, 1\}$, de sorte que $P(X = -1) = P(X = 0) = P(X = 1) = 1/3$. Soit $Y = X^2$. Y prend les valeurs $\{0, 1\}$. Évidemment, X et Y sont dépendantes (puisque Y est une fonction déterministe de X). Calculons la covariance. $XY = X^3 = X$. $\mathbb{E}[X] = (-1) \cdot \frac{1}{3} + 0 \cdot \frac{1}{3} + 1 \cdot \frac{1}{3} = 0$. Ainsi, $\mathbb{E}[XY] = \mathbb{E}[X] = 0$. Par ailleurs, $\mathbb{E}[X]\mathbb{E}[Y] = 0 \cdot \mathbb{E}[Y] = 0$. Donc $\mathrm{Cov}(X, Y) = 0$, mais les variables ne sont pas indépendantes. L'absence de corrélation linéaire ne signifie pas l'absence de dépendance.

> **Théorème (Lemme des coalitions) :** Soit $(X_1, \ldots, X_n)$ des variables indépendantes. Soit $1 \leq k < n$. Si f et g sont des fonctions mesurables, alors $Y = f(X_1, \ldots, X_k)$ et $Z = g(X_{k+1}, \ldots, X_n)$ sont des variables indépendantes.

3 Démonstrations

3.1 Démonstration 1 : Indépendance et Produit des Espérances

Théorème : Si X, Y sont deux variables aléatoires réelles indépendantes et intégrables, alors XY est intégrable et $\mathbb{E}[XY] = \mathbb{E}[X]\mathbb{E}[Y]$.

Preuve pas à pas : Nous allons démontrer le théorème par étapes, en utilisant la construction standard de l'intégrale de Lebesgue : d'abord pour les indicatrices, puis les fonctions étagées, puis les fonctions mesurables positives, et enfin pour les fonctions intégrables.

Étape 1 : Cas des indicatrices Supposons que $X = \mathbf{1}_A$ et $Y = \mathbf{1}_B$ avec A et B deux événements indépendants (puisque X et Y sont indépendantes). Le produit $XY = \mathbf{1}_A\mathbf{1}_B = \mathbf{1}_{A \cap B}$. L'espérance d'une indicatrice est la probabilité de l'événement associé :

$$\mathbb{E}[XY] = \mathbb{E}[\mathbf{1}_{A \cap B}] = P(A \cap B)$$

Par indépendance de A et B :

$$P(A \cap B) = P(A)P(B) = \mathbb{E}[\mathbf{1}_A]\mathbb{E}[\mathbf{1}_B] = \mathbb{E}[X]\mathbb{E}[Y]$$

Le résultat est établi pour les fonctions indicatrices.

Étape 2 : Cas des fonctions étagées positives Soient X et Y deux variables étagées positives indépendantes. Elles s'écrivent $X = \sum_{i=1}^{n} x_i \mathbf{1}_{A_i}$ et $Y = \sum_{j=1}^{m} y_j \mathbf{1}_{B_j}$, où (A_i) et (B_j)

sont des partitions de Ω formées d'événements respectivement générés par X et Y. Comme X et Y sont indépendantes, pour tous i, j, les événements A_i et B_j sont indépendants. Le produit s'écrit $XY = \sum_{i=1}^{n} \sum_{j=1}^{m} x_i y_j \mathbf{1}_{A_i \cap B_j}$. Par linéarité de l'espérance :

$$\mathbb{E}[XY] = \sum_{i=1}^{n} \sum_{j=1}^{m} x_i y_j \mathbb{E}[\mathbf{1}_{A_i \cap B_j}] = \sum_{i=1}^{n} \sum_{j=1}^{m} x_i y_j P(A_i \cap B_j)$$

Par indépendance :

$$\mathbb{E}[XY] = \sum_{i=1}^{n} \sum_{j=1}^{m} x_i y_j P(A_i) P(B_j) = \left(\sum_{i=1}^{n} x_i P(A_i) \right) \left(\sum_{j=1}^{m} y_j P(B_j) \right) = \mathbb{E}[X]\mathbb{E}[Y]$$

Étape 3 : Cas des fonctions mesurables positives Soient $X, Y \geq 0$ indépendantes. D'après le théorème d'approximation, il existe des suites croissantes de variables étagées positives $(X_n)_{n \in \mathbb{N}}$ et $(Y_n)_{n \in \mathbb{N}}$ convergeant respectivement vers X et Y presque sûrement. Pour tout n, X_n et Y_n sont indépendantes, donc $\mathbb{E}[X_n Y_n] = \mathbb{E}[X_n]\mathbb{E}[Y_n]$. Le produit $X_n Y_n$ est une suite croissante de variables positives convergeant vers XY. D'après le Théorème de Convergence Monotone (Beppo-Levi) appliqué aux trois suites :

$$\mathbb{E}[XY] = \lim_{n \to \infty} \mathbb{E}[X_n Y_n] = \lim_{n \to \infty} \mathbb{E}[X_n]\mathbb{E}[Y_n]$$

Les limites des produits étant le produit des limites (lorsque celles-ci existent dans $\mathbb{R} \cup \{+\infty\}$) :

$$\mathbb{E}[XY] = \left(\lim_{n \to \infty} \mathbb{E}[X_n] \right) \left(\lim_{n \to \infty} \mathbb{E}[Y_n] \right) = \mathbb{E}[X]\mathbb{E}[Y]$$

Étape 4 : Cas général (variables intégrables) Soient X et Y intégrables et indépendantes. On les décompose en leurs parties positives et négatives : $X = X^+ - X^-$ et $Y = Y^+ - Y^-$. L'indépendance de X et Y implique (par le lemme des coalitions) l'indépendance des paires de variables positives (X^+, Y^+), (X^+, Y^-), (X^-, Y^+), (X^-, Y^-). De plus :

$$|XY| = |X||Y| = (X^+ + X^-)(Y^+ + Y^-)$$

D'après l'étape 3, l'espérance de $|XY|$ est :

$$\mathbb{E}[|XY|] = \mathbb{E}[|X|]\mathbb{E}[|Y|]$$

Comme X et Y sont intégrables, $\mathbb{E}[|X|] < \infty$ et $\mathbb{E}[|Y|] < \infty$, ce qui prouve que XY est intégrable (l'espérance de la valeur absolue est finie). Enfin, par développement et linéarité de l'espérance :

$$\mathbb{E}[XY] = \mathbb{E}[(X^+ - X^-)(Y^+ - Y^-)] = \mathbb{E}[X^+Y^+] - \mathbb{E}[X^+Y^-] - \mathbb{E}[X^-Y^+] + \mathbb{E}[X^-Y^-]$$

Par l'étape 3 sur les parties positives indépendantes :

$$\mathbb{E}[XY] = \mathbb{E}[X^+]\mathbb{E}[Y^+] - \mathbb{E}[X^+]\mathbb{E}[Y^-] - \mathbb{E}[X^-]\mathbb{E}[Y^+] + \mathbb{E}[X^-]\mathbb{E}[Y^-]$$

Factorisons :

$$\mathbb{E}[XY] = (\mathbb{E}[X^+] - \mathbb{E}[X^-])(\mathbb{E}[Y^+] - \mathbb{E}[Y^-]) = \mathbb{E}[X]\mathbb{E}[Y]$$

La preuve est exhaustive et complète.

4 Applications en Mathématiques, Physique et Intelligence Artificielle

4.1 Modélisation en Mécanique Statistique

En physique statistique, l'indépendance est au cœur de l'hypothèse du chaos moléculaire (Stosszahlansatz) introduite par Boltzmann pour dériver l'équation d'évolution d'un gaz. Elle postule que, avant une collision, les vitesses des deux particules sont des variables aléatoires indépendantes. C'est cette hypothèse d'indépendance microscopique qui permet de justifier l'émergence d'un comportement irréversible macroscopique (le second principe de la thermodynamique et le théorème H de Boltzmann) à partir de dynamiques microscopiques réversibles, en factorisant les fonctions de distribution des paires de particules.

4.2 Hypothèse I.I.D. en Apprentissage Automatique

Le paradigme dominant en machine learning repose sur l'hypothèse I.I.D. (Indépendantes et Identiquement Distribuées). Un jeu de données d'apprentissage $\mathcal{D} = \{(x_1, y_1), \ldots, (x_N, y_N)\}$ est vu comme une suite de réalisations de variables aléatoires indépendantes, toutes issues de la même distribution conjointe inconnue $P(X, Y)$. L'indépendance est ce qui permet de définir la fonction de coût empirique et d'appliquer la Loi Forte des Grands Nombres. La fonction de vraisemblance, $L(\theta) = P(x_1, \ldots, x_N \mid \theta)$, se factorise grâce à l'indépendance :

$$L(\theta) = \prod_{i=1}^{N} P(x_i \mid \theta)$$

Le passage au logarithme (log-vraisemblance) transforme ce produit en somme, simplifiant drastiquement les calculs de gradients lors de la descente de gradient, puisque le gradient de la somme est la somme des gradients calculés sur chaque échantillon.

4.3 Dropout dans les Réseaux de Neurones

Le Dropout est une technique de régularisation inventée pour réduire le surapprentissage dans les réseaux de neurones profonds. L'algorithme annule de manière aléatoire et *indépendante* l'activation de certains neurones pendant l'entraînement (par exemple avec une probabilité $p = 0.5$). Cette indépendance forcée empêche les neurones de co-s'adapter (co-adaptation). Chaque sous-réseau échantillonné étant indépendant des autres itérations, le Dropout agit implicitement comme une méthode d'ensemble massique sur un très grand nombre de modèles exponentiellement différents.

4.4 Algorithme de Naïve Bayes

Le classifieur de Bayes Naïf tire son nom de l'hypothèse (souvent "naïve" en pratique) que les différentes caractéristiques d'observation $X_1, \ldots, X_d$ sont *conditionnellement indépendantes* sachant la classe Y. La règle de Bayes donne $P(Y = k \mid X_1, \ldots, X_d) \propto P(Y = k)P(X_1, \ldots, X_d \mid Y = k)$. Par l'hypothèse d'indépendance conditionnelle, le terme complexe factorise :

$$P(X_1, \ldots, X_d \mid Y = k) = \prod_{j=1}^{d} P(X_j \mid Y = k)$$

Cela réduit un problème d'estimation d'une densité de dimension d (souvent intraitable à cause du manque de données) à d problèmes unidimensionnels triviaux à résoudre séparément.

Deuxième partie

Exercices d'Application et de Concours

Exercice 1 : Indépendance et incompatibilité ★⋆⋆⋆⋆

Énoncé : Soit $(\Omega, \mathcal{F}, P)$ un espace probabilisé. Soient A et B deux événements tels que $P(A) > 0$ et $P(B) > 0$. Montrer que A et B ne peuvent pas être à la fois indépendants et incompatibles (disjoints).

Correction :

1. Supposons par l'absurde que A et B sont à la fois indépendants et incompatibles.
2. Puisque A et B sont incompatibles, leur intersection est vide : $A \cap B = \emptyset$.
3. La probabilité de l'ensemble vide est nulle, donc $P(A \cap B) = 0$.
4. Puisque A et B sont indépendants, par définition, $P(A \cap B) = P(A)P(B)$.
5. En combinant (3) et (4), on obtient $P(A)P(B) = 0$.
6. Or, par hypothèse, $P(A) > 0$ et $P(B) > 0$, donc leur produit est strictement positif : $P(A)P(B) > 0$.
7. On aboutit à une contradiction manifeste : $0 > 0$.
8. L'hypothèse de départ est fausse. A et B ne peuvent donc pas être à la fois indépendants et incompatibles.

Exercice 2 : Indépendance et événement contraire ★⋆⋆⋆⋆

Énoncé : Montrer que si A et B sont indépendants, alors A et B^c le sont aussi, où B^c désigne le complémentaire de B.

Correction :

1. On sait que B et B^c forment une partition de Ω. Donc $A = (A \cap B) \cup (A \cap B^c)$.
2. Les ensembles $(A \cap B)$ et $(A \cap B^c)$ sont disjoints.
3. Par additivité de la mesure de probabilité P : $P(A) = P(A \cap B) + P(A \cap B^c)$.
4. Puisque A et B sont indépendants, on a $P(A \cap B) = P(A)P(B)$.
5. En substituant dans l'équation de l'étape 3 : $P(A) = P(A)P(B) + P(A \cap B^c)$.
6. On isole $P(A \cap B^c)$: $P(A \cap B^c) = P(A) - P(A)P(B)$.
7. On factorise par $P(A)$: $P(A \cap B^c) = P(A)(1 - P(B))$.
8. Or, par propriété du complémentaire, $1 - P(B) = P(B^c)$.
9. Ainsi, $P(A \cap B^c) = P(A)P(B^c)$.
10. Cela correspond exactement à la définition de l'indépendance de A et B^c.

Exercice 3 : Indépendance deux à deux et mutuelle ★★⋆⋆⋆

Énoncé : On lance deux dés parfaits indépendants à 6 faces. Soit A l'événement "Le résultat du 1er dé est pair". Soit B l'événement "Le résultat du 2e dé est impair". Soit C l'événement "La somme des deux dés est impaire". Montrer que A, B, C sont indépendants deux à deux, mais ne sont pas mutuellement indépendants.

Correction :

1. Modélisation : $\Omega = \{1, 2, 3, 4, 5, 6\}^2$, de cardinal 36. La probabilité est uniforme.

2. Calculons les probabilités marginales : - $P(A) = \frac{3\times6}{36} = \frac{1}{2}$. - $P(B) = \frac{6\times3}{36} = \frac{1}{2}$. - Pour C, la somme est impaire si on a (Pair, Impair) ou (Impair, Pair). $P(C) = \frac{3\times3+3\times3}{36} = \frac{18}{36} = \frac{1}{2}$.
3. Calculons les probabilités des intersections deux à deux : - $A\cap B$: "1er pair ET 2e impair". Il y a $3 \times 3 = 9$ cas favorables. $P(A \cap B) = \frac{9}{36} = \frac{1}{4} = P(A)P(B)$. (Indépendance). - $A \cap C$: "1er pair ET somme impaire". Cela implique que le 2e dé doit être impair. C'est exactement $A \cap B$. $P(A \cap C) = P(A \cap B) = \frac{1}{4} = P(A)P(C)$. (Indépendance). - $B \cap C$: "2e impair ET somme impaire". Cela implique que le 1er dé doit être pair. C'est encore $A \cap B$. $P(B \cap C) = P(A \cap B) = \frac{1}{4} = P(B)P(C)$. (Indépendance).
4. Les événements A, B et C sont donc indépendants deux à deux.
5. Regardons l'intersection totale $A \cap B \cap C$: "1er pair ET 2e impair ET somme impaire". Puisque "1er pair ET 2e impair" implique nécessairement que la somme est impaire, l'événement $A \cap B$ est inclus dans C. Donc $A \cap B \cap C = A \cap B$. Sa probabilité est $P(A \cap B \cap C) = \frac{1}{4}$.
6. Cependant, $P(A)P(B)P(C) = \frac{1}{2} \times \frac{1}{2} \times \frac{1}{2} = \frac{1}{8}$.
7. Comme $P(A \cap B \cap C) \neq P(A)P(B)P(C)$, la famille $\{A, B, C\}$ n'est pas mutuellement indépendante.

Exercice 4 : Produit de variables de Bernoulli ★★⋆⋆⋆

Énoncé : Soient X et Y deux variables aléatoires indépendantes suivant des lois de Bernoulli de paramètres respectifs p et q. Déterminer la loi de la variable $Z = XY$.

Correction :

1. Les variables X et Y prennent leurs valeurs dans $\{0, 1\}$.
2. Le produit $Z = XY$ prend donc également ses valeurs dans $\{0, 1\}$. Z suit donc une loi de Bernoulli.
3. Il suffit de calculer le paramètre de cette loi de Bernoulli, qui est $P(Z = 1)$.
4. L'événement $\{Z = 1\}$ équivaut à $\{XY = 1\}$.
5. Puisque X et Y ne prennent que les valeurs 0 ou 1, le produit XY vaut 1 si et seulement si $X = 1$ et $Y = 1$.
6. Ainsi, $\{Z = 1\} = \{X = 1\} \cap \{Y = 1\}$.
7. Par indépendance de X et Y, la probabilité de l'intersection est le produit des probabilités : $P(Z = 1) = P(X = 1 \text{ et } Y = 1) = P(X = 1)P(Y = 1)$.
8. On remplace par les paramètres des lois : $P(X = 1) = p$ et $P(Y = 1) = q$.
9. On obtient $P(Z = 1) = pq$.
10. En conclusion, Z suit une loi de Bernoulli de paramètre pq : $Z \sim \mathcal{B}(pq)$.

Exercice 5 : Somme de variables de Poisson indépendantes ★★★⋆⋆

Énoncé : Soient X et Y deux variables aléatoires indépendantes suivant des lois de Poisson de paramètres respectifs λ et μ. Montrer que $Z = X + Y$ suit une loi de Poisson de paramètre $\lambda + \mu$.

Correction :

1. Les variables X et Y prennent leurs valeurs dans $\mathbb{N}$. La somme $Z = X + Y$ prend aussi ses valeurs dans $\mathbb{N}$.
2. Soit $n \in \mathbb{N}$. Calculons $P(Z = n)$.

3. L'événement $\{X+Y=n\}$ se décompose selon toutes les valeurs possibles pour X. Si $X=k$ (avec $0\leq k\leq n$), alors Y doit valoir $n-k$. $P(Z=n)=\sum_{k=0}^{n}P(X=k,Y=n-k)$.
4. Par indépendance de X et Y : $P(Z=n)=\sum_{k=0}^{n}P(X=k)P(Y=n-k)$.
5. On utilise la formule de la loi de Poisson : $P(X=k)=e^{-\lambda}\frac{\lambda^k}{k!}$ et $P(Y=n-k)=e^{-\mu}\frac{\mu^{n-k}}{(n-k)!}$. $P(Z=n)=\sum_{k=0}^{n}\left(e^{-\lambda}\frac{\lambda^k}{k!}\right)\left(e^{-\mu}\frac{\mu^{n-k}}{(n-k)!}\right)$.
6. On réarrange les termes : $P(Z=n)=e^{-(\lambda+\mu)}\sum_{k=0}^{n}\frac{\lambda^k\mu^{n-k}}{k!(n-k)!}$.
7. Pour faire apparaître le binôme de Newton, on multiplie et divise par $n!$: $P(Z=n)=e^{-(\lambda+\mu)}\frac{1}{n!}\sum_{k=0}^{n}\frac{n!}{k!(n-k)!}\lambda^k\mu^{n-k}$.
8. On reconnaît le coefficient binomial $\binom{n}{k}=\frac{n!}{k!(n-k)!}$: $P(Z=n)=e^{-(\lambda+\mu)}\frac{1}{n!}\sum_{k=0}^{n}\binom{n}{k}\lambda^k\mu^{n-k}$.
9. D'après la formule du binôme de Newton, $\sum_{k=0}^{n}\binom{n}{k}\lambda^k\mu^{n-k}=(\lambda+\mu)^n$.
10. Finalement, $P(Z=n)=e^{-(\lambda+\mu)}\frac{(\lambda+\mu)^n}{n!}$.
11. On reconnaît exactement la fonction de masse d'une loi de Poisson de paramètre $\lambda+\mu$. Donc $Z\sim\mathcal{P}(\lambda+\mu)$.

Exercice 6 : Covariance nulle sans indépendance ★★★⋆⋆

Énoncé : Soit X une variable aléatoire suivant une loi normale standard $\mathcal{N}(0,1)$. Soit $Y=X^2$.

1. Déterminer si X et Y sont indépendantes.
2. Calculer la covariance entre X et Y. Que conclut-on ?

Correction :

1. Étude de l'indépendance : Y est une fonction déterministe de X. Connaissant X, la valeur de Y est parfaitement déterminée. Elles ne peuvent pas être indépendantes. Montrons-le formellement. Considérons les événements $A=\{X\in[1,2]\}$ et $B=\{Y\in[0,0.5]\}$. Si $Y=X^2\leq 0.5$, alors $X\in[-\sqrt{0.5},\sqrt{0.5}]$. Donc l'intersection $A\cap B=\{X\in[1,2]\}\cap\{X\in[-\sqrt{0.5},\sqrt{0.5}]\}=\emptyset$. Ainsi, $P(A\cap B)=0$. Or, $P(A)>0$ et $P(B)>0$ (car la densité de la loi normale est strictement positive partout). Donc $P(A\cap B)\neq P(A)P(B)$. Les variables ne sont pas indépendantes.
2. Calcul de la covariance : Par définition, $\mathrm{Cov}(X,Y)=\mathbb{E}[XY]-\mathbb{E}[X]\mathbb{E}[Y]$. Comme $X\sim\mathcal{N}(0,1)$, on sait que $\mathbb{E}[X]=0$. Par conséquent, $\mathbb{E}[X]\mathbb{E}[Y]=0\times\mathbb{E}[X^2]=0$. Calculons $\mathbb{E}[XY]$. On a $XY=X(X^2)=X^3$. L'espérance de X^3 est le moment d'ordre 3 d'une loi normale centrée. $\mathbb{E}[X^3]=\int_{-\infty}^{+\infty}x^3\frac{1}{\sqrt{2\pi}}e^{-x^2/2}dx$. La fonction à intégrer est impaire ($f(-x)=-f(x)$) et intégrable, donc son intégrale sur $\mathbb{R}$ est nulle. Ainsi, $\mathbb{E}[XY]=\mathbb{E}[X^3]=0$. On en déduit que $\mathrm{Cov}(X,Y)=0-0=0$.
3. Conclusion : Bien que X et Y soient dépendantes, leur covariance est nulle (elles sont non corrélées). La covariance mesure la dépendance linéaire, mais ne capture pas les dépendances non linéaires (ici quadratique).

Exercice 7 : Produit de variables absolument continues ★★★★⋆

Énoncé : Soient X et Y deux variables aléatoires indépendantes de densités respectives f_X et f_Y. Montrer que la densité de probabilité de leur produit $Z=XY$ (en supposant $X>0, Y>0$) est donnée par : $f_Z(z)=\int_0^{+\infty}f_X(x)f_Y\left(\frac{z}{x}\right)\frac{1}{x}dx$ pour $z>0$

Correction :

1. La fonction de répartition de Z pour $z>0$ est $F_Z(z)=P(Z\leq z)=P(XY\leq z)$.

2. Puisque X et Y sont indépendantes et continues, leur densité conjointe est $f_{X,Y}(x,y) = f_X(x)f_Y(y)$.
3. On exprime la probabilité comme l'intégrale de la densité conjointe sur le domaine $D = \{(x,y) \in \mathbb{R}_+^2 \mid xy \leq z\}$: $F_Z(z) = \iint_D f_X(x)f_Y(y)dxdy = \int_0^{+\infty} \left(\int_0^{z/x} f_X(x)f_Y(y)dy \right) dx$.
4. On dérive $F_Z(z)$ par rapport à z pour obtenir la densité $f_Z(z)$.
5. Par le théorème de dérivation sous le signe intégral (les hypothèses de domination étant supposées vérifiées ici), on dérive l'intégrale interne : $f_Z(z) = \frac{d}{dz} \int_0^{+\infty} f_X(x) \left(\int_0^{z/x} f_Y(y)dy \right) dx$.
6. La dérivée par rapport à z de l'intégrale $\int_0^{z/x} f_Y(y)dy$ est $f_Y\left(\frac{z}{x}\right) \cdot \frac{\partial}{\partial z}\left(\frac{z}{x}\right)$.
7. La dérivée de $\frac{z}{x}$ par rapport à z est $\frac{1}{x}$.
8. Ainsi, on obtient : $f_Z(z) = \int_0^{+\infty} f_X(x)f_Y\left(\frac{z}{x}\right)\frac{1}{x}dx$.
9. Cette formule s'applique pour déterminer la distribution de produits (par exemple pour la loi de Fisher, issue du ratio d'un produit).

Exercice 8 : Indépendance et fonctions génératrices des moments ★★★★⋆

Énoncé : Soient $X_1, X_2, \ldots, X_n$ des variables aléatoires indépendantes ayant des fonctions génératrices des moments $M_{X_i}(t) = \mathbb{E}[e^{tX_i}]$. Montrer que la fonction génératrice des moments de la somme $S_n = \sum_{i=1}^n X_i$ est le produit des fonctions génératrices des X_i. En déduire la loi de la somme de n variables exponentielles indépendantes de même paramètre λ.

Correction :

1. Soit $S_n = X_1 + \ldots + X_n$. La fonction génératrice des moments de S_n est $M_{S_n}(t) = \mathbb{E}[e^{tS_n}]$.
2. $M_{S_n}(t) = \mathbb{E}[e^{t(X_1+\ldots+X_n)}] = \mathbb{E}[e^{tX_1}e^{tX_2}\ldots e^{tX_n}]$.
3. Par le lemme des coalitions, les variables e^{tX_i} sont mutuellement indépendantes (car les X_i le sont et $x \mapsto e^{tx}$ est mesurable).
4. L'espérance du produit de variables aléatoires indépendantes est égale au produit de leurs espérances : $M_{S_n}(t) = \mathbb{E}[e^{tX_1}] \times \mathbb{E}[e^{tX_2}] \times \ldots \times \mathbb{E}[e^{tX_n}]$.
5. Ainsi, $M_{S_n}(t) = \prod_{i=1}^n M_{X_i}(t)$.
6. Application : soit $X_i \sim \mathcal{E}(\lambda)$. Sa fonction génératrice des moments est, pour $t < \lambda$, $M_{X_i}(t) = \frac{\lambda}{\lambda - t} = \left(1 - \frac{t}{\lambda}\right)^{-1}$.
7. Pour S_n, on a $M_{S_n}(t) = \prod_{i=1}^n \left(1 - \frac{t}{\lambda}\right)^{-1} = \left(1 - \frac{t}{\lambda}\right)^{-n}$.
8. On reconnaît la fonction génératrice des moments de la loi Gamma de paramètres (n, λ).
9. Donc la somme de n lois exponentielles $\mathcal{E}(\lambda)$ indépendantes suit une loi Gamma $\Gamma(n, \lambda)$ (aussi appelée loi d'Erlang).

Exercice 9 : Indépendance conditionnelle ★★★★★

Énoncé : Deux événements A et B sont dits conditionnellement indépendants sachant C (avec $P(C) > 0$) si $P(A \cap B \mid C) = P(A \mid C)P(B \mid C)$. Montrer par un contre-exemple que l'indépendance conditionnelle sachant C n'implique pas l'indépendance (inconditionnelle) de A et B.

Correction :

1. Construisons un modèle probabiliste. Considérons deux pièces de monnaie : - Pièce 1 : truquée, donne Pile (P) avec probabilité $p_1 = 0.9$. - Pièce 2 : truquée, donne Pile (P) avec probabilité $p_2 = 0.1$.

2. L'expérience est la suivante : on choisit une pièce au hasard (probabilité 1/2 pour chaque), puis on lance cette *même* pièce deux fois de suite.
3. Soit l'événement $C =$ "La pièce 1 est choisie". Donc $P(C) = 1/2$. L'événement $C^c =$ "La pièce 2 est choisie". $P(C^c) = 1/2$.
4. Soit $A =$ "Le 1er lancer donne Pile" et $B =$ "Le 2e lancer donne Pile".
5. Sachant C, les deux lancers proviennent de la même pièce de probabilité 0.9. Les lancers physiques sont indépendants, donc : $P(A \mid C) = 0.9$, $P(B \mid C) = 0.9$, et $P(A \cap B \mid C) = 0.9 \times 0.9 = 0.81$. Donc $P(A \cap B \mid C) = P(A \mid C)P(B \mid C)$. A et B sont conditionnellement indépendants sachant C. (De même sachant C^c : $P(A \mid C^c) = 0.1$, $P(B \mid C^c) = 0.1$, $P(A \cap B \mid C^c) = 0.01$, indépendance conditionnelle vérifiée).
6. Regardons l'indépendance inconditionnelle. Par la loi des probabilités totales : $P(A) = P(A \mid C)P(C) + P(A \mid C^c)P(C^c) = 0.9(0.5) + 0.1(0.5) = 0.45 + 0.05 = 0.5$. $P(B) = 0.5$ de la même manière. Donc $P(A)P(B) = 0.5 \times 0.5 = 0.25$.
7. Calculons $P(A \cap B)$: $P(A \cap B) = P(A \cap B \mid C)P(C) + P(A \cap B \mid C^c)P(C^c) = (0.81)(0.5) + (0.01)(0.5) = 0.405 + 0.005 = 0.41$.
8. On constate que $P(A \cap B) = 0.41 \neq 0.25 = P(A)P(B)$.
9. Conclusion : A et B ne sont *pas* indépendants. L'incertitude sur l'origine du modèle (quelle pièce a été choisie) crée une dépendance forte entre les observations. C'est le principe des variables latentes en Machine Learning.

Exercice 10 : Produit scalaire de L2 et Indépendance ★★★★★

Énoncé : Dans l'espace de Hilbert $L^2(\Omega, \mathcal{F}, P)$, on définit le produit scalaire $\langle X, Y \rangle = \mathbb{E}[XY]$. Deux variables aléatoires $X, Y \in L^2$ sont orthogonales si $\langle X, Y \rangle = 0$. Soient $X, Y \in L^2$ deux variables d'espérance nulle ($\mathbb{E}[X] = \mathbb{E}[Y] = 0$). Montrer que si X et Y sont indépendantes, alors elles sont orthogonales. La réciproque est-elle vraie ? Justifier.

Correction :

1. Sens direct : Supposons X, Y indépendantes et centrées. Par le théorème d'indépendance (puisqu'elles sont dans L^2, elles sont dans L^1, donc intégrables) : $\langle X, Y \rangle = \mathbb{E}[XY] = \mathbb{E}[X]\mathbb{E}[Y]$. Comme $\mathbb{E}[X] = 0$ et $\mathbb{E}[Y] = 0$, on a $\mathbb{E}[X]\mathbb{E}[Y] = 0 \times 0 = 0$. Donc $\langle X, Y \rangle = 0$. X et Y sont orthogonales.
2. Étude de la réciproque : L'orthogonalité de variables centrées signifie que leur covariance est nulle ($\mathrm{Cov}(X, Y) = \mathbb{E}[XY] - \mathbb{E}[X]\mathbb{E}[Y] = 0 - 0 = 0$). L'orthogonalité est donc équivalente à l'absence de corrélation linéaire. Nous savons (vu dans un exercice précédent) que la covariance nulle n'implique pas l'indépendance.
3. Contre-exemple formel dans L^2 : Soit $\theta \sim \mathcal{U}([0, 2\pi])$. On pose $X = \cos(\theta)$ et $Y = \sin(\theta)$. Puisque θ est bornée, X et Y sont bornées par 1, elles sont donc dans L^2. Elles sont centrées : $\mathbb{E}[X] = \frac{1}{2\pi} \int_0^{2\pi} \cos(t)dt = 0$ et $\mathbb{E}[Y] = 0$. Vérifions l'orthogonalité : $\langle X, Y \rangle = \mathbb{E}[\cos(\theta)\sin(\theta)] = \mathbb{E}[\frac{1}{2}\sin(2\theta)] = \frac{1}{4\pi} \int_0^{2\pi} \sin(2t)dt = 0$. X et Y sont donc orthogonales. Cependant, elles ne sont pas indépendantes. Par l'identité trigonométrique fondamentale : $X^2 + Y^2 = 1$. La connaissance de X restreint les valeurs de Y à $\pm\sqrt{1 - X^2}$. Il y a une dépendance fonctionnelle parfaite (bien que non bijective).
4. Conclusion : L'indépendance implique l'orthogonalité (pour les V.A. centrées), mais l'orthogonalité (indépendance linéaire) n'implique pas l'indépendance stochastique (qui requiert l'indépendance à tous les ordres de moments).

Troisième partie

Travaux Pratiques et Simulations Algorithmiques

TP 1 : Simulation de l'indépendance de dés

Dans ce TP, nous allons simuler le lancer de deux des et verifier empiriquement leur independance. Nous calculerons la frequence d'apparition conjointe et la comparerons au produit des frequences marginales.

```
import random

def simuler_des(nb_lancers):
    nb_A = 0 # Evt A : de 1 est pair
    nb_B = 0 # Evt B : de 2 est impair
    nb_A_inter_B = 0

    for _ in range(nb_lancers):
        de1 = random.randint(1, 6)
        de2 = random.randint(1, 6)

        est_A = (de1 % 2 == 0)
        est_B = (de2 % 2 != 0)

        if est_A:
            nb_A += 1
        if est_B:
            nb_B += 1
        if est_A and est_B:
            nb_A_inter_B += 1

    freq_A = nb_A / nb_lancers
    freq_B = nb_B / nb_lancers
    freq_inter = nb_A_inter_B / nb_lancers

    print(f"Frequence A : {freq_A:.4f} (Theorie : 0.5)")
    print(f"Frequence B : {freq_B:.4f} (Theorie : 0.5)")
    print(f"Frequence A inter B : {freq_inter:.4f} (Theorie : 0.25)")
    print(f"Produit freq_A * freq_B : {freq_A * freq_B:.4f}")

    assert abs(freq_inter - (freq_A * freq_B)) < 0.05, "Ecart trop grand
        "

simuler_des(10000)
```

TP 2 : Covariance nulle de variables dependantes

Ce TP illustre le fait qu'une covariance nulle n'implique pas l'independance. Nous allons generer une variable X uniforme sur -1, 0, 1 et Y = X**2.

```
import random

def estimer_covariance_dependante(n_echantillons):
```

```
    somme_X = 0
    somme_Y = 0
    somme_XY = 0

    valeurs_possibles = [-1, 0, 1]

    for _ in range(n_echantillons):
        X = random.choice(valeurs_possibles)
        Y = X ** 2

        somme_X += X
        somme_Y += Y
        somme_XY += X * Y

    esp_X = somme_X / n_echantillons
    esp_Y = somme_Y / n_echantillons
    esp_XY = somme_XY / n_echantillons

    covariance = esp_XY - esp_X * esp_Y

    print(f"Esperance X : {esp_X:.4f}")
    print(f"Esperance Y : {esp_Y:.4f}")
    print(f"Esperance XY : {esp_XY:.4f}")
    print(f"Covariance estimee : {covariance:.4f}")

    assert abs(covariance) < 0.05, "La covariance doit etre proche de 0"

estimer_covariance_dependante(10000)
```

TP 3 : Somme de variables de Poisson

Nous allons generer empiriquement la somme de deux variables de Poisson independantes et verifier que la moyenne empirique correspond a la somme des parametres. Pour generer une variable de Poisson sans bibliotheque avancee, on utilise la methode de l'inverse de la fonction de repartition.

```
import math
import random

def poisson_random(lambd):
    L = math.exp(-lambd)
    k = 0
    p = 1.0
    while p > L:
        k += 1
        p *= random.random()
    return k - 1

def verifier_somme_poisson(lambda1, lambda2, n_tirages):
    somme_empirique = 0

    for _ in range(n_tirages):
        X = poisson_random(lambda1)
        Y = poisson_random(lambda2)
        Z = X + Y
```

```
        somme_empirique += Z

    moyenne_estimee = somme_empirique / n_tirages
    moyenne_theorique = lambda1 + lambda2

    print(f"Moyenne theorique Z : {moyenne_theorique}")
    print(f"Moyenne estimee Z : {moyenne_estimee:.4f}")

    assert abs(moyenne_estimee - moyenne_theorique) < 0.1, "L'estimation
        diverge"

verifier_somme_poisson(2.5, 3.5, 10000)
```

TP 4 : Simulation du Dropout (Independance forcee)

Ce TP simule le mecanisme de Dropout d'un reseau de neurones simplifie. Nous appliquons un masque binaire aleatoire et independant a chaque neurone d'une couche cachee lors de la transmission du signal.

```
import random

def relu(x):
    return x if x > 0 else 0

def forward_avec_dropout(entrees, poids, p_dropout):
    assert len(entrees) == len(poids)
    n = len(entrees)

    masque = []
    for _ in range(n):
        # Tirage de Bernoulli avec proba (1 - p_dropout) d'etre garde
        if random.random() > p_dropout:
            masque.append(1)
        else:
            masque.append(0)

    # Le facteur d'echelle corrige l'esperance pendant l'entrainement
    facteur = 1.0 / (1.0 - p_dropout)

    signal = 0
    for i in range(n):
        activation_neurone = relu(entrees[i] * poids[i])
        signal += activation_neurone * masque[i] * facteur

    return signal, masque

entrees = [1.5, -0.5, 2.0, 3.1, -1.0]
poids = [0.8, 1.2, -0.9, 0.5, 1.1]

signal_out, masque_applique = forward_avec_dropout(entrees, poids, 0.4)
print(f"Masque binaire aleatoire independant : {masque_applique}")
print(f"Signal aggrege resultant : {signal_out:.4f}")
```

TP 5 : Produit empirique des esperances

Nous verifions par la simulation numerique que l'esperance du produit de deux variables aleatoires independantes est le produit de leurs esperances, en utilisant des variables continues uniformes.

```python
import random

def verifier_theoreme_esperance(n_samples):
    somme_X = 0
    somme_Y = 0
    somme_XY = 0

    for _ in range(n_samples):
        # X uniforme sur [0, 2] -> Esperance theorique = 1
        X = random.uniform(0, 2)
        # Y uniforme sur [2, 6] -> Esperance theorique = 4
        Y = random.uniform(2, 6)

        produit = X * Y

        somme_X += X
        somme_Y += Y
        somme_XY += produit

    esp_X = somme_X / n_samples
    esp_Y = somme_Y / n_samples
    esp_XY = somme_XY / n_samples

    produit_des_esp = esp_X * esp_Y

    print(f"E[X] estimee : {esp_X:.4f}")
    print(f"E[Y] estimee : {esp_Y:.4f}")
    print(f"E[XY] estimee : {esp_XY:.4f}")
    print(f"E[X]*E[Y] calcule : {produit_des_esp:.4f}")

    assert abs(esp_XY - produit_des_esp) < 0.05, "Le theoreme n'est pas verifie empiriquement"

verifier_theoreme_esperance(20000)
```