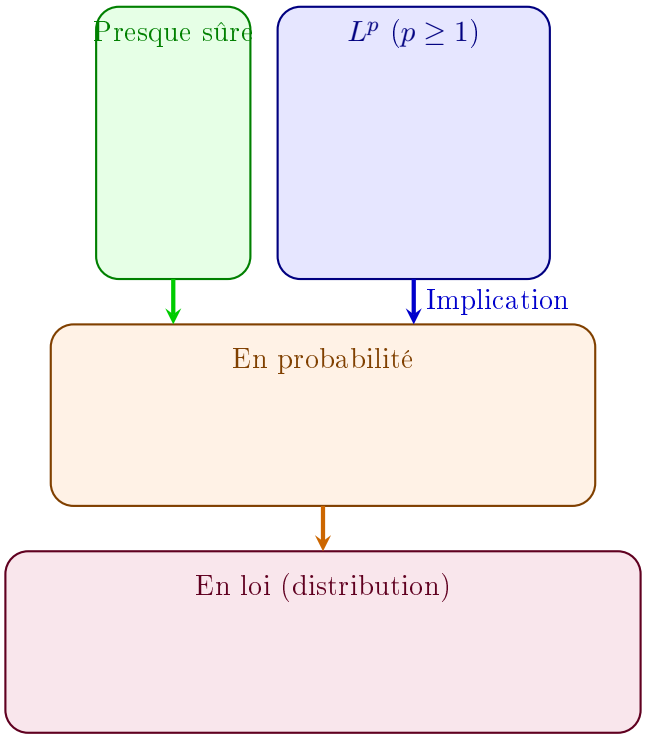
Les modes de convergence en probabilités

11 novembre 2026

1 1. Origines et intuitions asymptotiques

L'étude des phénomènes aléatoires, initialement circonscrite aux jeux de hasard, a pris une dimension analytique rigoureuse au tournant des XIXe et XXe siècles grâce aux travaux de mathématiciens russes tels que Pafnuty Chebyshev, Andrey Markov et Andrey Kolmogorov, ainsi que l'économiste et statisticien Eugen Slutsky. La question centrale qui animait ces chercheurs était de comprendre le comportement asymptotique des suites de variables aléatoires : lorsqu'une expérience est répétée une infinité de fois, de quelle manière la moyenne empirique converge-t-elle vers son espérance théorique ?

En mathématiques classiques, la convergence d'une suite de nombres réels est univoque et absolue. En probabilités, du fait de l'existence d'événements de mesure nulle (les fameux ensembles $\omega \in \Omega$ pour lesquels la propriété peut faire défaut sans affecter la probabilité globale), le concept de "proximité" entre variables aléatoires se décline sous plusieurs topologies distinctes. Il a fallu forger un arsenal d'outils analytiques pour mesurer si une suite de variables aléatoires (X_n) s'approche d'une limite X presque partout, en mesure, en moyenne ou seulement au niveau de ses répartitions (loi). Cette hiérarchie des modes de convergence permet d'isoler la nature exacte de la stabilité asymptotique d'un système.



2 2. Définitions formelles et exemples fondamentaux

Dans ce qui suit, on considère un espace probabilisé $(\Omega, \mathcal{F}, \mathbb{P})$. Toutes les variables aléatoires considérées sont à valeurs réelles et définies sur cet espace. On s'intéresse à la convergence d'une suite $(X_n)_{n\in\mathbb{N}}$ vers une variable aléatoire X.

2.1 2.1 Convergence Presque Sûre (p.s.)

La convergence presque sûre est le mode de convergence le plus fort au sens des trajectoires. Il stipule que la suite de fonctions $X_n(\omega)$ converge ponctuellement vers $X(\omega)$ pour presque toutes les réalisations $\omega \in \Omega$.

Définition : La suite (X_n) converge presque sûrement vers X, noté $X_n \xrightarrow{p.s.} X$, si :

$$\mathbb{P}\left(\left\{\omega \in \Omega \mid \lim_{n\to\infty} X_n(\omega) = X(\omega)\right\}\right) = 1$$

Ceci est équivalent à affirmer que l'événement sur lequel la convergence ponctuelle fait défaut est de probabilité nulle.

Exemple concret immédiat (Variable aléatoire sur le segment unité) : Soit $\Omega = [0, 1]$ muni de sa tribu borélienne $\mathcal{B}([0, 1])$ et de la mesure de Lebesgue $\mathbb{P}$. Considérons la suite de variables aléatoires $X_n : \Omega \to \mathbb{R}$ définie par $X_n(\omega) = \omega^n$. Fixons $\omega \in \Omega$.

— Si $\omega \in [0, 1[$, alors $\lim_{n\to\infty} \omega^n = 0$.

— Si $\omega = 1$, alors $\lim_{n\to\infty} 1^n = 1$.

Ainsi, la suite (X_n) converge ponctuellement vers la variable aléatoire X définie par $X(\omega) = 0$ sur $[0, 1[$ et $X(1) = 1$. Puisque $\mathbb{P}(\{1\}) = 0$, nous avons $X_n \xrightarrow{p.s.} 0$.

2.2 2.2 Convergence en Probabilité

La convergence en probabilité est plus faible que la convergence presque sûre. Elle garantit que, pour un n assez grand, la probabilité que X_n s'éloigne de X d'une distance macroscopique devient arbitrairement faible.

Définition : La suite (X_n) converge en probabilité vers X, noté $X_n \xrightarrow{\mathbb{P}} X$, si pour tout réel $\epsilon > 0$:

$$\lim_{n\to\infty} \mathbb{P}(|X_n - X| > \epsilon) = 0$$

Théorème d'implication (Presque sûre $\implies$ En probabilité) : Si $X_n \xrightarrow{p.s.} X$, alors $X_n \xrightarrow{\mathbb{P}} X$.

Exemple concret immédiat (La machine à écrire glissante) : Considérons à nouveau $\Omega = [0, 1]$ muni de la mesure de Lebesgue. Pour chaque $n \geq 1$, il existe un unique entier $k \geq 0$ et un entier $j \in \{0, \ldots, 2^k - 1\}$ tels que $n = 2^k + j$. Définissons $X_n(\omega) = \mathbf{1}_{\left[\frac{j}{2^k}, \frac{j+1}{2^k}\right]}(\omega)$. Pour tout $\epsilon \in]0, 1[$, $\mathbb{P}(|X_n - 0| > \epsilon) = \mathbb{P}(X_n = 1) = \frac{1}{2^k}$. Comme $k \to \infty$ lorsque $n \to \infty$, on a $\lim_{n\to\infty} \mathbb{P}(|X_n| > \epsilon) = 0$. Donc $X_n \xrightarrow{\mathbb{P}} 0$. Cependant, pour tout $\omega \in [0, 1]$, $X_n(\omega)$ alternera entre 0 et 1 une infinité de fois. Donc (X_n) ne converge ponctuellement pour aucun ω. Cela prouve que la convergence en probabilité n'implique pas la convergence presque sûre.

2.3 2.3 Convergence dans L^p (en moyenne d'ordre p)

Ce mode mesure la convergence fonctionnelle globale au sens des espaces normés L^p.

Définition : Soit $p \geq 1$. On suppose que $X_n \in L^p$ pour tout n (c'est-à-dire $\mathbb{E}[|X_n|^p] < \infty$). La suite (X_n) converge vers X dans L^p, noté $X_n \xrightarrow{L^p} X$, si $X \in L^p$ et :

$$\lim_{n\to\infty} \mathbb{E}[|X_n - X|^p] = 0$$

Exemple concret immédiat (La bosse fuyante) : Soit $\Omega = [0,1]$ et $X_n(\omega) = n \cdot \mathbf{1}_{[0,1/n]}(\omega)$.

— Convergence en probabilité : $\mathbb{P}(|X_n - 0| > \epsilon) \leq \mathbb{P}(X_n \neq 0) = \frac{1}{n} \to 0$. Donc $X_n \xrightarrow{\mathbb{P}} 0$.

— Convergence L^1 : $\mathbb{E}[|X_n|] = n \cdot \frac{1}{n} = 1$. L'espérance ne tend pas vers 0. Ainsi X_n ne converge pas vers 0 dans L^1.

Cet exemple montre qu'une suite peut converger en probabilité vers une limite sans pour autant converger en moyenne d'ordre p.

2.4 2.4 Convergence en Loi (ou en Distribution)

La convergence en loi est de nature fondamentalement différente. Elle exprime que la répartition probabiliste globale de X_n tend vers la répartition de X, indépendamment de toute corrélation trajectorielle.

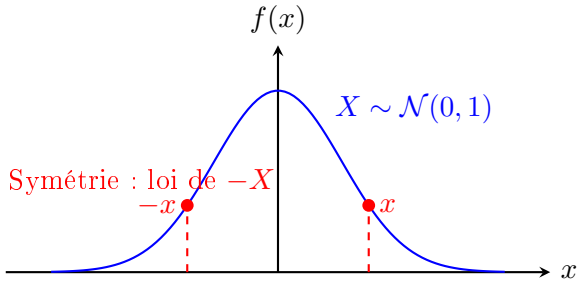
Définition (par les fonctions de répartition) : Soient $F_n(t) = \mathbb{P}(X_n \leq t)$ et $F_X(t) = \mathbb{P}(X \leq t)$ les fonctions de répartition respectives. On dit que $X_n \xrightarrow{\mathcal{L}} X$ si, en tout point de continuité t de F_X :

$$\lim_{n\to\infty} F_n(t) = F_X(t)$$

Théorème de Portmanteau (caractérisation par l'espérance) : $X_n \xrightarrow{\mathcal{L}} X$ si et seulement si pour toute fonction $f : \mathbb{R} \to \mathbb{R}$ continue et bornée :

$$\lim_{n\to\infty} \mathbb{E}[f(X_n)] = \mathbb{E}[f(X)]$$

Exemple concret immédiat (Symétrie et loi normale) : Soit $X \sim \mathcal{N}(0,1)$. Définissons $X_n = -X$ pour tout n. Puisque la loi normale standard est symétrique, $-X \sim \mathcal{N}(0,1)$. Les variables X_n et X ont rigoureusement la même loi. Ainsi, de façon triviale, $X_n \xrightarrow{\mathcal{L}} X$. En revanche, $|X_n - X| = |-2X| = 2|X|$. La distance est strictement positive, donc X_n ne converge vers X ni en probabilité, ni presque sûrement.



3 3. Démonstrations exhaustives

Le théorème fondamental de hiérarchie s'énonce comme suit : $X_n \xrightarrow{L^p} X \implies X_n \xrightarrow{\mathbb{P}} X \implies X_n \xrightarrow{\mathcal{L}} X$

3.1 3.1 Démonstration : $L^p \implies$ Convergence en probabilité

Nous devons prouver que si $\lim_{n\to\infty} \mathbb{E}[|X_n - X|^p] = 0$, alors pour tout $\epsilon > 0$, $\lim_{n\to\infty} \mathbb{P}(|X_n - X| > \epsilon) = 0$.

Preuve pas à pas : Soit $\epsilon > 0$ fixé. L'événement $E_n = \{\omega \in \Omega \mid |X_n(\omega) - X(\omega)| > \epsilon\}$ est équivalent à l'événement $\{\omega \in \Omega \mid |X_n(\omega) - X(\omega)|^p > \epsilon^p\}$, puisque la fonction $x \mapsto x^p$

est strictement croissante sur $\mathbb{R}^+$. Considérons la variable aléatoire positive $Y_n = |X_n - X|^p$. Appliquons l'inégalité de Markov à Y_n avec la constante $a = \epsilon^p > 0$:

$$\mathbb{P}(Y_n \geq a) \leq \frac{\mathbb{E}[Y_n]}{a}$$

En remplaçant par nos variables :

$$\mathbb{P}(|X_n - X|^p > \epsilon^p) \leq \frac{\mathbb{E}[|X_n - X|^p]}{\epsilon^p}$$

Par hypothèse, $X_n \xrightarrow{L^p} X$, donc $\lim_{n\to\infty} \mathbb{E}[|X_n - X|^p] = 0$. Puisque ϵ est fixé (et donc $\epsilon^p > 0$ est constant), le membre de droite tend vers 0 :

$$\lim_{n\to\infty} \frac{\mathbb{E}[|X_n - X|^p]}{\epsilon^p} = 0$$

Puisque les probabilités sont toujours minorées par 0, le théorème des gendarmes nous assure que :

$$\lim_{n\to\infty} \mathbb{P}(|X_n - X| > \epsilon) = 0$$

Ceci achève la démonstration. ■

3.2 3.2 Démonstration : Convergence en probabilité $\implies$ Convergence en loi

Nous voulons prouver que si $X_n \xrightarrow{\mathbb{P}} X$, alors pour toute fonction continue et bornée f, $\lim_{n\to\infty} \mathbb{E}[f(X_n)] = \mathbb{E}[f(X)]$.

Preuve pas à pas : Soit $f : \mathbb{R} \to \mathbb{R}$ continue et bornée. Soit $M > 0$ tel que $|f(x)| \leq M$ pour tout $x \in \mathbb{R}$. Soit $\eta > 0$ un seuil de tolérance. Puisque X est une variable aléatoire réelle, ses valeurs se concentrent. Il existe un intervalle compact $K = [-A, A]$ tel que $\mathbb{P}(X \notin K) < \eta$. La fonction f étant continue sur le segment compact K, elle y est uniformément continue d'après le théorème de Heine-Cantor. Il existe donc $\delta > 0$ tel que pour tout $x \in K$ et $y \in \mathbb{R}$, si $|x - y| < \delta$, alors $|f(x) - f(y)| < \eta$.

Majorons la différence d'espérance :

$$|\mathbb{E}[f(X_n)] - \mathbb{E}[f(X)]| \leq \mathbb{E}[|f(X_n) - f(X)|]$$

Partitionnons l'espace d'intégration Ω selon deux critères : l'éloignement de X_n et X, et l'appartenance de X au compact K. Soient les événements : $E_1 = \{\omega \in \Omega \mid |X_n(\omega) - X(\omega)| \geq \delta\}$ $E_2 = \{\omega \in \Omega \mid |X_n(\omega) - X(\omega)| < \delta \text{ et } X(\omega) \notin K\}$ $E_3 = \{\omega \in \Omega \mid |X_n(\omega) - X(\omega)| < \delta \text{ et } X(\omega) \in K\}$

Décomposons l'intégrale (espérance) selon cette partition :

$$\mathbb{E}[|f(X_n) - f(X)|] = \mathbb{E}[|f(X_n) - f(X)| \cdot \mathbf{1}_{E_1}] + \mathbb{E}[|f(X_n) - f(X)| \cdot \mathbf{1}_{E_2}] + \mathbb{E}[|f(X_n) - f(X)| \cdot \mathbf{1}_{E_3}]$$

1. Sur E_1, on majore brutalement avec la borne de f : $|f(X_n) - f(X)| \leq |f(X_n)| + |f(X)| \leq 2M$. Donc $\mathbb{E}[|f(X_n) - f(X)| \cdot \mathbf{1}_{E_1}] \leq 2M \cdot \mathbb{P}(E_1) \leq 2M \cdot \mathbb{P}(|X_n - X| \geq \delta)$. 2. Sur E_2, on majore aussi brutalement : $|f(X_n) - f(X)| \leq 2M$. Donc $\mathbb{E}[|f(X_n) - f(X)| \cdot \mathbf{1}_{E_2}] \leq 2M \cdot \mathbb{P}(E_2) \leq 2M \cdot \mathbb{P}(X \notin K) \leq 2M\eta$. 3. Sur E_3, on exploite la continuité uniforme : $|f(X_n) - f(X)| < \eta$. Donc $\mathbb{E}[|f(X_n) - f(X)| \cdot \mathbf{1}_{E_3}] \leq \eta \cdot \mathbb{P}(E_3) \leq \eta \cdot 1 = \eta$.

En sommant, nous obtenons :

$$\mathbb{E}[|f(X_n) - f(X)|] \leq 2M \cdot \mathbb{P}(|X_n - X| \geq \delta) + 2M\eta + \eta = 2M \cdot \mathbb{P}(|X_n - X| \geq \delta) + (2M + 1)\eta$$

Puisque $X_n \xrightarrow{\mathbb{P}} X$, nous savons que pour ce $\delta > 0$ fixé, $\lim_{n\to\infty} \mathbb{P}(|X_n - X| \geq \delta) = 0$. En passant à la limite supérieure lorsque $n \to \infty$:

$$\limsup_{n\to\infty} \mathbb{E}[|f(X_n) - f(X)|] \leq (2M + 1)\eta$$

Or, $\eta > 0$ a été choisi de manière arbitraire. Cette inégalité étant valide pour tout $\eta > 0$, cela force la limite à être nulle :

$$\lim_{n\to\infty} \mathbb{E}[|f(X_n) - f(X)|] = 0$$

Ainsi, la convergence en loi est démontrée. ■

4 4. Applications en Physique, Logique et Intelligence Artificielle

4.1 A. Consistance asymptotique (Machine Learning)

En théorie de l'apprentissage statistique, on dit qu'un algorithme fournissant un estimateur paramétrique $\hat{\theta}_n$ (calculé sur n observations) est convergent si cet estimateur approche la "vraie" valeur θ^* du modèle génératif sous-jacent. Cette convergence est quantifiée mathématiquement par la convergence en probabilité ($\hat{\theta}_n \xrightarrow{\mathbb{P}} \theta^*$), justifiant ainsi théoriquement que l'accumulation massive de données permet l'extraction de signaux constants sans ambiguïté.

4.2 B. Dynamique de la rétropropagation du gradient (SGD)

La descente de gradient stochastique, clé de voûte de l'entraînement des modèles d'IA génératifs (Transformers, CNNs), repose sur une suite de poids synaptiques θ_n. Bien que chaque mise à jour $\nabla L(\theta_n, x_i)$ soit bruitée car évaluée sur un mini-batch aléatoire, la théorie des martingales garantit (sous les conditions de pas de Robbins-Monro) que l'algorithme converge **presque sûrement** vers un point critique (gradient nul) de l'espace de perte.

4.3 C. Théorème Central Limite (Physique statistique)

En mécanique statistique, les variables macroscopiques (comme la pression d'un gaz sur une paroi) résultent de l'accumulation de millions de petites fluctuations (les impacts des molécules microscopiques, que l'on peut modéliser par des variables aléatoires (X_i) i.i.d). Bien qu'il soit impossible de connaître la répartition microscopique individuelle, le Théorème Central Limite garantit que la somme normalisée $\frac{1}{\sqrt{n}}\sum(X_i - \mu)$ converge universellement **en loi** vers une distribution Gaussienne $\mathcal{N}(0, \sigma^2)$, expliquant la prévalence quasi-universelle de la cloche de Gauss dans les phénomènes thermiques et browniens.

Travaux Dirigés

Exercice 01

Difficulté : ★⋆⋆⋆⋆

Énoncé : Convergence p.s. d'une suite géométrique

Soit (X_n) une suite de variables aléatoires indépendantes et identiquement distribuées selon la loi uniforme sur $[0,1]$. Posons $Y_n = \max(X_1, X_2, \ldots, X_n)$. Montrez que Y_n converge presque sûrement vers la variable certaine $Y = 1$.

Correction exhaustive : Puisque Y_n est le maximum de variables à valeurs dans $[0,1]$, on a pour tout n, $0 \leq Y_n \leq 1$. De plus, la suite $(Y_n)_{n\geq 1}$ est par définition croissante. En effet, $Y_{n+1} = \max(Y_n, X_{n+1}) \geq Y_n$. Une suite de variables aléatoires presque sûrement croissante et presque sûrement majorée converge presque sûrement vers une limite. Appelons cette limite Y. Montrons que $Y = 1$ presque sûrement. Pour tout $\epsilon \in]0,1[$, évaluons la probabilité que $Y_n \leq 1-\epsilon$:

$$\mathbb{P}(Y_n \leq 1-\epsilon) = \mathbb{P}(\max(X_1, \ldots, X_n) \leq 1-\epsilon)$$

Par indépendance des variables X_i :

$$\mathbb{P}(Y_n \leq 1-\epsilon) = \prod_{i=1}^{n} \mathbb{P}(X_i \leq 1-\epsilon) = (1-\epsilon)^n$$

La probabilité de l'événement $\{Y \leq 1-\epsilon\}$ est bornée par $\mathbb{P}(Y_n \leq 1-\epsilon)$ pour tout n. En faisant tendre $n \to \infty$, comme $(1-\epsilon) \in]0,1[$, on a $(1-\epsilon)^n \to 0$. Ainsi, $\mathbb{P}(Y \leq 1-\epsilon) = 0$ pour tout $\epsilon > 0$. Comme $Y_n \leq 1$ p.s., on a $Y \leq 1$ p.s. La seule possibilité restante est que $\mathbb{P}(Y = 1) = 1$. La convergence presque sûre vers 1 est donc établie.

Exercice 02

Difficulté : ★⋆⋆⋆⋆

Énoncé : Non-convergence dans L1 avec convergence p.s.

Construisez explicitement une suite de variables aléatoires $(X_n)_{n\in\mathbb{N}^*}$ qui converge presque sûrement vers 0, mais qui diverge vers $+\infty$ dans L^1.

Correction exhaustive : Considérons l'espace probabilisé usuel $(\Omega, \mathcal{F}, \mathbb{P}) = ([0,1], \mathcal{B}([0,1]), \lambda)$ où λ est la mesure de Lebesgue. Définissons la variable aléatoire $X_n : \Omega \to \mathbb{R}$ par :

$$X_n(\omega) = n^2 \mathbf{1}_{\left[0,\frac{1}{n}\right]}(\omega)$$

Étudions la convergence presque sûre : Fixons $\omega \in]0,1]$. Par la propriété d'Archimède, il existe un entier $N \geq 1$ tel que $\frac{1}{N} < \omega$. Pour tout $n \geq N$, $\omega \notin \left[0, \frac{1}{n}\right]$, ce qui implique $X_n(\omega) = 0$. Par conséquent, $\lim_{n\to\infty} X_n(\omega) = 0$ pour tout $\omega \in]0,1]$. L'événement sur lequel la convergence n'a pas lieu est contenu dans $\{0\}$, qui est de mesure de Lebesgue nulle ($\lambda(\{0\}) = 0$). Ainsi, $X_n \xrightarrow{p.s.} 0$.

Calculons l'espérance de X_n (norme L^1) :

$$\mathbb{E}[|X_n|] = \int_0^1 n^2 \mathbf{1}_{\left[0,\frac{1}{n}\right]}(\omega)\, d\lambda(\omega) = n^2 \cdot \lambda\left(\left[0, \frac{1}{n}\right]\right) = n^2 \cdot \frac{1}{n} = n$$

Lorsque $n \to \infty$, $\mathbb{E}[|X_n|] = n \to +\infty$. La suite diverge donc grossièrement dans L^1, bien qu'elle s'écrase presque partout. Ceci illustre la rupture de l'uniforme intégrabilité.

Exercice 03

Difficulté : ★★⋆⋆

Énoncé : Lemme de Borel-Cantelli

Soit $(X_n)_{n\geq 1}$ une suite de variables aléatoires. On suppose que pour tout $\epsilon > 0$, la série $\sum_{n=1}^{\infty} \mathbb{P}(|X_n| > \epsilon)$ est convergente. Démontrez que X_n converge presque sûrement vers 0.

Correction exhaustive : Fixons $\epsilon > 0$. Considérons la suite d'événements $A_n^\epsilon = \{|X_n| > \epsilon\}$. Par hypothèse, la série $\sum_{n=1}^{\infty} \mathbb{P}(A_n^\epsilon) < \infty$. D'après le premier lemme de Borel-Cantelli, la probabilité que l'événement A_n^ϵ se réalise une infinité de fois est nulle :

$$\mathbb{P}(\limsup_{n\to\infty} A_n^\epsilon) = 0$$

L'événement $\limsup A_n^\epsilon$ s'écrit $\bigcap_{N=1}^{\infty} \bigcup_{n\geq N} A_n^\epsilon$. Prenons une suite de réels strictement positifs décroissant vers zéro, par exemple $\epsilon_k = \frac{1}{k}$ pour $k \in \mathbb{N}^*$. Soit $E_k = \limsup_{n\to\infty} A_n^{\epsilon_k}$. Nous avons montré que $\mathbb{P}(E_k) = 0$. Par sous-additivité de la mesure de probabilité, l'union dénombrable de ces événements de probabilité nulle est également de probabilité nulle :

$$\mathbb{P}\left(\bigcup_{k=1}^{\infty} E_k\right) \leq \sum_{k=1}^{\infty} \mathbb{P}(E_k) = 0$$

Considérons l'événement complémentaire de cette union, notons-le $\Omega^* = (\bigcup_{k=1}^{\infty} E_k)^c = \bigcap_{k=1}^{\infty} E_k^c$. Sa probabilité vaut 1. Pour tout $\omega \in \Omega^*$, et pour tout $k \geq 1$, $\omega \in E_k^c$, ce qui signifie qu'il n'appartient pas à $\limsup A_n^{\epsilon_k}$. Donc pour tout $k \geq 1$, l'événement $\{|X_n(\omega)| > \frac{1}{k}\}$ ne se réalise qu'un nombre fini de fois. Autrement dit, il existe un entier $N(\omega, k)$ tel que pour tout $n \geq N(\omega, k)$, $|X_n(\omega)| \leq \frac{1}{k}$. Ceci est exactement la définition de la convergence $\lim_{n\to\infty} X_n(\omega) = 0$. Puisque ce résultat est vrai pour tout $\omega \in \Omega^*$, et que $\mathbb{P}(\Omega^*) = 1$, nous avons prouvé que $X_n \xrightarrow{p.s.} 0$.

Exercice 04

Difficulté : ★★⋆⋆

Énoncé : Convergence de la moyenne empirique (Loi Faible)

Soit $(X_n)_{n\geq 1}$ une suite de variables aléatoires indépendantes et identiquement distribuées, d'espérance $\mu = \mathbb{E}[X_1]$ et de variance $\sigma^2 = \mathrm{Var}(X_1) < \infty$. Posons la moyenne empirique $S_n = \frac{1}{n}\sum_{i=1}^{n} X_i$. Montrez en utilisant l'inégalité de Bienaymé-Chebyshev que S_n converge en probabilité vers μ.

Correction exhaustive : La moyenne empirique S_n est une combinaison linéaire de variables aléatoires. Par linéarité de l'espérance, nous calculons l'espérance de S_n :

$$\mathbb{E}[S_n] = \mathbb{E}\left[\frac{1}{n}\sum_{i=1}^{n} X_i\right] = \frac{1}{n}\sum_{i=1}^{n} \mathbb{E}[X_i] = \frac{1}{n} \cdot (n\mu) = \mu$$

Par indépendance des variables aléatoires X_i, la variance de la somme est la somme des variances :

$$\mathrm{Var}(S_n) = \mathrm{Var}\left(\frac{1}{n}\sum_{i=1}^{n} X_i\right) = \frac{1}{n^2}\sum_{i=1}^{n} \mathrm{Var}(X_i) = \frac{1}{n^2} \cdot (n\sigma^2) = \frac{\sigma^2}{n}$$

Nous voulons montrer la convergence en probabilité vers μ, c'est-à-dire que pour tout $\epsilon > 0$, $\lim_{n\to\infty} \mathbb{P}(|S_n - \mu| > \epsilon) = 0$. Fixons un réel $\epsilon > 0$. Appliquons l'inégalité de Bienaymé-Chebyshev à la variable aléatoire S_n :

$$\mathbb{P}(|S_n - \mathbb{E}[S_n]| \geq \epsilon) \leq \frac{\mathrm{Var}(S_n)}{\epsilon^2}$$

En remplaçant l'espérance et la variance par les valeurs calculées :

$$\mathbb{P}(|S_n - \mu| \geq \epsilon) \leq \frac{\sigma^2}{n\epsilon^2}$$

Puisque σ^2 et ϵ sont des constantes indépendantes de n, lorsque nous passons à la limite $n \to \infty$:

$$\lim_{n\to\infty} \frac{\sigma^2}{n\epsilon^2} = 0$$

Étant donné qu'une probabilité est positive ou nulle, le théorème d'encadrement donne :

$$\lim_{n\to\infty} \mathbb{P}(|S_n - \mu| \geq \epsilon) = 0$$

Ainsi, $S_n \xrightarrow{\mathbb{P}} \mu$. C'est la démonstration de la Loi Faible des Grands Nombres dans le cas fini-variant.

Exercice 05

Difficulté : ★★★⋆⋆

Énoncé : Convergence en loi (théorème de Slutsky partiel)

Soient (X_n) et (Y_n) deux suites de variables aléatoires. On suppose que X_n converge en loi vers X, et que Y_n converge en probabilité vers la variable certaine c ($c \in \mathbb{R}$). Montrez que la suite $X_n + Y_n$ converge en loi vers $X + c$.

Correction exhaustive : Pour prouver que $X_n + Y_n \xrightarrow{\mathcal{L}} X + c$, nous allons utiliser la caractérisation par l'espérance des fonctions continues bornées. Soit $f : \mathbb{R} \to \mathbb{R}$ uniformément continue et bornée. Soit $M > 0$ la borne telle que $|f(x)| \leq M$ pour tout x. Puisque f est uniformément continue, pour tout $\eta > 0$, il existe $\delta > 0$ tel que pour tous $x, y \in \mathbb{R}$, $|x - y| < \delta \implies |f(x) - f(y)| < \eta$. Nous voulons montrer que $\lim_{n\to\infty} \mathbb{E}[f(X_n + Y_n)] = \mathbb{E}[f(X + c)]$. Décomposons la différence :

$$|\mathbb{E}[f(X_n + Y_n)] - \mathbb{E}[f(X + c)]| \leq |\mathbb{E}[f(X_n + Y_n)] - \mathbb{E}[f(X_n + c)]| + |\mathbb{E}[f(X_n + c)] - \mathbb{E}[f(X + c)]|$$

Traitons le second terme : soit $g(x) = f(x + c)$. La fonction g est également continue et bornée. Puisque $X_n \xrightarrow{\mathcal{L}} X$, par définition de la convergence en loi, on a :

$$\lim_{n\to\infty} \mathbb{E}[g(X_n)] = \mathbb{E}[g(X)] \implies \lim_{n\to\infty} |\mathbb{E}[f(X_n + c)] - \mathbb{E}[f(X + c)]| = 0$$

Traitons le premier terme : nous majorons $|f(X_n + Y_n) - f(X_n + c)|$. L'écart dans l'argument est $|(X_n + Y_n) - (X_n + c)| = |Y_n - c|$. Introduisons l'événement $A_n = \{|Y_n - c| \geq \delta\}$.

$$\mathbb{E}[|f(X_n + Y_n) - f(X_n + c)|] = \mathbb{E}[|f(X_n + Y_n) - f(X_n + c)|\mathbf{1}_{A_n}] + \mathbb{E}[|f(X_n + Y_n) - f(X_n + c)|\mathbf{1}_{A_n^c}]$$

Sur l'événement A_n, on majore l'écart par $2M$. Donc l'espérance est majorée par $2M \cdot \mathbb{P}(A_n)$. Sur l'événement complémentaire A_n^c, on a $|Y_n - c| < \delta$. Par uniforme continuité de f, $|f(X_n + Y_n) - f(X_n + c)| < \eta$. L'espérance est donc majorée par η. Ainsi :

$$\mathbb{E}[|f(X_n + Y_n) - f(X_n + c)|] \leq 2M \cdot \mathbb{P}(|Y_n - c| \geq \delta) + \eta$$

Puisque $Y_n \xrightarrow{\mathbb{P}} c$, pour ce $\delta > 0$ fixé, la probabilité $\mathbb{P}(|Y_n - c| \geq \delta)$ tend vers 0 lorsque $n \to \infty$. La limite de l'écart est donc inférieure ou égale à η. Comme η a été choisi arbitrairement petit, la limite de ce terme est nulle. En sommant les deux limites nulles, on obtient la convergence désirée. (Le résultat se généralise pour f continue bornée grâce au théorème de Portmanteau partiel).

Exercice 06

Difficulté : ★★★⋆⋆

Énoncé : Convergence d'une variable exponentielle rescalée

Soit (X_n) une suite de variables aléatoires indépendantes suivant la loi exponentielle de paramètre $\lambda = n$. Étudiez les modes de convergence (presque sûre, probabilité, loi) de la suite (X_n).

Correction exhaustive : Déterminons d'abord la fonction de répartition de X_n. Pour tout $t > 0$, $F_n(t) = \mathbb{P}(X_n \leq t) = 1 - e^{-nt}$. Pour $t \leq 0$, $F_n(t) = 0$. Fixons $t > 0$. Lorsque $n \to \infty$, $e^{-nt} \to 0$, donc $F_n(t) \to 1$. Pour $t < 0$, $F_n(t) = 0 \to 0$. La limite simple des fonctions de répartition est la fonction $\mathbf{1}_{[0,+\infty[}(t)$, qui correspond à la fonction de répartition de la variable certaine $X = 0$. Puisque la convergence a lieu en tout point de continuité de la fonction de répartition de la variable constante 0 (seul le point $t = 0$ pose question, mais on ne regarde que les points de continuité), on déduit que :

$$X_n \xrightarrow{\mathcal{L}} 0$$

Puisque la limite est une variable certaine (constante), le théorème de convergence affirme que la convergence en loi vers une constante est équivalente à la convergence en probabilité. Vérifions-le analytiquement : pour tout $\epsilon > 0$,

$$\mathbb{P}(|X_n - 0| > \epsilon) = \mathbb{P}(X_n > \epsilon) = 1 - F_n(\epsilon) = e^{-n\epsilon}$$

Puisque $\epsilon > 0$, $\lim_{n\to\infty} e^{-n\epsilon} = 0$. Ainsi, $X_n \xrightarrow{\mathbb{P}} 0$. Étudions la convergence presque sûre via Borel-Cantelli. Fixons $\epsilon > 0$. Formons la somme des probabilités :

$$\sum_{n=1}^{\infty} \mathbb{P}(|X_n| > \epsilon) = \sum_{n=1}^{\infty} e^{-n\epsilon}$$

Il s'agit d'une série géométrique de raison $q = e^{-\epsilon} \in]0, 1[$, qui est convergente. Par le premier lemme de Borel-Cantelli, l'événement $\{|X_n| > \epsilon\}$ ne se réalise qu'un nombre fini de fois avec probabilité 1. Puisque cela est vrai pour une suite de ϵ tendant vers 0, on en déduit que :

$$X_n \xrightarrow{p.s.} 0$$

La suite converge donc selon les trois modes principaux vers la variable 0.

Exercice 07

Difficulté : ★★★★⋆

Énoncé : Convergence et transformée fonctionnelle continue

Soit (X_n) convergeant en probabilité vers X. Soit $g : \mathbb{R} \to \mathbb{R}$ une fonction uniformément continue. Démontrez que $g(X_n)$ converge en probabilité vers $g(X)$. (Ce résultat s'étend aux fonctions continues par le théorème d'approximation sur les compacts).

Correction exhaustive : Puisque g est uniformément continue, par définition, pour tout $\epsilon > 0$, il existe un $\delta > 0$ tel que pour tous $x, y \in \mathbb{R}$,

$$|x - y| < \delta \implies |g(x) - g(y)| < \epsilon$$

Par contraposée de cette implication purement déterministe (logique propositionnelle), on obtient :

$$|g(x) - g(y)| \geq \epsilon \implies |x - y| \geq \delta$$

En remplaçant x par la variable aléatoire $X_n(\omega)$ et y par $X(\omega)$, on obtient l'inclusion d'événements aléatoires suivante :

$$\{\omega \in \Omega \mid |g(X_n(\omega)) - g(X(\omega))| \geq \epsilon\} \subseteq \{\omega \in \Omega \mid |X_n(\omega) - X(\omega)| \geq \delta\}$$

Puisque le premier événement est inclus dans le second, la croissance de la mesure de probabilité nous indique que :

$$\mathbb{P}(|g(X_n) - g(X)| \geq \epsilon) \leq \mathbb{P}(|X_n - X| \geq \delta)$$

Par hypothèse, X_n converge en probabilité vers X. Donc, pour le réel fixé $\delta > 0$, nous avons :

$$\lim_{n\to\infty} \mathbb{P}(|X_n - X| \geq \delta) = 0$$

Le terme majorant tendant vers zéro, et les probabilités étant minorées par zéro, le théorème d'encadrement conclut formellement :

$$\lim_{n\to\infty} \mathbb{P}(|g(X_n) - g(X)| \geq \epsilon) = 0$$

Ceci constitue l'exacte définition de la convergence en probabilité de la suite $(g(X_n))$ vers la variable $g(X)$.

Exercice 08

Difficulté : ★★★★⋆

Énoncé : Convergence L^p et intégrabilité de la limite

Supposons que $X_n \xrightarrow{L^p} X$ pour $p \geq 1$. Démontrez de façon complète que la fonction limite X appartient nécessairement à L^p, en utilisant la stricte inégalité de Minkowski.

Correction exhaustive : Par hypothèse, pour tout n, $X_n \in L^p$, c'est-à-dire $\mathbb{E}[|X_n|^p] < \infty$. La condition $X_n \xrightarrow{L^p} X$ signifie que la quantité $\mathbb{E}[|X_n - X|^p]$ (la puissance p-ème de la norme $\|X_n - X\|_p$) tend vers 0 lorsque $n \to \infty$. Ceci implique en particulier qu'il existe un rang N à partir duquel cette quantité est finie. Ainsi, $\|X_n - X\|_p < \infty$ pour $n \geq N$. Considérons la norme dans l'espace L^p définie par $\|Z\|_p = (\mathbb{E}[|Z|^p])^{1/p}$. La variable aléatoire X peut s'écrire artificiellement comme une somme télescopique :

$$X = (X - X_N) + X_N$$

Prenons la norme L^p de cette somme. L'inégalité de Minkowski, qui exprime la sous-additivité de la norme, affirme que :

$$\|X\|_p = \|(X - X_N) + X_N\|_p \leq \|X - X_N\|_p + \|X_N\|_p$$

Puisque la norme est symétrique (absolue), $\|X - X_N\|_p = \|X_N - X\|_p$. Par hypothèse, nous savons que $\|X_N - X\|_p < \infty$ puisque la limite tend vers 0. De plus, $X_N \in L^p$ garantit que $\|X_N\|_p < \infty$. La somme de deux nombres réels finis étant finie, nous en déduisons :

$$\|X\|_p < \infty$$

L'élévation à la puissance p conserve la finitude (puisque $p \geq 1$) :

$$\mathbb{E}[|X|^p] = (\|X\|_p)^p < \infty$$

Nous avons ainsi démontré que l'espace vectoriel d'arrivée n'a pas été fracturé : la limite de la convergence en norme L^p reste strictement emprisonnée dans la classe des fonctions L^p intégrables.

Exercice 09

Difficulté : ★★★★★

Énoncé : Absence de convergence L^p pour la loi de Cauchy

Considérons une suite (X_n) de variables indépendantes suivant la loi de Cauchy standard. La densité de X_i est $f(x) = \frac{1}{\pi(1+x^2)}$. Posons la moyenne empirique $S_n = \frac{1}{n}\sum_{i=1}^{n} X_i$. Montrez rigoureusement que S_n ne converge ni en probabilité, ni presque sûrement vers la constante 0, ruinant l'intuition de la loi des grands nombres.

Correction exhaustive : La loi des grands nombres s'applique aux variables aléatoires admettant une espérance (une norme L^1 finie). Or, l'intégrale pour l'espérance de la loi de Cauchy vaut :

$$\int_{-\infty}^{\infty} |x| \frac{1}{\pi(1+x^2)} dx$$

L'intégrande se comporte comme $\frac{1}{|x|}$ à l'infini. L'intégrale de Riemann d'une fonction de la forme $\frac{1}{x^a}$ avec $a \leq 1$ est divergente. La loi de Cauchy ne possède donc pas de moment d'ordre 1. Pour étudier la somme, utilisons l'outil fondamental des probabilités additives : la fonction caractéristique. La fonction caractéristique de la loi de Cauchy standard est connue et vaut :

$$\phi_{X_1}(t) = \mathbb{E}[e^{itX_1}] = e^{-|t|}$$

Par indépendance des X_i, la fonction caractéristique de la somme s'obtient par multiplication :

$$\phi_{\sum_{i=1}^{n} X_i}(t) = \prod_{i=1}^{n} \phi_{X_i}(t) = (e^{-|t|})^n = e^{-n|t|}$$

Appliquons la transformation linéaire due au coefficient $1/n$: pour toute variable aléatoire Y et scalaire c, $\phi_{cY}(t) = \phi_Y(ct)$.

$$\phi_{S_n}(t) = \phi_{\frac{1}{n}\sum X_i}(t) = \phi_{\sum X_i}\left(\frac{t}{n}\right) = e^{-n\left|\frac{t}{n}\right|} = e^{-|t|}$$

Incroyablement, la fonction caractéristique de S_n reste rigoureusement identique à celle de X_1 ! Puisque la fonction caractéristique détermine univoquement la loi d'une variable aléatoire (Théorème d'inversion de Fourier-Lévy), la variable empirique S_n suit elle-même une loi de Cauchy standard pour tout n.

$$S_n \sim \text{Cauchy}(0, 1)$$

Par conséquent, la suite des distributions de S_n ne s'écrase pas vers un dirac en 0. Elle converge en loi vers une variable $X \sim \text{Cauchy}(0, 1)$ non-dégénérée. Puisque la limite en loi n'est pas constante, et que la convergence en probabilité vers une variable impliquerait la convergence en loi vers cette même variable dégénérée, on conclut de manière absolue que S_n ne converge **pas** en probabilité vers 0 (ni vers aucune constante). A fortiori, puisqu'elle ne converge pas en probabilité, elle ne peut pas converger presque sûrement vers 0, pulvérisant ainsi l'idée naïve d'une stabilisation algorithmique de ces données.

Exercice 10

Difficulté : ★★★★★

Énoncé : Preuve du contre-exemple p.s n'implique pas L^p

Rédigez la démonstration formelle du fait que la convergence presque sûre n'implique pas la convergence dans L^p (ni même L^1). On exhibera un contre-exemple explicite et on calculera toutes les normes.

Correction exhaustive : Nous devons fournir un exemple canonique illustrant la fuite de masse vers l'infini (concentration d'énergie sur un volume évanescent). Considérons l'espace de

probabilité $\Omega =]0,1]$ muni de la mesure de Borel-Lebesgue usuelle $\mathbb{P}$. Définissons la suite de fonctions $X_n : \Omega \to \mathbb{R}$ par :

$$X_n(\omega) = n \cdot \mathbf{1}_{]0,1/n]}(\omega)$$

1. Convergence presque sûre : Soit un événement élémentaire $\omega \in]0,1]$. Parce que $\omega > 0$, et par la propriété archimédienne des réels, il existe un entier $N \geq 1$ tel que $\frac{1}{N} < \omega$. Pour tout $n \geq N$, nous aurons $\frac{1}{n} \leq \frac{1}{N} < \omega$. Cela signifie que pour $n \geq N$, $\omega \notin]0, 1/n]$, et donc par définition de la fonction indicatrice, $X_n(\omega) = 0$. La suite numérique déterministe $X_n(\omega)$ devient stationnaire et égale à 0 pour tout indice $n \geq N$. Elle converge donc trivialement vers 0. Puisque ceci est vrai pour **tout** $\omega \in]0,1]$, la convergence a lieu ponctuellement sur tout Ω. L'événement exceptionnel est l'ensemble vide, dont la probabilité est bien 0. Ainsi, $X_n \xrightarrow{p.s.} 0$.

2. Non-convergence dans L^1 : Pour prouver la convergence L^1 vers 0, il faudrait que $\lim_{n\to\infty} \mathbb{E}[|X_n|] = 0$. Procédons au calcul rigoureux de l'espérance pour un n fixé, en utilisant l'intégrale de Lebesgue :

$$\mathbb{E}[|X_n|] = \int_\Omega |X_n(\omega)| d\mathbb{P}(\omega) = \int_0^1 n \cdot \mathbf{1}_{]0,1/n]}(\omega) d\omega$$

$$\mathbb{E}[|X_n|] = n \int_0^{1/n} 1 d\omega = n \cdot [\omega]_0^{1/n} = n \cdot \left(\frac{1}{n} - 0\right) = n \cdot \frac{1}{n} = 1$$

Pour tout indice $n \geq 1$, la masse fonctionnelle (l'aire sous la courbe) est constante et strictement égale à 1. Par passage à la limite :

$$\lim_{n\to\infty} \mathbb{E}[|X_n - 0|] = 1 \neq 0$$

La suite ne converge donc absolument pas vers 0 dans la topologie des espaces L^1, établissant la démonstration définitive qu'une singularité géométrique empêche l'inversion limite/intégrale.

Travaux Pratiques

TP 01 :

Loi Faible des Grands Nombres empirique

Dans ce TP, nous implémentons de zéro la simulation d'une moyenne empirique de variables de Bernoulli pour illustrer la convergence en probabilité (Loi Faible des Grands Nombres).

```python
import random
import math

def simuler_bernoulli(p):
    return 1 if random.random() < p else 0

def moyenne_empirique_bernoulli(n, p):
    somme = sum(simuler_bernoulli(p) for _ in range(n))
    return somme / n

def estimer_probabilite_ecart(n, p, epsilon, n_simulations):
    depassements = 0
    for _ in range(n_simulations):
        moyenne = moyenne_empirique_bernoulli(n, p)
        if abs(moyenne - p) > epsilon:
            depassements += 1
    return depassements / n_simulations

# Parametres
p = 0.5
epsilon = 0.05
n_simulations = 1000

# Validation math matique de la convergence en probabilit
n_petit = 10
proba_petit = estimer_probabilite_ecart(n_petit, p, epsilon, n_simulations)

n_grand = 1000
proba_grand = estimer_probabilite_ecart(n_grand, p, epsilon, n_simulations)

print("Proba ecart pour n=10 :", proba_petit)
print("Proba ecart pour n=1000 :", proba_grand)

assert proba_grand < proba_petit, "La probabilit  de l' cart  doit diminuer avec n"
assert proba_grand < 0.05, "Pour n grand, la probabilit  d'un  cart  > epsilon doit  tre  proche de 0"
```

TP 02 :

Divergence L1 de la bosse fuyante

Nous allons simuler l'exemple de la "bosse fuyante" : X_n vaut n^2 avec probabilité $1/n$ et 0 sinon. Nous vérifierons numériquement que X_n converge en probabilité vers 0, mais que son espérance diverge.

```python
import random

def simuler_Xn(n):
    if random.random() < (1.0 / n):
        return n * n
    return 0

def estimer_esperance(n, n_simulations):
    somme = sum(simuler_Xn(n) for _ in range(n_simulations))
```

```
    return somme / n_simulations

def estimer_proba_ecart(n, epsilon, n_simulations):
    depassements = sum(1 for _ in range(n_simulations) if simuler_Xn(n) >
    epsilon)
    return depassements / n_simulations

n_simulations = 5000
epsilon = 0.1

n_valeurs = [10, 50, 200]

esperances = []
probas = []

for n in n_valeurs:
    esperances.append(estimer_esperance(n, n_simulations))
    probas.append(estimer_proba_ecart(n, epsilon, n_simulations))

print("Esperances (L1) :", esperances)
print("Probabilites ecart :", probas)

# Assertions : l'esperance doit croitre (divergence L1), la proba doit decroitre
    (convergence Proba)
assert esperances[2] > esperances[0], "L'esp rance doit diverger vers l'infini"
assert probas[2] < probas[0], "La probabilit  d' cart  doit tendre vers 0"
```

TP 03 :

Théorème Central Limite (Convergence en Loi)

Ce TP illustre la convergence en loi. Nous sommons des variables uniformes et vérifions que les moments empiriques de la variable standardisée s'approchent de ceux d'une loi normale $\mathcal{N}(0,1)$ (Espérance 0, Variance 1, Kurtosis 3).

```
import random

def somme_uniforme(n):
    # Somme de n variables uniformes sur [0, 1]
    return sum(random.random() for _ in range(n))

def generer_Z_n(n):
    # E[U] = 0.5, Var(U) = 1/12
    Sn = somme_uniforme(n)
    esperance_Sn = n * 0.5
    variance_Sn = n * (1.0 / 12.0)
    ecart_type_Sn = variance_Sn ** 0.5

    Zn = (Sn - esperance_Sn) / ecart_type_Sn
    return Zn

def estimer_moments(n, n_simulations):
    somme = 0
    somme_carr = 0
    somme_puiss4 = 0

    for _ in range(n_simulations):
        z = generer_Z_n(n)
        somme += z
        somme_carr += z * z
        somme_puiss4 += z ** 4

    esperance = somme / n_simulations
```

```
    variance = somme_carr / n_simulations - esperance**2
    # Kurtosis = E[Z^4] / Var^2
    kurtosis = (somme_puiss4 / n_simulations) / (variance ** 2)
    return esperance, variance, kurtosis

n = 50
n_simulations = 10000
esp, var, kurt = estimer_moments(n, n_simulations)

print("Esperance empirique :", esp)
print("Variance empirique :", var)
print("Kurtosis empirique :", kurt)

# Validation de la convergence en loi (Moments d'une normale N(0,1))
assert abs(esp) < 0.1, "L'esp rance doit  tre  proche de 0"
assert abs(var - 1.0) < 0.1, "La variance doit  tre  proche de 1"
assert abs(kurt - 3.0) < 0.2, "Le kurtosis doit converger vers 3 (loi normale)"
```

TP 04 :

Rupture du TCL pour la loi de Cauchy

Nous implémentons une simulation démontrant que la moyenne empirique de variables de Cauchy ne converge pas en probabilité vers une constante, et ne réduit pas sa variance (car elle est infinie).

```
import random
import math

def simuler_cauchy():
    # Methode d'inversion pour Cauchy standard
    u = random.random()
    return math.tan(math.pi * (u - 0.5))

def generer_moyenne_cauchy(n):
    somme = sum(simuler_cauchy() for _ in range(n))
    return somme / n

def evaluer_dispersion_cauchy(n_valeurs, n_simulations):
    # La m diane absolue donne une idee de l'  talement  (variance = infini)
    dispersions = {}
    for n in n_valeurs:
        valeurs = sorted(abs(generer_moyenne_cauchy(n)) for _ in range(
    n_simulations))
        mediane_abs = valeurs[n_simulations // 2]
        dispersions[n] = mediane_abs
    return dispersions

n_valeurs = [10, 100, 1000]
n_simulations = 2000
dispersions = evaluer_dispersion_cauchy(n_valeurs, n_simulations)

print("Dispersions m dianes absolues pour Cauchy :", dispersions)

# La moyenne d'une Cauchy est encore une Cauchy(0,1), la dispersion ne diminue
    PAS avec n.
assert dispersions[1000] > 0.5, "La dispersion ne tend pas vers 0, la loi des
    grands nombres  choue ."
```

TP 05 :

Convergence en Probabilité via Fonction de Répartition

Ce TP vérifie numériquement la caractérisation de la convergence en loi : on simule le maximum de n variables uniformes sur [0,1], puis on étudie le comportement asymptotique de $n(1 - Y_n)$, qui doit converger en loi vers une Exponentielle de paramètre 1.

```python
import random
import math

def simuler_Yn(n):
    return max(random.random() for _ in range(n))

def simuler_Zn(n):
    Yn = simuler_Yn(n)
    return n * (1.0 - Yn)

def estimer_cdf(n, x, n_simulations):
    # Estime P(Z_n <= x)
    succes = sum(1 for _ in range(n_simulations) if simuler_Zn(n) <= x)
    return succes / n_simulations

# On teste pour x = 1.
# La limite theorique est la CDF d'une Exp(1) evaluee en 1 : 1 - exp(-1)
x_test = 1.0
theorique = 1.0 - math.exp(-1.0)

n = 500
n_simulations = 5000
empirique = estimer_cdf(n, x_test, n_simulations)

print("Valeur theorique de P(Z <= 1) :", theorique)
print("Valeur empirique P(Z_n <= 1) :", empirique)

assert abs(empirique - theorique) < 0.05, "La distribution empirique doit
    correspondre    la loi Exponentielle asympotique"
```