LES MODES DE CONVERGENCE EN PROBABILITÉS

Cours magistral, exercices corrigés et travaux pratiques

Charles EDOU NZE

29 octobre 2026

Table des matières

I Cours Magistral **2**

1 Introduction historique et physique **2**

2 Définitions, Théorèmes et Exemples **2**
2.1 Convergence Presque Sûre 2
2.2 Convergence en Probabilité 2
2.3 Convergence en Moyenne d'Ordre p (L^p) 3
2.4 Convergence en Loi 3
2.5 Théorème des Hiérarchies de Convergence 3

3 Démonstrations **4**
3.1 Démonstration : $L^p \implies \mathbb{P}$ 4
3.2 Démonstration : $\mathbb{P} \implies \mathcal{L}$ 5

4 Applications en Physique, Logique et Intelligence Artificielle **5**
4.1 Application en Physique Statistique 5
4.2 Application en Logique 5
4.3 Application en Intelligence Artificielle (Deep Learning) 6

II Exercices d'Application et de Concours **7**

III Travaux Pratiques et Simulations Algorithmiques **11**

Première partie

Cours Magistral

1 Introduction historique et physique

La notion de convergence d'une suite de variables aléatoires est au coeur de la théorie asymptotique en probabilités et en statistiques. Historiquement, l'étude des jeux de hasard et la nécessité de quantifier la précision d'une moyenne empirique par rapport à l'espérance théorique ont conduit à la formulation de la loi faible des grands nombres par Jacques Bernoulli (1713). Plus tard, Émile Borel (1909) introduit une notion beaucoup plus forte, affirmant que certains événements se produisent avec une certitude absolue, formalisant la convergence presque sûre et la loi forte des grands nombres. Enfin, la convergence en loi a été développée pour formaliser le théorème central limite, où l'on ne s'intéresse plus aux variables elles-mêmes, mais à la forme limite de leur distribution.

D'un point de vue physique, ces modes de convergence reflètent différentes manières dont un système aléatoire se stabilise : - La **convergence presque sûre** correspond à une trajectoire physique qui finit par se confondre exactement avec la trajectoire limite, l'ensemble des trajectoires aberrantes étant de probabilité nulle (comme un système dissipatif qui s'arrête). - La **convergence en probabilité** signifie que la probabilité d'observer le système loin de son état limite à un instant donné s'estompe, bien qu'il puisse y avoir sporadiquement de grandes fluctuations. - La **convergence en moyenne (L^p)** indique que l'énergie moyenne (pour p=2) de l'écart au système limite tend vers zéro. - La **convergence en loi** décrit un état macroscopique stationnaire : l'état microscopique peut fluctuer, mais la fraction du temps passée dans chaque région de l'espace des phases (la distribution statistique) se fige.

2 Définitions, Théorèmes et Exemples

Soit $(\Omega, \mathcal{F}, \mathbb{P})$ un espace probabilisé. Soit $(X_n)_{n\in\mathbb{N}}$ une suite de variables aléatoires réelles et X une variable aléatoire réelle.

2.1 Convergence Presque Sûre

Définition (Convergence presque sûre). La suite (X_n) converge presque sûrement vers X, noté $X_n \xrightarrow{p.s.} X$, si et seulement si l'ensemble des $\omega \in \Omega$ pour lesquels la suite numérique $(X_n(\omega))$ converge vers $X(\omega)$ est de probabilité 1 :

$$\mathbb{P}\left(\left\{\omega \in \Omega \mid \lim_{n\to+\infty} X_n(\omega) = X(\omega)\right\}\right) = 1.$$

Exemple 1 : L'archer infaillible asymptotiquement. Soit $\Omega = [0, 1]$ muni de la mesure de Lebesgue. Définissons $X_n(\omega) = \omega^n$. Pour tout $\omega \in [0, 1[$, $\lim_{n\to\infty} \omega^n = 0$. Pour $\omega = 1$, $\lim_{n\to\infty} 1^n = 1$. L'ensemble des ω où la limite est 0 est $[0, 1[$, de mesure 1. Donc $X_n \xrightarrow{p.s.} 0$. L'événement exceptionnel $\{\omega = 1\}$ a une probabilité nulle.

2.2 Convergence en Probabilité

Définition (Convergence en probabilité). La suite (X_n) converge en probabilité vers X, noté $X_n \xrightarrow{\mathbb{P}} X$, si pour tout $\varepsilon > 0$, la probabilité que l'écart entre X_n et X dépasse ε tend

vers 0 lorsque $n \to +\infty$:

$$\forall \varepsilon > 0, \quad \lim_{n \to +\infty} \mathbb{P}(|X_n - X| > \varepsilon) = 0.$$

Exemple 2 : Le promeneur farfelu. Considérons une suite X_n valant n avec probabilité $\frac{1}{n}$, et 0 avec probabilité $1 - \frac{1}{n}$. Soit $\varepsilon \in]0, 1[$. L'événement $\{|X_n - 0| > \varepsilon\}$ se réduit à l'événement $\{X_n = n\}$, car pour $n \geq 1$, $n > \varepsilon$. La probabilité est $\mathbb{P}(X_n = n) = \frac{1}{n}$. Puisque $\lim_{n\to\infty} \frac{1}{n} = 0$, nous avons $X_n \xrightarrow{\mathbb{P}} 0$. Cependant, l'écart peut être immense (n), mais cela se produit de plus en plus rarement.

2.3 Convergence en Moyenne d'Ordre p (L^p)

Définition (Convergence dans L^p). Soit $p \geq 1$. Supposons que $\mathbb{E}[|X_n|^p] < +\infty$ et $\mathbb{E}[|X|^p] < +\infty$. La suite (X_n) converge dans L^p vers X, noté $X_n \xrightarrow{L^p} X$, si l'espérance de la puissance p-ième de l'écart tend vers 0 :

$$\lim_{n \to +\infty} \mathbb{E}[|X_n - X|^p] = 0.$$

Si $p = 1$, on parle de convergence en moyenne. Si $p = 2$, on parle de convergence en moyenne quadratique.

Exemple 3 : Calcul explicite d'erreur quadratique. Soit X_n une variable de loi uniforme sur $[0, \frac{1}{n}]$. Étudions la convergence vers 0 dans L^2. $\mathbb{E}[|X_n - 0|^2] = \int_0^{1/n} x^2 \cdot (n)\, dx = n \left[\frac{x^3}{3}\right]_0^{1/n} = n\frac{1}{3n^3} = \frac{1}{3n^2}$. Comme $\lim_{n\to\infty} \frac{1}{3n^2} = 0$, nous avons $X_n \xrightarrow{L^2} 0$.

2.4 Convergence en Loi

Définition (Convergence en loi). La suite (X_n) converge en loi vers X, noté $X_n \xrightarrow{\mathcal{L}} X$ ou $X_n \implies X$, si pour toute fonction $f : \mathbb{R} \to \mathbb{R}$ continue et bornée :

$$\lim_{n \to +\infty} \mathbb{E}[f(X_n)] = \mathbb{E}[f(X)].$$

Exemple 4 : Convergence des distributions. Soit $X_n = \frac{1}{n}$. La variable X_n est déterministe. Soit $X = 0$. Pour toute fonction f continue, $\lim_{n\to\infty} f(X_n) = f(0)$ (par continuité). Ici, $\mathbb{E}[f(X_n)] = f(\frac{1}{n})$ et $\mathbb{E}[f(X)] = f(0)$. Donc $\lim_{n\to\infty} \mathbb{E}[f(X_n)] = \mathbb{E}[f(X)]$. Ainsi, la constante $\frac{1}{n}$ converge en loi vers 0.

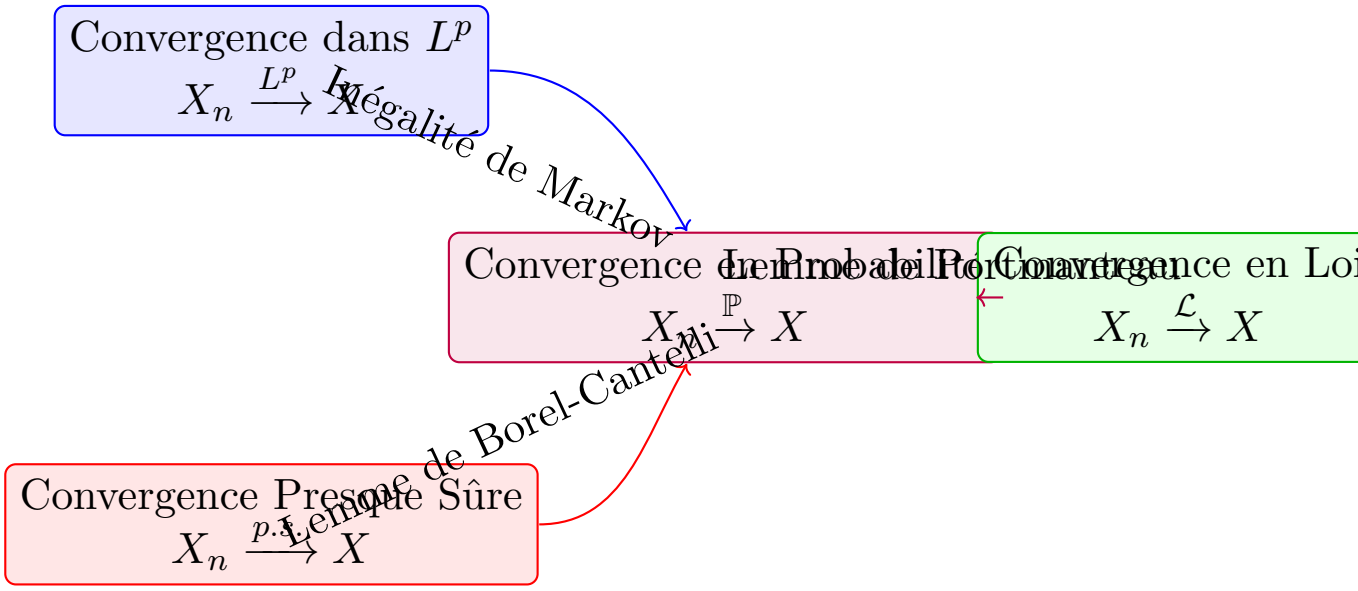
2.5 Théorème des Hiérarchies de Convergence

Théorème. Les implications suivantes sont strictement vraies : 1. $X_n \xrightarrow{p.s.} X \implies X_n \xrightarrow{\mathbb{P}} X$ 2. $X_n \xrightarrow{L^p} X \implies X_n \xrightarrow{\mathbb{P}} X$ 3. $X_n \xrightarrow{\mathbb{P}} X \implies X_n \xrightarrow{\mathcal{L}} X$

De plus, si $p > q \geq 1$, alors $X_n \xrightarrow{L^p} X \implies X_n \xrightarrow{L^q} X$.

Les réciproques sont fausses en général. Cependant, si $X_n \xrightarrow{\mathbb{P}} X$, on peut extraire une sous-suite $(X_{\phi(n)})$ telle que $X_{\phi(n)} \xrightarrow{p.s.} X$. De plus, si $X_n \xrightarrow{\mathcal{L}} c$ où c est une constante, alors $X_n \xrightarrow{\mathbb{P}} c$.

Exemple 5 : Contre-exemple L^p n'implique pas presque sûre. L'exemple 2 montre que $X_n \xrightarrow{\mathbb{P}} 0$. Regardons $L^1 : \mathbb{E}[|X_n|] = n \times \frac{1}{n} = 1 \neq 0$. Donc la convergence en probabilité n'implique pas la convergence dans L^p.



3 Démonstrations

3.1 Démonstration : $L^p \implies \mathbb{P}$

Théorème. Soit $p \geq 1$. Si $X_n \xrightarrow{L^p} X$, alors $X_n \xrightarrow{\mathbb{P}} X$.

Preuve rigoureuse. Supposons que $X_n \xrightarrow{L^p} X$. Cela signifie par définition que $\lim_{n\to+\infty} \mathbb{E}[|X_n - X|^p] = 0$. Soit $\varepsilon > 0$ fixé arbitrairement. Nous cherchons à évaluer $\mathbb{P}(|X_n - X| > \varepsilon)$. Considérons la variable aléatoire positive ou nulle $Y_n = |X_n - X|^p$. Puisque la fonction $x \mapsto x^p$ est strictement croissante sur $\mathbb{R}_+$, l'événement $\{|X_n - X| > \varepsilon\}$ est exactement l'événement $\{|X_n - X|^p > \varepsilon^p\}$, c'est-à-dire $\{Y_n > \varepsilon^p\}$. Appliquons l'inégalité de Markov à la variable aléatoire Y_n qui est à valeurs positives, pour le seuil $a = \varepsilon^p > 0$:

$$\mathbb{P}(Y_n > a) \leq \frac{\mathbb{E}[Y_n]}{a}$$

En substituant Y_n et a par leurs expressions :

$$\mathbb{P}(|X_n - X|^p > \varepsilon^p) \leq \frac{\mathbb{E}[|X_n - X|^p]}{\varepsilon^p}$$

Ce qui se réécrit :

$$\mathbb{P}(|X_n - X| > \varepsilon) \leq \frac{\mathbb{E}[|X_n - X|^p]}{\varepsilon^p}$$

Puisque X_n converge dans L^p vers X, le numérateur $\mathbb{E}[|X_n - X|^p]$ tend vers 0 lorsque n tend vers l'infini. Comme ε^p est une constante strictement positive, le terme de droite de l'inégalité tend vers 0. Par le théorème des gendarmes, sachant qu'une probabilité est minorée par 0 :

$$0 \leq \lim_{n\to+\infty} \mathbb{P}(|X_n - X| > \varepsilon) \leq 0$$

Ainsi, pour tout $\varepsilon > 0$, $\lim_{n\to+\infty} \mathbb{P}(|X_n - X| > \varepsilon) = 0$. La convergence en probabilité est donc démontrée. □

3.2 Démonstration : $\mathbb{P} \implies \mathcal{L}$

Théorème. Si $X_n \xrightarrow{\mathbb{P}} X$, alors $X_n \xrightarrow{\mathcal{L}} X$.

Preuve rigoureuse. Supposons que $X_n \xrightarrow{\mathbb{P}} X$. Nous devons montrer que pour toute fonction $f : \mathbb{R} \to \mathbb{R}$ continue et bornée, $\lim_{n\to+\infty} \mathbb{E}[f(X_n)] = \mathbb{E}[f(X)]$. Soit f une fonction continue et bornée. Il existe $M > 0$ tel que pour tout $x \in \mathbb{R}$, $|f(x)| \leq M$. Soit $\varepsilon > 0$ fixé. La difficulté réside dans le fait que f n'est a priori pas uniformément continue. Cependant, on peut restreindre le problème à un compact. Puisque X est une vraie variable aléatoire (à valeurs réelles finies presque sûrement), il existe un compact $K = [-A, A]$ tel que $\mathbb{P}(X \notin K) < \frac{\varepsilon}{6M}$. La fonction f étant continue sur $\mathbb{R}$, elle est uniformément continue sur le compact $[-A-1, A+1]$ (théorème de Heine). Donc il existe $\delta > 0$ (avec $\delta < 1$) tel que pour tous $x, y \in [-A-1, A+1]$, si $|x-y| < \delta$, alors $|f(x) - f(y)| < \frac{\varepsilon}{3}$. Nous évaluons l'écart en espérance :

$$|\mathbb{E}[f(X_n)] - \mathbb{E}[f(X)]| \leq \mathbb{E}[|f(X_n) - f(X)|]$$

Décomposons l'espace Ω en fonction de deux critères : l'écart entre X_n et X, et la position de X. Considérons l'événement $E_n = \{|X_n - X| < \delta\}$ et l'événement $C = \{X \in K\}$. Nous découpons l'intégrale (l'espérance) en trois parties :

$$\mathbb{E}[|f(X_n)-f(X)|] = \mathbb{E}[|f(X_n)-f(X)|\cdot\mathbb{I}_{E_n\cap C}]+\mathbb{E}[|f(X_n)-f(X)|\cdot\mathbb{I}_{E_n^c}]+\mathbb{E}[|f(X_n)-f(X)|\cdot\mathbb{I}_{E_n\cap C^c}]$$

1. Sur $E_n \cap C$, on a $X \in K$ donc $|X| \leq A$. Puisque $|X_n - X| < \delta < 1$, on a $|X_n| \leq A + 1$. Ainsi, X et X_n sont dans le compact $[-A-1, A+1]$ et sont distants de moins de δ. Par continuité uniforme, $|f(X_n) - f(X)| < \frac{\varepsilon}{3}$. L'espérance sur cette partie est majorée par $\frac{\varepsilon}{3}\mathbb{P}(E_n \cap C) \leq \frac{\varepsilon}{3}$. 2. Sur E_n^c, $|X_n - X| \geq \delta$. L'écart $|f(X_n) - f(X)|$ est brutalement majoré par $2M$. L'espérance sur cette partie est majorée par $2M\mathbb{P}(|X_n - X| \geq \delta)$. Puisque $X_n \xrightarrow{\mathbb{P}} X$, il existe un rang N tel que pour tout $n \geq N$, $\mathbb{P}(|X_n - X| \geq \delta) < \frac{\varepsilon}{6M}$. Donc pour $n \geq N$, cette partie est majorée par $2M\frac{\varepsilon}{6M} = \frac{\varepsilon}{3}$. 3. Sur C^c, on a $X \notin K$. L'écart est à nouveau majoré par $2M$. L'espérance est majorée par $2M\mathbb{P}(X \notin K)$. Par choix de K, ceci est strictement inférieur à $2M\frac{\varepsilon}{6M} = \frac{\varepsilon}{3}$.

En additionnant ces trois majorations pour $n \geq N$:

$$|\mathbb{E}[f(X_n)] - \mathbb{E}[f(X)]| < \frac{\varepsilon}{3} + \frac{\varepsilon}{3} + \frac{\varepsilon}{3} = \varepsilon$$

Ceci étant vrai pour tout $\varepsilon > 0$, on a bien $\lim_{n\to+\infty} \mathbb{E}[f(X_n)] = \mathbb{E}[f(X)]$. La convergence en loi est démontrée. □

4 Applications en Physique, Logique et Intelligence Artificielle

4.1 Application en Physique Statistique

Dans l'étude des gaz, le théorème de limite centrale illustre comment une grandeur macroscopique comme la pression ou la température émerge d'un ensemble astronomique de collisions microscopiques indépendantes. La vitesse d'une particule au hasard suit une distribution complexe, mais la vitesse moyenne de 10^{23} particules converge en loi vers une distribution gaussienne (Maxwell-Boltzmann). C'est la convergence en loi qui fonde la thermodynamique, car on ne regarde plus les trajectoires individuelles (presque sûres) qui sont chaotiques, mais la statistique stabilisée du système.

4.2 Application en Logique

En théorie des modèles aléatoires, la loi du zéro-un (qui repose sur des événements limites de probabilité 0 ou 1) utilise les modes de convergence forte. Une propriété logique du premier ordre

exprimée sur un graphe aléatoire de taille n (par exemple "le graphe contient un triangle") aura une probabilité de vérité qui converge, lorsque $n \to \infty$, soit vers 0, soit vers 1. La convergence presque sûre traduit alors une certitude sémantique à la limite asymptotique.

4.3 Application en Intelligence Artificielle (Deep Learning)

En apprentissage automatique, un modèle (réseau de neurones) est entraîné via l'algorithme de Descente de Gradient Stochastique (SGD). Les poids du réseau W_n à l'étape n sont des variables aléatoires. L'objectif est que W_n converge vers les poids optimaux W^*. - Si le taux d'apprentissage η est constant, on montre que W_n ne converge pas presque sûrement ni en probabilité, mais converge en loi vers une distribution stationnaire autour de W^* (le bruit stochastique empêche une immobilisation parfaite). - Si on décroît le taux d'apprentissage (ex : $\eta_n = \frac{1}{n}$), alors l'algorithme vérifie les conditions de Robbins-Monro, et $W_n \xrightarrow{p.s.} W^*$. Cette convergence forte garantit (théoriquement) la consistance de l'apprentissage sur un temps infini, assurant que l'intelligence artificielle a effectivement appris le concept cible sans ambiguïté résiduelle.

Deuxième partie

Exercices d'Application et de Concours

Exercice 1 : Convergence d'une variable déterministe par morceaux ★⋆⋆⋆⋆

Soit $(X_n)_{n\geq 1}$ une suite de variables aléatoires définie par $\mathbb{P}(X_n = 1/n) = 1$. 1. Étudier la convergence de X_n en probabilité. 2. Étudier la convergence de X_n presque sûre.

Correction : 1. Soit $\varepsilon > 0$. Pour $n > 1/\varepsilon$, nous avons $1/n < \varepsilon$, ce qui implique $|X_n| < \varepsilon$ presque sûrement. Par conséquent, $\mathbb{P}(|X_n| > \varepsilon) = 0$ pour tout $n > 1/\varepsilon$. Ainsi, $\lim_{n\to\infty} \mathbb{P}(|X_n| > \varepsilon) = 0$. La suite X_n converge en probabilité vers la constante 0. 2. Par définition, l'événement $\{\omega \in \Omega \mid \lim_{n\to\infty} X_n(\omega) = 0\}$ est de probabilité 1, car $X_n = 1/n$ est une suite numérique déterministe qui converge vers 0. Donc X_n converge presque sûrement vers 0.

Exercice 2 : La masse qui fuit à l'infini ★⋆⋆⋆⋆

Soit X_n une suite de variables aléatoires de loi de probabilité donnée par : $\mathbb{P}(X_n = n) = \frac{1}{n^2}$ et $\mathbb{P}(X_n = 0) = 1 - \frac{1}{n^2}$. 1. Montrer que X_n converge en probabilité vers 0. 2. Étudier la convergence dans L^1. 3. Étudier la convergence presque sûre.

Correction : 1. Soit $\varepsilon \in]0, 1[$. Pour $n \geq 1$, $\mathbb{P}(|X_n - 0| > \varepsilon) = \mathbb{P}(X_n = n) = \frac{1}{n^2}$. Comme $\lim_{n\to\infty} \frac{1}{n^2} = 0$, X_n converge en probabilité vers 0. 2. Évaluons l'espérance de $|X_n|$: $\mathbb{E}[|X_n|] = n \times \mathbb{P}(X_n = n) + 0 = n \times \frac{1}{n^2} = \frac{1}{n}$. Comme $\lim_{n\to\infty} \mathbb{E}[|X_n|] = \lim_{n\to\infty} \frac{1}{n} = 0$, la suite X_n converge dans L^1 vers 0. 3. Pour la convergence presque sûre, posons $A_n = \{X_n = n\}$. Nous avons $\sum_{n=1}^{\infty} \mathbb{P}(A_n) = \sum_{n=1}^{\infty} \frac{1}{n^2} < \infty$. Par le lemme de Borel-Cantelli, la probabilité que les événements A_n se réalisent une infinité de fois est nulle : $\mathbb{P}(\limsup A_n) = 0$. Donc, avec probabilité 1, $X_n = 0$ pour un rang assez grand, ce qui implique $X_n \to 0$. X_n converge presque sûrement vers 0.

Exercice 3 : Convergence en probabilité n'implique pas presque sûre ★★⋆⋆⋆

On se place sur l'espace $\Omega = [0, 1[$, muni de la tribu borélienne et de la mesure de Lebesgue λ. On définit les variables $X_{n,k} = \mathbf{1}_{[\frac{k}{n}, \frac{k+1}{n}[}$ pour $n \geq 1$ et $0 \leq k < n$. Soit Y_m la suite obtenue en énumérant les $X_{n,k}$ dans l'ordre lexicographique. 1. Montrer que $Y_m \xrightarrow{\mathbb{P}} 0$. 2. Montrer que Y_m ne converge presque sûrement pour aucun $\omega \in \Omega$.

Correction : 1. Soit $\varepsilon \in]0, 1[$. L'événement $\{Y_m > \varepsilon\}$ est exactement le support de l'indicatrice $X_{n,k}$ correspondante. La probabilité (qui est la mesure de Lebesgue) est $\frac{1}{n}$. Lorsque $m \to \infty$, l'indice n associé tend aussi vers ∞. Donc $\mathbb{P}(Y_m > \varepsilon) = \frac{1}{n} \to 0$. Ainsi, $Y_m \xrightarrow{\mathbb{P}} 0$. 2. Pour tout $\omega \in [0, 1[$, fixons-le. Pour chaque niveau n, il existe un unique $k \in \{0, \ldots, n-1\}$ tel que $\omega \in [\frac{k}{n}, \frac{k+1}{n}[$. Pour ce k, on a $X_{n,k}(\omega) = 1$. Pour les autres, $X_{n,j}(\omega) = 0$. Donc, dans la suite numérique $(Y_m(\omega))_{m\geq 1}$, la valeur 1 apparaît une infinité de fois, et la valeur 0 apparaît une infinité de fois. La suite ne converge pas pour ω. Puisque ceci est vrai pour tout $\omega \in \Omega$, il n'y a pas convergence presque sûre vers 0 (ni vers aucune limite).

Exercice 4 : Stabilité par composition continue ★★⋆⋆

Soit X_n une suite de variables aléatoires et X une variable aléatoire telles que $X_n \xrightarrow{\mathbb{P}} X$. Soit $g : \mathbb{R} \to \mathbb{R}$ une fonction uniformément continue. Montrer que $g(X_n) \xrightarrow{\mathbb{P}} g(X)$.

Correction : Soit $\varepsilon > 0$. Puisque g est uniformément continue sur $\mathbb{R}$, il existe $\delta > 0$ tel que pour tout $x, y \in \mathbb{R}$, $|x - y| < \delta \implies |g(x) - g(y)| < \varepsilon$. Par contraposée, $|g(x) - g(y)| \geq \varepsilon \implies |x - y| \geq \delta$. Si on applique cela aux variables aléatoires, l'événement $\{|g(X_n) - g(X)| \geq \varepsilon\}$ est inclus dans l'événement $\{|X_n - X| \geq \delta\}$. Par conséquent, en termes de probabilités : $\mathbb{P}(|g(X_n) - g(X)| \geq \varepsilon) \leq \mathbb{P}(|X_n - X| \geq \delta)$. Par hypothèse, $X_n \xrightarrow{\mathbb{P}} X$, donc pour tout $\delta > 0$, on a $\lim_{n\to\infty} \mathbb{P}(|X_n - X| \geq \delta) = 0$. Il en découle immédiatement par le théorème des gendarmes que $\lim_{n\to\infty} \mathbb{P}(|g(X_n) - g(X)| \geq \varepsilon) = 0$. La suite $g(X_n)$ converge donc en probabilité vers $g(X)$.

Exercice 5 : Somme de variables convergentes ★★★⋆⋆

Montrer que si $X_n \xrightarrow{\mathbb{P}} X$ et $Y_n \xrightarrow{\mathbb{P}} Y$, alors $X_n + Y_n \xrightarrow{\mathbb{P}} X + Y$.

Correction : Soit $\varepsilon > 0$. Nous cherchons à évaluer $\mathbb{P}(|(X_n + Y_n) - (X + Y)| > \varepsilon)$. D'après l'inégalité triangulaire : $|(X_n+Y_n)-(X+Y)| = |(X_n-X)+(Y_n-Y)| \leq |X_n-X|+|Y_n-Y|$. Ainsi, si la somme $|X_n-X|+|Y_n-Y|$ est strictement supérieure à ε, alors l'un au moins des deux termes doit être strictement supérieur à $\varepsilon/2$. Ceci se traduit par l'inclusion d'événements suivante : $\{|(X_n+Y_n)-(X+Y)| > \varepsilon\} \subset \{|X_n-X| > \varepsilon/2\} \cup \{|Y_n-Y| > \varepsilon/2\}$. En utilisant la sous-additivité des probabilités : $\mathbb{P}(|(X_n+Y_n)-(X+Y)| > \varepsilon) \leq \mathbb{P}(|X_n-X| > \varepsilon/2)+\mathbb{P}(|Y_n-Y| > \varepsilon/2)$. Puisque $X_n \xrightarrow{\mathbb{P}} X$ et $Y_n \xrightarrow{\mathbb{P}} Y$, on a : $\lim_{n\to\infty} \mathbb{P}(|X_n - X| > \varepsilon/2) = 0$ et $\lim_{n\to\infty} \mathbb{P}(|Y_n - Y| > \varepsilon/2) = 0$. Par somme de limites, le membre de droite tend vers 0, ce qui conclut la preuve par le théorème des gendarmes. $X_n + Y_n \xrightarrow{\mathbb{P}} X + Y$.

Exercice 6 : Convergence en loi d'un maximum ★★★⋆⋆

Soit $(X_i)_{1\leq i\leq n}$ des variables aléatoires indépendantes et identiquement distribuées selon la loi uniforme sur $[0, \theta]$. Soit $M_n = \max(X_1, X_2, \ldots, X_n)$. Montrer que $n(\theta - M_n)$ converge en loi vers une variable exponentielle que l'on précisera.

Correction : Exprimons la fonction de répartition de M_n. Pour tout $x \in [0, \theta]$: $F_{M_n}(x) = \mathbb{P}(M_n \leq x) = \mathbb{P}(X_1 \leq x, \ldots, X_n \leq x) = \mathbb{P}(X_1 \leq x)^n = \left(\frac{x}{\theta}\right)^n$. Soit $Y_n = n(\theta - M_n)$. Calculons sa fonction de répartition $F_{Y_n}(y)$ pour un $y \geq 0$. $F_{Y_n}(y) = \mathbb{P}(Y_n \leq y) = \mathbb{P}(n(\theta - M_n) \leq y) = \mathbb{P}\left(M_n \geq \theta - \frac{y}{n}\right) = 1 - \mathbb{P}\left(M_n < \theta - \frac{y}{n}\right)$. Pour n suffisamment grand (dès que $\frac{y}{n} < \theta$), nous avons : $F_{Y_n}(y) = 1 - \left(\frac{\theta - y/n}{\theta}\right)^n = 1 - \left(1 - \frac{y/\theta}{n}\right)^n$. Un résultat classique d'analyse garantit que la suite numérique $(1 - \frac{z}{n})^n$ converge vers e^{-z}. En l'appliquant avec $z = \frac{y}{\theta}$, nous obtenons : $\lim_{n\to\infty} F_{Y_n}(y) = 1 - e^{-y/\theta}$. Cette limite est la fonction de répartition de la loi exponentielle de paramètre $\lambda = \frac{1}{\theta}$. Puisque la fonction de répartition limite est continue partout, la convergence en loi est établie vers la distribution $\mathcal{E}(1/\theta)$.

Exercice 7 : Convergence du produit par Slutsky ★★★★⋆

Soit X_n une suite convergeant en loi vers X, et Y_n une suite convergeant en probabilité vers une constante c. Montrer rigoureusement le théorème de Slutsky pour le produit : $X_n Y_n \xrightarrow{\mathcal{L}} cX$.

Correction : La preuve générale est technique. Il est possible de l'établir à l'aide des fonctions caractéristiques, mais nous procéderons par une méthode directe avec les fonctions

bornées continues uniformément. Soit $f : \mathbb{R} \to \mathbb{R}$ bornée par M et Lipschitzienne de constante K (la convergence sur ces fonctions suffit pour la convergence en loi, lemme de Portmanteau). $\mathbb{E}[f(X_nY_n)] - \mathbb{E}[f(cX)] = (\mathbb{E}[f(X_nY_n)] - \mathbb{E}[f(cX_n)]) + (\mathbb{E}[f(cX_n)] - \mathbb{E}[f(cX)])$. Le second terme tend vers 0. En effet, $X_n \xrightarrow{\mathcal{L}} X \implies cX_n \xrightarrow{\mathcal{L}} cX$. Soit $h(x) = f(cx)$, h est continue bornée, donc $\mathbb{E}[h(X_n)] \to \mathbb{E}[h(X)]$. Il reste le premier terme, noté E_n. Soit $\varepsilon > 0$. $|f(X_nY_n) - f(cX_n)| \leq \min(2M, K|X_n||Y_n - c|)$. Fixons un compact $A = [-R, R]$ tel que $\mathbb{P}(|X| > R) < \varepsilon/(8M)$. Par la convergence en loi (Portmanteau sur les ouverts), pour n grand, $\mathbb{P}(|X_n| > R) < \varepsilon/(4M)$. Découpons l'espace Ω : - Sur $\{|X_n| \leq R\} \cap \{|Y_n - c| \leq \delta\}$, l'écart est $\leq K \cdot R \cdot \delta$. En choisissant $\delta = \frac{\varepsilon}{2KR}$, l'écart est $\leq \varepsilon/2$. - Sur l'événement contraire, on le majore brutalement par $2M$. L'espérance du premier terme se majore par : $\varepsilon/2 + 2M \cdot [\mathbb{P}(|X_n| > R) + \mathbb{P}(|Y_n - c| > \delta)]$. Par hypothèse $Y_n \xrightarrow{\mathbb{P}} c$, donc $\mathbb{P}(|Y_n - c| > \delta) \to 0$. Pour n grand, cette somme est $\leq \varepsilon/2 + 2M(\varepsilon/(4M) + \varepsilon/(4M)) = \varepsilon/2 + \varepsilon = \frac{3\varepsilon}{2}$. Ainsi, $\lim_{n\to\infty} |\mathbb{E}[f(X_nY_n)] - \mathbb{E}[f(cX_n)]| = 0$. D'où $X_nY_n \xrightarrow{\mathcal{L}} cX$.

Exercice 8 : La méthode Delta ★★★★⋆

Soit (X_n) une suite de variables aléatoires telle que $\sqrt{n}(X_n - \mu) \xrightarrow{\mathcal{L}} \mathcal{N}(0, \sigma^2)$. Soit $g : \mathbb{R} \to \mathbb{R}$ une fonction dérivable en μ avec $g'(\mu) \neq 0$. Montrer que $\sqrt{n}(g(X_n) - g(\mu)) \xrightarrow{\mathcal{L}} \mathcal{N}(0, (g'(\mu)\sigma)^2)$.

Correction : La dérivabilité de g en μ permet d'écrire le développement limité d'ordre 1 : $g(x) = g(\mu) + (x - \mu)g'(\mu) + (x - \mu)\varepsilon(x - \mu)$, où $\lim_{x\to\mu} \varepsilon(x - \mu) = 0$. En substituant la variable aléatoire X_n à x, on obtient : $g(X_n) - g(\mu) = (X_n - \mu)g'(\mu) + (X_n - \mu)\varepsilon(X_n - \mu)$. Multiplions l'équation par $\sqrt{n}$: $\sqrt{n}(g(X_n) - g(\mu)) = \sqrt{n}(X_n - \mu)g'(\mu) + \sqrt{n}(X_n - \mu)\varepsilon(X_n - \mu)$. Par hypothèse, le terme $\sqrt{n}(X_n - \mu)$ converge en loi vers $Z \sim \mathcal{N}(0, \sigma^2)$. La constante $g'(\mu)$ multipliant Z donne une convergence en loi du premier terme vers $g'(\mu)Z \sim \mathcal{N}(0, (g'(\mu)\sigma)^2)$. Il reste à montrer que le second terme tend vers 0 en probabilité. Puisque $\sqrt{n}(X_n - \mu) \xrightarrow{\mathcal{L}} Z$, la suite est tendue (uniformément bornée en probabilité, $O_P(1)$). De plus, la convergence en loi vers une limite fixe finie implique que $X_n \xrightarrow{\mathbb{P}} \mu$. Par continuité de ε, $\varepsilon(X_n - \mu) \xrightarrow{\mathbb{P}} 0$ ($o_P(1)$). Le produit d'un terme $O_P(1)$ par un terme $o_P(1)$ converge en probabilité vers 0 (Slutsky). Ainsi, le second terme disparaît à la limite, et la convergence finale est assurée.

Exercice 9 : Théorème de représentation de Skorokhod ★★★★★

On suppose que des variables aléatoires réelles X_n convergent en loi vers X. Énoncer le théorème de représentation de Skorokhod et l'utiliser pour prouver le Continuous Mapping Theorem (Si $X_n \xrightarrow{\mathcal{L}} X$ et g continue, alors $g(X_n) \xrightarrow{\mathcal{L}} g(X)$).

Correction : Le théorème de représentation de Skorokhod affirme que si $X_n \xrightarrow{\mathcal{L}} X$, alors il existe un espace probabilisé unifié $(\Omega, \mathcal{F}, \mathbb{P})$ et des variables aléatoires Y_n, Y définies sur cet espace, telles que : 1. Y_n a la même loi que X_n pour tout n. 2. Y a la même loi que X. 3. $Y_n \xrightarrow{p.s.} Y$. Prouvons le Continuous Mapping Theorem avec ce puissant outil. Soit $g : \mathbb{R} \to \mathbb{R}$ une fonction continue. Puisque $Y_n \xrightarrow{p.s.} Y$, pour presque tout $\omega \in \Omega$, la limite de la suite $Y_n(\omega)$ est $Y(\omega)$. Par continuité numérique usuelle de la fonction g, nous avons pour ces mêmes ω : $\lim_{n\to\infty} g(Y_n(\omega)) = g(Y(\omega))$. Cela signifie précisément que $g(Y_n) \xrightarrow{p.s.} g(Y)$. D'après la hiérarchie des convergences, la convergence presque sûre implique la convergence en probabilité, qui elle-même implique la convergence en loi. Donc $g(Y_n) \xrightarrow{\mathcal{L}} g(Y)$. Enfin, puisque $Y_n \sim X_n$, alors par substitution stricte des lois, $g(Y_n) \sim g(X_n)$. De même, $g(Y) \sim g(X)$. Il en découle

trivialement que $g(X_n) \xrightarrow{\mathcal{L}} g(X)$. Le théorème de continuité (Continuous Mapping Theorem) est démontré.

Exercice 10 : Convergence L^p et intégrabilité uniforme ★★★★★

Soit $X_n \xrightarrow{\mathbb{P}} X$. Montrer que $X_n \xrightarrow{L^p} X$ si et seulement si la suite $(|X_n|^p)$ est uniformément intégrable. Définition : Une famille (Y_n) est uniformément intégrable si $\lim_{K\to\infty} \sup_n \mathbb{E}[|Y_n|\mathbf{1}_{|Y_n|>K}] = 0$.

Correction : Ce résultat, connu sous le nom de théorème de convergence de Vitali, généralise le théorème de convergence dominée de Lebesgue. ($\Rightarrow$) Supposons que $X_n \xrightarrow{L^p} X$. Posons $Z_n = |X_n|^p$. On a $\lim_n \mathbb{E}[|X_n - X|^p] = 0$. L'inégalité de Minkowski montre que $\mathbb{E}[Z_n] \to \mathbb{E}[|X|^p]$. La convergence dans L^p pour L^1 des $|X_n|^p$ implique leur intégrabilité uniforme selon un résultat fondamental d'analyse. ($\Leftarrow$) Supposons $X_n \xrightarrow{\mathbb{P}} X$ et que $|X_n|^p$ est uniformément intégrable. Pour $R > 0$, considérons la fonction de troncature $T_R(x) = \max(-R, \min(x, R))$. La fonction est bornée et continue. On a $|X_n - X|^p \leq 2^{p-1}(|X_n|^p + |X|^p)$. L'intégrabilité uniforme de la somme de séquences uniformément intégrables garantit que $|X_n - X|^p$ est uniformément intégrable. On décompose l'espérance : $\mathbb{E}[|X_n - X|^p] = \mathbb{E}[|X_n - X|^p \mathbf{1}_{|X_n - X| \leq \delta}] + \mathbb{E}[|X_n - X|^p \mathbf{1}_{|X_n - X| > \delta, |X_n - X| \leq M}] + \mathbb{E}[|X_n - X|^p \mathbf{1}_{|X_n - X| > M}]$. - Le premier terme est majoré par δ^p. - Le deuxième terme est majoré par $M^p \mathbb{P}(|X_n - X| > \delta)$, qui tend vers 0 par convergence en probabilité. - Le troisième terme est contrôlé indépendamment de n et de δ en choisissant M grand, grâce à l'intégrabilité uniforme, il peut être rendu $< \varepsilon$. On a donc $\limsup \mathbb{E}[|X_n - X|^p] \leq \delta^p + \varepsilon$. En faisant tendre $\delta \to 0$ puis $\varepsilon \to 0$, on obtient bien la convergence L^p.

Troisième partie

Travaux Pratiques et Simulations Algorithmiques

TP 1 : Simulation de la loi faible des grands nombres (Convergence en Probabilité)

L'objectif est d'illustrer la convergence en probabilité de la moyenne empirique vers l'espérance théorique en simulant des tirages de pièces.

```python
import random

def simulate_coin_flips(n):
    return sum(random.randint(0, 1) for _ in range(n)) / n

def probability_convergence(num_trials, n, epsilon):
    count_outside = 0
    for _ in range(num_trials):
        mean = simulate_coin_flips(n)
        if abs(mean - 0.5) > epsilon:
            count_outside += 1
    return count_outside / num_trials

# Test
trials = 1000
epsilon = 0.05
for n in [10, 100, 1000, 5000]:
    prob = probability_convergence(trials, n, epsilon)
    print("n =", n, "-> Probabilite empirique d'ecart >", epsilon, ":",
        prob)
    if n == 5000:
        assert prob < 0.05, "La probabilite devrait etre tres faible
            pour grand n"
```

TP 2 : Convergence Presque Sûre (Trajectoires)

On trace ici des trajectoires individuelles pour observer la convergence presque sûre. On simule $X_n = Y/n$ où Y est uniforme. On s'attend à ce que toutes les trajectoires convergent vers 0.

```python
import random

def generate_trajectory(n_steps):
    y = random.uniform(0, 10)
    return [y / n for n in range(1, n_steps + 1)]

def check_trajectory_convergence(trajectory, threshold, N_tail):
    # Verifie si la fin de la trajectoire reste sous le seuil
    tail = trajectory[-N_tail:]
    return all(val < threshold for val in tail)

# Simulation
```

```
num_trajectories = 100
n_steps = 1000
threshold = 0.05
N_tail = 100

converged_count = 0
for _ in range(num_trajectories):
    traj = generate_trajectory(n_steps)
    if check_trajectory_convergence(traj, threshold, N_tail):
        converged_count += 1

print("Nombre de trajectoires convergentes sur", num_trajectories, ":", converged_count)
assert converged_count == num_trajectories, "Presque surement, toutes devraient converger."
```

TP 3 : Convergence dans L2 (Moyenne quadratique)

Ce TP simule l'erreur quadratique moyenne d'un estimateur convergent dans L^2. On génère X_n uniforme sur $[0, 1/n]$ et on calcule empiriquement $E[X_n^2]$.

```
import random

def expected_squared_error(n, num_samples):
    squared_errors = []
    for _ in range(num_samples):
        xn = random.uniform(0, 1 / n)
        squared_errors.append(xn * xn)
    return sum(squared_errors) / num_samples

# Calcul
num_samples = 10000
for n in [1, 5, 10, 50, 100]:
    mse = expected_squared_error(n, num_samples)
    theoretical = 1 / (3 * n * n)
    print("n =", n, "-> MSE empirique:", mse, " / MSE theorique:", theoretical)
    assert abs(mse - theoretical) < 0.01, "L'erreur empirique doit etre proche de la theorie"
```

TP 4 : Convergence en Loi (Théorème Central Limite)

On montre que la somme centrée et réduite de variables uniformes approche une distribution dont on mesure l'écart à la loi normale via les moments empiriques.

```
import random
import math

def generate_clt_sample(n):
    # Uniforme sur [-0.5, 0.5], variance = 1/12
    s = sum(random.uniform(-0.5, 0.5) for _ in range(n))
    variance_n = n * (1/12)
```

```
    return s / math.sqrt(variance_n)

def empirical_moments(n, num_samples):
    samples = [generate_clt_sample(n) for _ in range(num_samples)]
    mean = sum(samples) / num_samples
    variance = sum((x - mean)**2 for x in samples) / num_samples
    # Moment d'ordre 4 pour verifier le kurtosis (3 pour une normale)
    m4 = sum((x - mean)**4 for x in samples) / num_samples
    return mean, variance, m4

# Test
n = 100
num_samples = 50000
mean, var, m4 = empirical_moments(n, num_samples)
print("Moyenne empirique (attendu ~0) :", mean)
print("Variance empirique (attendu ~1) :", var)
print("Moment d'ordre 4 (attendu ~3) :", m4)

assert abs(mean) < 0.05, "La moyenne doit etre proche de 0"
assert abs(var - 1) < 0.05, "La variance doit etre proche de 1"
assert abs(m4 - 3) < 0.2, "Le moment d'ordre 4 doit etre proche de 3 (kurtosis gaussien)"
```

TP 5 : Illustration de la méthode Delta

On étudie la variable $g(X_n)$ où X_n est la moyenne empirique d'une loi exponentielle, et $g(x) = x^2$. On vérifie la variance asymptotique modifiée par la dérivée.

```
import random
import math

def sample_mean_exp(n, lambda_param):
    # Loi exponentielle par inversion
    return sum(-math.log(1 - random.random()) / lambda_param for _ in range(n)) / n

def delta_method_simulation(n, lambda_param, num_samples):
    mu = 1 / lambda_param
    g_mu = mu ** 2

    samples = []
    for _ in range(num_samples):
        xn = sample_mean_exp(n, lambda_param)
        samples.append(math.sqrt(n) * (xn**2 - g_mu))

    empirical_var = sum(x**2 for x in samples) / num_samples
    # Variance asymptotique = (g'(mu) * sigma)^2 = (2*mu * mu)^2 = 4 * mu**4
    theoretical_var = 4 * (mu ** 4)
    return empirical_var, theoretical_var

# Execution
n = 500
lambda_p = 1.0
```

```
num_samples = 20000

emp_var, theo_var = delta_method_simulation(n, lambda_p, num_samples)
print("Variance empirique de l'estimateur transformee :", emp_var)
print("Variance theorique (Methode Delta) :", theo_var)

assert abs(emp_var - theo_var) < 0.5, "La variance observee doit
    correspondre a la methode Delta"
```