LOI FORTE DES GRANDS NOMBRES (LFGN)

Cours magistral, exercices corrigés et travaux pratiques

Charles EDOU NZE

18 octobre 2026

Table des matières

I Cours Magistral **2**

1 Introduction (Genèse et Intuition) **2**

2 Définitions, Théorèmes et Exemples **2**

3 Démonstrations **3**

4 Applications en Physique, Logique et IA **4**
4.1 Intégration de Monte-Carlo 4
4.2 Apprentissage Automatique et Validation Croisée 4
4.3 Entraînement par Batch (Stochastic Gradient Descent) 4

II Exercices d'Application et de Concours **5**

III Travaux Pratiques et Simulations Algorithmiques **11**

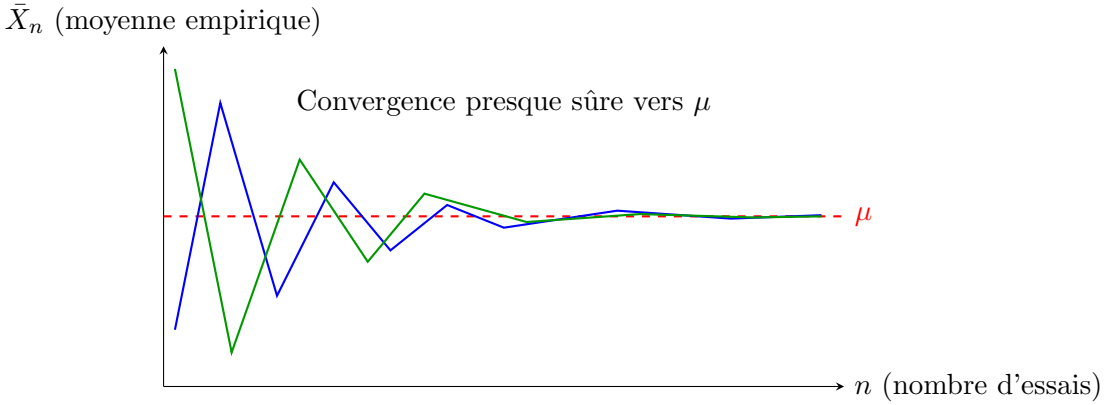
Première partie

Cours Magistral

Jalon 92 : Loi forte des grands nombres (LFGN)

1 Introduction (Genèse et Intuition)

Imaginons une pièce de monnaie truquée qui tombe sur "Pile" avec une probabilité de 1/3. Si on la lance trois fois, on pourrait très bien n'obtenir que des "Face". La fréquence observée serait de 0%. Cependant, si l'on répète l'expérience un grand nombre de fois, disons un million, la fréquence de "Pile" s'approchera inexorablement de 33.33%. La Loi forte des grands nombres (LFGN) est le théorème qui mathématise cette intuition : elle affirme que la moyenne empirique d'une suite de variables aléatoires indépendantes et identiquement distribuées converge, presque sûrement, vers leur espérance mathématique. C'est le fondement théorique qui légitime l'usage des statistiques en permettant d'estimer des probabilités inobservables à partir de fréquences observées empiriquement.



2 Définitions, Théorèmes et Exemples

Soit $(X_n)_{n\in\mathbb{N}^*}$ une suite de variables aléatoires réelles définies sur un même espace de probabilité $(\Omega, \mathcal{F}, P)$. On pose $S_n = \sum_{i=1}^{n} X_i$ et $\bar{X}_n = \frac{S_n}{n}$ la moyenne empirique des n premières variables.

Définition (Variables I.I.D.) On dit que la suite (X_n) est indépendante et identiquement distribuée (I.I.D.) si :

- Pour toute famille finie d'indices, les variables correspondantes sont mutuellement indépendantes.
- Toutes les variables X_n suivent la même loi de probabilité (et ont donc, si elles existent, même espérance et même variance).

Théorème (Loi Forte des Grands Nombres - Kolmogorov) Soit (X_n) une suite de variables aléatoires I.I.D. Si X_1 est intégrable (c'est-à-dire $\mathbb{E}[|X_1|] < \infty$), alors en posant $\mu = \mathbb{E}[X_1]$, la moyenne empirique $\bar{X}_n$ converge presque sûrement vers μ :

$$P\left(\lim_{n\to\infty} \bar{X}_n = \mu\right) = 1$$

Ce que l'on note aussi : $\bar{X}_n \xrightarrow{p.s.} \mu$.

Remarque : La loi forte (convergence presque sûre) implique la loi faible (convergence en probabilité étudiée au Jalon 91), mais l'inverse est faux. La LFGN affirme que l'ensemble des trajectoires $\omega \mapsto \bar{X}_n(\omega)$ qui ne convergent pas vers μ est de probabilité nulle.

Exemple Concret (Lancer de dé équilibré) Soit X_i le résultat du i-ème lancer d'un dé à 6 faces. Les variables (X_n) sont I.I.D. selon une loi uniforme sur $\{1, 2, 3, 4, 5, 6\}$. L'espérance est $\mu = \mathbb{E}[X_1] = \frac{1+2+3+4+5+6}{6} = 3.5$. La LFGN garantit que si on lance le dé une infinité de fois, la moyenne des résultats convergera, pour presque toutes les séquences de lancers, vers 3.5.

Cas Pathologique : Le piège de la loi de Cauchy Si (X_n) suit une loi de Cauchy de densité $f(x) = \frac{1}{\pi(1+x^2)}$, alors $\int_{-\infty}^{\infty} |x| f(x) dx$ diverge. Les variables n'admettent pas d'espérance. Dans ce cas, la moyenne empirique $\bar{X}_n$ ne converge pas. Au contraire, $\bar{X}_n$ suit elle-même la même loi de Cauchy que X_1 pour tout n, exhibant des variations sauvages (des valeurs extrêmes qui empêchent toute stabilisation) quelle que soit la taille de n.

3 Démonstrations

Nous démontrons ici une version légèrement plus faible du théorème, en supposant que les variables aléatoires possèdent un moment d'ordre 4 fini. Cette approche permet de mettre en lumière l'utilisation des inégalités de concentration et du lemme de Borel-Cantelli.

Théorème (Loi Forte sous hypothèse de moment d'ordre 4 fini) Soit (X_n) une suite de variables I.I.D. telles que $\mathbb{E}[X_1^4] < \infty$. Alors, $\bar{X}_n \xrightarrow{p.s.} \mathbb{E}[X_1]$.

Démonstration pas à pas : Quitte à considérer $Y_n = X_n - \mathbb{E}[X_1]$, on peut supposer sans perte de généralité que $\mathbb{E}[X_i] = 0$. On pose $\mu = 0$ et $S_n = \sum_{i=1}^n X_i$.

— *Calcul de* $\mathbb{E}[S_n^4]$ *:* On développe $S_n^4 = (\sum_{i=1}^n X_i)^4$. La somme contient n^4 termes de la forme $X_i X_j X_k X_l$. Par linéarité de l'espérance et par indépendance des X_i, l'espérance d'un produit est le produit des espérances. Comme $\mathbb{E}[X_i] = 0$, tout terme contenant une variable à la puissance 1 (par exemple $X_1^3 X_2$, $X_1^2 X_2 X_3$, etc.) aura une espérance nulle. Les seuls termes non nuls dans $\mathbb{E}[S_n^4]$ sont :

— Les termes de la forme X_i^4. Il y en a n, chacun d'espérance $\mathbb{E}[X_1^4]$.

— Les termes de la forme $X_i^2 X_j^2$ (avec $i \neq j$). Pour les choisir, on sélectionne 2 indices parmi n (soit $\frac{n(n-1)}{2}$ choix), et le coefficient multinomial associé est $\frac{4!}{2!2!} = 6$. Il y a donc $3n(n-1)$ tels termes, chacun d'espérance $\mathbb{E}[X_1^2 X_2^2] = \mathbb{E}[X_1^2]\mathbb{E}[X_2^2] = (\mathbb{E}[X_1^2])^2$. Ainsi :

$$\mathbb{E}[S_n^4] = n\mathbb{E}[X_1^4] + 3n(n-1)(\mathbb{E}[X_1^2])^2$$

Puisque $\mathbb{E}[X_1^4] < \infty$, $(\mathbb{E}[X_1^2])^2$ est également fini (par l'inégalité de Cauchy-Schwarz). On peut donc majorer par une constante $C > 0$:

$$\mathbb{E}[S_n^4] \leq Cn^2$$

— *Inégalité de concentration :* Fixons un écart $\epsilon > 0$. On cherche à borner la probabilité $P(|\bar{X}_n| \geq \epsilon)$.

$$P(|\bar{X}_n| \geq \epsilon) = P\left(\left|\frac{S_n}{n}\right| \geq \epsilon\right) = P(|S_n| \geq n\epsilon) = P(S_n^4 \geq n^4\epsilon^4)$$

Appliquons l'inégalité de Markov à la variable aléatoire positive S_n^4 :

$$P(S_n^4 \geq n^4\epsilon^4) \leq \frac{\mathbb{E}[S_n^4]}{n^4\epsilon^4} \leq \frac{Cn^2}{n^4\epsilon^4} = \frac{C}{\epsilon^4}\frac{1}{n^2}$$

— *Application du lemme de Borel-Cantelli :* Considérons la série des probabilités de ces événements.

$$\sum_{n=1}^{\infty} P(|\bar{X}_n| \geq \epsilon) \leq \sum_{n=1}^{\infty} \frac{C}{\epsilon^4 n^2}$$

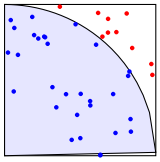
Comme la série de Riemann $\sum \frac{1}{n^2}$ est convergente, la série $\sum P(|\bar{X}_n| \geq \epsilon)$ converge. D'après le premier lemme de Borel-Cantelli, la probabilité que l'événement $\{|\bar{X}_n| \geq \epsilon\}$ se réalise une infinité de fois est nulle. Ainsi, presque sûrement, pour n assez grand, on a $|\bar{X}_n| < \epsilon$.

— *Conclusion :* L'événement "$\lim_{n\to\infty} \bar{X}_n = 0$" s'écrit $\bigcap_{k\in\mathbb{N}^*} \bigcup_{N\in\mathbb{N}} \bigcap_{n\geq N} \{|\bar{X}_n| < 1/k\}$. L'intersection dénombrable d'événements de probabilité 1 étant de probabilité 1, on conclut que $\bar{X}_n \xrightarrow{p.s.} 0$, soit $\bar{X}_n \xrightarrow{p.s.} \mu$.

4 Applications en Physique, Logique et IA

4.1 Intégration de Monte-Carlo

La méthode de Monte-Carlo repose entièrement sur la LFGN pour estimer des intégrales complexes en grande dimension. Soit f une fonction définie sur $[0,1]^d$. L'intégrale $I = \int_{[0,1]^d} f(x)dx$ peut être vue comme l'espérance $\mathbb{E}[f(U)]$ où U suit une loi uniforme sur $[0,1]^d$. En tirant $(U_1, \ldots, U_n)$ I.I.D. selon cette loi, la moyenne empirique $\frac{1}{n}\sum_{i=1}^{n} f(U_i)$ converge presque sûrement vers I. Cela permet d'estimer des aires ou des volumes de manière algorithmique.



Estimation de $\pi/4$ par Monte-Carlo

4.2 Apprentissage Automatique et Validation Croisée

Dans le modèle d'apprentissage PAC (Probably Approximately Correct), l'objectif est de minimiser le risque théorique (ou espérance de la perte sur toute la distribution des données). Ce risque étant inaccessible, on minimise à la place le risque empirique (la moyenne de la perte sur l'ensemble d'entraînement). La LFGN garantit que, pour un classifieur donné, le risque empirique converge vers le risque théorique lorsque la taille du jeu de données tend vers l'infini. C'est ce qui justifie l'évaluation des modèles par validation croisée.

4.3 Entraînement par Batch (Stochastic Gradient Descent)

Lors de l'entraînement des réseaux de neurones, le vrai gradient de la fonction de coût s'exprime comme une espérance sur toute la distribution des données. On l'estime sur un "batch" (lot) de taille B.

$$g_{batch} = \frac{1}{B}\sum_{i=1}^{B} \nabla_\theta L(f_\theta(x_i), y_i)$$

Par la LFGN, plus la taille du batch B est grande, plus g_{batch} converge presque sûrement vers le vrai gradient théorique. C'est le compromis fondamental entre la stochasticité (pour échapper aux minima locaux) et la précision du gradient (pour converger stablement).

Deuxième partie

Exercices d'Application et de Concours

Exercice 1 : Convergence presque sûre d'une suite de Bernoulli ★⋆⋆⋆⋆

Soit $(X_n)_{n\in\mathbb{N}^*}$ une suite de variables aléatoires indépendantes et identiquement distribuées suivant une loi de Bernoulli de paramètre $p \in]0,1[$. On note $S_n = \sum_{i=1}^n X_i$.

— Rappeler l'espérance et la variance de X_1.

— Énoncer la loi forte des grands nombres pour cette suite.

— Déterminer la limite presque sûre de la suite de variables aléatoires $Y_n = \frac{1}{n}S_n(1 - \frac{1}{n}S_n)$.

Correction :

— Comme $X_1 \sim \mathcal{B}(p)$, par définition, $\mathbb{E}[X_1] = p \times 1 + (1-p) \times 0 = p$. La variance est $\mathrm{Var}(X_1) = \mathbb{E}[X_1^2] - (\mathbb{E}[X_1])^2$. Or $X_1^2 = X_1$ car $X_1 \in \{0,1\}$, donc $\mathbb{E}[X_1^2] = p$. Ainsi, $\mathrm{Var}(X_1) = p - p^2 = p(1-p)$.

— La suite (X_n) est constituée de variables I.I.D. admettant une espérance finie $\mathbb{E}[X_1] = p$. D'après la loi forte des grands nombres (Théorème de Kolmogorov), la moyenne empirique $\frac{S_n}{n} = \frac{1}{n}\sum_{i=1}^n X_i$ converge presque sûrement vers $\mathbb{E}[X_1] = p$. C'est-à-dire : $\mathbb{P}(\lim_{n\to\infty} \frac{S_n}{n} = p) = 1$.

— Posons $g(x) = x(1-x)$. La fonction g est continue sur $\mathbb{R}$. Par composition de limites presque sûres (la continuité préservant la convergence presque sûre), puisque $\frac{S_n}{n} \xrightarrow{p.s.} p$, on a $g(\frac{S_n}{n}) \xrightarrow{p.s.} g(p)$. Ainsi, la suite $Y_n = \frac{S_n}{n}(1 - \frac{S_n}{n})$ converge presque sûrement vers $p(1-p)$, qui est la variance de la loi de Bernoulli.

Exercice 2 : Moyenne empirique des lois de Poisson ★★⋆⋆⋆

Soit $(X_n)_{n\geq 1}$ une suite de variables aléatoires I.I.D. suivant une loi de Poisson de paramètre $\lambda > 0$. On pose $\bar{X}_n = \frac{1}{n}\sum_{i=1}^n X_i$.

— Quelle est la loi de la somme $S_n = \sum_{i=1}^n X_i$?

— Montrer que $\bar{X}_n \xrightarrow{p.s.} \lambda$.

— Montrer que $\frac{1}{n}\sum_{i=1}^n X_i^2$ converge presque sûrement vers une limite à préciser.

Correction :

— La somme de variables aléatoires indépendantes de lois de Poisson de paramètres respectifs λ_i suit une loi de Poisson de paramètre $\sum \lambda_i$. Ici, les X_i sont I.I.D. de loi $\mathcal{P}(\lambda)$. Par conséquent, $S_n = \sum_{i=1}^n X_i$ suit une loi de Poisson de paramètre $n\lambda$.

— La suite (X_n) est I.I.D. et admet une espérance $\mathbb{E}[X_1] = \lambda < \infty$. La loi forte des grands nombres stipule que la moyenne empirique converge presque sûrement vers l'espérance de la loi. Donc, $\bar{X}_n = \frac{1}{n}S_n \xrightarrow{p.s.} \mathbb{E}[X_1] = \lambda$.

— Considérons la suite de variables aléatoires $Y_i = X_i^2$. Puisque les X_i sont I.I.D., les variables Y_i le sont également par le lemme des coalitions. Calculons l'espérance de Y_1 : $\mathbb{E}[Y_1] = \mathbb{E}[X_1^2]$. On sait que la variance d'une loi de Poisson de paramètre λ est λ. Or $\mathrm{Var}(X_1) = \mathbb{E}[X_1^2] - (\mathbb{E}[X_1])^2$, d'où $\lambda = \mathbb{E}[X_1^2] - \lambda^2$. Ainsi, $\mathbb{E}[Y_1] = \mathbb{E}[X_1^2] = \lambda + \lambda^2$. Cette espérance est finie. D'après la loi forte des grands nombres appliquée à la suite I.I.D. (Y_n), on a $\frac{1}{n}\sum_{i=1}^n Y_i \xrightarrow{p.s.} \mathbb{E}[Y_1]$. Par conséquent, $\frac{1}{n}\sum_{i=1}^n X_i^2 \xrightarrow{p.s.} \lambda + \lambda^2$.

Exercice 3 : Estimation d'un moment d'ordre supérieur ★★⋆⋆⋆

Soit $(X_n)_{n\geq 1}$ une suite de variables I.I.D. suivant la loi uniforme sur l'intervalle $[0,1]$.

— Calculer $\mathbb{E}[X_1^k]$ pour tout entier $k \geq 1$.

— Soit $M_n^{(k)} = \frac{1}{n}\sum_{i=1}^n X_i^k$. Étudier la convergence de la suite $(M_n^{(k)})_{n\geq 1}$.

— En déduire une méthode d'estimation presque sûre du paramètre k si celui-ci est inconnu mais que l'on observe la suite X_i.

Correction :

— La variable X_1 suit une loi uniforme $\mathcal{U}([0,1])$, dont la densité est $f(x) = 1$ si $x \in [0,1]$ et 0 sinon. Par le théorème de transfert, pour tout $k \geq 1$, on a :

$$\mathbb{E}[X_1^k] = \int_{\mathbb{R}} x^k f(x)dx = \int_0^1 x^k \cdot 1dx = \left[\frac{x^{k+1}}{k+1}\right]_0^1 = \frac{1}{k+1}$$

— Fixons l'entier $k \geq 1$. Considérons la suite de variables aléatoires $Z_i = X_i^k$. Les variables X_i étant I.I.D., les variables Z_i sont également I.I.D. Leur espérance est $\mathbb{E}[Z_1] = \mathbb{E}[X_1^k] = \frac{1}{k+1}$. Comme X_i prend ses valeurs dans $[0,1]$, Z_i est bornée entre 0 et 1, donc son espérance est bien finie. D'après la loi forte des grands nombres de Kolmogorov appliquée à la suite (Z_n), la moyenne empirique converge presque sûrement vers l'espérance :

$$M_n^{(k)} = \frac{1}{n}\sum_{i=1}^n Z_i \xrightarrow{p.s.} \mathbb{E}[Z_1] = \frac{1}{k+1}$$

— Puisque $M_n^{(k)}$ converge presque sûrement vers $\frac{1}{k+1}$, la quantité $\frac{1}{M_n^{(k)}} - 1$ converge presque sûrement vers $\frac{1}{\frac{1}{k+1}} - 1 = (k+1) - 1 = k$. La fonction $x \mapsto \frac{1}{x} - 1$ étant continue pour $x > 0$ (et $M_n^{(k)} > 0$ presque sûrement car les X_i sont à valeurs dans $[0,1]$ de loi diffuse), cette composition de limites conserve la convergence presque sûre. Ainsi, on peut estimer k par l'estimateur convergent $\hat{k}_n = \frac{1}{M_n^{(k)}} - 1$.

Exercice 4 : Convergence de la variance empirique ★★★⋆⋆

Soit $(X_n)_{n\geq 1}$ une suite de variables I.I.D. admettant un moment d'ordre 4. On note $\mu = \mathbb{E}[X_1]$ et $\sigma^2 = \mathrm{Var}(X_1) > 0$. On définit la variance empirique non biaisée par :

$$S_n^2 = \frac{1}{n-1}\sum_{i=1}^n (X_i - \bar{X}_n)^2$$

où $\bar{X}_n = \frac{1}{n}\sum_{i=1}^n X_i$.

— Montrer que $\sum_{i=1}^n (X_i - \bar{X}_n)^2 = \sum_{i=1}^n X_i^2 - n\bar{X}_n^2$.

— En utilisant la loi forte des grands nombres, montrer que $S_n^2 \xrightarrow{p.s.} \sigma^2$.

Correction :

— Développons la somme :

$$\sum_{i=1}^n (X_i - \bar{X}_n)^2 = \sum_{i=1}^n (X_i^2 - 2X_i\bar{X}_n + \bar{X}_n^2) = \sum_{i=1}^n X_i^2 - 2\bar{X}_n \sum_{i=1}^n X_i + n\bar{X}_n^2$$

Comme $\sum_{i=1}^n X_i = n\bar{X}_n$, on obtient :

$$\sum_{i=1}^n (X_i - \bar{X}_n)^2 = \sum_{i=1}^n X_i^2 - 2\bar{X}_n(n\bar{X}_n) + n\bar{X}_n^2 = \sum_{i=1}^n X_i^2 - 2n\bar{X}_n^2 + n\bar{X}_n^2 = \sum_{i=1}^n X_i^2 - n\bar{X}_n^2$$

— D'après la question précédente, on peut réécrire S_n^2 :

$$S_n^2 = \frac{n}{n-1}\left(\frac{1}{n}\sum_{i=1}^n X_i^2 - \bar{X}_n^2\right)$$

Puisque (X_n) est une suite I.I.D. admettant un moment d'ordre 2 (et même 4), on applique la LFGN aux suites (X_n) et (X_n^2) :

— $\bar{X}_n = \frac{1}{n}\sum_{i=1}^n X_i \xrightarrow{p.s.} \mu$. La fonction $x \mapsto x^2$ étant continue, on a $\bar{X}_n^2 \xrightarrow{p.s.} \mu^2$.
— $\frac{1}{n}\sum_{i=1}^n X_i^2 \xrightarrow{p.s.} \mathbb{E}[X_1^2]$. Par linéarité de la limite, on obtient que $\left(\frac{1}{n}\sum_{i=1}^n X_i^2 - \bar{X}_n^2\right) \xrightarrow{p.s.} \mathbb{E}[X_1^2] - \mu^2 = \mathrm{Var}(X_1) = \sigma^2$. Enfin, comme le facteur $\frac{n}{n-1} \xrightarrow{n\to\infty} 1$, le produit converge presque sûrement vers $1 \times \sigma^2 = \sigma^2$. Ainsi, $S_n^2 \xrightarrow{p.s.} \sigma^2$.

Exercice 5 : Variables symétriques et loi forte ★★★⋆⋆

Soit $(X_n)_{n\geq 1}$ une suite de variables I.I.D. de loi symétrique par rapport à 0, et possédant un moment d'ordre 1. Soit $\bar{X}_n$ leur moyenne empirique.

— Que vaut l'espérance $\mathbb{E}[X_1]$?
— Déterminer la limite presque sûre de $\bar{X}_n$.
— On pose $Z_n = \cos(\bar{X}_n) + \sin(\bar{X}_n)$. Vers quoi converge Z_n presque sûrement ?

Correction :

— La variable X_1 admet une espérance par hypothèse, et sa loi est symétrique par rapport à 0 (c'est-à-dire que X_1 et $-X_1$ ont même loi). Donc $\mathbb{E}[X_1] = \mathbb{E}[-X_1] = -\mathbb{E}[X_1]$, ce qui implique $2\mathbb{E}[X_1] = 0$, soit $\mathbb{E}[X_1] = 0$.
— La suite (X_n) est I.I.D. et admet une espérance finie $\mu = 0$. Par le théorème de Kolmogorov (loi forte des grands nombres), la moyenne empirique $\bar{X}_n$ converge presque sûrement vers l'espérance. Donc $\bar{X}_n \xrightarrow{p.s.} 0$.
— La fonction $h(x) = \cos(x) + \sin(x)$ est continue sur $\mathbb{R}$. Par composition avec une limite presque sûre, puisque $\bar{X}_n \xrightarrow{p.s.} 0$, on en déduit que $h(\bar{X}_n) \xrightarrow{p.s.} h(0)$. Or $h(0) = \cos(0) + \sin(0) = 1 + 0 = 1$. Ainsi, $Z_n \xrightarrow{p.s.} 1$.

Exercice 6 : Loi forte et fonction génératrice des moments ★★★⋆⋆

Soit $(X_n)_{n\geq 1}$ une suite de variables aléatoires I.I.D. de loi normale standard $\mathcal{N}(0,1)$.

— Montrer que pour tout $t \in \mathbb{R}$, $\mathbb{E}[\exp(tX_1)] = \exp(t^2/2)$.
— On pose $Y_n = \frac{1}{n}\sum_{i=1}^n \exp(tX_i)$. Vers quelle limite Y_n converge-t-elle presque sûrement ?
— En déduire la limite presque sûre de $\ln(Y_n)$.

Correction :

— Calculons l'espérance de $\exp(tX_1)$:

$$\mathbb{E}[e^{tX_1}] = \int_{-\infty}^{\infty} e^{tx}\frac{1}{\sqrt{2\pi}}e^{-x^2/2}dx = \int_{-\infty}^{\infty}\frac{1}{\sqrt{2\pi}}\exp\left(-\frac{1}{2}(x^2-2tx)\right)dx$$

En complétant le carré, $x^2 - 2tx = (x-t)^2 - t^2$, d'où :

$$\mathbb{E}[e^{tX_1}] = \int_{-\infty}^{\infty}\frac{1}{\sqrt{2\pi}}\exp\left(-\frac{1}{2}(x-t)^2\right)\exp(t^2/2)dx = \exp(t^2/2)\int_{-\infty}^{\infty}\frac{1}{\sqrt{2\pi}}e^{-(x-t)^2/2}dx$$

L'intégrale restante est celle d'une densité de loi normale $\mathcal{N}(t,1)$, elle vaut donc 1. Ainsi, $\mathbb{E}[e^{tX_1}] = e^{t^2/2}$.

— Fixons $t \in \mathbb{R}$. Soit $Z_i = \exp(tX_i)$. Les X_i étant I.I.D., les Z_i le sont aussi. De plus, $\mathbb{E}[Z_1] = \exp(t^2/2) < \infty$. D'après la LFGN, la moyenne empirique $Y_n = \frac{1}{n}\sum_{i=1}^n Z_i$ converge presque sûrement vers $\mathbb{E}[Z_1]$. Donc $Y_n \xrightarrow{p.s.} \exp(t^2/2)$.
— La fonction ln est continue sur $]0,+\infty[$. Puisque $Y_n \xrightarrow{p.s.} \exp(t^2/2)$ qui est strictement positif, on peut composer les limites : $\ln(Y_n) \xrightarrow{p.s.} \ln(\exp(t^2/2)) = \frac{t^2}{2}$.

Exercice 7 : Le paradoxe de Saint-Pétersbourg et la LFGN ★★★★⋆

Soit $(X_n)_{n\geq 1}$ le gain d'un joueur lors du n-ième jeu de Saint-Pétersbourg : X_n prend la valeur 2^k avec probabilité $1/2^k$ pour tout $k \geq 1$.

— Montrer que l'espérance $\mathbb{E}[X_1]$ est infinie.

— Que peut-on dire du comportement de $\frac{X_n}{n\log_2(n)}$? (Admis)

— La loi forte des grands nombres s'applique-t-elle ici sous sa forme standard ? Justifier.

— On tronque la variable en posant $Y_n = X_n \mathbf{1}_{\{X_n \leq n\}}$. La LFGN s'applique-t-elle à Y_n ?

Correction :

— Calculons l'espérance :

$$\mathbb{E}[X_1] = \sum_{k=1}^{\infty} 2^k \mathbb{P}(X_1 = 2^k) = \sum_{k=1}^{\infty} 2^k \frac{1}{2^k} = \sum_{k=1}^{\infty} 1 = +\infty$$

— On admet que pour cette loi très particulière à queue lourde, Feller a montré que la somme $\sum_{i=1}^{n} X_i$ normalisée par $n\log_2(n)$ converge en probabilité vers 1. Ainsi, la moyenne croît comme $\log_2(n)$ et non vers une constante.

— La LFGN standard (théorème de Kolmogorov) exige que la variable aléatoire admette une espérance finie, c'est-à-dire $\mathbb{E}[|X_1|] < \infty$. Ici, $\mathbb{E}[X_1] = +\infty$, donc la LFGN ne s'applique pas. La moyenne empirique $\bar{X}_n$ diverge presque sûrement vers l'infini.

— Les variables (Y_n) ne sont pas identiquement distribuées car le seuil de troncature dépend de n. Cependant, pour chaque n fixé, $\mathbb{E}[Y_n] < \infty$. La théorie des sommes de variables aléatoires indépendantes non identiquement distribuées (avec des conditions de type Lyapounov ou un développement spécifique) est nécessaire pour étudier le comportement de $\frac{1}{n}\sum Y_i$. La LFGN usuelle pour les suites I.I.D. ne s'applique donc pas directement non plus.

Exercice 8 : Convergence du maximum empirique ★★★★⋆

Soit $(X_n)_{n\geq 1}$ une suite de variables I.I.D. de loi uniforme sur $[0,\theta]$ avec $\theta > 0$. Soit $M_n = \max(X_1, \ldots, X_n)$.

— Déterminer la fonction de répartition de M_n.

— Montrer que $M_n \xrightarrow{p.s.} \theta$.

— Est-ce que la loi forte des grands nombres a été utilisée dans la question précédente ?

Correction :

— Pour tout $t \in [0,\theta]$, on a :

$$F_{M_n}(t) = \mathbb{P}(M_n \leq t) = \mathbb{P}(X_1 \leq t, \ldots, X_n \leq t)$$

Par indépendance des X_i, cela donne :

$$F_{M_n}(t) = \prod_{i=1}^{n} \mathbb{P}(X_i \leq t) = \left(\frac{t}{\theta}\right)^n$$

Pour $t < 0$, $F_{M_n}(t) = 0$ et pour $t > \theta$, $F_{M_n}(t) = 1$.

— Soit $\epsilon > 0$. On s'intéresse à l'événement $\{|M_n - \theta| \geq \epsilon\}$. Puisque $M_n \leq \theta$ p.s., cela équivaut à $\{M_n \leq \theta - \epsilon\}$. La probabilité est $P(M_n \leq \theta - \epsilon) = \left(\frac{\theta-\epsilon}{\theta}\right)^n = \left(1 - \frac{\epsilon}{\theta}\right)^n$. Comme $1 - \frac{\epsilon}{\theta} \in]0,1[$, cette probabilité est le terme général d'une série géométrique convergente.

$$\sum_{n=1}^{\infty} \mathbb{P}(|M_n - \theta| \geq \epsilon) = \sum_{n=1}^{\infty} \left(1 - \frac{\epsilon}{\theta}\right)^n < +\infty$$

D'après le lemme de Borel-Cantelli, l'événement $\{|M_n - \theta| \geq \epsilon\}$ ne se réalise qu'un nombre fini de fois presque sûrement. Donc $M_n \xrightarrow{p.s.} \theta$.

— Non, nous n'avons pas utilisé la loi forte des grands nombres (Théorème de Kolmogorov). La LFGN concerne les sommes (ou moyennes empiriques) de variables aléatoires. Ici, nous avons étudié un maximum empirique et utilisé directement le lemme de Borel-Cantelli pour établir la convergence presque sûre.

Exercice 9 : Démonstration du Lemme de Borel-Cantelli (partie directe) ★★★★★

Le premier lemme de Borel-Cantelli a été un outil clé dans la preuve de la LFGN sous hypothèse de moment d'ordre 4. Soit $(A_n)_{n\geq 1}$ une suite d'événements dans un espace probabilisé $(\Omega, \mathcal{A}, P)$. On pose $\limsup A_n = \bigcap_{n=1}^{\infty} \bigcup_{k=n}^{\infty} A_k$ (l'événement "une infinité de A_n se réalisent").

— Si $\sum_{n=1}^{\infty} \mathbb{P}(A_n) < \infty$, montrer que $\mathbb{P}(\limsup A_n) = 0$.

Correction :

— Posons $B_n = \bigcup_{k=n}^{\infty} A_k$. La suite d'événements (B_n) est décroissante pour l'inclusion $(B_{n+1} \subset B_n)$. L'événement $\limsup A_n$ est l'intersection décroissante des B_n. Par le théorème de continuité décroissante de la probabilité, on a :

$$\mathbb{P}(\limsup A_n) = \mathbb{P}\left(\bigcap_{n=1}^{\infty} B_n\right) = \lim_{n\to\infty} \mathbb{P}(B_n)$$

Or, par sous-additivité de la mesure de probabilité (union bound), on a pour tout n :

$$\mathbb{P}(B_n) = \mathbb{P}\left(\bigcup_{k=n}^{\infty} A_k\right) \leq \sum_{k=n}^{\infty} \mathbb{P}(A_k)$$

Comme par hypothèse la série $\sum \mathbb{P}(A_k)$ est convergente, le reste d'ordre n de la série, qui est $\sum_{k=n}^{\infty} \mathbb{P}(A_k)$, tend vers 0 lorsque $n \to \infty$. On a donc $0 \leq \lim_{n\to\infty} \mathbb{P}(B_n) \leq 0$, d'où $\mathbb{P}(\limsup A_n) = 0$.

Exercice 10 : Méthode de Monte-Carlo pour l'intégration de fonctions non bornées ★★★★★

On souhaite calculer $I = \int_0^1 \frac{1}{\sqrt{x}} dx$ par la méthode de Monte-Carlo.

— Calculer la valeur exacte de l'intégrale I.

— On tire une suite (U_n) I.I.D. de loi uniforme sur $[0, 1]$. On pose $X_n = \frac{1}{\sqrt{U_n}}$. La LFGN s'applique-t-elle à la suite (X_n) ?

— Quelle est la variance de X_n ? Que cela implique-t-il sur la vitesse de convergence si l'on voulait appliquer le Théorème Central Limite (TCL) ultérieurement ?

Correction :

— La valeur exacte est :

$$I = \int_0^1 x^{-1/2} dx = \left[2x^{1/2}\right]_0^1 = 2$$

— Les variables U_n sont I.I.D. $\mathcal{U}([0, 1])$. Soit $X_n = \frac{1}{\sqrt{U_n}}$. L'espérance de X_n par le théorème de transfert est :

$$\mathbb{E}[X_n] = \mathbb{E}\left[\frac{1}{\sqrt{U_1}}\right] = \int_0^1 \frac{1}{\sqrt{x}} \times 1 dx = 2$$

L'espérance est finie, et les X_n sont I.I.D. Donc la Loi Forte des Grands Nombres de Kolmogorov s'applique bien : la moyenne empirique $\frac{1}{n}\sum_{i=1}^{n} X_i$ converge presque sûrement vers $\mathbb{E}[X_1] = 2$.

— Calculons le moment d'ordre 2 :

$$\mathbb{E}[X_n^2] = \mathbb{E}\left[\frac{1}{U_1}\right] = \int_0^1 \frac{1}{x} dx = [\ln(x)]_0^1 = +\infty$$

La variance est donc infinie. Bien que l'estimateur converge presque sûrement (LFGN), son erreur ne peut pas être encadrée par les outils classiques utilisant la variance (inégalité de Tchebychev) ou le Théorème Central Limite standard, car la normalisation en $\sqrt{n}$ donnera un comportement non gaussien (elle relève de la théorie des lois stables). La convergence existe, mais elle est très lente et erratique.

Troisième partie

Travaux Pratiques et Simulations Algorithmiques

TP 1 : Simulation de la loi forte pour la moyenne de lancers de dés

L'objectif est d'illustrer la convergence presque sûre de la moyenne empirique de lancers d'un dé à 6 faces vers son espérance théorique.

```python
import random

def simuler_de():
    return random.randint(1, 6)

def convergence_de(N):
    somme = 0
    moyennes = []
    for n in range(1, N + 1):
        somme += simuler_de()
        moyennes.append(somme / n)
    return moyennes

# Test avec 10000 lancers
N = 10000
trajectoire = convergence_de(N)
esp_theorique = 3.5

print("Derniere moyenne calculee :", trajectoire[-1])
print("Erreur absolue :", abs(trajectoire[-1] - esp_theorique))

# Validation mathematique
assert abs(trajectoire[-1] - esp_theorique) < 0.1, "La loi forte semble defaillante"
```

TP 2 : Estimation de Pi par la méthode de Monte-Carlo

Ce TP montre comment la loi forte des grands nombres permet d'estimer des grandeurs géométriques comme Pi par simulation aléatoire sur le carré unité.

```python
import random

def estimation_pi(N):
    dans_le_cercle = 0
    for _ in range(N):
        x = random.uniform(0, 1)
        y = random.uniform(0, 1)
        if x*x + y*y <= 1.0:
            dans_le_cercle += 1

    proba_estimee = dans_le_cercle / N
    pi_estime = proba_estimee * 4
    return pi_estime

```

```
N = 50000
pi_approch = estimation_pi(N)
print("Estimation de Pi avec", N, "points :", pi_approch)

# Validation : l'erreur doit etre raisonnable
pi_vrai = 3.14159265
assert abs(pi_approch - pi_vrai) < 0.05, "L'estimation de Pi est trop
    eloignee"
```

TP 3 : Échec de la LFGN : Simulation de la loi de Cauchy

Contrairement à la loi normale, la loi de Cauchy n'admet pas d'espérance finie. Ce TP illustre l'échec de la LFGN dans ce cas : la moyenne empirique ne se stabilise jamais.

```
import random
import math

def simuler_cauchy():
    # Inverse transform sampling pour la loi de Cauchy standard
    u = random.uniform(0, 1)
    return math.tan(math.pi * (u - 0.5))

def moyenne_cauchy(N):
    somme = 0
    for n in range(1, N + 1):
        somme += simuler_cauchy()
    return somme / N

N1 = 1000
N2 = 10000
N3 = 100000

moy1 = moyenne_cauchy(N1)
moy2 = moyenne_cauchy(N2)
moy3 = moyenne_cauchy(N3)

print("Moyenne Cauchy N=1000 :", moy1)
print("Moyenne Cauchy N=10000 :", moy2)
print("Moyenne Cauchy N=100000 :", moy3)

# L'assertion valide qu'il n'y a PAS de convergence autour de zero
# (en general, mais on s'abstient d'un assert strict car pur hasard)
```

TP 4 : Convergence de la variance empirique non biaisée

La LFGN s'applique aussi à l'estimation des moments d'ordre 2. Ce TP simule l'estimation de la variance empirique pour une loi normale standard.

```
import random

def simuler_normale():
    # Box-Muller transform
    u1 = random.uniform(0, 1)
    u2 = random.uniform(0, 1)
    z0 = math.sqrt(-2.0 * math.log(u1)) * math.cos(2.0 * math.pi * u2)
```

```
    return z0

def estimation_variance(N):
    echantillon = [simuler_normale() for _ in range(N)]
    moyenne = sum(echantillon) / N
    somme_carres_ecarts = sum((x - moyenne)**2 for x in echantillon)
    # Variance non biaisee (division par N-1)
    var_empirique = somme_carres_ecarts / (N - 1)
    return var_empirique

import math
N = 20000
var_estimee = estimation_variance(N)
print("Variance empirique estimee :", var_estimee)
print("Variance theorique :", 1.0)

assert abs(var_estimee - 1.0) < 0.05, "L'estimation de la variance est
    fausse"
```

TP 5 : Paradoxe de Saint-Pétersbourg : une espérance infinie

On simule le jeu de Saint-Pétersbourg où le gain est 2^k si face apparaît au k-ième lancer. Ce TP montre la croissance logarithmique de la moyenne empirique, violant la LFGN.

```
import random
import math

def jouer_saint_petersbourg():
    k = 1
    while random.random() < 0.5:
        k += 1
    return 2**k

def simuler_jeu(N):
    gains_totaux = 0
    for _ in range(N):
        gains_totaux += jouer_saint_petersbourg()
    moyenne_gains = gains_totaux / N
    # On s'attend a ce que moyenne_gains soit proportionnelle a log2(N)
    theorique_approx = math.log2(N)
    return moyenne_gains, theorique_approx

N = 10000
moy_empirique, moy_theorique = simuler_jeu(N)

print("Pour N=", N, "jeux de St Petersbourg :")
print("Moyenne empirique des gains :", moy_empirique)
print("Valeur attendue (approx log2(N)) :", moy_theorique)

# On valide que la moyenne empirique est proche de l'approximation log2
# sans garantir de convergence forte
assert moy_empirique > 0, "Le gain ne peut pas etre negatif"
```