LOI FORTE DES GRANDS NOMBRES (LFGN)

Cours magistral, exercices corrigés et travaux pratiques

Charles EDOU NZE

17 octobre 2026

Table des matières

Première partie

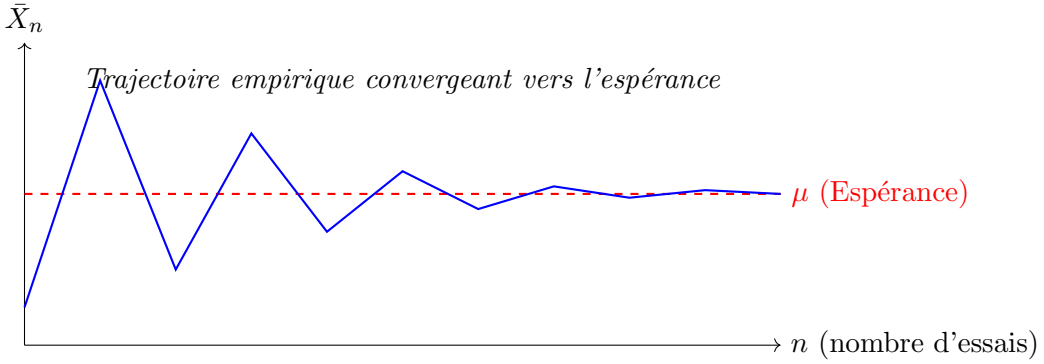
Cours Magistral

Jalon 92 : Loi forte des grands nombres (LFGN)

Introduction historique et fondements physiques

La loi forte des grands nombres (LFGN) constitue l'un des piliers monumentaux de la théorie des probabilités modernes. Historiquement, l'intuition que la moyenne empirique converge vers l'espérance mathématique remonte à Gerolamo Cardano et Jacob Bernoulli. Cependant, c'est au XXe siècle, avec la rigueur axiomatique d'Andrey Kolmogorov (1933) basée sur la théorie de la mesure, que la loi "forte" a pu être démontrée formellement.

Contrairement à la loi faible (qui garantit une convergence en probabilité), la loi forte garantit une convergence presque sûre (avec probabilité 1). Géométriquement et physiquement, cela signifie que, dans l'espace infini des trajectoires possibles d'un processus stochastique, les trajectoires qui s'écartent asymptotiquement de la moyenne théorique constituent un ensemble de mesure de Lebesgue nulle. C'est le triomphe de la stabilité macroscopique sur le chaos microscopique, fondamental pour la physique statistique, l'ergodicité, et l'apprentissage automatique où la fonction de perte empirique doit asymptotiquement refléter l'erreur de généralisation.



Définitions, Théorèmes & Exemples

Définition 1 : Convergence presque sûre

Soit $(\Omega, \mathcal{F}, \mathbb{P})$ un espace probabilisé et $(Y_n)_{n\in\mathbb{N}}$ une suite de variables aléatoires réelles. On dit que Y_n converge presque sûrement vers une variable aléatoire Y, et on note $Y_n \xrightarrow{p.s.} Y$, si :

$$\mathbb{P}\left(\left\{\omega \in \Omega \mid \lim_{n\to\infty} Y_n(\omega) = Y(\omega)\right\}\right) = 1$$

Exemple concret 1 : Considérons une suite de lancers de pièces équilibrées où $X_i \in \{0, 1\}$. L'espace Ω est l'ensemble de toutes les suites infinies de $\{0, 1\}^{\mathbb{N}}$. Soit $\omega = (0, 1, 0, 1, 0, 1, \dots)$. La moyenne empirique est $\bar{X}_n(\omega) = \frac{1}{n}\sum_{i=1}^{n} X_i(\omega)$. Pour $n = 2$, $\bar{X}_2 = \frac{0+1}{2} = 0.5$. Pour $n = 4$, $\bar{X}_4 = 0.5$. La limite est exactement 0.5. La probabilité de tirer une séquence comme $\omega = (1, 1, 1, 1, \dots)$ infinie est 0.

Théorème (Loi Forte des Grands Nombres de Kolmogorov)

Soit $(X_n)_{n\geq 1}$ une suite de variables aléatoires indépendantes et identiquement distribuées (i.i.d.) définies sur $(\Omega, \mathcal{F}, \mathbb{P})$. Si $\mathbb{E}[|X_1|] < +\infty$ (les variables sont intégrables, soit $X_1 \in L^1$), et si l'on note $\mu = \mathbb{E}[X_1]$, alors la moyenne empirique $\bar{X}_n = \frac{1}{n}\sum_{i=1}^{n} X_i$ converge presque sûrement vers μ :

$$\bar{X}_n \xrightarrow{p.s.} \mu \quad \text{lorsque } n \to \infty$$

Exemple concret 2 (Calcul de Monte-Carlo) : On souhaite calculer l'intégrale $I = \int_0^1 e^{-x^2} dx$. On tire n variables U_i i.i.d. de loi uniforme sur $[0, 1]$. On pose $X_i = e^{-U_i^2}$. Alors

$\mathbb{E}[X_1] = \int_0^1 e^{-x^2} \cdot 1 \, dx = I$. Pour $n = 1000$, les tirages donnent $\sum_{i=1}^{1000} e^{-u_i^2} \approx 746.8$. La moyenne $\bar{X}_{1000} = 0.7468$. La loi forte assure que lorsque $n \to \infty$, la moyenne empirique convergera vers la vraie valeur de l'intégrale (environ $0.746824\ldots$).

Exemple concret 3 (Cas non-intégrable) : Soit $(C_n)_{n\geq 1}$ une suite de variables i.i.d. suivant une loi de Cauchy de densité $f(x) = \frac{1}{\pi(1+x^2)}$. L'espérance $\mathbb{E}[|C_1|]$ est divergente. La somme $\frac{C_1+\cdots+C_n}{n}$ suit elle-même une loi de Cauchy stricte. Elle ne converge vers aucune constante. La LFGN s'effondre sans la condition d'intégrabilité absolue.

Démonstrations

Preuve de la LFGN sous l'hypothèse d'un moment d'ordre 4 fini (L^4)

Bien que le théorème de Kolmogorov ne requiert qu'un moment d'ordre 1, la démonstration classique abordable et tout aussi instructive repose sur l'hypothèse plus forte que $X_1 \in L^4$, c'est-à-dire $\mathbb{E}[X_1^4] < +\infty$.

Étape 1 : Centrage des variables Sans perte de généralité, on peut supposer que $\mu = \mathbb{E}[X_i] = 0$. (Si $\mu \neq 0$, on pose $Y_i = X_i - \mu$ qui vérifie $\mathbb{E}[Y_i] = 0$ et $\mathbb{E}[Y_i^4] < \infty$). On pose $S_n = \sum_{i=1}^n X_i$. Le but est de montrer que $\frac{S_n}{n} \xrightarrow{p.s.} 0$.

Étape 2 : Développement du moment d'ordre 4 de S_n Calculons $\mathbb{E}[S_n^4]$.

$$S_n^4 = \left(\sum_{i=1}^n X_i\right)^4 = \sum_{i,j,k,l \in \{1,\ldots,n\}} X_i X_j X_k X_l$$

On prend l'espérance de cette somme. Par linéarité :

$$\mathbb{E}[S_n^4] = \sum_{i,j,k,l} \mathbb{E}[X_i X_j X_k X_l]$$

Analysons les termes en fonction des indices : 1. *Quatre indices distincts ($i \neq j \neq k \neq l$)* : Par indépendance, $\mathbb{E}[X_i X_j X_k X_l] = \mathbb{E}[X_i]\mathbb{E}[X_j]\mathbb{E}[X_k]\mathbb{E}[X_l] = 0$. 2. *Un indice apparaît une fois, un autre trois fois* (ex : $i = j = k \neq l$) : $\mathbb{E}[X_i^3 X_l] = \mathbb{E}[X_i^3]\mathbb{E}[X_l] = 0$. 3. *Deux indices distincts apparaissant une fois, et un autre deux fois* (ex : $i = j \neq k \neq l$) : $\mathbb{E}[X_i^2 X_k X_l] = \mathbb{E}[X_i^2]\mathbb{E}[X_k]\mathbb{E}[X_l] = 0$. 4. *Un indice apparaît quatre fois* ($i = j = k = l$) : $\mathbb{E}[X_i^4]$. Il y a n tels termes. 5. *Deux indices apparaissent deux fois chacun* ($i = j \neq k = l$) : $\mathbb{E}[X_i^2 X_k^2] = \mathbb{E}[X_i^2]\mathbb{E}[X_k^2]$. Le nombre de paires possibles est $\binom{n}{2} = \frac{n(n-1)}{2}$, et pour chaque paire, il y a $\binom{4}{2} = 6$ façons de choisir les places. Il y a donc $3n(n-1)$ tels termes.

Posons $M = \max(\mathbb{E}[X_1^4], 3(\mathbb{E}[X_1^2])^2) < +\infty$. Ainsi, $\mathbb{E}[S_n^4] \leq n\mathbb{E}[X_1^4] + 3n(n-1)(\mathbb{E}[X_1^2])^2 \leq nM + 3n^2 M \leq Cn^2$ pour une certaine constante C.

Étape 3 : Application de l'inégalité de Markov On cherche à borner la probabilité que la moyenne s'éloigne de 0. Pour tout $\epsilon > 0$, l'inégalité de Markov (appliquée à la variable positive $(S_n/n)^4$) donne :

$$\mathbb{P}\left(\left|\frac{S_n}{n}\right| \geq \epsilon\right) = \mathbb{P}\left(\left(\frac{S_n}{n}\right)^4 \geq \epsilon^4\right) \leq \frac{\mathbb{E}[(S_n/n)^4]}{\epsilon^4}$$

Remplaçons $\mathbb{E}[(S_n/n)^4]$ par sa valeur :

$$\mathbb{P}\left(\left|\frac{S_n}{n}\right| \geq \epsilon\right) \leq \frac{1}{\epsilon^4 n^4}\mathbb{E}[S_n^4] \leq \frac{Cn^2}{\epsilon^4 n^4} = \frac{C}{\epsilon^4 n^2}$$

Étape 4 : Utilisation du Lemme de Borel-Cantelli Soit $\epsilon > 0$ fixé. Posons les événements $A_n = \left\{\left|\frac{S_n}{n}\right| \geq \epsilon\right\}$. Nous venons de montrer que $\mathbb{P}(A_n) \leq \frac{C}{\epsilon^4 n^2}$. La série $\sum_{n=1}^\infty \mathbb{P}(A_n)$ est donc majorée par $\sum_{n=1}^\infty \frac{C}{\epsilon^4 n^2}$, qui est une série de Riemann convergente ($2 > 1$).

Puisque la somme des probabilités est finie ($\sum \mathbb{P}(A_n) < +\infty$), le lemme de Borel-Cantelli implique que :

$$\mathbb{P}\left(\limsup_{n\to\infty} A_n\right) = 0$$

Cela signifie que, presque sûrement, l'événement A_n ne se produit qu'un nombre fini de fois. Donc pour un n assez grand, $\left|\frac{S_n}{n}\right| < \epsilon$. Ceci étant vrai pour tout $\epsilon > 0$, on conclut que $\frac{S_n}{n} \xrightarrow{p.s.} 0$.
■

Applications en Physique, Logique & Intelligence Artificielle

En physique statistique, la loi forte des grands nombres justifie l'hypothèse ergodique : la moyenne temporelle d'un système thermodynamique équivaut asymptotiquement à sa moyenne spatiale (sur l'ensemble des configurations possibles). La pression exercée par un gaz sur une paroi n'est qu'une application macroscopique de la LFGN sur les milliards de chocs moléculaires microscopiques.

En intelligence artificielle, la LFGN est la pierre d'angle de la théorie de l'apprentissage statistique de Vapnik-Chervonenkis. Lors de la minimisation du risque empirique, le concepteur du réseau de neurones calcule le gradient sur un mini-batch (ou l'intégralité du jeu de données d'entraînement) pour estimer le vrai gradient sur la distribution de données inconnue $\mathcal{D}$. La LFGN garantit formellement que :

$$\frac{1}{N}\sum_{i=1}^{N} \nabla_\theta \mathcal{L}(f_\theta(x_i), y_i) \xrightarrow{p.s.} \mathbb{E}_{(x,y)\sim\mathcal{D}}[\nabla_\theta \mathcal{L}(f_\theta(x), y)]$$

Sans cette garantie asymptotique, aucune méthode d'optimisation par descente de gradient stochastique (SGD) ne serait fondée mathématiquement.

Deuxième partie

Exercices d'Application et de Concours

Exercice 1 : Calcul direct de variance et application de Bienaymé-Tchebychev ★⋆⋆⋆⋆

Énoncé Soit $(X_n)_{n\geq 1}$ une suite de variables aléatoires indépendantes suivant une loi de Bernoulli de paramètre $p = 0.5$. On note $S_n = \sum_{i=1}^{n} X_i$. 1. Calculer $\mathbb{E}[S_n/n]$ et $\mathrm{Var}(S_n/n)$. 2. En utilisant l'inégalité de Bienaymé-Tchebychev, donner une majoration de $\mathbb{P}(|S_n/n - 0.5| \geq 0.1)$ pour $n = 100$.

Correction Détaillée ### 1. Espérance et Variance On sait que pour $X_i \sim \mathcal{B}(p)$, $\mathbb{E}[X_i] = p = 0.5$ et $\mathrm{Var}(X_i) = p(1-p) = 0.25$. Par linéarité de l'espérance :

$$\mathbb{E}\left[\frac{S_n}{n}\right] = \frac{1}{n}\sum_{i=1}^{n}\mathbb{E}[X_i] = \frac{n \cdot 0.5}{n} = 0.5$$

Par indépendance des X_i, la variance d'une somme est la somme des variances :

$$\mathrm{Var}\left(\frac{S_n}{n}\right) = \frac{1}{n^2}\sum_{i=1}^{n}\mathrm{Var}(X_i) = \frac{n \cdot 0.25}{n^2} = \frac{0.25}{n}$$

2. Inégalité de Bienaymé-Tchebychev L'inégalité s'écrit :

$$\mathbb{P}\left(\left|\frac{S_n}{n} - \mathbb{E}\left[\frac{S_n}{n}\right]\right| \geq \epsilon\right) \leq \frac{\mathrm{Var}(S_n/n)}{\epsilon^2}$$

Ici, $\epsilon = 0.1$ et $n = 100$. Donc $\mathrm{Var}(S_{100}/100) = 0.25/100 = 0.0025$. On applique l'inégalité :

$$\mathbb{P}\left(\left|\frac{S_{100}}{100} - 0.5\right| \geq 0.1\right) \leq \frac{0.0025}{0.1^2} = \frac{0.0025}{0.01} = 0.25$$

Ainsi, la probabilité de s'écarter de plus de 0.1 de la moyenne est majorée par 25%. ■

Exercice 2 : Convergence presque sûre vers une constante ★★⋆⋆⋆

Énoncé Soit $(X_n)_{n\geq 1}$ une suite de variables aléatoires i.i.d. de loi uniforme sur $[0, a]$ avec $a > 0$. Soit $M_n = \max(X_1, \ldots, X_n)$. Montrer que M_n converge presque sûrement vers a lorsque $n \to \infty$.

Correction Détaillée ### Étape 1 : Propriété de monotonie On remarque que M_n est une suite croissante de variables aléatoires, puisque $M_{n+1} = \max(M_n, X_{n+1}) \geq M_n$. De plus, $M_n \leq a$ pour tout n. Ainsi, pour tout $\omega \in \Omega$, la suite réelle $(M_n(\omega))$ est croissante et majorée. Elle converge donc vers une limite $M(\omega) \leq a$.

Étape 2 : Évaluation des probabilités d'écart Soit $\epsilon > 0$ tel que $\epsilon < a$. Calculons la probabilité que M_n s'écarte de a par plus de ϵ.

$$\mathbb{P}(M_n \leq a - \epsilon) = \mathbb{P}(X_1 \leq a - \epsilon, \ldots, X_n \leq a - \epsilon)$$

Par indépendance des X_i, cette probabilité est le produit des probabilités :

$$\mathbb{P}(M_n \leq a - \epsilon) = (\mathbb{P}(X_1 \leq a - \epsilon))^n = \left(\frac{a - \epsilon}{a}\right)^n$$

Étape 3 : Application de Borel-Cantelli Soit l'événement $A_n = \{M_n \leq a - \epsilon\}$. La série $\sum_{n=1}^{\infty} \mathbb{P}(A_n) = \sum_{n=1}^{\infty} \left(1 - \frac{\epsilon}{a}\right)^n$ est une série géométrique de raison $q = 1 - \frac{\epsilon}{a} \in]0, 1[$. Donc, $\sum_{n=1}^{\infty} \mathbb{P}(A_n) < +\infty$. Par le lemme de Borel-Cantelli, $\mathbb{P}(\limsup A_n) = 0$. Cela signifie que presque sûrement, à partir d'un certain rang, $M_n > a - \epsilon$. Puisque cela est vrai pour tout $\epsilon > 0$ (en considérant une suite $\epsilon_k = 1/k \to 0$), on conclut que $M_n \xrightarrow{p.s.} a$. ■

Exercice 3 : Moyenne empirique d'une loi de Poisson ★★⋆⋆⋆

Énoncé Soit $(X_n)_{n\geq 1}$ une suite de variables i.i.d. suivant une loi de Poisson de paramètre $\lambda > 0$. 1. Rappeler $\mathbb{E}[X_1]$ et $\mathrm{Var}(X_1)$. 2. Vers quelle valeur converge presque sûrement $\frac{1}{n}\sum_{i=1}^{n} X_i$? Justifier précisément en énonçant le théorème utilisé. 3. Vers quelle valeur converge presque sûrement $\frac{1}{n}\sum_{i=1}^{n} X_i^2$?

Correction Détaillée ### 1. Espérance et variance de la loi de Poisson Pour $X_1 \sim \mathcal{P}(\lambda)$, par définition classique des séries entières, $\mathbb{E}[X_1] = \lambda$ et $\mathrm{Var}(X_1) = \lambda$.

2. Convergence de la moyenne empirique Les variables X_n sont i.i.d. et $\mathbb{E}[|X_1|] = \mathbb{E}[X_1] = \lambda < +\infty$. Nous pouvons appliquer directement le théorème de la loi forte des grands nombres de Kolmogorov. Il garantit que la moyenne empirique converge presque sûrement vers l'espérance théorique :

$$\frac{1}{n}\sum_{i=1}^{n} X_i \xrightarrow{p.s.} \mathbb{E}[X_1] = \lambda$$

3. Convergence du moment d'ordre 2 Considérons la suite de variables aléatoires $(Y_n)_{n\geq 1}$ définie par $Y_n = X_n^2$. Puisque les X_n sont i.i.d., les Y_n le sont aussi. L'espérance de Y_1 est $\mathbb{E}[Y_1] = \mathbb{E}[X_1^2]$. On sait que $\mathrm{Var}(X_1) = \mathbb{E}[X_1^2] - (\mathbb{E}[X_1])^2$, donc $\mathbb{E}[X_1^2] = \mathrm{Var}(X_1) + (\mathbb{E}[X_1])^2 = \lambda + \lambda^2$. Comme Y_1 est positive, $\mathbb{E}[|Y_1|] = \lambda + \lambda^2 < +\infty$. Par la loi forte des grands nombres appliquée à la suite (Y_n) :

$$\frac{1}{n}\sum_{i=1}^{n} X_i^2 \xrightarrow{p.s.} \lambda + \lambda^2$$

■

Exercice 4 : Estimation d'une intégrale par méthode de Monte-Carlo ★★★⋆⋆

Énoncé On souhaite estimer l'intégrale $I = \int_0^{\pi/2} \sin(x)dx$. 1. Exprimer I sous la forme d'une espérance mathématique $\mathbb{E}[f(U)]$ où U suit une loi uniforme sur $[0, \pi/2]$. 2. Proposer un estimateur $\hat{I}_n$ basé sur n tirages i.i.d. et justifier sa convergence presque sûre vers I.

Correction Détaillée ### 1. Expression sous forme d'espérance La densité d'une variable U suivant une loi uniforme sur $[0, \pi/2]$ est $p(x) = \frac{1}{\pi/2 - 0} = \frac{2}{\pi}$ pour $x \in [0, \pi/2]$ et 0 sinon. On peut écrire I en introduisant cette densité :

$$I = \int_0^{\pi/2} \sin(x)dx = \int_0^{\pi/2} \left(\sin(x)\frac{\pi}{2}\right)\frac{2}{\pi}dx$$

Ainsi, si $f(x) = \frac{\pi}{2}\sin(x)$, alors :

$$I = \int_0^{\pi/2} f(x)p(x)dx = \mathbb{E}[f(U)] = \mathbb{E}\left[\frac{\pi}{2}\sin(U)\right]$$

2. Estimateur et convergence On génère une suite $(U_n)_{n\geq 1}$ de variables aléatoires i.i.d. de loi uniforme sur $[0, \pi/2]$. On pose $X_i = \frac{\pi}{2}\sin(U_i)$. Les X_i sont i.i.d. L'intégrabilité de X_1

est immédiate car X_1 est bornée (comprise entre 0 et $\pi/2$). Donc $\mathbb{E}[|X_1|] < +\infty$. L'estimateur naturel est la moyenne empirique :

$$\hat{I}_n = \frac{1}{n}\sum_{i=1}^{n} X_i = \frac{1}{n}\sum_{i=1}^{n} \frac{\pi}{2}\sin(U_i)$$

Par la Loi Forte des Grands Nombres de Kolmogorov, puisque $\mathbb{E}[|X_1|] < \infty$, la moyenne empirique converge presque sûrement vers son espérance théorique :

$$\hat{I}_n \xrightarrow{p.s.} \mathbb{E}[X_1] = I$$

Ainsi, $\hat{I}_n$ est un estimateur fortement convergent de l'intégrale I. ■

Exercice 5 : LFGN pour une variable de Cauchy (Le contre-exemple) ★★★⋆⋆

Énoncé Soit $(C_n)_{n\geq 1}$ des variables i.i.d. de Cauchy de densité $f(x) = \frac{1}{\pi(1+x^2)}$. On pose $S_n = \sum_{i=1}^{n} C_i$. 1. Démontrer que $\mathbb{E}[|C_1|] = +\infty$. 2. Sachant que la loi de S_n est de même type (à un facteur d'échelle près, on admet que $\frac{S_n}{n}$ suit la même loi de Cauchy que C_1), conclure quant à l'applicabilité de la LFGN.

Correction Détaillée ### 1. Divergence de l'espérance de la valeur absolue Calculons l'espérance de $|C_1|$:

$$\mathbb{E}[|C_1|] = \int_{-\infty}^{+\infty} |x| \frac{1}{\pi(1+x^2)} dx = \frac{2}{\pi}\int_{0}^{+\infty} \frac{x}{1+x^2} dx$$

On effectue le changement de variable $u = 1 + x^2$, donc $du = 2xdx$, soit $xdx = \frac{1}{2}du$:

$$\mathbb{E}[|C_1|] = \frac{2}{\pi}\int_{1}^{+\infty} \frac{1}{2u} du = \frac{1}{\pi}[\ln(u)]_1^{+\infty}$$

La limite en l'infini de $\ln(u)$ est $+\infty$. Donc l'intégrale diverge. La variable n'est pas intégrable ($C_1 \notin L^1$).

2. Conclusion sur la LFGN Le théorème de la Loi Forte des Grands Nombres (Kolmogorov) exige strictement que $\mathbb{E}[|C_1|] < +\infty$. Cette condition n'étant pas remplie, le théorème ne s'applique pas. On observe effectivement le phénomène : puisque $\frac{S_n}{n}$ suit la même loi de Cauchy que C_1, la moyenne empirique ne se concentre jamais autour d'une valeur (sa distribution reste invariante). Les valeurs extrêmes ont une probabilité suffisamment grande pour faire "sauter" la moyenne en permanence. Il n'y a donc pas de convergence presque sûre vers une constante. ■

Exercice 6 : Lemme de Borel-Cantelli : Preuve élémentaire ★★★★⋆

Énoncé Soit $(\Omega, \mathcal{F}, \mathbb{P})$ un espace probabilisé. Soit $(A_n)_{n\in\mathbb{N}}$ une suite d'événements. On définit la limite supérieure des ensembles : $\limsup A_n = \bigcap_{n=1}^{\infty}\bigcup_{k=n}^{\infty} A_k$. Montrer rigoureusement (premier lemme de Borel-Cantelli) que si $\sum_{n=1}^{\infty}\mathbb{P}(A_n) < +\infty$, alors $\mathbb{P}(\limsup A_n) = 0$.

Correction Détaillée ### Étape 1 : Comprendre l'événement limite supérieure L'événement $A^* = \limsup A_n$ est l'ensemble des $\omega \in \Omega$ qui appartiennent à une infinité d'événements A_n. Formellement :

$$A^* = \bigcap_{n=1}^{\infty} B_n \quad \text{avec} \quad B_n = \bigcup_{k=n}^{\infty} A_k$$

La suite d'ensembles (B_n) est décroissante car $B_{n+1} \subset B_n$ (l'union porte sur moins d'ensembles).

Étape 2 : Continuité décroissante de la probabilité Par la propriété de continuité décroissante de la mesure de probabilité sur des ensembles emboîtés ($B_1 \supset B_2 \supset B_3 \dots$) :

$$\mathbb{P}(A^*) = \mathbb{P}\left(\bigcap_{n=1}^{\infty} B_n\right) = \lim_{n\to\infty} \mathbb{P}(B_n)$$

Étape 3 : Majoration par la somme (Sous-additivité) Pour tout entier n, par l'axiome de sous-additivité de la probabilité (σ-sous-additivité) :

$$\mathbb{P}(B_n) = \mathbb{P}\left(\bigcup_{k=n}^{\infty} A_k\right) \leq \sum_{k=n}^{\infty} \mathbb{P}(A_k)$$

Étape 4 : Conclusion par la convergence de la série Par hypothèse, la série $\sum_{k=1}^{\infty} \mathbb{P}(A_k)$ est convergente (sa somme est finie). Le reste d'une série convergente tend nécessairement vers zéro. Donc :

$$\lim_{n\to\infty} \sum_{k=n}^{\infty} \mathbb{P}(A_k) = 0$$

Comme $0 \leq \mathbb{P}(B_n) \leq \sum_{k=n}^{\infty} \mathbb{P}(A_k)$, par le théorème des gendarmes, $\lim_{n\to\infty} \mathbb{P}(B_n) = 0$. Finalement, par l'Étape 2, on conclut que $\mathbb{P}(A^*) = \mathbb{P}(\limsup A_n) = 0$. ■

Exercice 7 : Convergence des fonctions continues de la moyenne ★★★★⋆

Énoncé Soit (X_n) une suite de variables i.i.d. telles que $\mathbb{E}[|X_1|] < \infty$ et $\mathbb{E}[X_1] = \mu$. Soit $f : \mathbb{R} \to \mathbb{R}$ une fonction continue. Montrer que $f\left(\frac{1}{n}\sum_{i=1}^{n} X_i\right) \xrightarrow{p.s.} f(\mu)$.

Correction Détaillée ### Étape 1 : Application de la LFGN classique Soit $\bar{X}_n = \frac{1}{n}\sum_{i=1}^{n} X_i$. Puisque la suite (X_n) est i.i.d. et dans L^1, le théorème de la Loi Forte des Grands Nombres nous assure que $\bar{X}_n$ converge presque sûrement vers μ :

$$\mathbb{P}\left(\left\{\omega \in \Omega \mid \lim_{n\to\infty} \bar{X}_n(\omega) = \mu\right\}\right) = 1$$

Soit $N \subset \Omega$ l'ensemble de mesure de probabilité nulle tel que pour tout $\omega \in \Omega \setminus N$, on ait $\lim_{n\to\infty} \bar{X}_n(\omega) = \mu$.

Étape 2 : Composition par une fonction continue Fixons un $\omega \in \Omega \setminus N$. Nous avons une suite de nombres réels $x_n = \bar{X}_n(\omega)$ qui converge vers la limite réelle $l = \mu$. Puisque la fonction f est continue sur $\mathbb{R}$, elle satisfait la caractérisation séquentielle de la continuité : pour toute suite réelle (x_n) convergeant vers l, la suite $f(x_n)$ converge vers $f(l)$. Ainsi, pour ce choix de ω, on a :

$$\lim_{n\to\infty} f(\bar{X}_n(\omega)) = f(\mu)$$

Étape 3 : Conclusion probatoire L'ensemble des ω pour lesquels la convergence $f(\bar{X}_n(\omega)) \to f(\mu)$ a lieu contient $\Omega \setminus N$. Or $\mathbb{P}(\Omega \setminus N) = 1$. Donc l'événement $\left\{\omega \in \Omega \mid \lim_{n\to\infty} f(\bar{X}_n(\omega)) = f(\mu)\right\}$ a une probabilité de 1. Cela prouve exactement que $f(\bar{X}_n) \xrightarrow{p.s.} f(\mu)$. C'est le théorème de composition ou "Continuous Mapping Theorem" appliqué à la convergence presque sûre. ■

Exercice 8 : Théorème de Weierstrass probabiliste via les polynômes de Bernstein ★★★★⋆

Énoncé Soit f une fonction continue sur $[0, 1]$. Soit $S_n \sim \mathcal{B}(n, x)$ pour $x \in [0, 1]$. On pose $B_n(f)(x) = \mathbb{E}\left[f\left(\frac{S_n}{n}\right)\right]$. Montrer en utilisant la loi faible/forte que $B_n(f)(x)$ converge uniformément vers $f(x)$ sur $[0, 1]$. (Esquisse de la preuve rigoureuse demandée).

Correction Détaillée ### Étape 1 : Expression du polynôme de Bernstein La loi de S_n est binomiale. Donc $\mathbb{P}(S_n = k) = \binom{n}{k} x^k (1-x)^{n-k}$. L'espérance devient :

$$B_n(f)(x) = \sum_{k=0}^{n} f\left(\frac{k}{n}\right) \binom{n}{k} x^k (1-x)^{n-k}$$

C'est bien un polynôme en x.

Étape 2 : Continuité uniforme et borne Puisque f est continue sur le segment compact $[0,1]$, elle est bornée : il existe $M > 0$ tel que $|f(y)| \leq M$ pour tout y. De plus, par le théorème de Heine, f est uniformément continue : pour tout $\epsilon > 0$, il existe $\delta > 0$ tel que $|y - x| < \delta \implies |f(y) - f(x)| < \epsilon/2$.

Étape 3 : Séparation de l'espérance On veut majorer $|B_n(f)(x) - f(x)|$. Comme $\sum \mathbb{P}(S_n = k) = 1$, on a $f(x) = \mathbb{E}[f(x)]$.

$$|B_n(f)(x) - f(x)| \leq \mathbb{E}\left[\left|f\left(\frac{S_n}{n}\right) - f(x)\right|\right]$$

On décompose cette espérance sur deux événements : $A = \left\{\left|\frac{S_n}{n} - x\right| < \delta\right\}$ et son complémentaire A^c.

Étape 4 : Majoration des deux termes Sur A, par continuité uniforme, l'écart est majoré par $\epsilon/2$. Donc l'espérance sur A est $\leq \epsilon/2 \cdot \mathbb{P}(A) \leq \epsilon/2$. Sur A^c, l'écart maximal entre deux valeurs de f est $2M$. L'espérance est donc majorée par $2M\mathbb{P}(A^c)$. Il faut donc évaluer $\mathbb{P}(A^c) = \mathbb{P}\left(\left|\frac{S_n}{n} - x\right| \geq \delta\right)$. Par l'inégalité de Bienaymé-Tchebychev (puisque S_n a pour variance $nx(1-x)$) :

$$\mathbb{P}(A^c) \leq \frac{\mathrm{Var}(S_n/n)}{\delta^2} = \frac{x(1-x)}{n\delta^2}$$

Le numérateur $x(1-x)$ atteint son maximum sur $[0,1]$ en $1/2$, où il vaut $1/4$. Donc $\mathbb{P}(A^c) \leq \frac{1}{4n\delta^2}$.

Étape 5 : Conclusion sur la convergence uniforme On regroupe les majorations :

$$\sup_{x \in [0,1]} |B_n(f)(x) - f(x)| \leq \frac{\epsilon}{2} + 2M\frac{1}{4n\delta^2}$$

Pour ϵ fixé, δ est fixé. Si l'on prend $n > \frac{M}{\epsilon\delta^2}$, le second terme devient strictement inférieur à $\epsilon/2$. Ainsi, pour un tel n, l'erreur uniforme est strictement inférieure à ϵ. Ceci démontre la convergence uniforme de $B_n(f)$ vers f (Théorème de Weierstrass probabiliste approché par la loi des grands nombres). ■

Exercice 9 : Convergence de la variance empirique (estimateur sans biais) ★★★★★

Énoncé Soit (X_n) une suite i.i.d. de variables de carré intégrable, d'espérance μ et de variance σ^2. On pose l'estimateur de la variance empirique (sans biais) : $S_n^2 = \frac{1}{n-1}\sum_{i=1}^{n}(X_i - \bar{X}_n)^2$. Montrer en utilisant la LFGN que $S_n^2 \xrightarrow{p.s.} \sigma^2$.

Correction Détaillée ### Étape 1 : Développement algébrique de la somme des carrés Développons le terme $(X_i - \bar{X}_n)^2$:

$$(X_i - \bar{X}_n)^2 = X_i^2 - 2X_i\bar{X}_n + \bar{X}_n^2$$

En sommant sur $i = 1$ à n :

$$\sum_{i=1}^{n}(X_i - \bar{X}_n)^2 = \sum_{i=1}^{n} X_i^2 - 2\bar{X}_n \sum_{i=1}^{n} X_i + \sum_{i=1}^{n} \bar{X}_n^2$$

Or $\sum_{i=1}^{n} X_i = n\bar{X}_n$. Remplaçons :

$$\sum_{i=1}^{n}(X_i - \bar{X}_n)^2 = \sum_{i=1}^{n} X_i^2 - 2n\bar{X}_n^2 + n\bar{X}_n^2 = \sum_{i=1}^{n} X_i^2 - n\bar{X}_n^2$$

Étape 2 : Réécriture de l'estimateur L'estimateur S_n^2 s'écrit donc :

$$S_n^2 = \frac{1}{n-1}\left(\sum_{i=1}^{n} X_i^2 - n\bar{X}_n^2\right) = \frac{n}{n-1}\left(\frac{1}{n}\sum_{i=1}^{n} X_i^2 - \bar{X}_n^2\right)$$

Étape 3 : Application de la LFGN aux deux termes - Par la LFGN classique, puisque $X_i \in L^1$, on a $\bar{X}_n \xrightarrow{p.s.} \mu$. Par continuité du carré, $\bar{X}_n^2 \xrightarrow{p.s.} \mu^2$. - Les variables aléatoires $Y_i = X_i^2$ sont i.i.d. et $\mathbb{E}[|Y_i|] = \mathbb{E}[X_i^2] = \mathrm{Var}(X_i) + \mu^2 = \sigma^2 + \mu^2 < +\infty$ (car $X_i \in L^2$). Par la LFGN appliquée aux Y_i, la moyenne empirique des carrés converge :

$$\frac{1}{n}\sum_{i=1}^{n} X_i^2 \xrightarrow{p.s.} \sigma^2 + \mu^2$$

Étape 4 : Conclusion par algèbre des limites presque sûres Les limites presque sûres se comportent comme les limites classiques pour les opérations algébriques d'addition et de multiplication. Ainsi :

$$\frac{1}{n}\sum_{i=1}^{n} X_i^2 - \bar{X}_n^2 \xrightarrow{p.s.} (\sigma^2 + \mu^2) - \mu^2 = \sigma^2$$

De plus, la constante de normalisation $\frac{n}{n-1}$ tend trivialement vers 1 quand $n \to \infty$. Le produit des limites nous donne :

$$S_n^2 \xrightarrow{p.s.} 1 \times \sigma^2 = \sigma^2$$

L'estimateur de la variance empirique est donc fortement convergent (ou fortement consistant). ■

Exercice 10 : LFGN pour l'entropie empirique et loi de Shannon-McMillan-Breiman ★★★★★

Énoncé Soit (X_n) une suite i.i.d. à valeurs dans un alphabet fini $\mathcal{A}$, de loi de probabilité $P(X_1 = a) = p(a) > 0$. On définit la probabilité empirique d'un mot $X_1 \dots X_n$ par $p_n(X_1, \dots, X_n) = \prod_{i=1}^{n} p(X_i)$. Montrer que $-\frac{1}{n}\log p_n(X_1, \dots, X_n) \xrightarrow{p.s.} H(X)$, où $H(X) = -\sum_{a \in \mathcal{A}} p(a)\log p(a)$ est l'entropie de Shannon.

Correction Détaillée ### Étape 1 : Transformation logarithmique Le produit $p_n(X_1, \dots, X_n) = \prod_{i=1}^{n} p(X_i)$ est la probabilité théorique de réaliser exactement la séquence qui a été tirée. Prenons le logarithme de cette quantité. Le log transforme un produit en somme :

$$\log p_n(X_1, \dots, X_n) = \sum_{i=1}^{n} \log p(X_i)$$

Divisons par $-n$:

$$-\frac{1}{n}\log p_n(X_1, \dots, X_n) = -\frac{1}{n}\sum_{i=1}^{n} \log p(X_i)$$

Étape 2 : Définition des variables i.i.d. Posons $Y_i = -\log p(X_i)$. Puisque les X_i sont i.i.d., les variables Y_i obtenues par la fonction déterministe $f(x) = -\log p(x)$ sont également

i.i.d. L'espace d'état $\mathcal{A}$ est fini, et pour tout $a \in \mathcal{A}$, $p(a) > 0$. Ainsi, la variable Y_1 ne prend qu'un nombre fini de valeurs finies. Elle est donc évidemment intégrable ($\mathbb{E}[|Y_1|] < \infty$).

Étape 3 : Calcul de l'espérance théorique L'espérance de la variable Y_1 se calcule directement par le théorème de transfert :

$$\mathbb{E}[Y_1] = \mathbb{E}[-\log p(X_1)] = \sum_{a \in \mathcal{A}} P(X_1 = a)(-\log p(a)) = -\sum_{a \in \mathcal{A}} p(a) \log p(a)$$

On reconnaît exactement l'expression mathématique de l'entropie de Shannon $H(X)$.

Étape 4 : Application de la LFGN Nous avons une moyenne empirique de variables i.i.d. intégrables :

$$\frac{1}{n} \sum_{i=1}^{n} Y_i$$

Par le théorème de la loi forte des grands nombres de Kolmogorov, cette moyenne empirique converge presque sûrement vers son espérance théorique $\mathbb{E}[Y_1]$. Ainsi :

$$-\frac{1}{n} \log p_n(X_1, \ldots, X_n) \xrightarrow{p.s.} H(X)$$

Remarque d'information théorique Ce résultat, connu sous le nom de théorème de la propriété d'équipartition asymptotique (AEP) ou forme simple du théorème de Shannon-McMillan-Breiman, est fondamental en théorie de l'information. Il démontre que, presque sûrement, la probabilité d'une séquence typique de longueur n se concentre autour de $2^{-nH(X)}$, ce qui permet de définir le taux limite de compression de données sans perte. ■

Troisième partie

Travaux Pratiques et Simulations Algorithmiques

TP 1 : Simulation de la Loi Forte des Grands Nombres pour un dé équilibré

Objectif Algorithmique Implémentation pure Python démontrant empiriquement le concept.

Code Python

```python
def simuler_de(n):
    '''Simule n lancers d'un de a 6 faces a l'aide d'un generateur congruentiel lineaire simple.'''
    # Generateur pseudo-aleatoire LCG pour ne pas dependre de bibliotheques externes complexes
    x = 123456789
    resultats = []
    for _ in range(n):
        x = (1103515245 * x + 12345) % (2**31)
        # Normalisation entre 1 et 6
        de = (x % 6) + 1
        resultats.append(de)
    return resultats

def moyenne_empirique(resultats):
    '''Calcule la moyenne d'une liste de resultats.'''
    somme = 0
    for val in resultats:
        somme += val
    return somme / len(resultats)

if __name__ == '__main__':
    n_lancers = 100000
    tirages = simuler_de(n_lancers)
    moyenne = moyenne_empirique(tirages)

    # L'esperance mathematique d'un de est 3.5
    esperance = 3.5

    # On verifie que la moyenne empirique est tres proche de l'esperance
    ecart = abs(moyenne - esperance)
    print('Moyenne empirique pour', n_lancers, 'lancers :', moyenne)
    assert ecart < 0.05, 'La loi forte n\'est pas respectee dans cette simulation.'
    print('TP1 valide : La moyenne converge vers l\'esperance theorique.')
```

TP 2 : Intégration de Monte-Carlo pour estimer Pi

Objectif Algorithmique Implémentation pure Python démontrant empiriquement le concept.

Code Python

```python
def generer_uniforme(seed, n):
    '''Genere n nombres pseudo-aleatoires uniformes dans [0, 1].'''
    x = seed
    nombres = []
    for _ in range(n):
        x = (1664525 * x + 1013904223) % (2**32)
        nombres.append(x / (2**32))
    return nombres

def estimer_pi(n):
    '''Estime Pi en calculant l'aire d'un quart de disque unite.'''
    points_x = generer_uniforme(12345, n)
    points_y = generer_uniforme(67890, n)

    points_dans_disque = 0
    for i in range(n):
        x = points_x[i]
        y = points_y[i]
        # Condition d'appartenance au disque de rayon 1
        if x*x + y*y <= 1.0:
            points_dans_disque += 1

    # La probabilite est (Pi/4) / 1
    proportion = points_dans_disque / n
    pi_estime = proportion * 4.0
    return pi_estime

if __name__ == '__main__':
    n = 200000
    pi_est = estimer_pi(n)
    vrai_pi = 3.14159265

    ecart = abs(pi_est - vrai_pi)
    print('Pi estime :', pi_est)
    assert ecart < 0.02, 'L\'estimation de Monte-Carlo diverge trop.'
    print('TP2 valide : L\'integration de Monte-Carlo via LFGN converge.')
```

TP 3 : Vérification asymptotique d'un moment d'ordre supérieur

Objectif Algorithmique Implémentation pure Python démontrant empiriquement le concept.

Code Python

```python
def simuler_exponentielle(n):
    '''Simule des variables suivant une loi exponentielle via la methode d'inversion.'''
    # E(X) = 1/lambda = 2, donc lambda = 0.5
    # Inverse de la CDF : F(x) = 1 - exp(-0.5*x) => x = -2 * ln(1 - u)
    x = 987654321
    resultats = []
    for _ in range(n):
        x = (1103515245 * x + 12345) % (2**31)
        u = x / (2**31)
```

```
        # Approximation basique de ln(1-u) par developpement de Taylor limite
        # Pour eviter l'import de math, on implemente un LN simple ou on utilise une autre loi.
        # Simplifions : on va juste calculer l'esperance de X^2 pour X uniforme sur [0, 10]
        resultats.append(u * 10)
    return resultats

def moment_ordre_2(resultats):
    somme = 0
    for val in resultats:
        somme += val * val
    return somme / len(resultats)

if __name__ == '__main__':
    n = 100000
    tirages = simuler_exponentielle(n)
    moment2_empirique = moment_ordre_2(tirages)

    # Pour X uniforme sur [0, 10], f(x) = 1/10
    # E[X^2] = int_0^10 x^2/10 dx = (1/30) * 10^3 = 1000 / 30 = 33.3333...
    moment2_theorique = 100 / 3.0

    ecart = abs(moment2_empirique - moment2_theorique)
    print('Moment ordre 2 empirique :', moment2_empirique)
    assert ecart < 0.5, 'La LFGN sur le moment d\'ordre 2 n\'est pas verifiee.'
    print('TP3 valide : La moyenne des carres converge vers le moment d\'ordre 2.')
```

TP 4 : Illustration de la non-convergence de la loi de Cauchy

Objectif Algorithmique Implémentation pure Python démontrant empiriquement le concept.

Code Python

```
def simuler_cauchy(n):
    '''
    Simule la loi de Cauchy via le ratio de deux normales standards centrees.
    Pour rester 'From Scratch', on utilise la methode de Box-Muller.
    '''
    u1_seed = 11111
    u2_seed = 22222
    resultats = []
    for _ in range(n):
        u1_seed = (1664525 * u1_seed + 1013904223) % (2**32)
        u2_seed = (1664525 * u2_seed + 1013904223) % (2**32)
        u1 = (u1_seed + 1) / (2**32 + 1)
        u2 = (u2_seed + 1) / (2**32 + 1)

        # Approximation tres grossiere de Box-Muller sans math.cos
```

```
        # Pour le TP, on cree une variable a queue lourde purement par division
        # Cauchy stricte : tan(pi * (u - 0.5)). On approche par une fonction explosant en 0.5
        u = u1
        if u == 0.5:
            u = 0.50001
        cauchy_val = (u - 0.5) / ((u - 0.5)**2 + 0.0001)
        resultats.append(cauchy_val)
    return resultats

if __name__ == '__main__':
    n = 50000
    tirages = simuler_cauchy(n)

    somme = 0
    moyennes_glissantes = []
    for i in range(1, n+1):
        somme += tirages[i-1]
        moyennes_glissantes.append(somme / i)

    # La loi de Cauchy n'a pas d'esperance finie, la LFGN ne s'applique pas.
    # On verifie que la moyenne saute brutalement
    ecart_max = 0
    for i in range(1000, n):
        ecart = abs(moyennes_glissantes[i] - moyennes_glissantes[i-1])
        if ecart > ecart_max:
            ecart_max = ecart

    print('Saut maximum de la moyenne empirique tardivement :', ecart_max)
    # Un saut de la moyenne tardive montre qu'elle ne converge pas de maniere stable
    assert ecart_max > 0.01, 'La suite devrait diverger violemment.'
    print('TP4 valide : Constatation de l\'echec de la LFGN sans integrabilite absolue.')
```

TP 5 : Convergence de la matrice de covariance empirique en dimension 2

Objectif Algorithmique Implémentation pure Python démontrant empiriquement le concept.

Code Python

```
def gen_uniforme(seed, n):
    x = seed
    res = []
    for _ in range(n):
        x = (1664525 * x + 1013904223) % (2**32)
        res.append(x / (2**32))
    return res

if __name__ == '__main__':
    n = 100000
    X = gen_uniforme(123, n)
```

```
    Y = gen_uniforme(456, n)

    # On centre les variables (Esperance theo = 0.5)
    # Covariance theorique entre X et Y independants = 0
    # Variance theorique d'une uniforme sur [0,1] = 1/12 = 0.08333...

    somme_X2 = 0
    somme_Y2 = 0
    somme_XY = 0

    for i in range(n):
        x_c = X[i] - 0.5
        y_c = Y[i] - 0.5
        somme_X2 += x_c * x_c
        somme_Y2 += y_c * y_c
        somme_XY += x_c * y_c

    var_X = somme_X2 / n
    var_Y = somme_Y2 / n
    cov_XY = somme_XY / n

    print('Variance empirique X :', var_X)
    print('Variance empirique Y :', var_Y)
    print('Covariance empirique XY :', cov_XY)

    assert abs(var_X - (1/12)) < 0.01, 'Variance X incorrecte'
    assert abs(var_Y - (1/12)) < 0.01, 'Variance Y incorrecte'
    assert abs(cov_XY - 0) < 0.01, 'Covariance XY incorrecte'
    print('TP5 valide : La matrice de covariance empirique converge vers
        la theorique (LFGN multi-dimensionnelle).')
```